

Python 을 활용한 머신러닝 입문

강사: 오영제

교육 환경 준비

- 인터넷 연결
- Chrome Browser
- Anaconda 설치
- Gmail ID

Anaconda 설치

Download from <https://www.anaconda.com/products/individual#download-section>

The screenshot shows the Anaconda website's main navigation bar at the top, featuring links for Products, Pricing, Solutions, Resources, Blog, and Company. A prominent "Get Started" button is located on the right side of the bar. Below the navigation, the "Individual Edition" is highlighted. The main content area features the Anaconda logo (a green stylized 'Q') and the text "Individual Edition". The headline "Your data science toolkit" is displayed in large, bold letters. A descriptive paragraph explains that the Individual Edition is the easiest way to perform Python/R data science and machine learning on a single machine, developed for solo practitioners. It mentions that it includes thousands of open-source packages and libraries. To the right, a callout box titled "Anaconda Individual Edition" contains a "Download" button with a Windows icon, followed by text indicating it's for Windows, Python 3.8, 64-Bit Graphical Installer, and 477 MB. At the bottom of the callout box, there's a link "Get Additional Installers" with icons for Windows, Apple, and Linux.

ANACONDA. Products ▾ Pricing Solutions ▾ Resources ▾ Blog Company ▾ Get Started

Individual Edition

Your data science toolkit

With over 25 million users worldwide, the open-source Individual Edition (Distribution) is the easiest way to perform Python/R data science and machine learning on a single machine. Developed for solo practitioners, it is the toolkit that equips you to work with thousands of open-source packages and libraries.

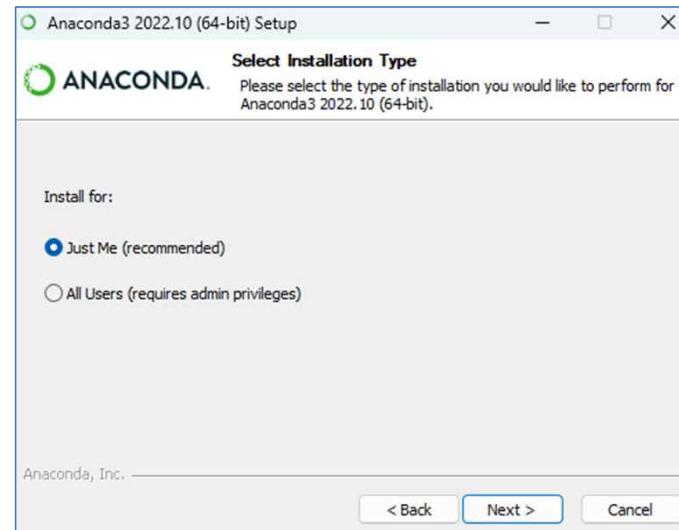
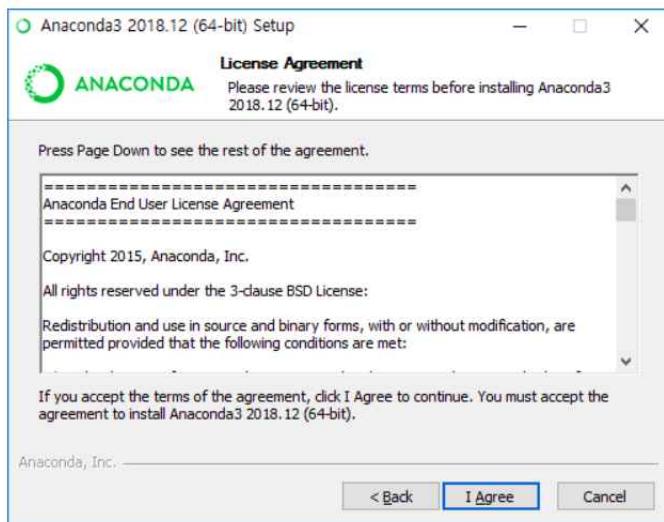
Anaconda Individual Edition

Download

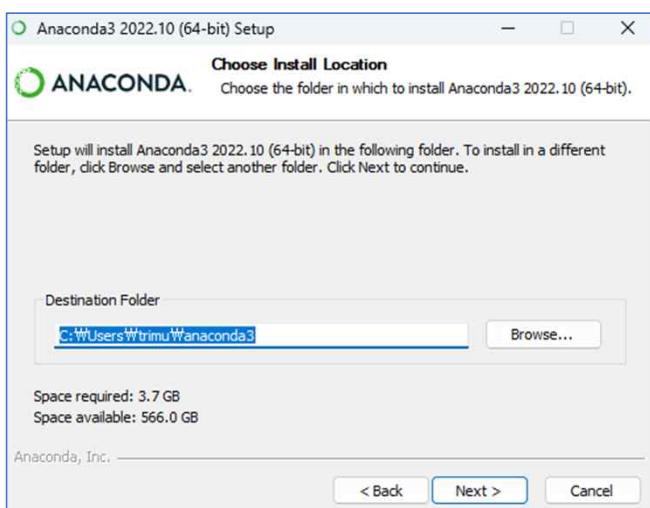
For Windows
Python 3.8 • 64-Bit Graphical Installer • 477 MB

Get Additional Installers

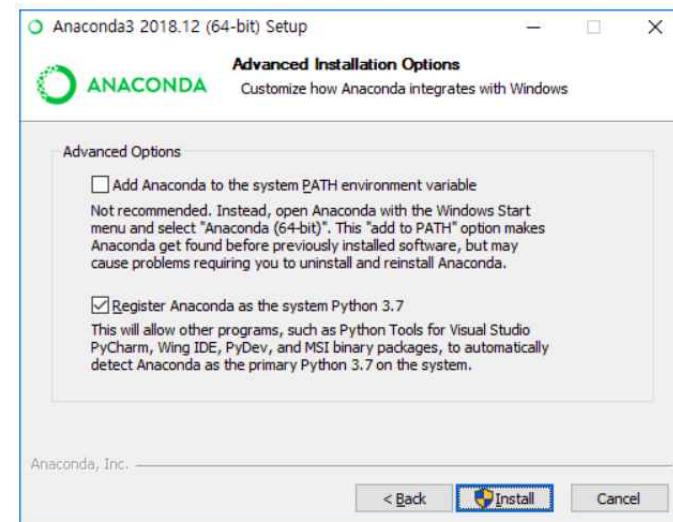
Next 를 눌러 설치 시작



Anaconda, Inc.



Anaconda, Inc.



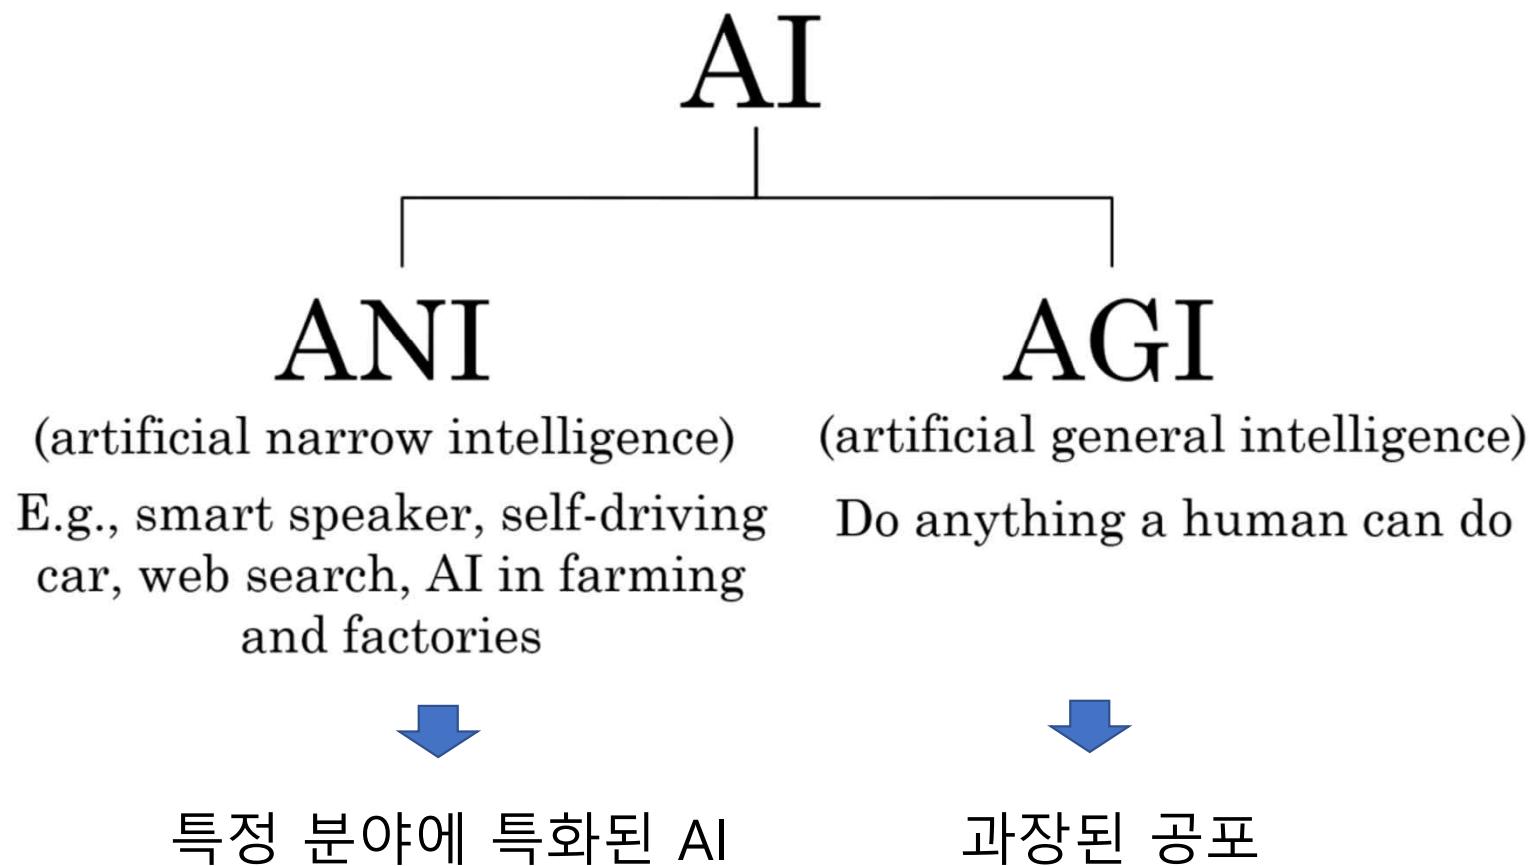
Anaconda, Inc.



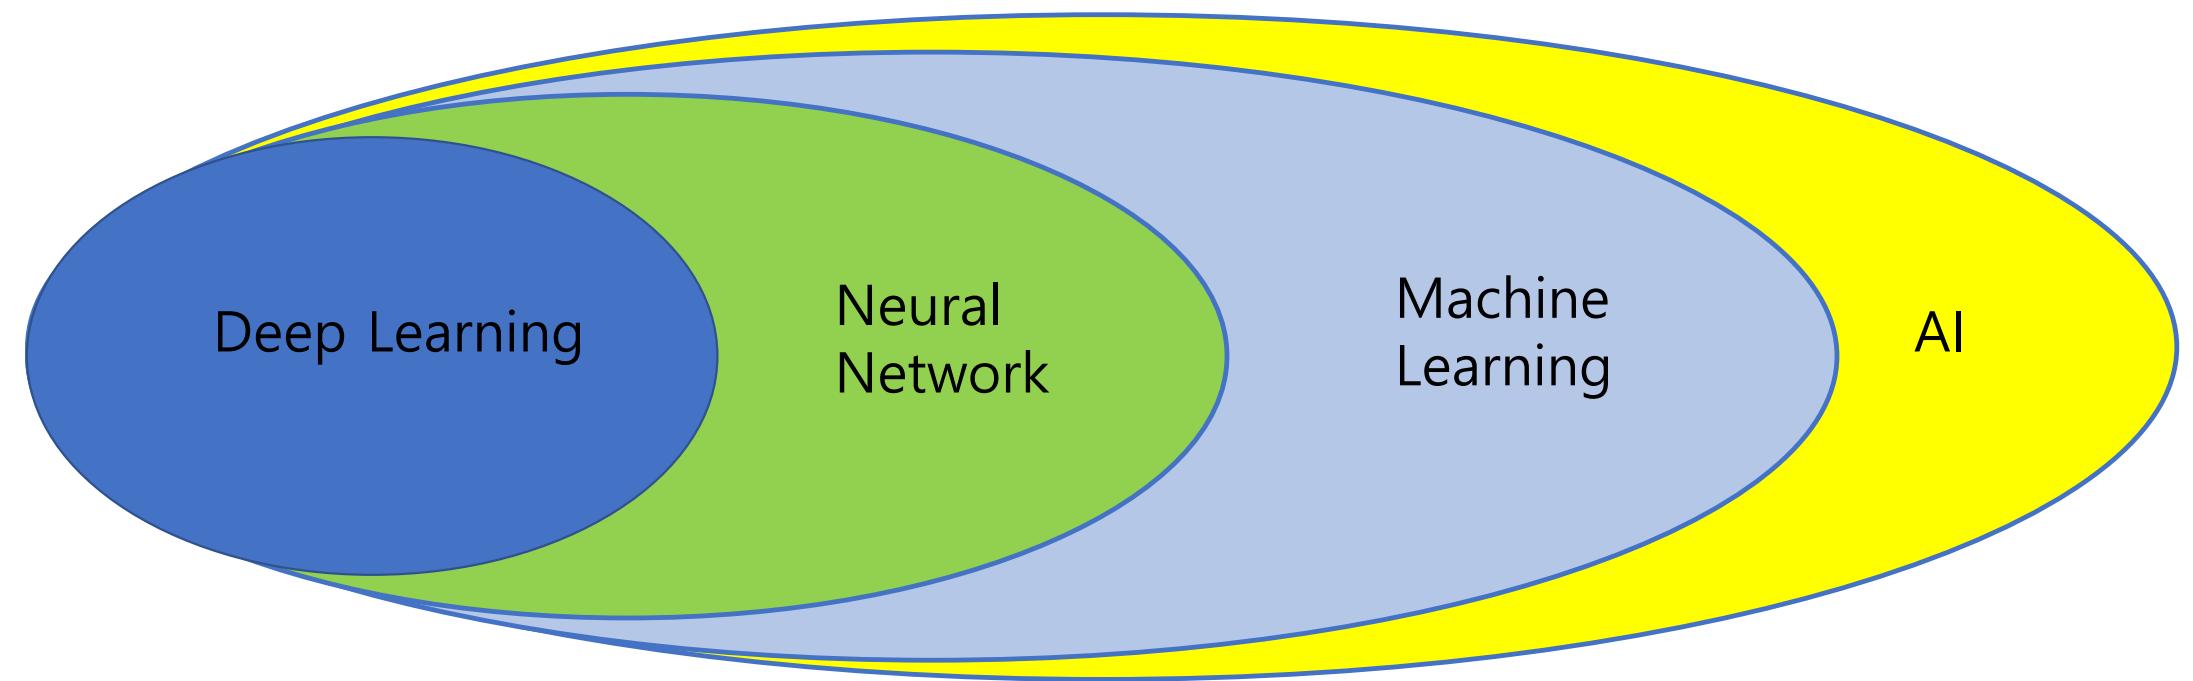
완료

Machine Learning 개요

AI 의 종류



AI vs. Machine Learning vs. Deep Learning



History of Machine Learning

- 탄생 [1950년대]

1958년 코넬대 심리학자 프랭크 로센블래트가 인간의 뇌신경을 본떠 Perceptron 고안. 신경망 기반 인공지능 연구의 부흥기 시작

- AI의 첫번째 암흑기 [1970년대]

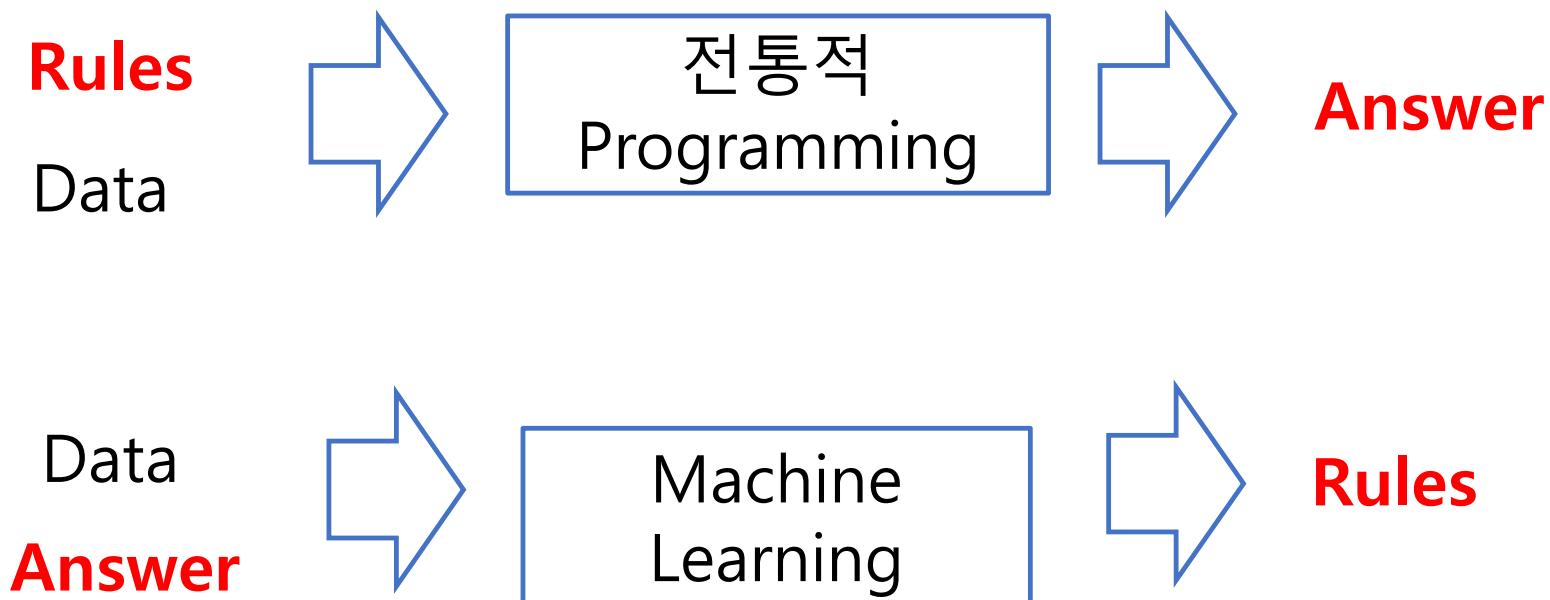
Marvin Minsky가 대규모 신경망은 학습시킬 수 없음을 수학적으로 증명. 인공지능에 대한 대규모 연구 지원 중단

- 중흥기 [1980년대]

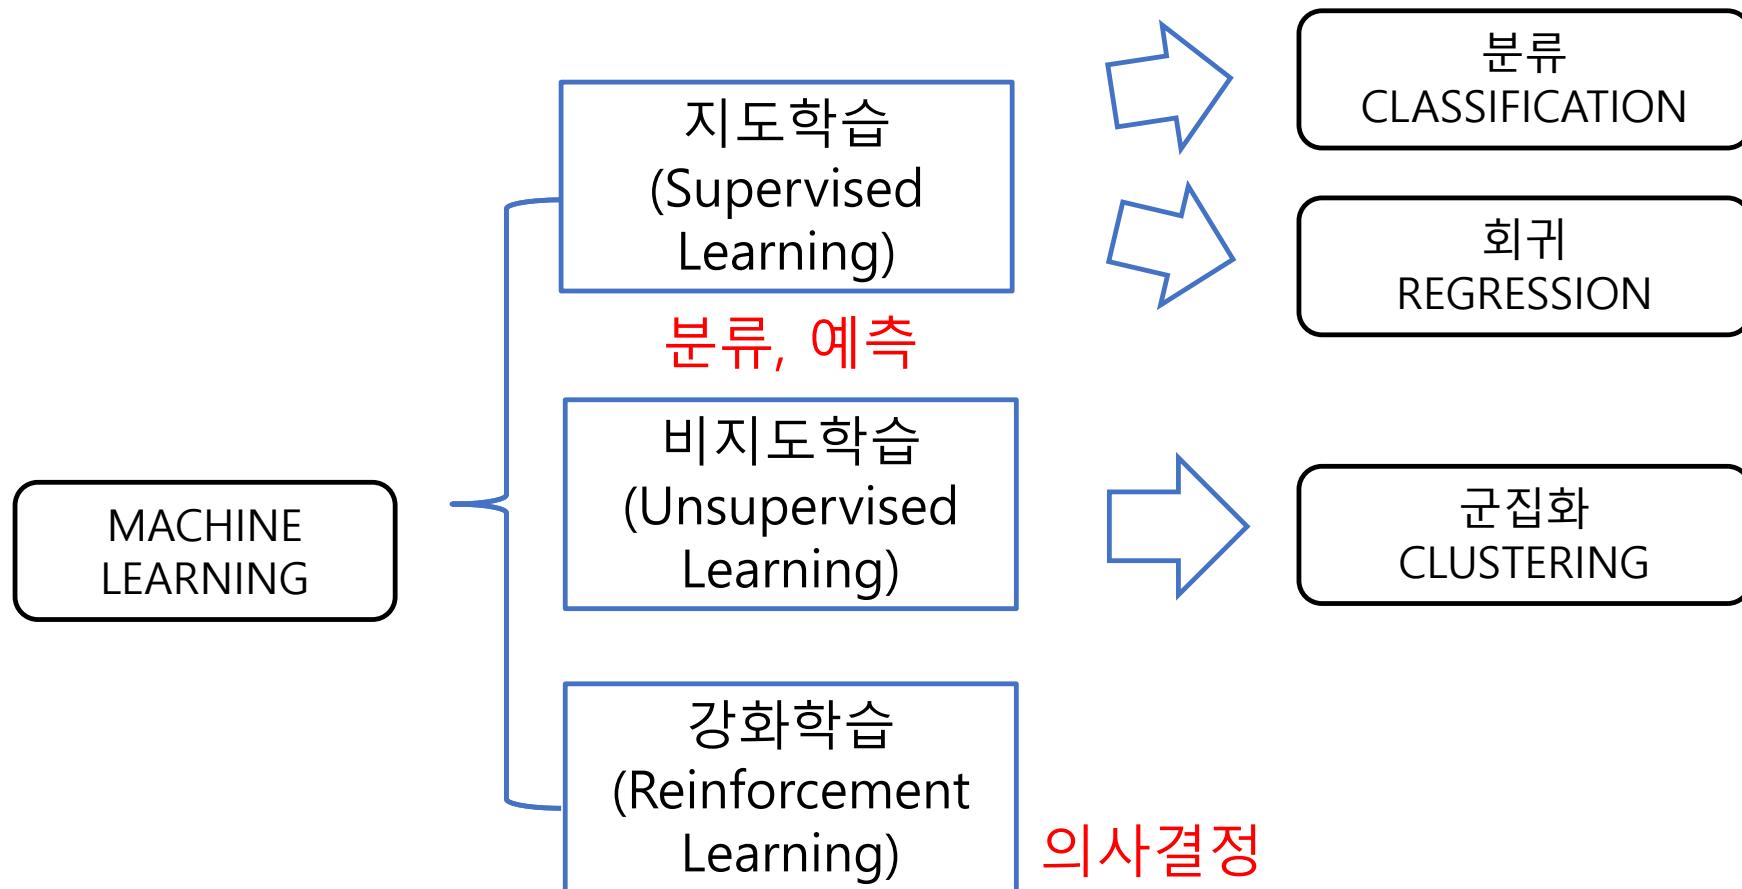
산업계에 전문가 시스템(Expert System)이 도입되며 본격 확산

- AI 의 두번째 암흑기 [1987 – 1993]
 - 투자대비 효용성의 한계 노출
 - 슈퍼컴퓨터와 시뮬레이션 분야로 연구방향을 전환
 - Jeffery Hinton (Toronto 대학) back-propagation algorithm 개발
→ Marvin Minsky가 틀렸다는 것을 증명
- IBM Deep Blue 가 Garry Kasparov 에 승리 – 1996
 - Expert System
- Google Brain 이 최초로 인간 얼굴 인식 - 2012
- ~ 상업적 대 폭발기
- Alphago 이세돌에 승리 – 2016
 - 강화학습 알고리즘

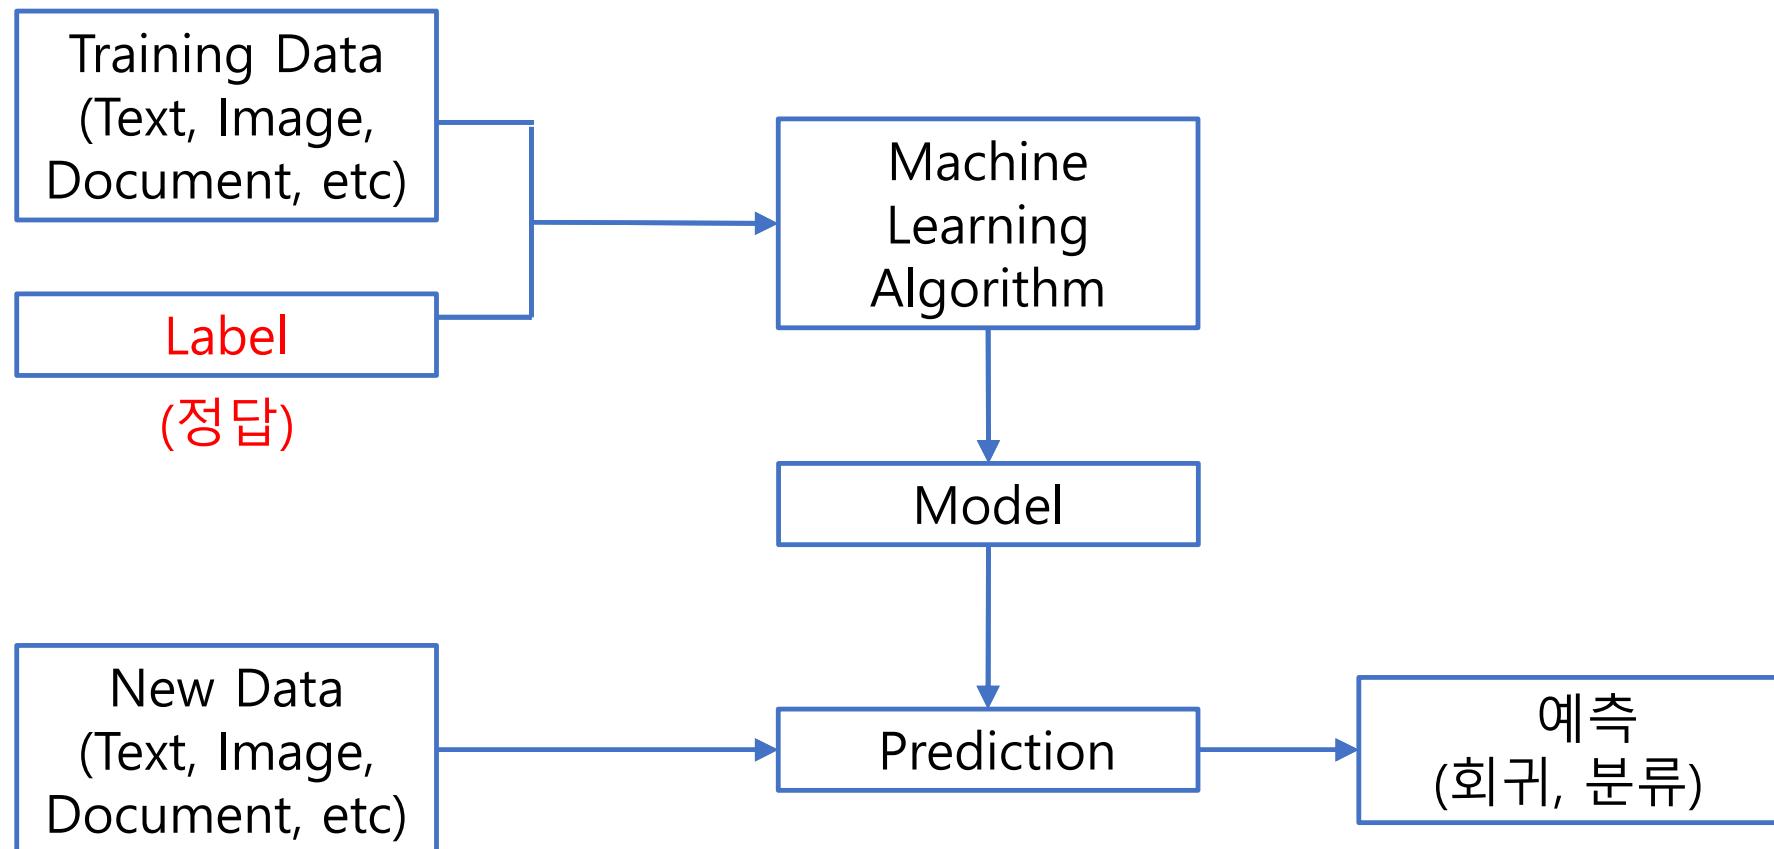
전통적 Programming vs Machine Learning



Machine Learning 의 종류



Supervised Learning (지도학습)



지도학습 모델의 획기적 성공 이유

90%
OF THE
WORLD'S DATA
WAS CREATED IN
THE LAST

2
YEARS





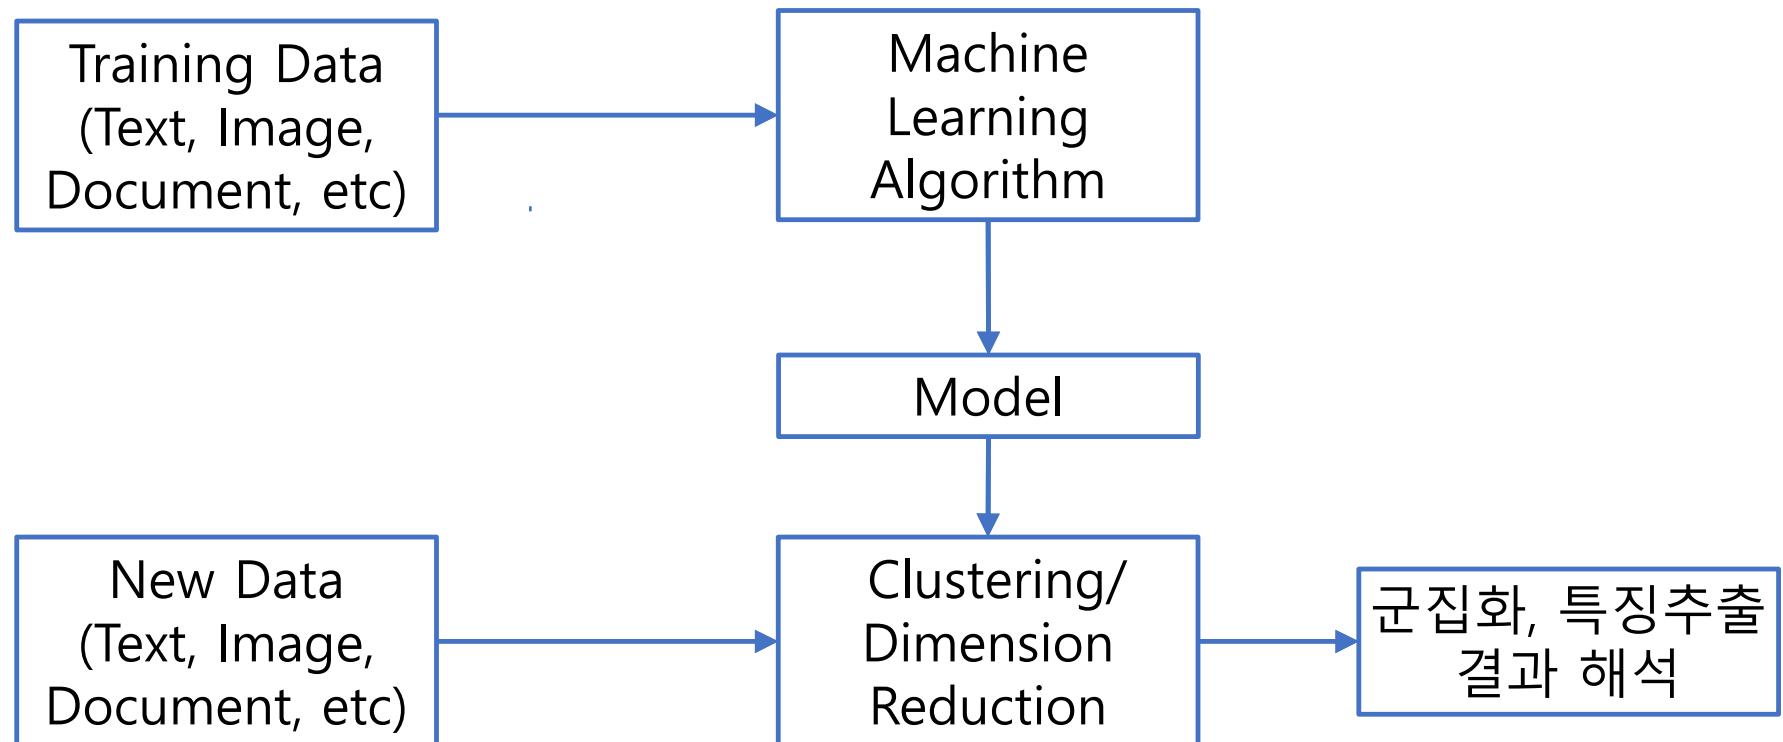
1.2 billion photos and videos are uploaded to Google Photos every day.

Total size of over 13 PB of photo data.



(1PB or 400 hours of video uploaded every minute)

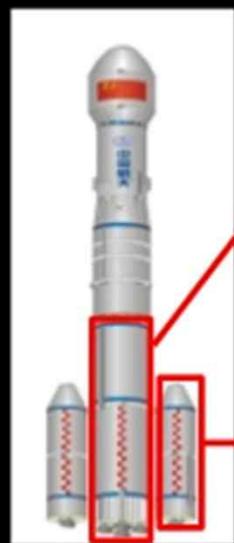
Unsupervised Learning (비지도학습)



Machine Learning 기법의 종류

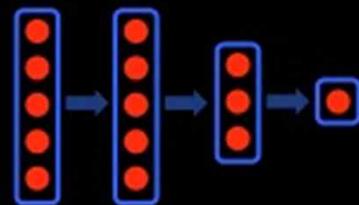
<p>Types of Machine Learning</p> <ul style="list-style-type: none">SupervisedUnsupervisedReinforcement	<p>전통적 ML</p> <ul style="list-style-type: none">• Linear & Logistic Regression• KNN• Decision Tree• SVM• Ensembles• K-Means Clustering• PCA <p>Deep Learning (Neural Network)</p> <ul style="list-style-type: none">• FC• CNN• RNN• Auto Encoder• GAN
--	---

Why is Deep Learning taking off?



Engine

Fuel



Large neural networks



Labeled data
(x, y pairs)

Bai du Research

Andrew Ng

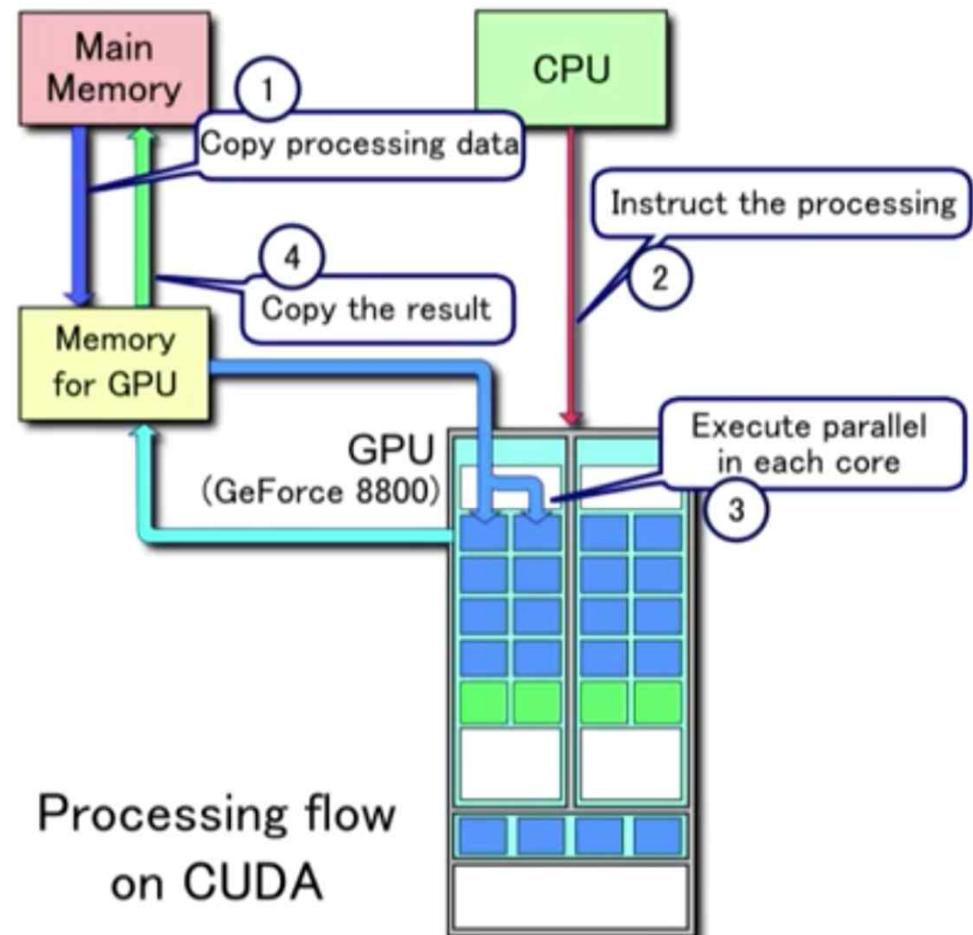
Rocket Engine : NVIDIA + Deep Learning Algorithm

Fuel : Data (25,000 pictures for cat)

CUDA for GPU

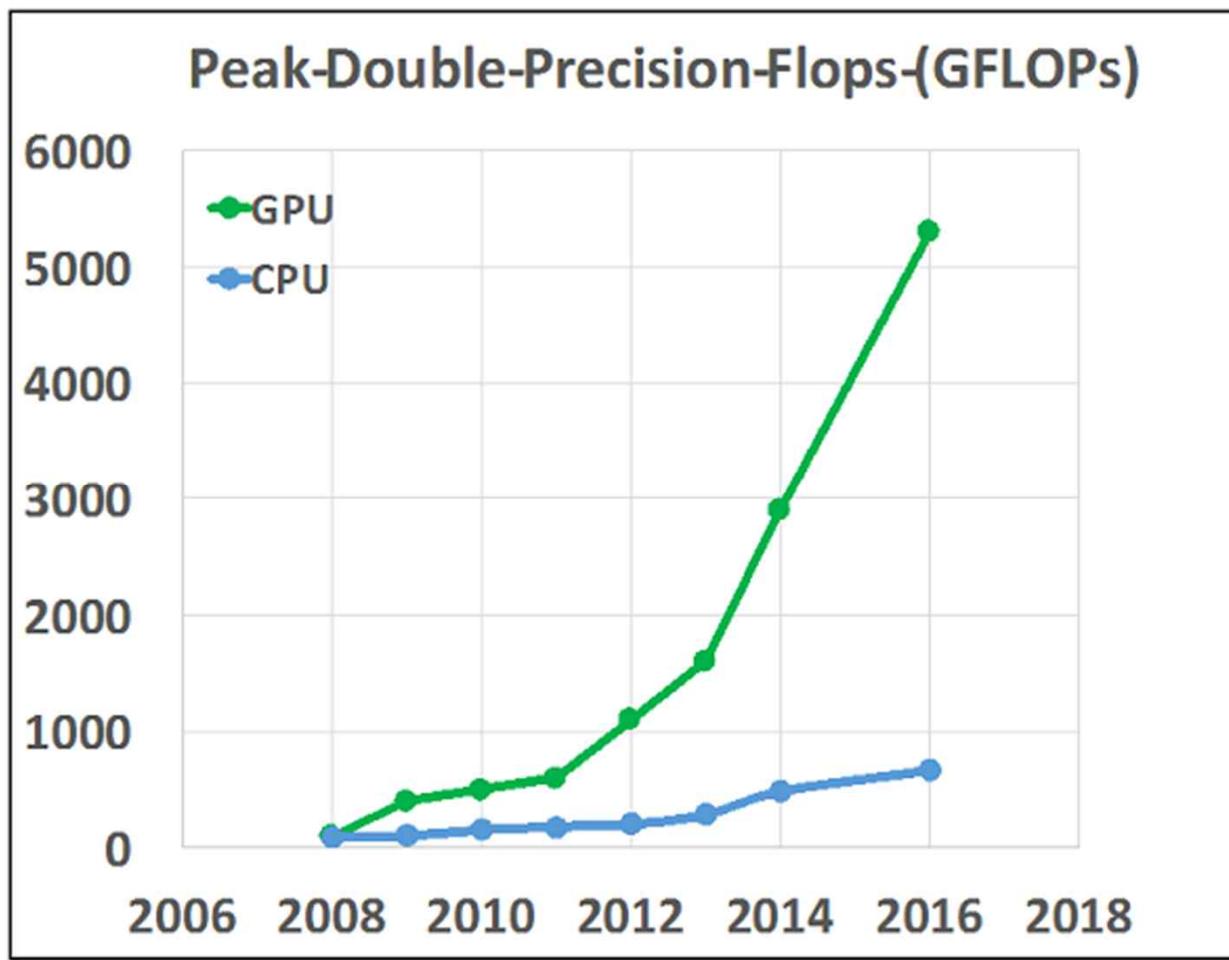


CUDA - Compute Unified Device Architecture



Source: Wikimedia Commons

CPU vs GPU Performance



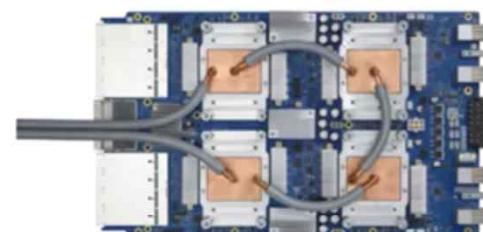
TPU (Tensor Processing Unit) - Custom ASIC by Google



TPU v1
(2015)
92 teraops
First Generation

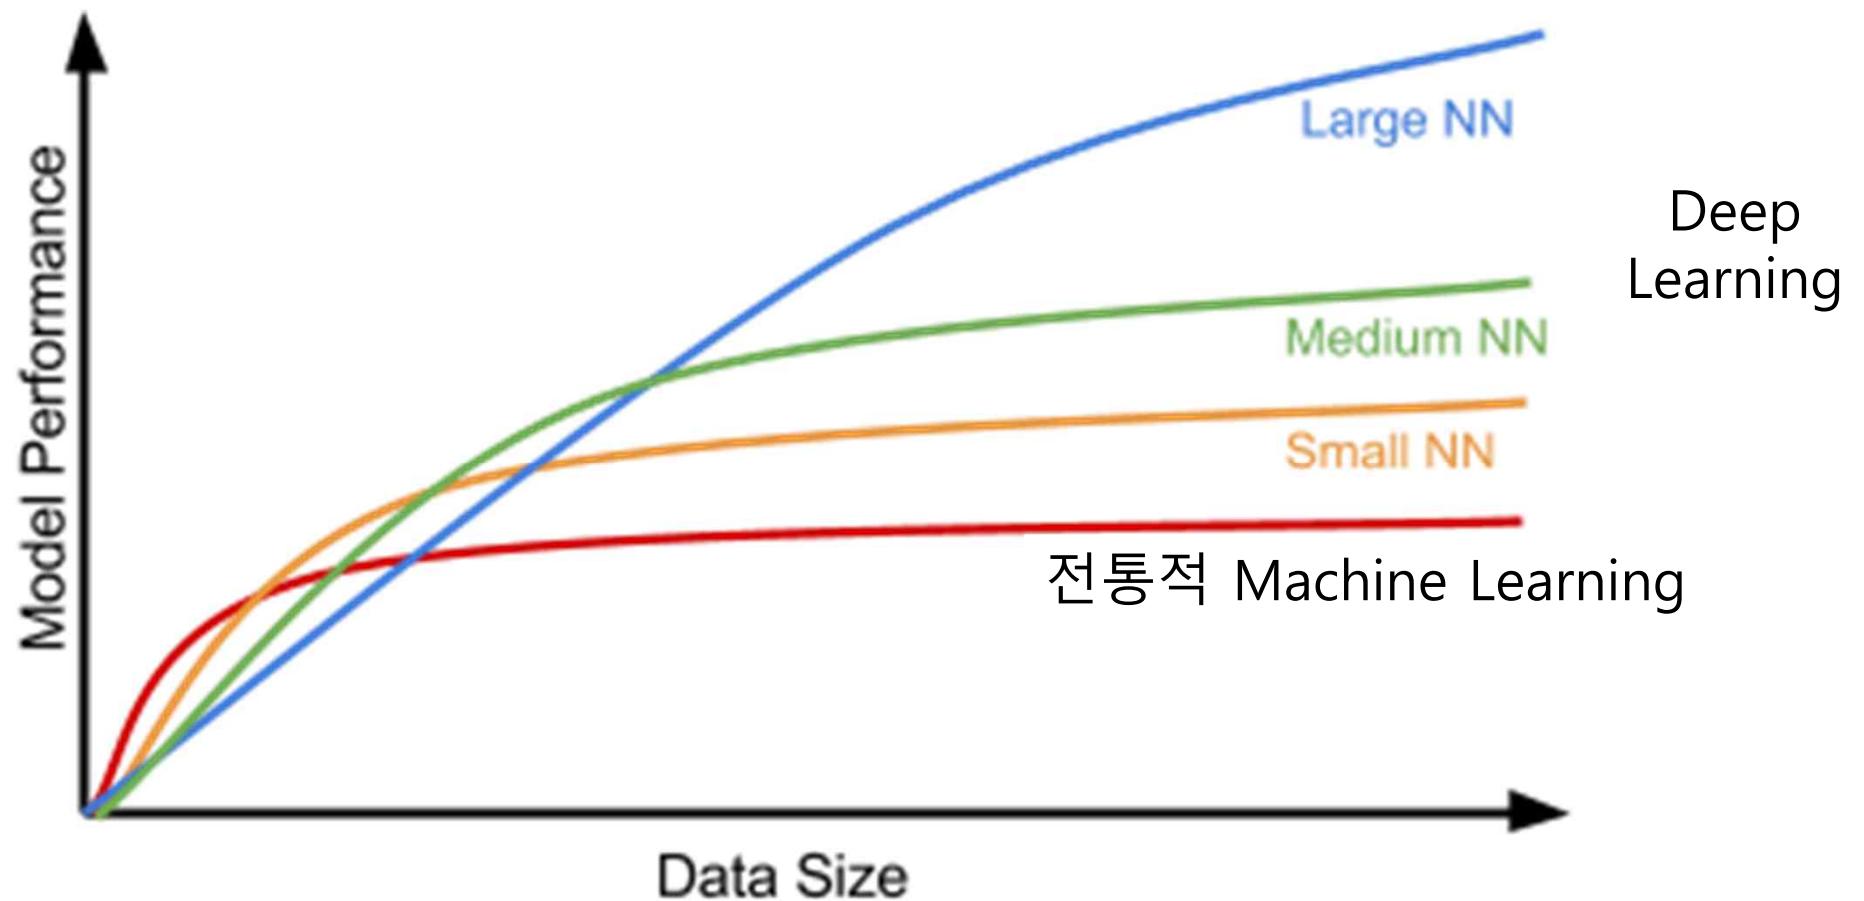


TPU v2
(2017)
180 teraflops
Available via Google
Cloud



TPU v3
(2018)
420 teraflops
Available via Google
Cloud

전통적 Machine Learning vs. Deep Neural Network



Scikit-Learn



전통적 Machine Learning Tool:

- 벤치마크용 데이터셋 예제
- 데이터 전처리(preprocessing)
- 지도 학습(Supervised learning)
- 비지도 학습(Unsupervised learning)
- 모형 평가 및 선택 (evaluation and selection)

Open Source Libraries for Deep Learning

- **Scikit-Learn** – 2007, Python Library based on Matplotlib, NumPy, SciPy
- Theano - 2007, Open Source Python Library
- **Tensorflow** – 2015, Google. Open Source Machine Learning Framework
- **Keras** – 2015, Open Source Python Library
 - (working on top of Tensorflow, Theano, CNTK)
- Microsoft Cognitive Tool – 2016, CNTK
- Caffe – 2017, Berkeley AI Research
- **Pytorch** – 2016, Facebook
- H2O – 2011, Open Source Big Data platform on Apache Hadoop

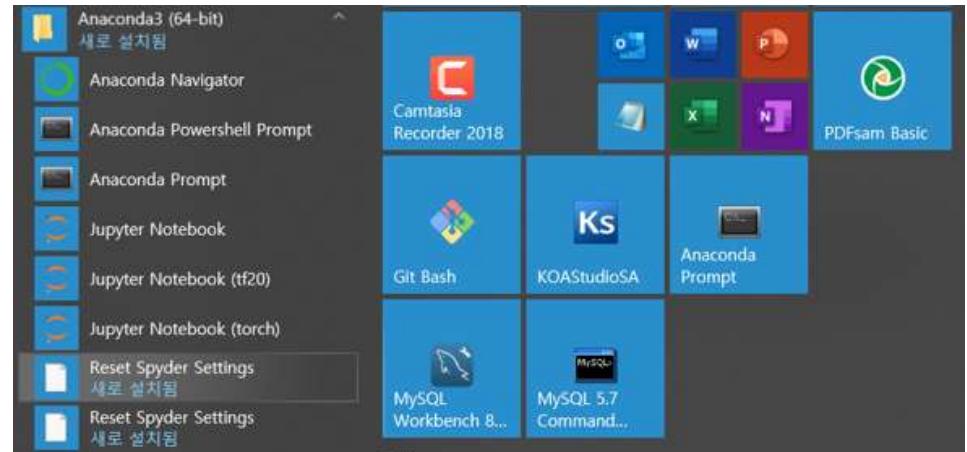
Jupyter Notebook 사용 방법

What is Jupyter Notebook ?

- 주피터 노트북(**Jupyter Notebook**)은 웹 브라우저에서 파이썬 코드를 작성하고 실행해 볼 수 있는 개발도구
- 아나콘다(Anaconda)를 설치하면 **Jupyter Notebook**이 함께 설치
- Notebook 서버 프로그램은 백그라운드에서 실행되는 파이썬 프로그램으로 웹 브라우저를 통해 interactive하게 Python 명령 실행

Jupyter Notebook 실행 방법

1) Start menu에서 실행



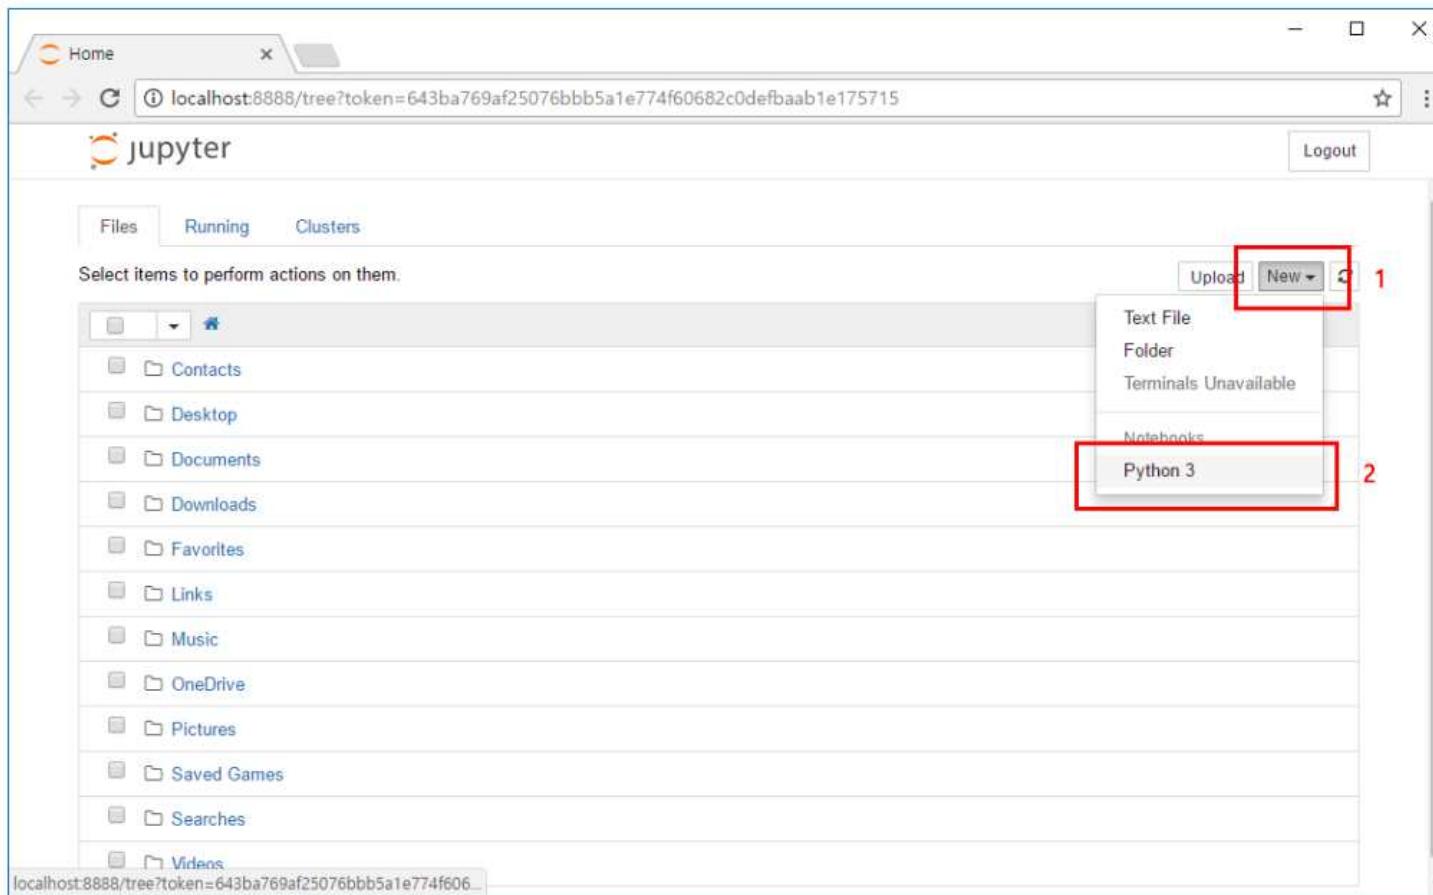
2) 명령 prompt에서 실행
> jupyter notebook

```
(base) C:\Users\trimu>jupyter notebook
[I 08:20:31.790 NotebookApp] Serving notebooks from local directory: C:\Users\trimu
[I 08:20:31.791 NotebookApp] The Jupyter Notebook is running at:
[I 08:20:31.793 NotebookApp] http://localhost:8888/?token=e1bb3f10db684cd21f9dd3c0e89f713306df271678b97d9d
[I 08:20:31.798 NotebookApp] or http://127.0.0.1:8888/?token=e1bb3f10db684cd21f9dd3c0e89f713306df271678b97d9d
[I 08:20:31.800 NotebookApp] Use Control-C to stop this server and shut down all kernels (twice to skip confirmation).
[C 08:20:31.994 NotebookApp]

To access the notebook, open this file in a browser:
    file:///C:/Users/trimu/AppData/Roaming/jupyter/runtime/nbserver-12876-open.html
Or copy and paste one of these URLs:
    http://localhost:8888/?token=e1bb3f10db684cd21f9dd3c0e89f713306df271678b97d9d
    or http://127.0.0.1:8888/?token=e1bb3f10db684cd21f9dd3c0e89f713306df271678b97d9d
```

Jupyter Notebook 사용방법

주피터 노트북 초기 화면에서 New → Python 3 선택 → 새로운 notebook 생성



Python Code 입력 및 실행

설명 추가

The screenshot shows two Jupyter Notebook windows side-by-side.

Top Window: A new notebook titled "Untitled". The toolbar has "Markdown" selected. A red box highlights the "Markdown" cell content, which displays "# Hello, world! 출력" and the explanatory text "print 함수로 Hello, world!를 출력합니다.". A red number "2" is in the bottom right corner of the cell area.

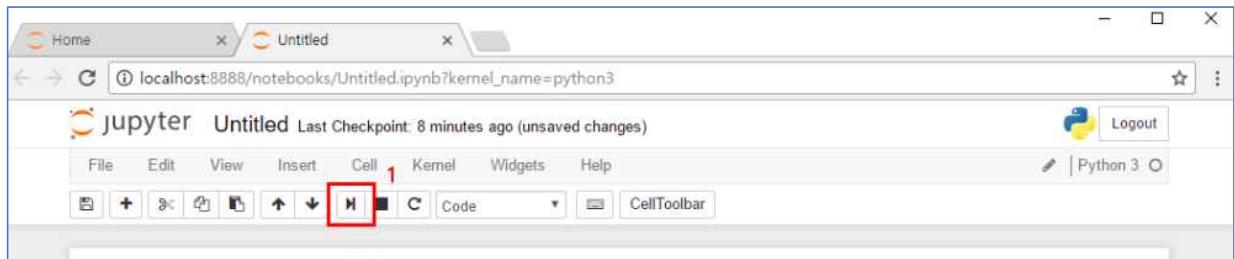
Bottom Window: An existing notebook titled "14.object-oriented-programming". It contains several code cells labeled In [25] through In [30].

- In [25]: print(type(12.5))
<class 'float'>
- In [26]: def f(n):
 return n
- In [27]: print(type(f))
<class 'function'>
- In [28]: print(type(print))
<class 'builtin_function_or_method'>
- In [29]: class Car:
 color = "blue"
 max_speed = 100

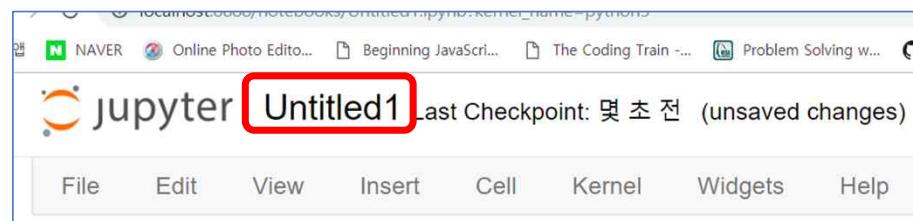
 def speedCheck(self, n):
 if n > self.max_speed:
 print("Too fast")
 else:
 print("Good speed")
- In [30]: sonata = Car()

A red box highlights the code in In [29], and a red number "1" is placed to its left. To the right of the code in In [29], the text "Python 명령어 입력" is written in red.

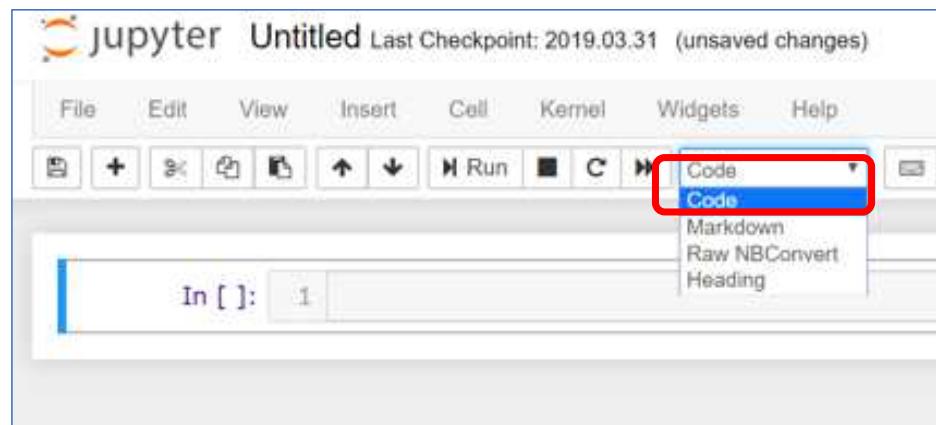
Code 실행



Notebook File Name 바꾸기



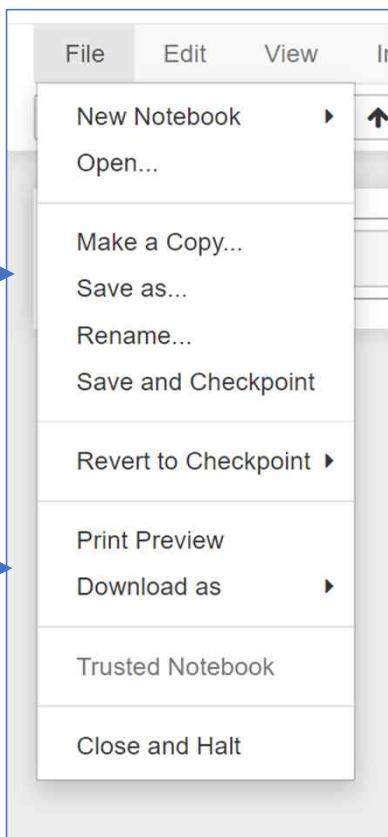
Cell Type 변경



자주 사용하는 menu 들

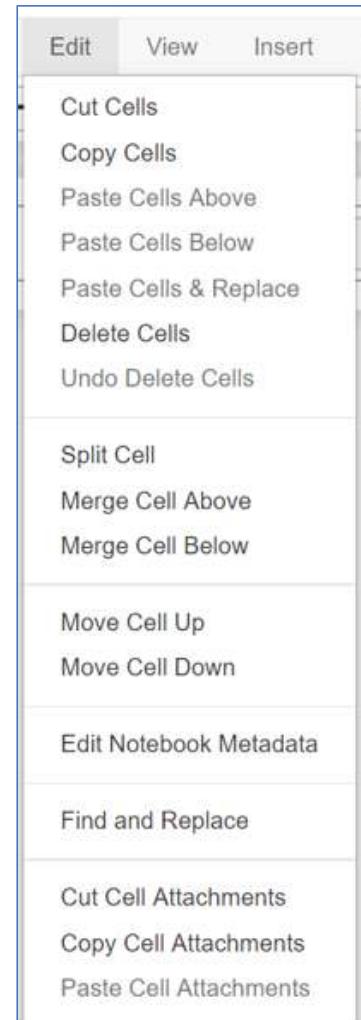
Notebook
저장

Notebook
download



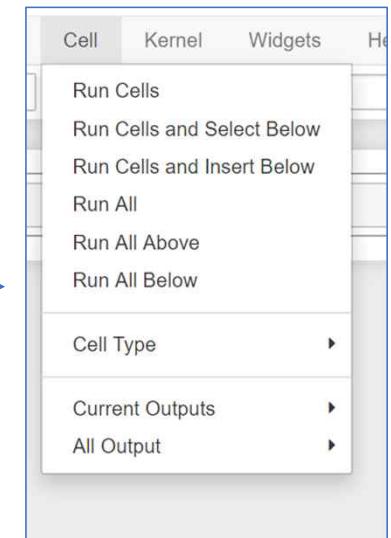
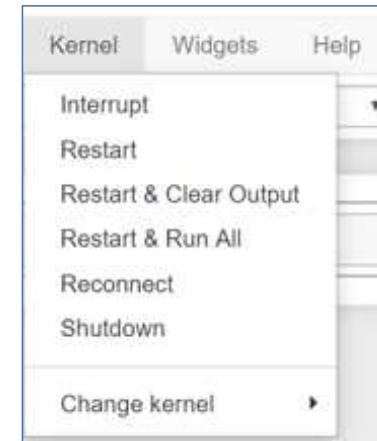
Cell 삭제
취소

Find/
Replace



Notebook
restart →

Cell 실행 →



Jupyter Notebook 사용방법

- 자주 사용하는 short-cut key

Shift + Enter : cell 실행 + 다음 cell 이동

Ctrl + S : save + checkpoint

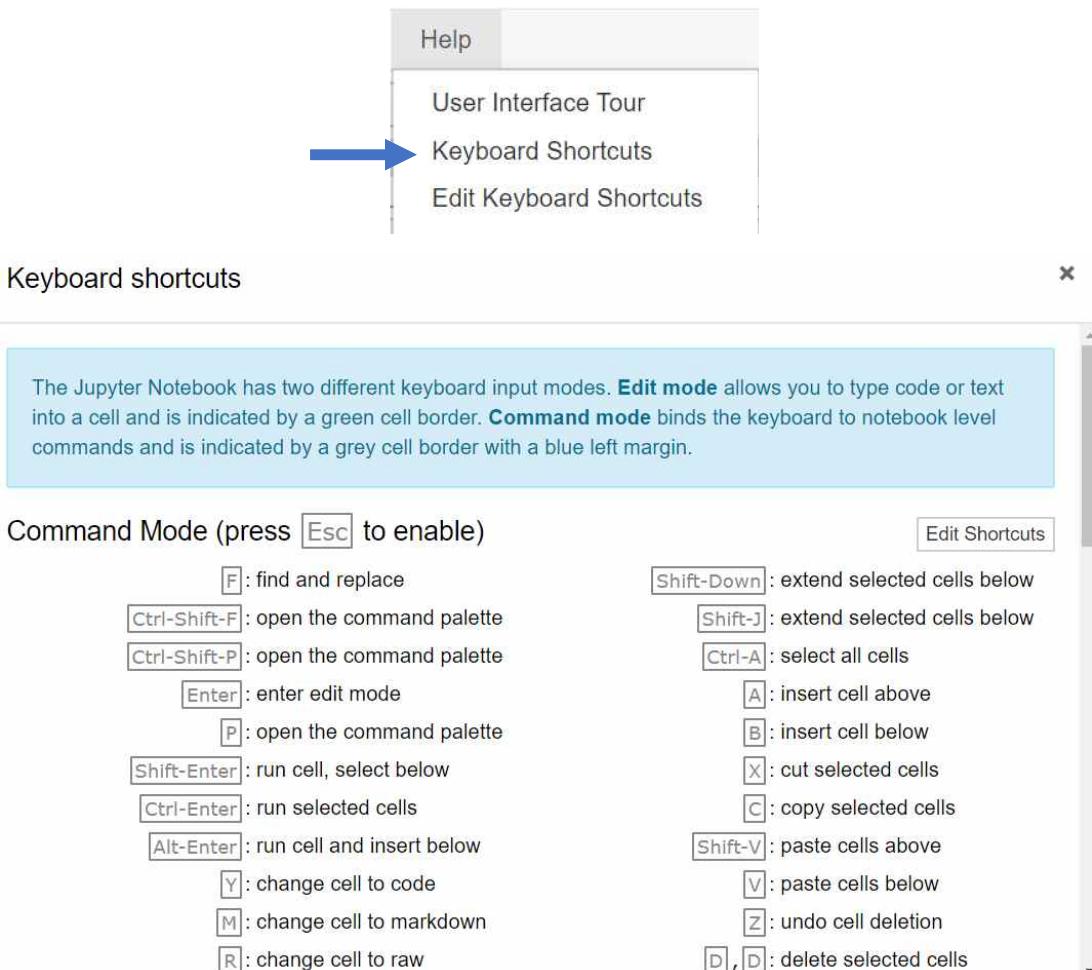
Esc+A : 위쪽에 cell 삽입

Esc+B : 아래쪽에 cell 삽입

Esc+X : cell 삭제

Esc+Z : cell 삭제 취소

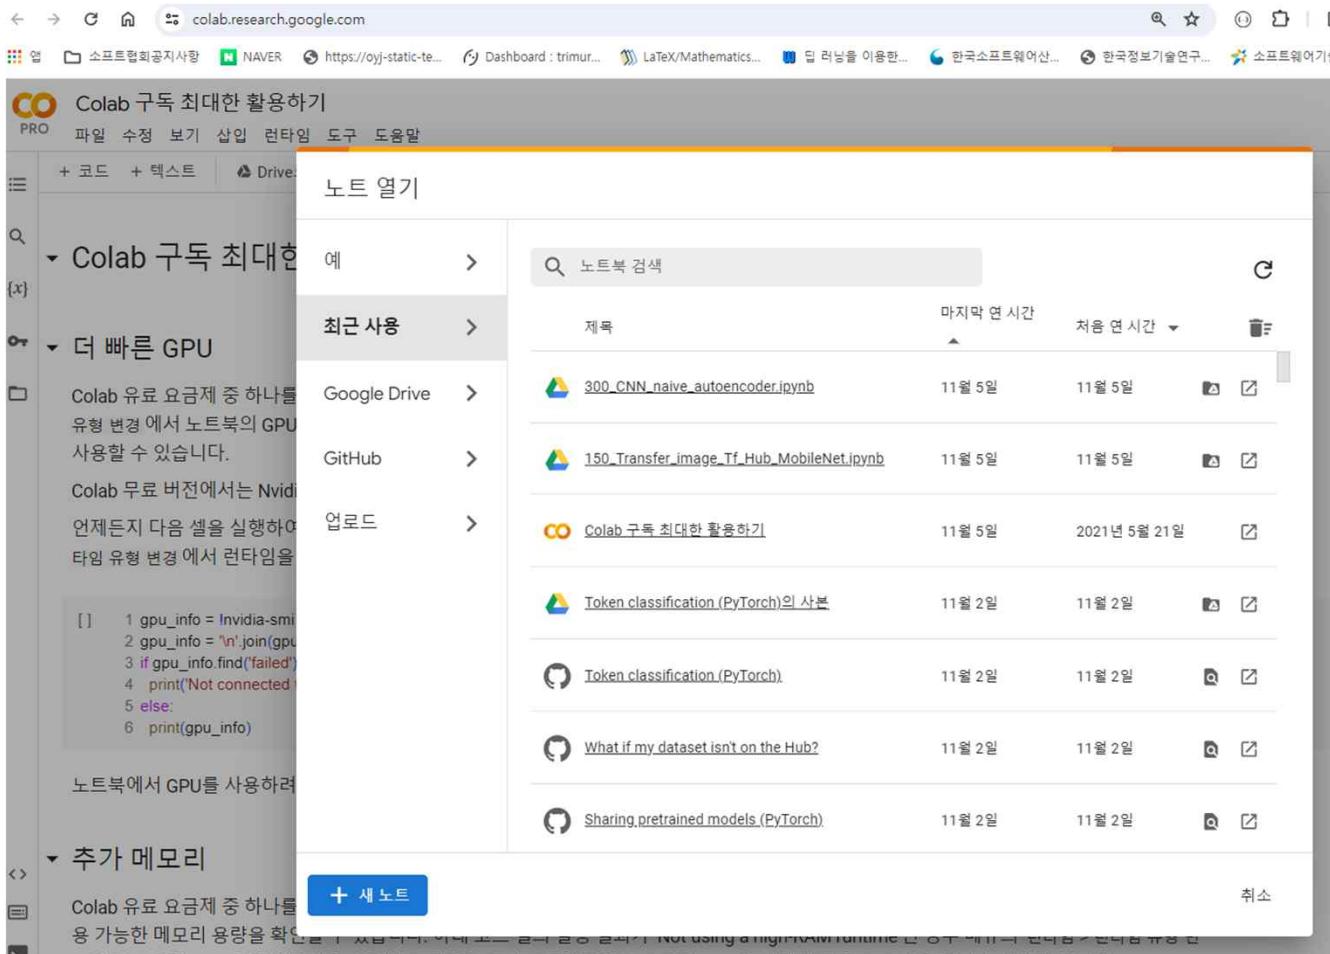
Esc+M : cell 을 markdown type 으로 변경



Google Colaboratory 소개

- Free GPU 제공
- Google Drive 와 연동
- Jupyter Notebook 환경
- Deep Learning beginner 를 위한 최적의 환경
- 각종 snippet 제공

Google Colaboratory (<https://colab.research.google.com/>)



Crash Course

1. Numpy & Linear Algebra
2. Pandas
3. Matplotlib

What is Numpy ?

- Numerical Python
- 대용량 데이터 배열을 효율적으로 다룰 수 있도록 설계
- 선형대수, 매트릭스 연산 등의 함수 내장
- numpy 의 속도가 필요한 알고리즘은 C, C++ 로 작성

Numpy (Numerical Python)

- numpy array
 - 1 차원 - vector, 2 차원 – matrix, 3 차원 이상 - tensor
 - rank – array 의 dimension (차원)
 - shape – 각 dimension 의 size
 - dtype – tensor 의 data type

	Scalar	Vector	Matrix	Tensor
1		$\begin{bmatrix} 1 \\ 2 \end{bmatrix}$	$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$	$\begin{bmatrix} \begin{bmatrix} 1 & 2 \end{bmatrix} & \begin{bmatrix} 3 & 2 \end{bmatrix} \\ \begin{bmatrix} 1 & 7 \end{bmatrix} & \begin{bmatrix} 5 & 4 \end{bmatrix} \end{bmatrix}$
shape :		(2,)	(2, 2)	(2, 2, 2)

Matrix 의 numpy 표현

1D array(Vector)

8	5	3
---	---	---

`np.array([8, 5, 3]), shape=(3,)`

2D array(Matrix)

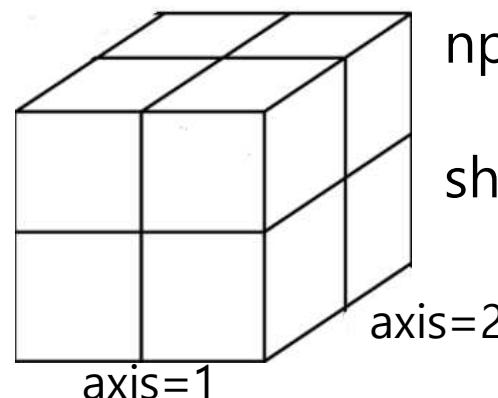
8	5	3
1	2	9

`np.array([[8, 5, 3], [1, 2, 9]]), shape=(2, 3)`

$\begin{bmatrix} 8 & 5 & 3 \\ 1 & 2 & 9 \end{bmatrix}$

axis=1

3D array(Tensor)



`np.array([[[1, 2], [3, 4]], [[5, 6], [7, 8]]])`

$\begin{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \\ \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix} \end{bmatrix}$

`shape=(2, 2, 2)`

$\begin{bmatrix} \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix} \end{bmatrix}$

axis=0

axis=1

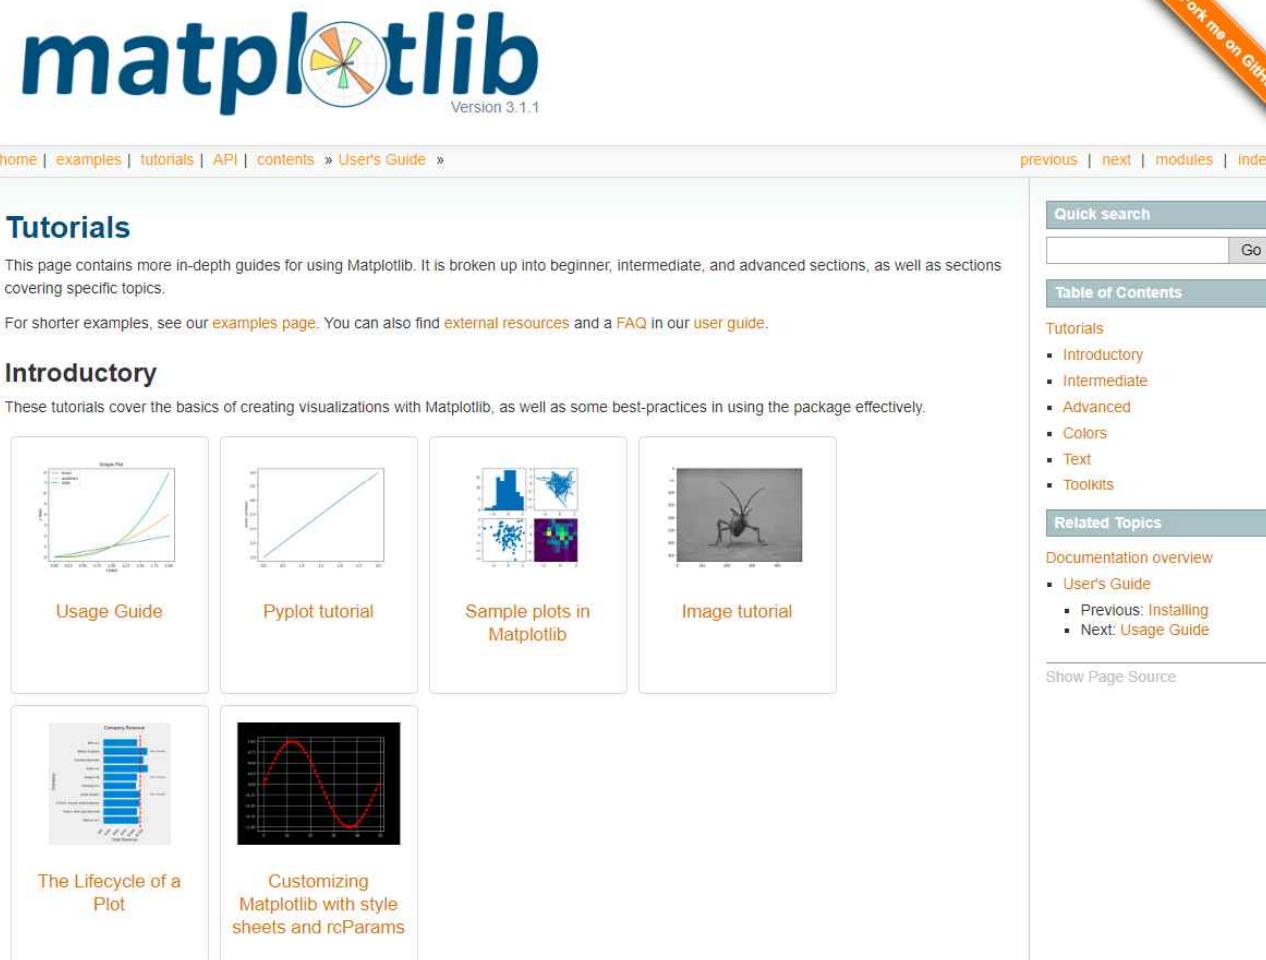
axis=2

Pandas

- Dataframe - R 을 모방하여 구현
- Tabular 형식의 Data 처리 (Excel 대체 가능)

	A	B	C	D	E	F	G	H	I
1	Order Date	OrderID	Salesperson	UK Units	UK Order Amt	USA Units	USA Order Amt	Total Units	Total Order Amt
2	1/01/2011	10392	Fuller			13	1440	13	1440
3	2/01/2011	10397	Gloucester	17	716.72			17	716.72
4	2/01/2011	10771	Bromley	18	344			18	344
5	3/01/2011	10393	Finchley			16	2556.95	16	2556.95
6	3/01/2011	10394	Finchley			10	442	10	442
7	3/01/2011	10395	Gillingham	9	2122.92			9	2122.92
8	6/01/2011	10396	Finchley			7	1903.8	7	1903.8
9	8/01/2011	10399	Callahan			17	1765.6	17	1765.6
10	8/01/2011	10404	Fuller			7	1591.25	7	1591.25
11	9/01/2011	10398	Fuller			11	2505.6	11	2505.6
12	9/01/2011	10403	Coghill	18	855.01			18	855.01
13	10/01/2011	10401	Finchley			7	3868.6	7	3868.6

Matplotlib – 대표적 시각화 도구



The screenshot shows the Matplotlib User's Guide page. At the top, there is a logo for "matplotlib" with the text "Version 3.1.1". A blue banner on the right says "Fork me on GitHub". Below the logo, there is a navigation bar with links: "home | examples | tutorials | API | contents » User's Guide ». On the right side of the navigation bar are links for "previous | next | modules | index".

Tutorials

This page contains more in-depth guides for using Matplotlib. It is broken up into beginner, intermediate, and advanced sections, as well as sections covering specific topics.

For shorter examples, see our [examples page](#). You can also find [external resources](#) and a [FAQ](#) in our [user guide](#).

Introductory

These tutorials cover the basics of creating visualizations with Matplotlib, as well as some best-practices in using the package effectively.

Usage Guide (Thumbnail: A plot showing a curve and a legend)

Pyplot tutorial (Thumbnail: A plot showing a straight line)

Sample plots in Matplotlib (Thumbnail: A grid of small plots including histograms and scatter plots)

Image tutorial (Thumbnail: A grayscale image of a fly)

The Lifecycle of a Plot (Thumbnail: A diagram showing the stages of plot creation)

Customizing Matplotlib with style sheets and rcParams (Thumbnail: A plot showing a red sine wave)

Quick search (with a search input field and a "Go" button)

Table of Contents

Tutorials

- Introductory
- Intermediate
- Advanced
- Colors
- Text
- Toolkits

Related Topics

Documentation overview

- [User's Guide](#)
 - Previous: [Installing](#)
 - Next: [Usage Guide](#)

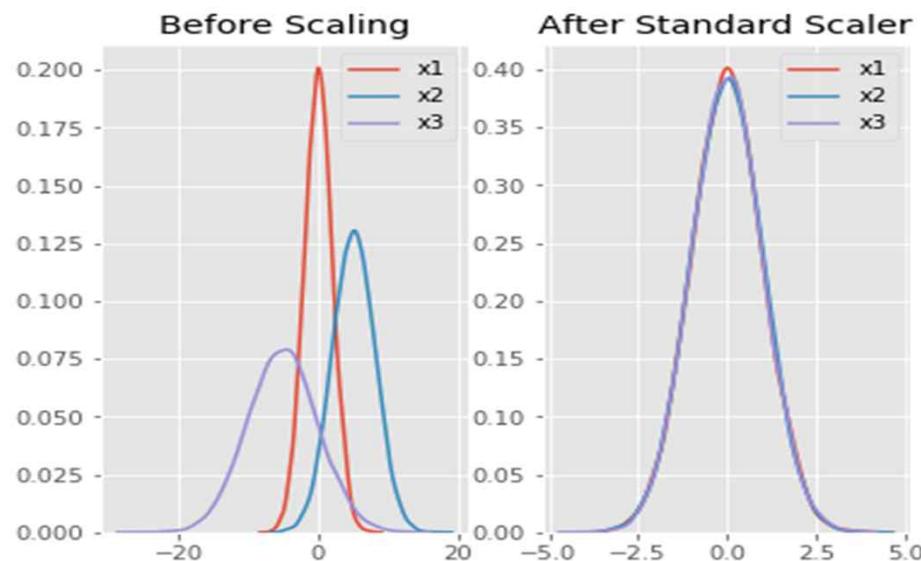
[Show Page Source](#)

- 실습:
- 001. Numpy Array Crash
 - 002. Pandas Crash
 - 003. Matplotlib Crash

Feature Scaling

- Raw data 를 전 처리하여 input data 의 구간을 표준화
- Standard Scaling :
$$z = (x - \mu) / s \quad (\mu : 평균, s : 표준편차)$$
- Minmax Scaling :

$$x_{\text{new}} = \frac{x_i - \min(X)}{\max(x) - \min(X)}$$



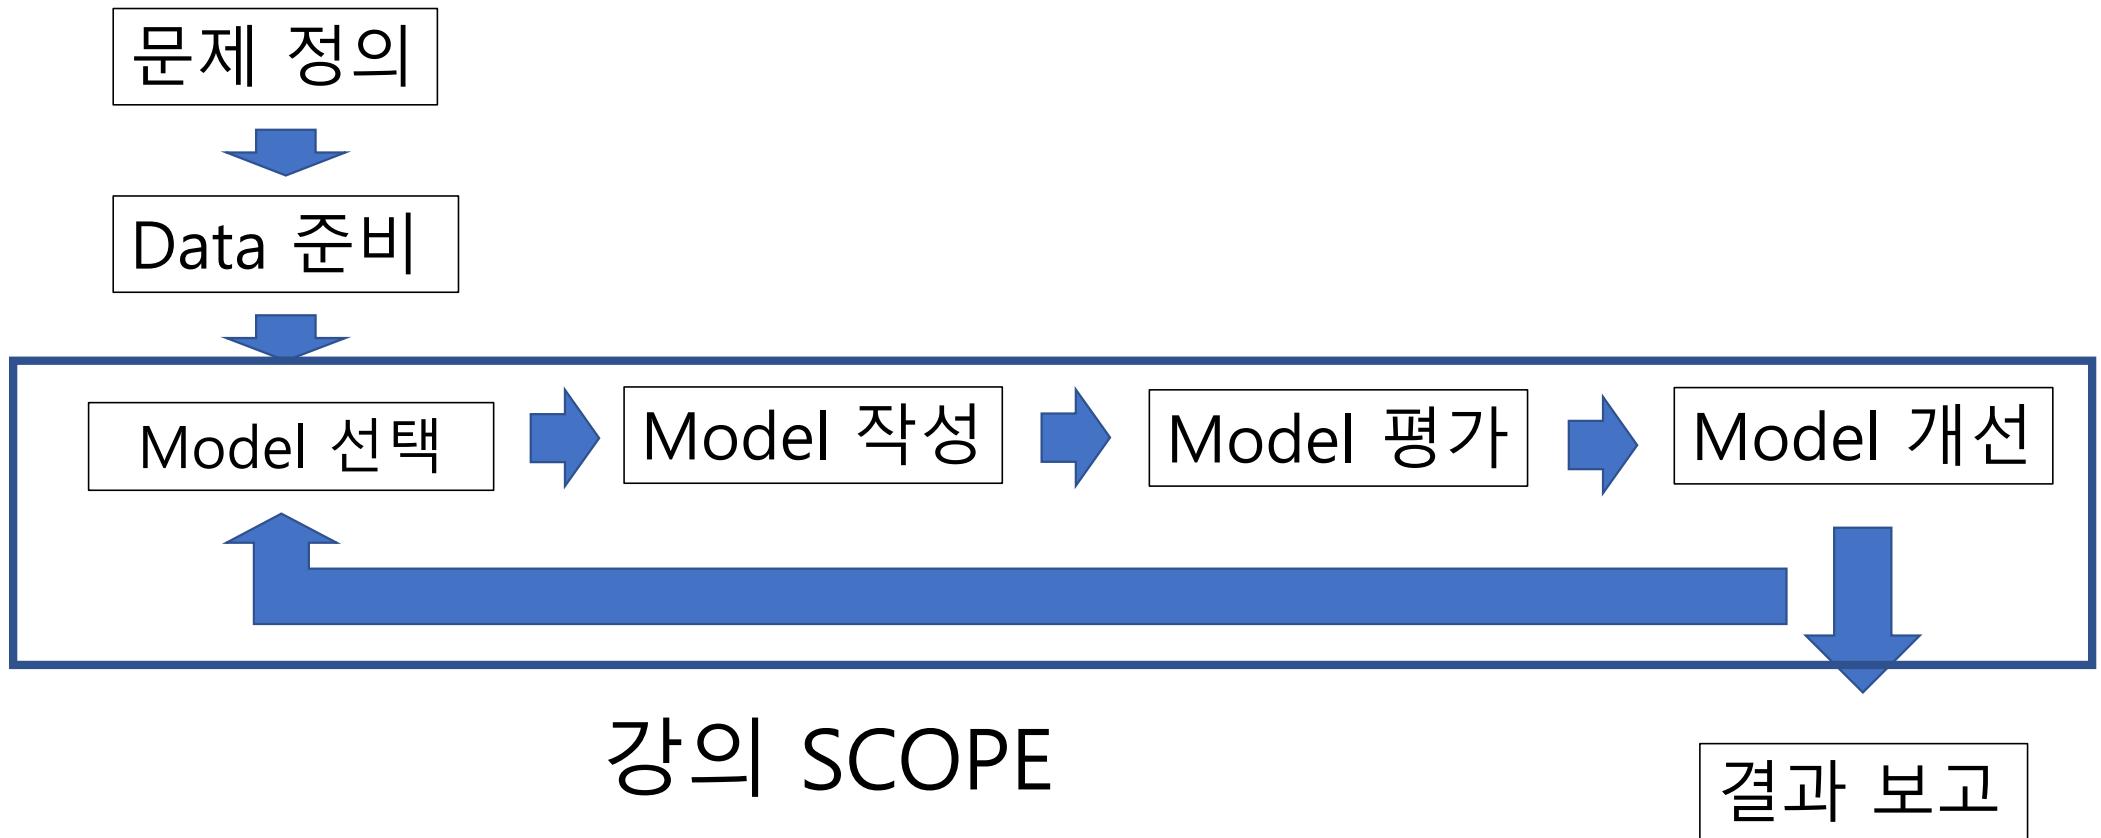
실습: 004. sklearn 을 이용한 feature scaling (normalization)

- Simple Feature Scaling
- Standard Scaling
- MinMax Scaling

Machine Learning

End-to-End Process

Machine Learning Model 작성



Model 작성 순서

Import Libraries : sklearn, numpy, pandas, matplotlib, etc



Data Load : csv, sklearn.datasets, etc

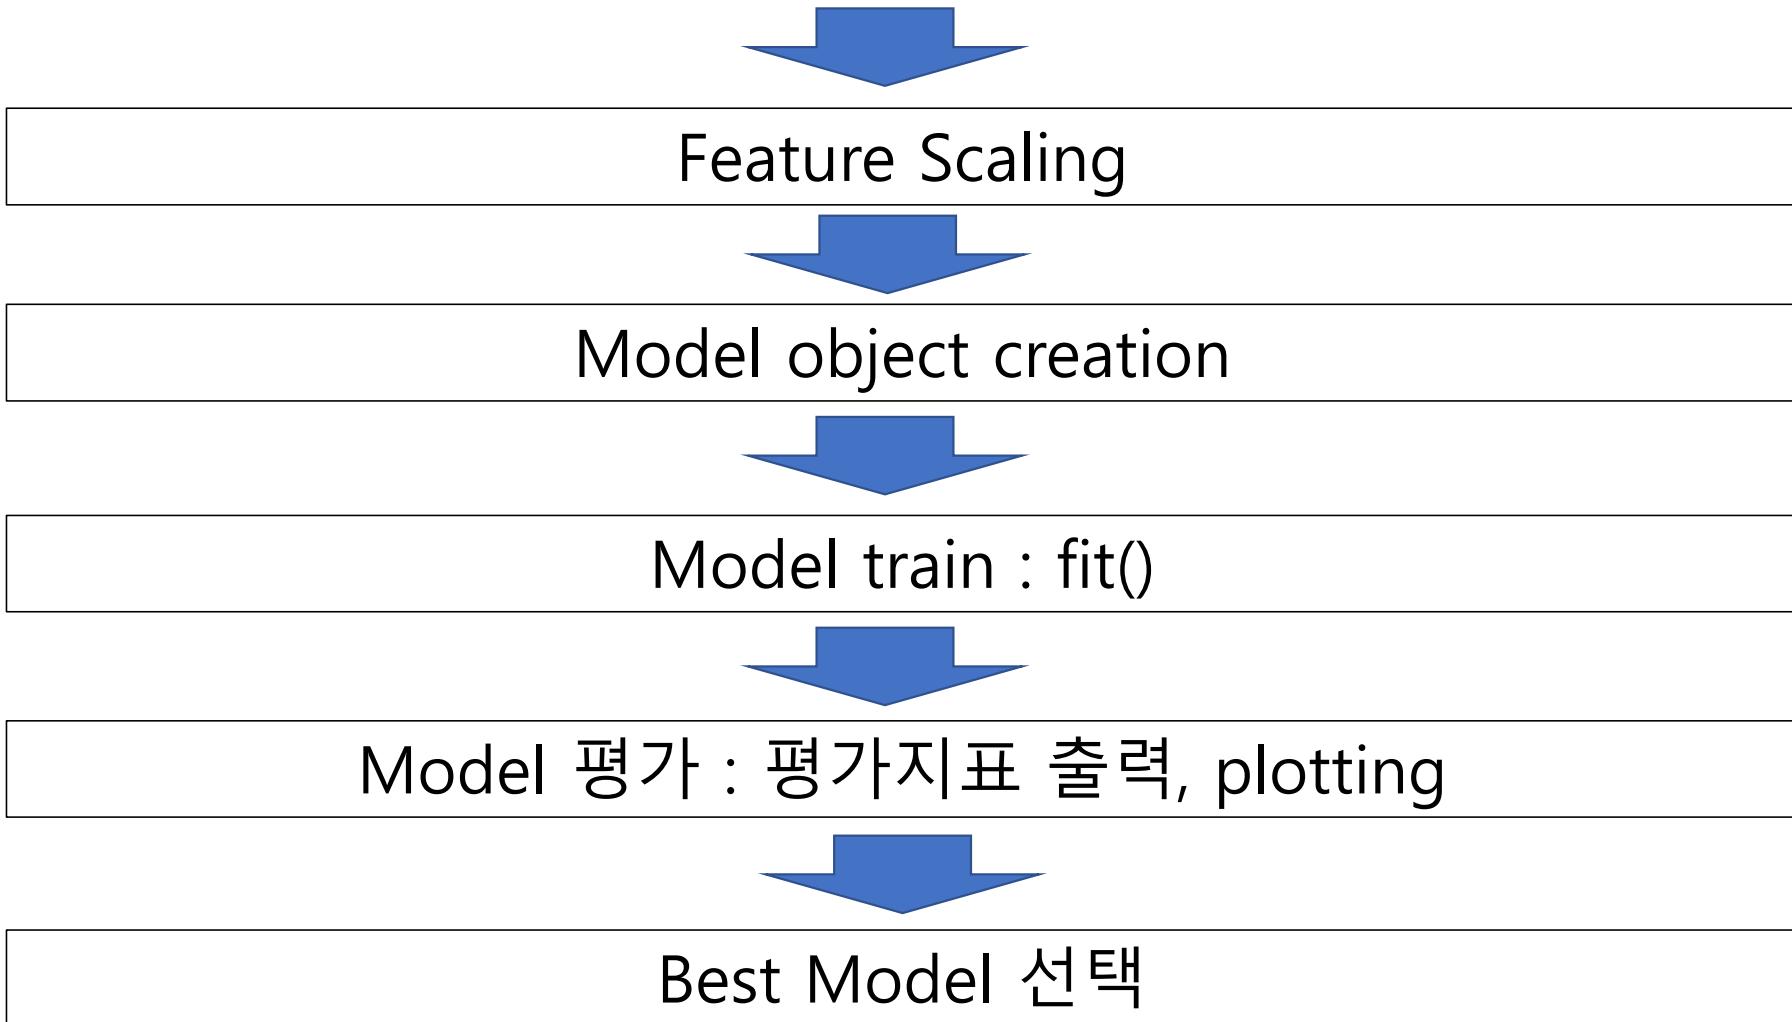


Data 내용 파악 : shape, statistics, visualize



Train / test dataset 분할 : sklearn, manual

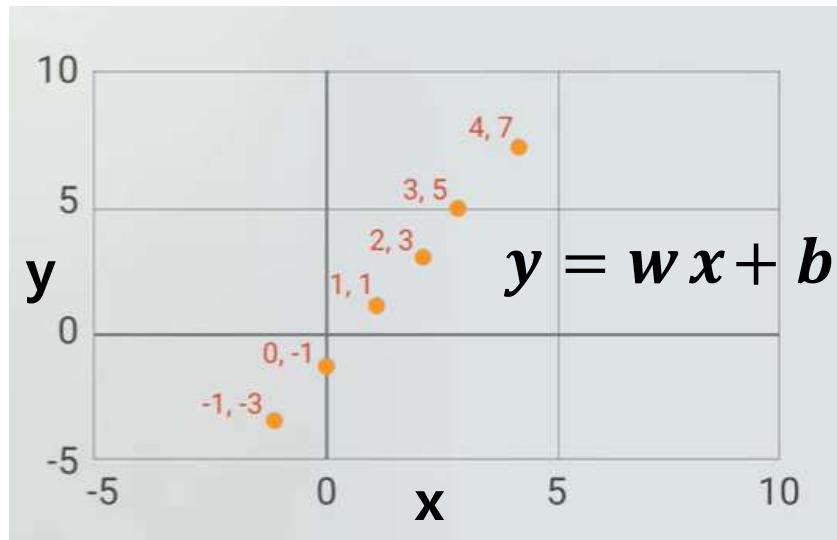




Linear Regression

1. Univariate Linear Regression (단변수 선형회귀)

- 한개의 변수로 결과 예측 (ex. 혈압으로 당뇨병 여부 예측)



- x, y 가 주어지고
w, b 가 미지수
- ▼
- w, b 를 infer (추정)

1. Univariate Linear Regression (단변수선형회귀)

$$y = wx + b \rightarrow \text{Hypothesis (가설)}$$



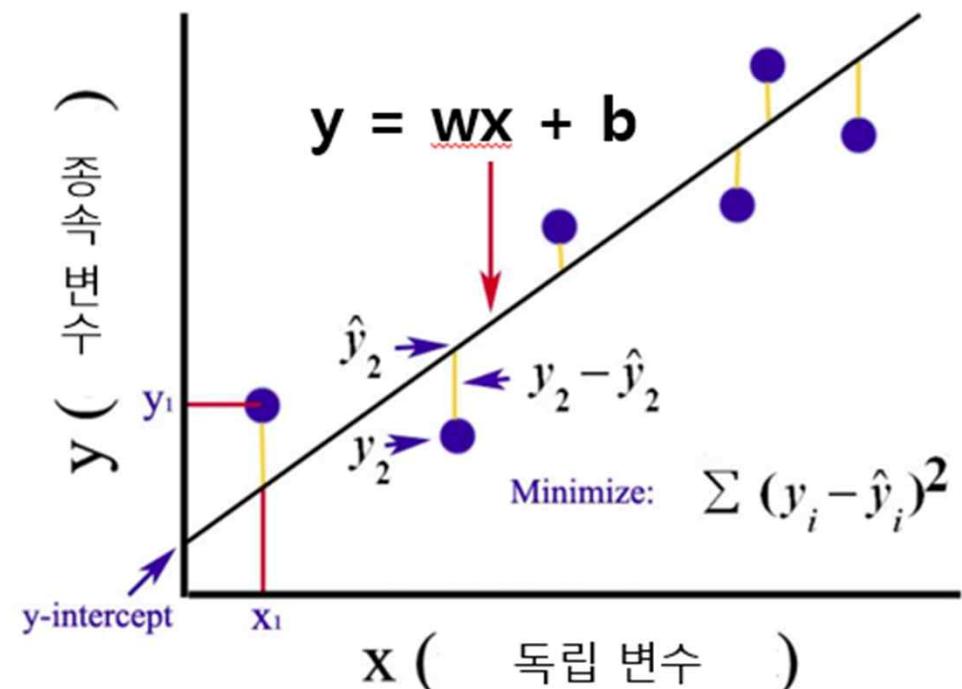
- OLS (Ordinary Least Squares, 최소자승법)

$$Minimize \sum_{i=1}^n (true - prediction)^2$$



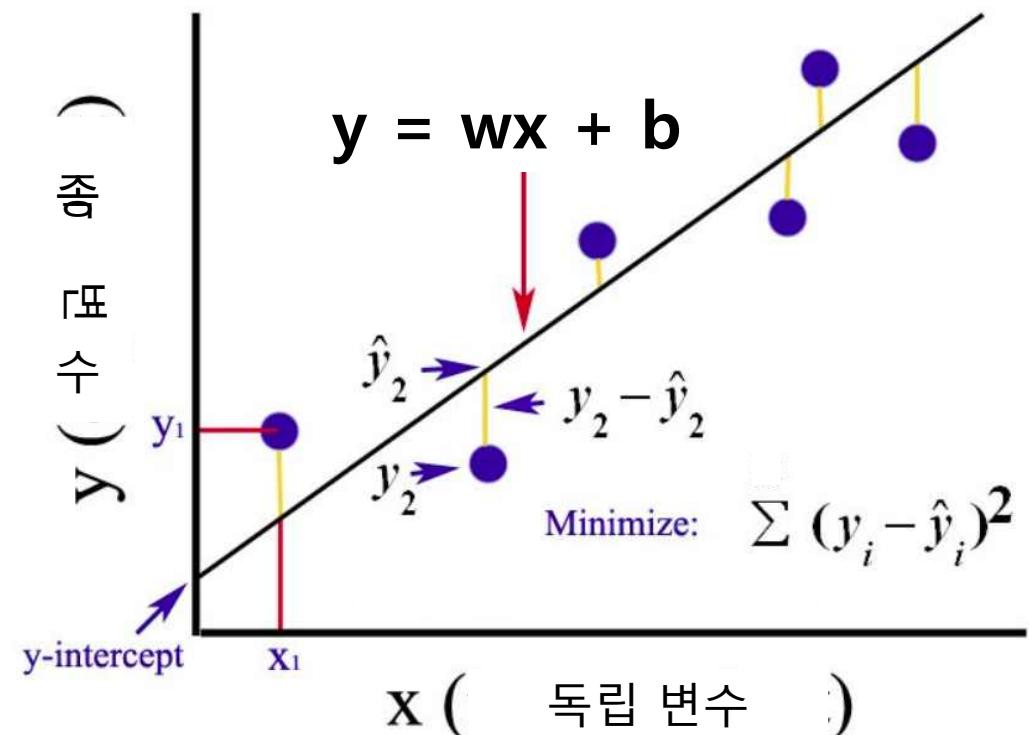
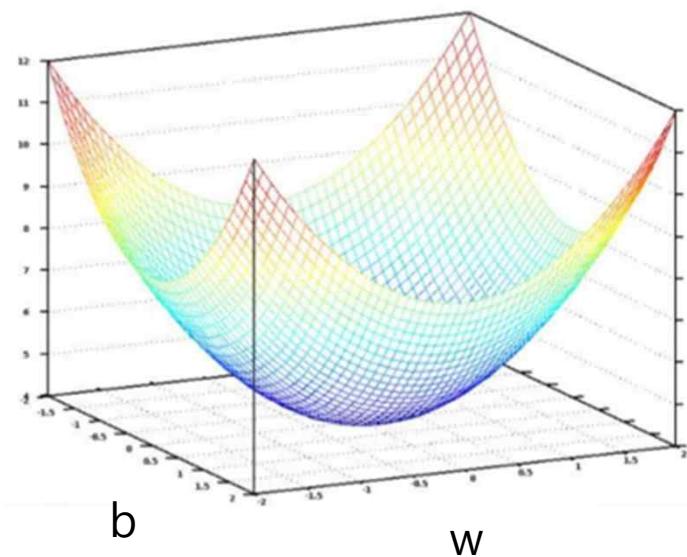
Cost Function (비용함수)

- 가설이 얼마나 틀렸는지 측정



Cost Function - Linear Regression

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{Y}_i - Y_i)^2$$



MSE 를 최소화 하는
θ 와 b 를 optimize

Linear Regression 의 Accuracy (정확도) 측정

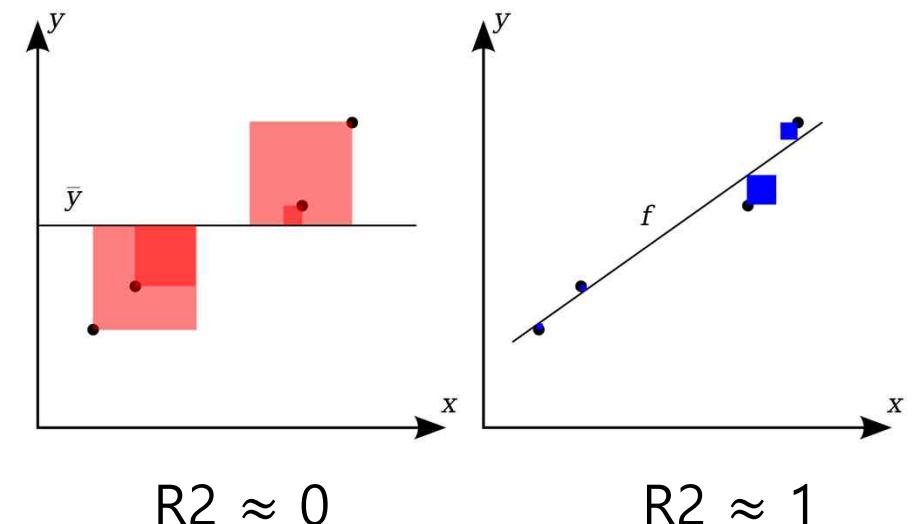
- 평가기준 2 : R2 score (결정계수)
sklearn.metrics.r2_score

* 결정계수(R2) – 회귀식의 정확도 측정
 $0 \leq R2 \leq 1$

$$R2 = 1 - \frac{SSE}{SST}$$

$$= 1 - \left(\frac{\text{Sum of Square Error}}{\text{Sum of Square Total}} \right)$$

$$= 1 - \left(\frac{\text{예측값에 대한 분산의 합}}{\text{분산의 합}} \right)$$



2. Multivariate Linear Regression (다변수선형회귀)

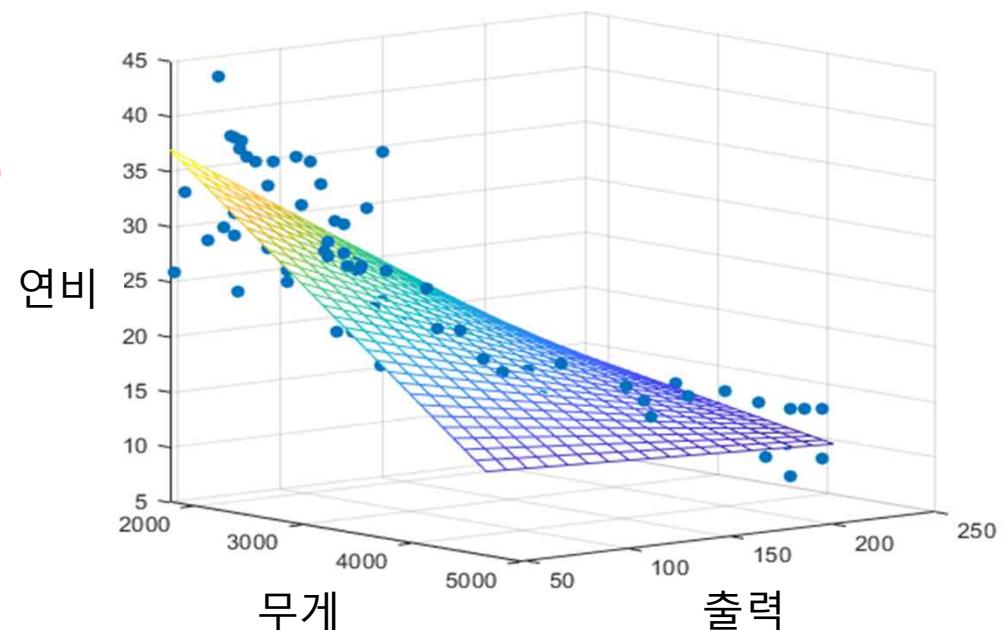
$$\hat{Y} = \theta_0 + \theta_1 X_1 + \theta_2 X_2 + \theta_3 X_3 + \dots + \theta_n X_n$$

$$\hat{Y} = \theta \mathbf{X}$$

`sklearn.linear_model.LinearRegression()`

$\theta = \text{coef}_\text{-}$

$\theta_0 = \text{intercept}_\text{-}$



실습: 010. 당뇨병 data 를 이용한 선형회귀

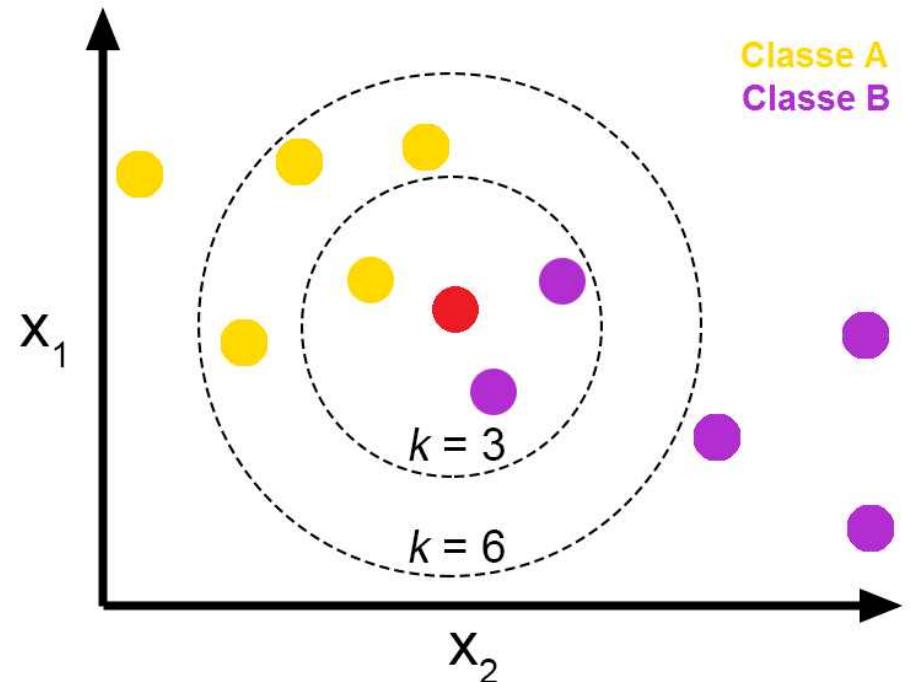
- Dataset : `sklearn.datasets.load_diabetes()`
- Feature : 나이, 성별, 체질량지수, 혈압, 6가지 혈청 수치 → scaling 되어 있음
- Target : 1년 뒤 측정한 당뇨병의 진행률
- Model : `linear_model.LinearRegression()`

Classification

K-Nearest Neighbors

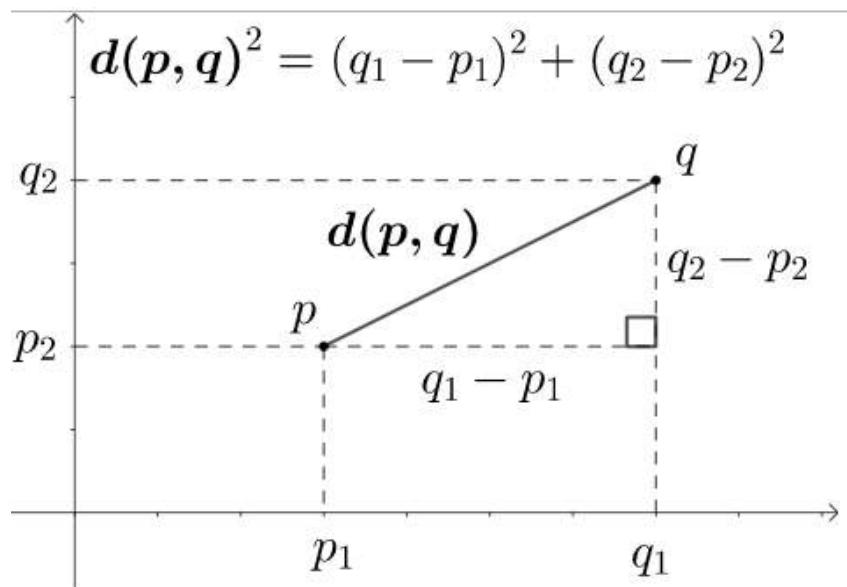
KNN (K-Nearest Neighbors, K 최근접 이웃)

- 다른 observation (관측치, X data) 과의 유사성에 따라 분류 (classify)
- 서로 가까이 있는 data 들을 “이웃” (neighbor)이라고 부른다.
- 가까이 있는 이웃의 label 들 중 가장 많은 것을 unknown case 의 prediction 으로 응답한다.
- 장점 : simple and easy to implement
- 단점 : dataset 이 커지면 slow.
outlier/missing value 의 영향이 크다.



KNN 알고리즘

1. K 값을 선택한다.
2. Unknown case 와 모든 data point 간의 거리를 계산한다.



$$\begin{aligned} d(\mathbf{p}, \mathbf{q}) &= d(\mathbf{q}, \mathbf{p}) = \sqrt{(q_1 - p_1)^2 + (q_2 - p_2)^2 + \cdots + (q_n - p_n)^2} \\ &= \sqrt{\sum_{i=1}^n (q_i - p_i)^2}. \end{aligned}$$

3. Training dataset에서 unknown data point와 가장 가까이 있는 K개의 관측치(observation)을 선택한다.
4. K개의 nearest neighbors의 label 중 가장 많은 것을 unknown data point의 **class**로 **분류**한다 (\rightarrow classification)

K개의 nearest neighbors의 label value의 평균을 predicted **value**로 **계산** 한다 (\rightarrow regression)

실습 : 020. KNN(K-Nearest Neighbors, 최근접 이웃)

1. sklearn에서 제공하는 iris(붓꽃) 분류 dataset 사용 :

꽃잎의 각 부분의 너비와 길이 등을 측정한 데이터이며 150개의 레코드로 구성

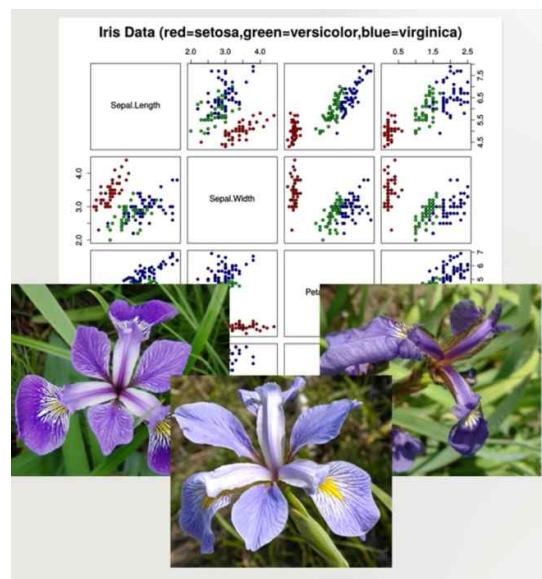
2. Data의 내용 :

Sepal Length : 꽃받침 길이

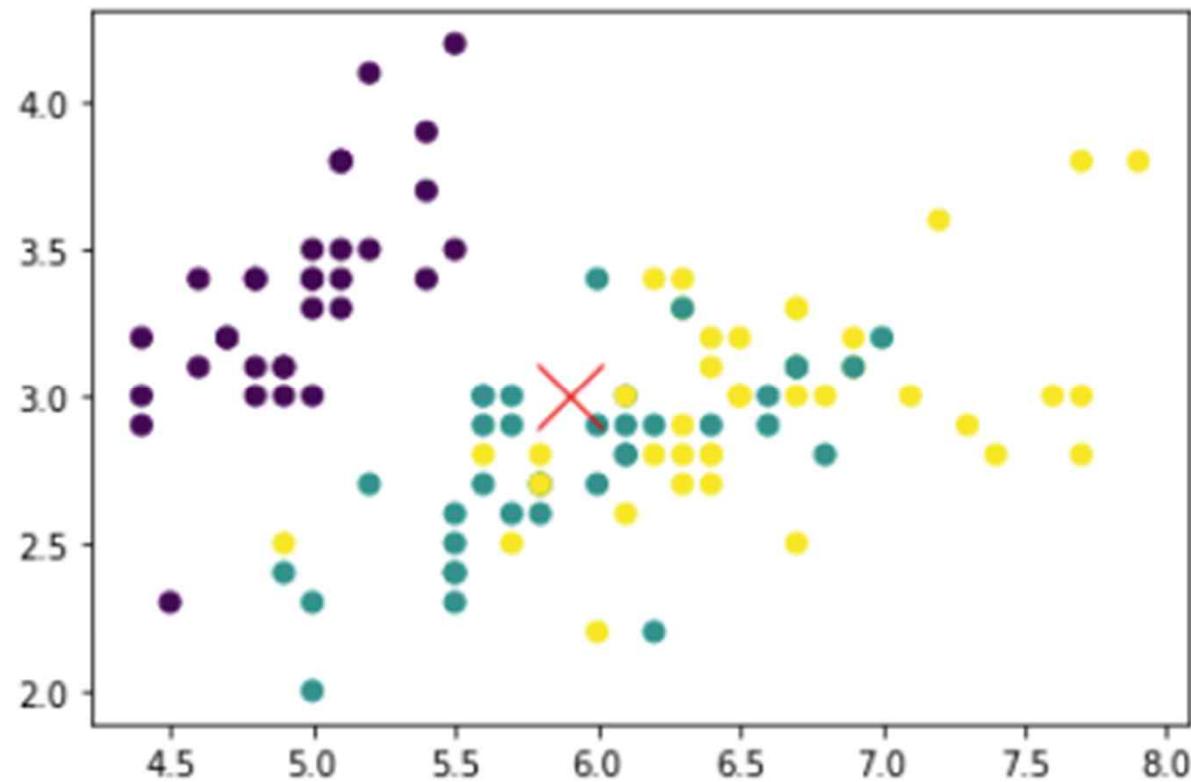
Sepal Width : 꽃받침 너비

Petal Length : 꽃잎 길이

Petal Width : 꽃잎 너비



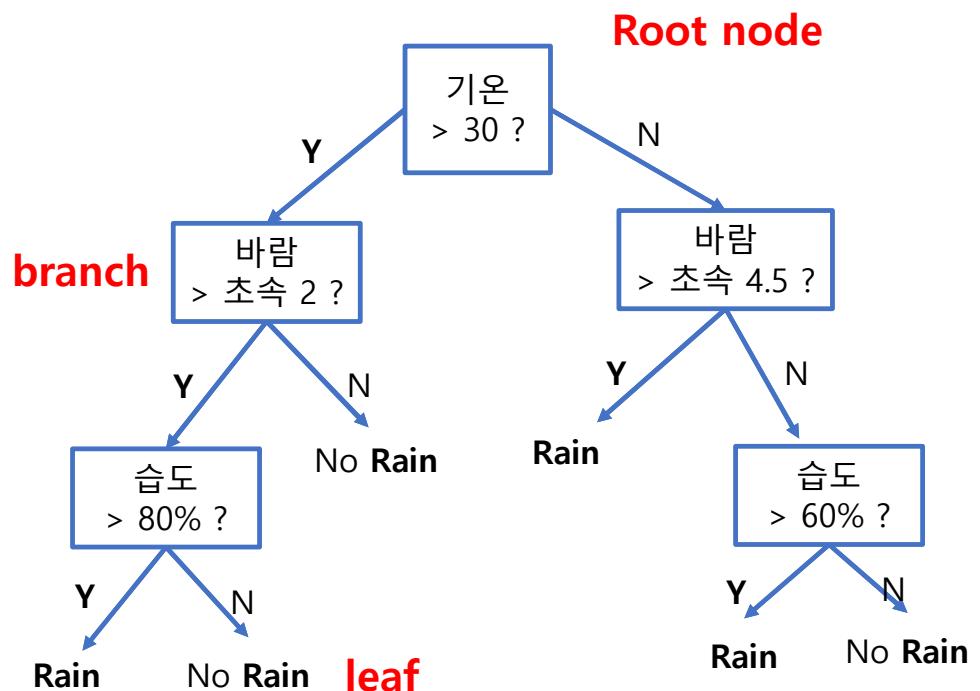
3. 시각화



Decision Tree

Decision Tree (결정나무)

- 모든 가능한 결정 경로(Decision Path)를 tree 형태로 구성
- 각 node 는 test 를 의미
- 각 branch 는 test 의 결과에 해당
- 각 leaf node 는 classification 에 해당
- 장점 : **white-box model**
data preprocessing 불필요
- 단점 : **overfitting** 되기 쉽다.
훈련 데이터의 작은 변화에도 매우 민감



Decision Tree 알고리즘의 종류

1. ID3 – 기본적 알고리즘. 정보이득(Information Gain) 을 이용한 트리 구성
2. CART (Classification and Regression Tree)
 - Gini 불순도에 기반한 트리 구성
3. C4.5, C5.0 – ID3 개선
4. 기타 – CHAID, MARS

엔트로피 (Entropy), 정보 이득(information gain)

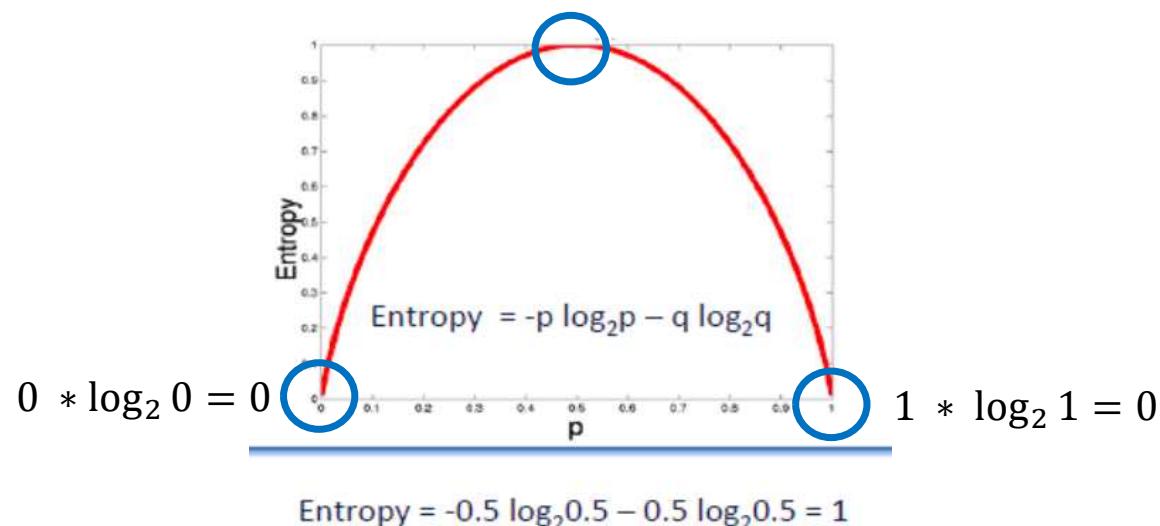
- 엔트로피(Entropy) - 주어진 데이터 집합의 혼잡도. 즉, 우리가 가지고 있지 않은 정보의 양을 의미.
- 주어진 데이터 집합에서 서로 다른 종류의 레코드들이 섞여 있으면 엔트로피가 높고, 같은 종류의 레코드들이 섞여 있으면 엔트로피가 낮음.
- 우리가 시스템에 대해 알게 될수록 시스템의 엔트로피는 감소. 예를 들어 데이터의 통계를 알게 되면 엔트로피는 감소. 이것을 정보 이득(information gain)이라고 한다.
- 엔트로피 값은 0에서 1사이의 값. 가장 혼합도가 높은 상태의 값이 1이고, 반대는 0

- Decision Tree 에서는 엔트로피가 높은 상태에서 낮은 상태가 되도록 데이터를 특정 조건을 찾아 나무 모양으로 구분해 나감.

$$\text{Entropy} = - \sum_{i=1}^m p_i \log_2(p_i), \quad p_i = \frac{\text{freq}(C_i, S)}{|S|}$$

(S: 주어진 데이터들의 집합, C: 레코드(클래스) 값들의 집합, freq(Ci,S): S에서 Ci에 속하는 레코드의 수, |S|: 주어진 데이터들의 집합의 데이터 개수)

$$p = 0.5, \text{ Entropy} = 1$$



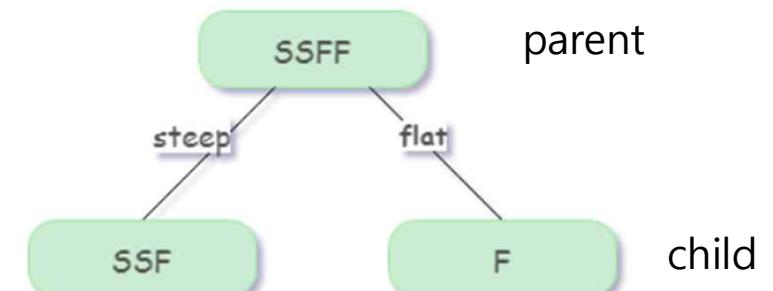
$$\begin{aligned}\log_2 0.5 &= \log_2 \frac{1}{2} = -\log_2 2 = -1 \\ \log_a 1 &= 0 \\ \log_a a &= 1\end{aligned}$$

$$\begin{aligned}bg \quad a^{MN} &= bg \quad a^M + bg \quad a^N \\ bg \quad a^{M/N} &= bg \quad a^M - bg \quad a^N \\ bg \quad a^{Mp} &= p \quad bg \quad a^M\end{aligned}$$

- Information Gain = Entropy(Parent) – (weight) * Entropy(Child)

ex)

Feature			Label
경사도	노면상태	속도제한	속도
steep	bumpy	Yes	slow
steep	smooth	Yes	slow
flat	bumpy	No	fast
steep	smooth	No	fast



- "경사도"의 information gain 계산:

$$\text{Entropy}(\text{Parent}) = -\{0.5 \log_2(0.5) + 0.5 \log_2(0.5)\} = 1$$

$$\text{Entropy}(\text{Child/steep}) = -\{0.667 \log_2(0.667) + 0.334 \log_2(0.334)\} = 0.918$$

$$\text{Entropy}(\text{Child/flat}) = -\{0 + 1 \log_2(1)\} = 0$$

$$\text{Entropy}(\text{가중평균}) = \frac{3}{4} \cdot 0.918 + \frac{1}{4} \cdot 0 = 0.688$$

- Information Gain = $1 - 0.688 = 0.312$

Decision Tree 알고리즘 (ID3)

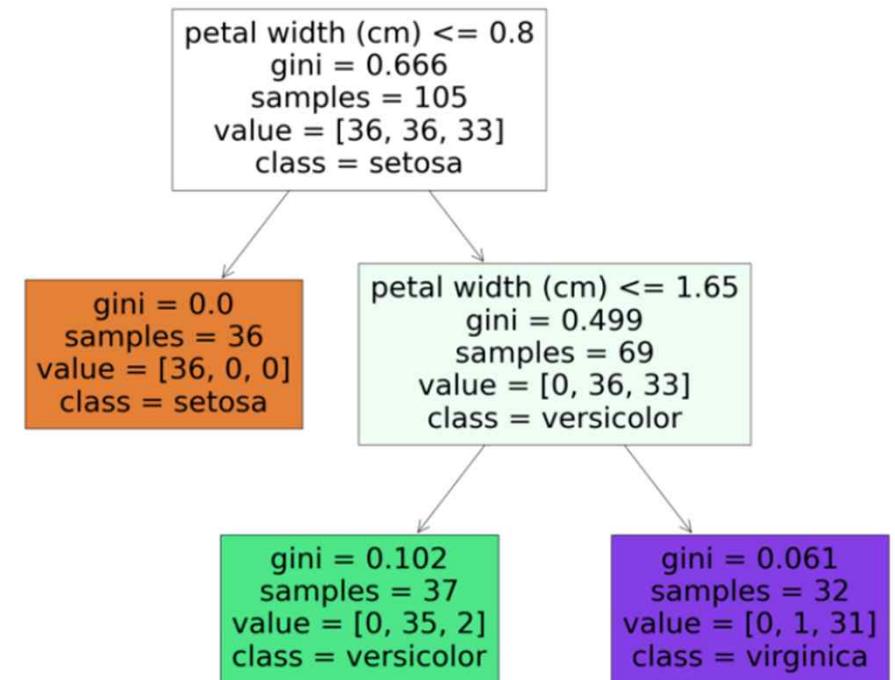
1. Initial open node 를 생성하고 모든 instance 를 open node 에 넣는다.
2. Open node 가 없어질 때까지 loop
 - 분할할 open node 선택
 - information gain 이 최대인 attribute(feature) 선택
 - 선택된 attribute 의 class (Y, N) 별로 instance sort
 - sort 된 item 으로 새로운 branch 생성
 - sort 된 item 이 모두 하나의 class 인 경우 leaf node close

실습 : 030. Decision Tree 작성 및 시각화

1. KNN에서 사용하였던 Iris data 사용

2. Tree의 max_depth = 2,
None으로 변경하여 test/비교

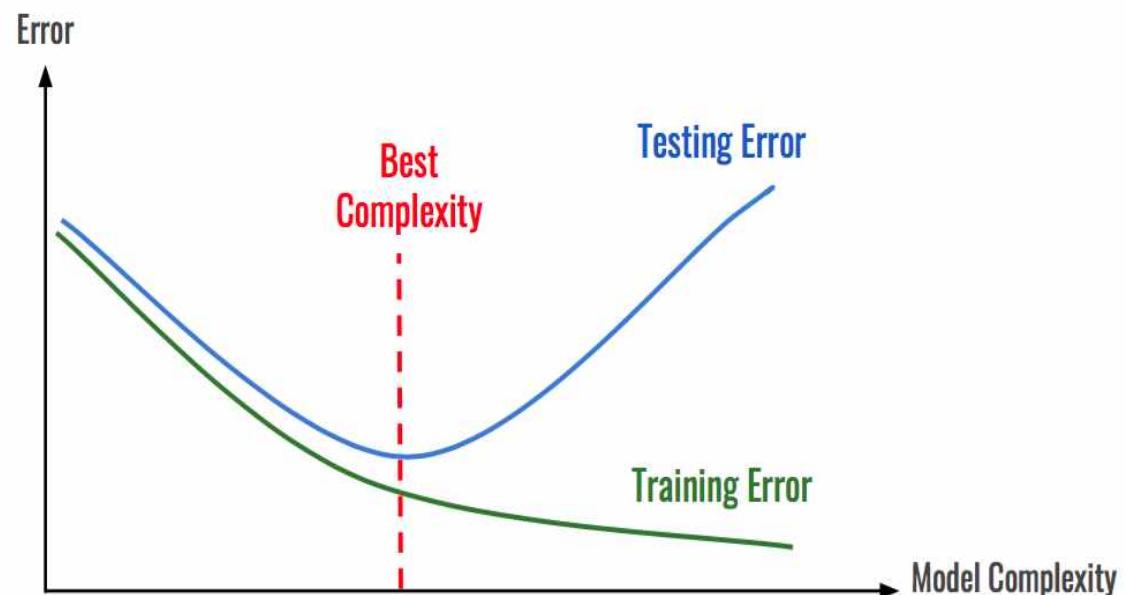
3. visualization



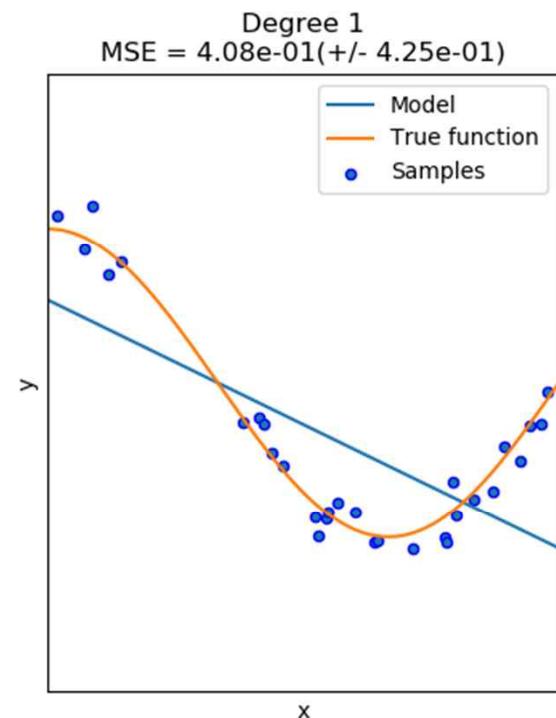
Training/Test/Evaluation

Overfitting(과적합) 과 Underfitting(과소적합)

- Training Data 에 비해 Test Data 의 ERROR 율이 높게 나타나는 경우 이를 과적합 (Overfitting) 이라고 한다.
- 반대로 모델이 너무 단순해서 데이터의 내재된 구조를 학습하지 못하는 경우 과소적합 (Underfitting) 이라고 한다.



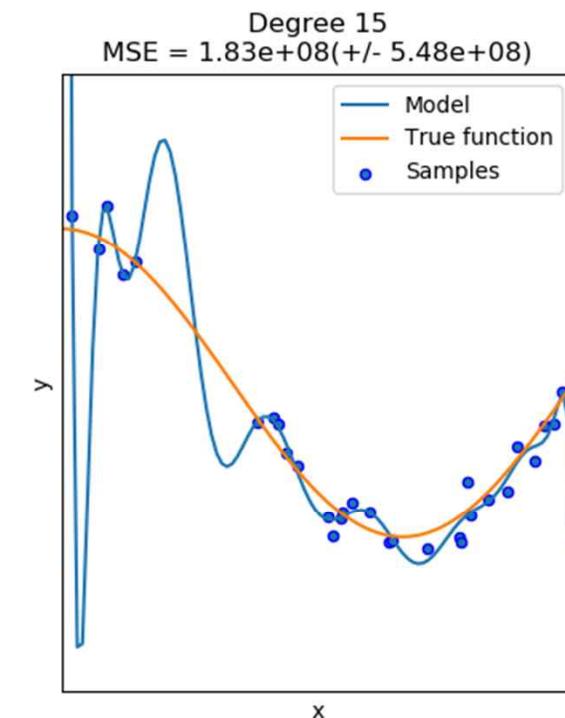
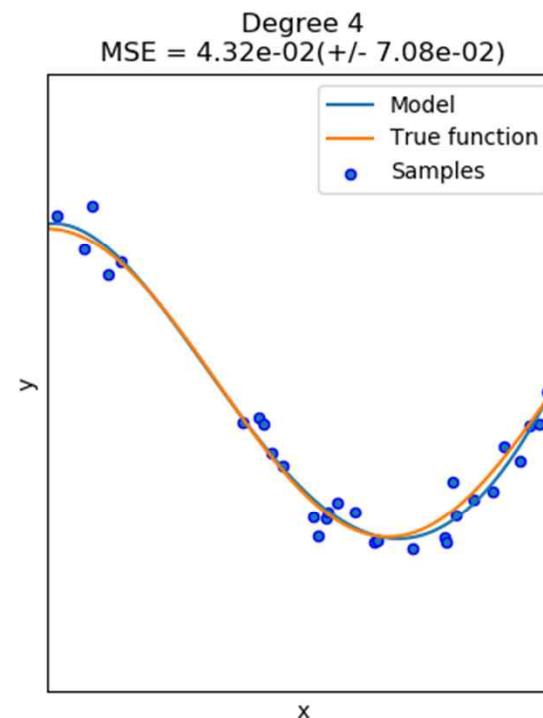
Underfitting (과소적합)



모델이 너무 단순
(data의 중요 부분을 놓침)
High Bias Model



Overfitting (과대적합)

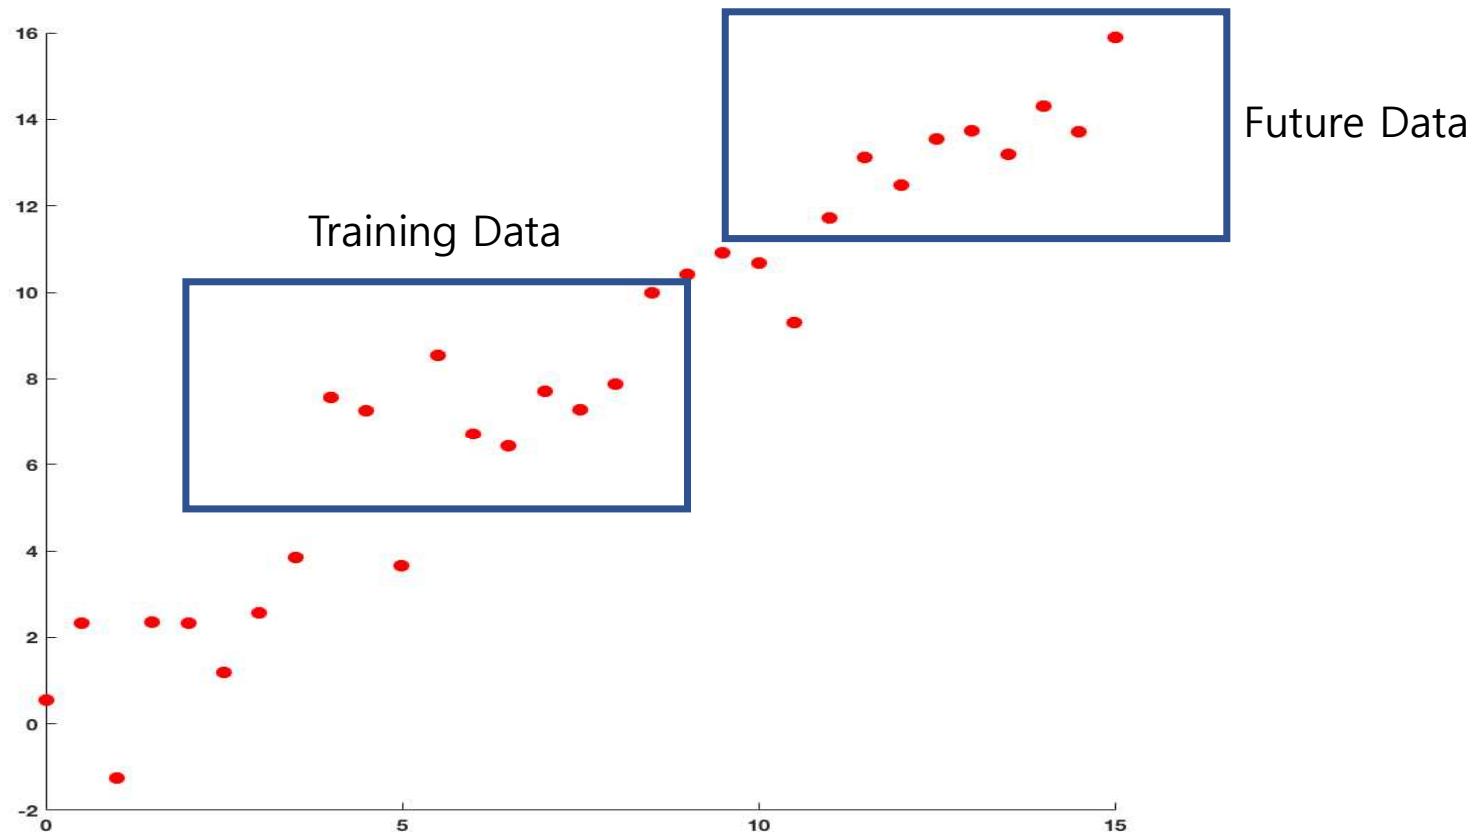


모델이 (데이터에 비해) 너무 복잡
(실제와 무관한 noise 까지 학습)
High Variance Model

Bias-Variance Trade-off

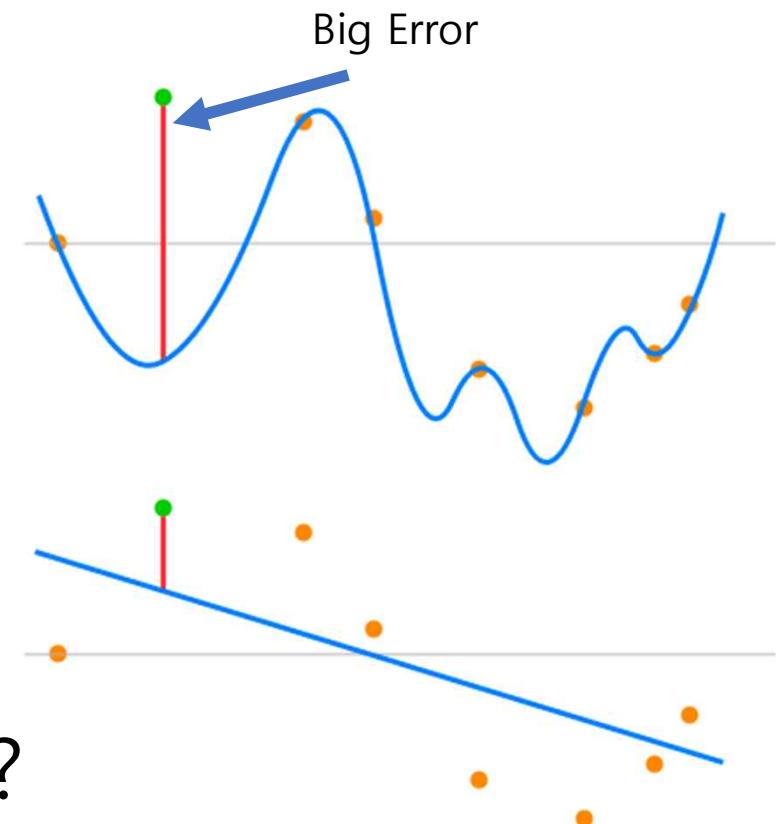
- ML의 세가지 Error Source
 1. 학습 Data 와 실제 data 분포의 차이에 의한 error → Variance
 2. Approximation Model 과 True Function 의 차이에 의한 error → Bias
 3. Noise 에 의한 error → 제거할 수 없음
 - Variance 를 줄이려면 Dataset 의 크기를 늘이고,
Bias 를 줄이려면 모델의 Complexity 를 올린다.
- Bias-Variance Dilemma (Bias-Variance Trade-off)

Variance – Training Data vs. Future Data



Bias – True & Inference Function 차이

- True function 은 sine 함수
- Model 1 – polynomial regression
- Model 2 – Linear regression



Which one is better model ?

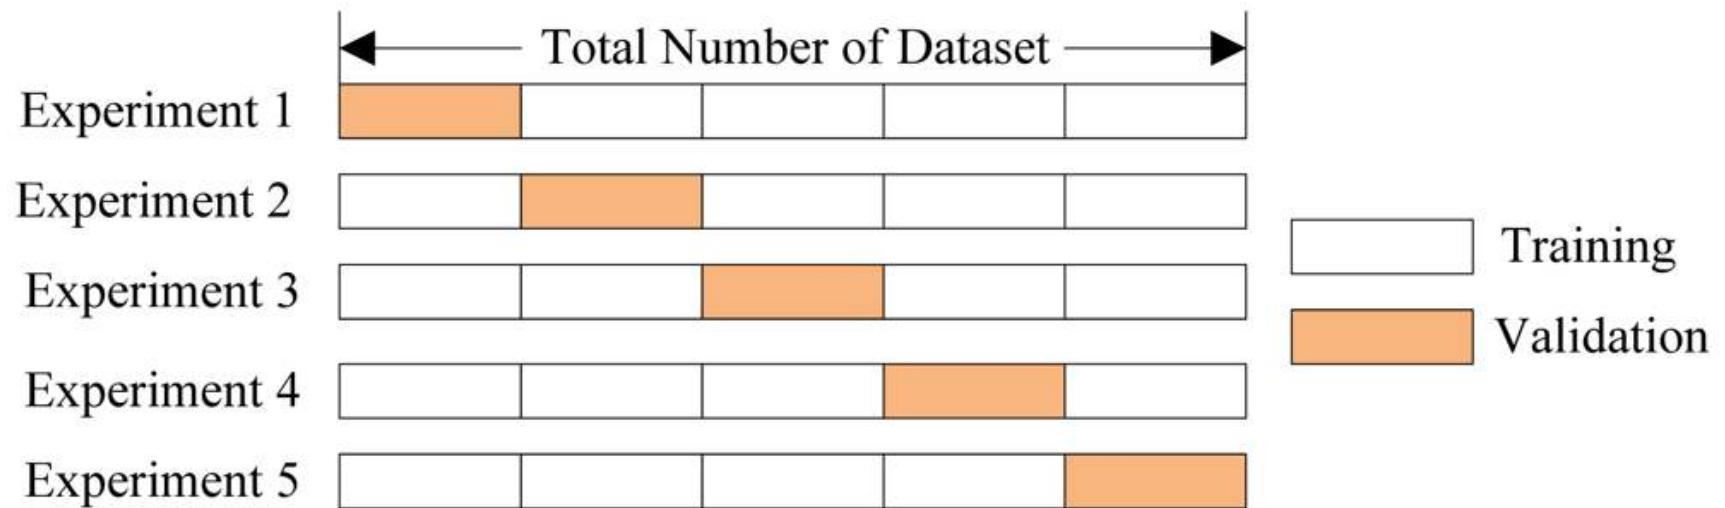
- Variance – infinite data sampling 으로 해결 가능
- Bias – true function 을 알면 해결 가능
- **BUT**, 현실에서는 infinite data sampling 도 할 수 없고 true function 도 알 수 없으므로 간접적 방법을 사용
 1. Cross Validation
 2. Precision / Recall / F1-Score

Training & Testing & Cross-Validation Set

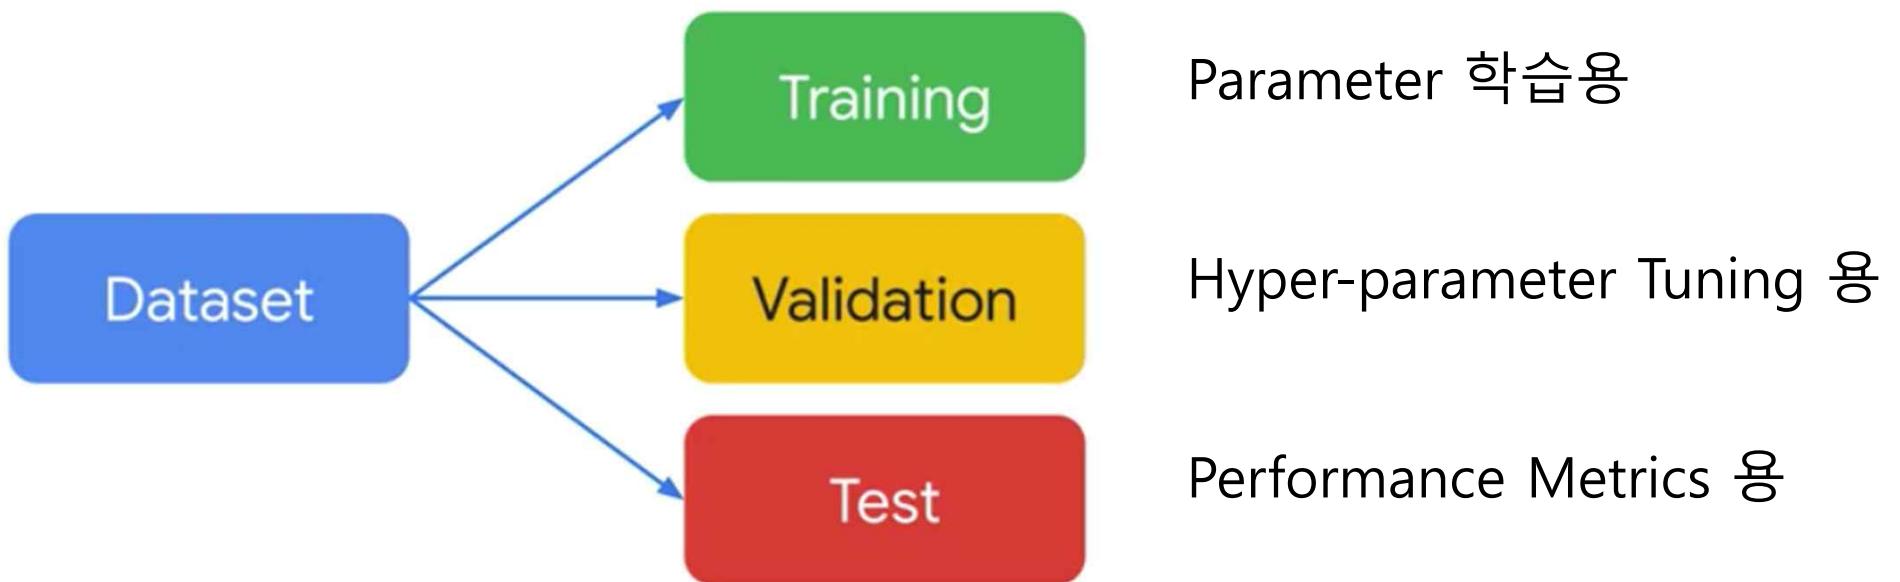
- Training Set
 - parameter 를 inference 하는 procedure 에 사용하는 data
 - 보지 못한 Data 의 분포가 Training set 과 상이할 경우 문제
 - Training set 내에서 cross-validation set 을 구성 (Data 가 불충분한 경우)
- Testing Set
 - 학습한 Machine Learning Model 을 Test 하기 위해 사용하는 data
 - 미래의 instance 인 것처럼 간주
- Training set 과 Testing set 은 섞이면 안되고 동일한 분포를 유지해야 함.

Cross Validation (교차검증)

- 훈련세트를 여러 개의 sub-set 으로 나누고 각 모델을 이 sub-set 의 조합으로 훈련시키고 나머지 부분으로 검증
- Data 의 수가 적은 경우 사용



Dataset Split – 3 splits



편향된 Data (Biased Data) 의 Model Performance 측정

Confusion Matrix (혼동 행렬)

		True condition	
		Condition positive	Condition negative
Predicted Condition	Total population	Condition positive	Condition negative
	Predicted condition positive	TP True positive	FP False positive
	Predicted condition negative	FN False negative	TN True negative

- Classification (분류) 성능의 정확성 측정

TP – 1 을 1 로 제대로 분류, FP – 0 을 1 로 잘못 분류

FN – 1 을 0 로 잘못 분류, TN – 0 을 0 으로 제대로 분류

- Classification rate (Accuracy) = $(TP + TN) / (TP+TN+FP+FN)$
→ 단순 정확성. 전체 데이터 중에서, 제대로 분류된 데이터의 비율

Confusion Matrix 를 이용한 분류 모델 성능 평가

- Precision = TP / (TP + FP)
 - 정밀성. Positive로 예측한 내용 중에, 실제 Positive의 비율
→ Model 이 sample 을 True 로 분류했을 때 얼마나 자주 맞추었는가 ?
 - positive 분류의 정확성 측정 (1 에 가까울 수록 좋음)

		True condition	
		Condition positive	Condition negative
Total population		Condition positive	Condition negative
Predicted Condition	Predicted condition positive	True positive	False positive
	Predicted condition negative	False negative	True negative

ex) 포르노 영상 검출기 – 포르노로 분류했을 때 실제 포르노인 비율
security check 영상 탐지기 – 통과 승인된 사람 중 실제 직원 비율

Confusion Matrix 를 이용한 분류 모델 성능 평가

- Recall (positive Rate) = $TP / (TP + FN)$
 - 재현율. 전체 Positive 데이터 중에서 Positive로 분류한 비율 (1에 가까울수록 좋음)
 - Positive case 를 놓치고 싶지 않은 경우의 성능 측정

		True condition	
		Condition positive	Condition negative
Total population		Condition positive	Condition negative
Predicted Condition	Predicted condition positive	True positive	False positive
	Predicted condition negative	False negative	True negative

Diagram description: A 4x2 confusion matrix table. The columns represent 'True condition' (Condition positive, Condition negative) and the rows represent 'Predicted Condition' (Predicted condition positive, Predicted condition negative). The 'Predicted condition positive' row has a red border around its entire area. The 'Predicted condition negative' row also has a red border around its entire area. A blue arrow points from the 'False positive' cell to the text 'Type I error'. A blue arrow points from the 'False negative' cell to the text 'Type II error'.

ex) 포르노 영상 검출기 – 전체 포르노 중 포르노로 분류된 비율
security check 영상 탐지기 – 전체 직원 중에서 통과로 분류된 비율

Precision/Recall Trade-off

- 숫자 중 5 (positive) 를 검출

5로 예측한 내용 중에, 실제 5의 비율

TP / (TP + FP)

Precision: $6/8 = 75\%$

$4/5 = 80\%$

$3/3 = 100\%$

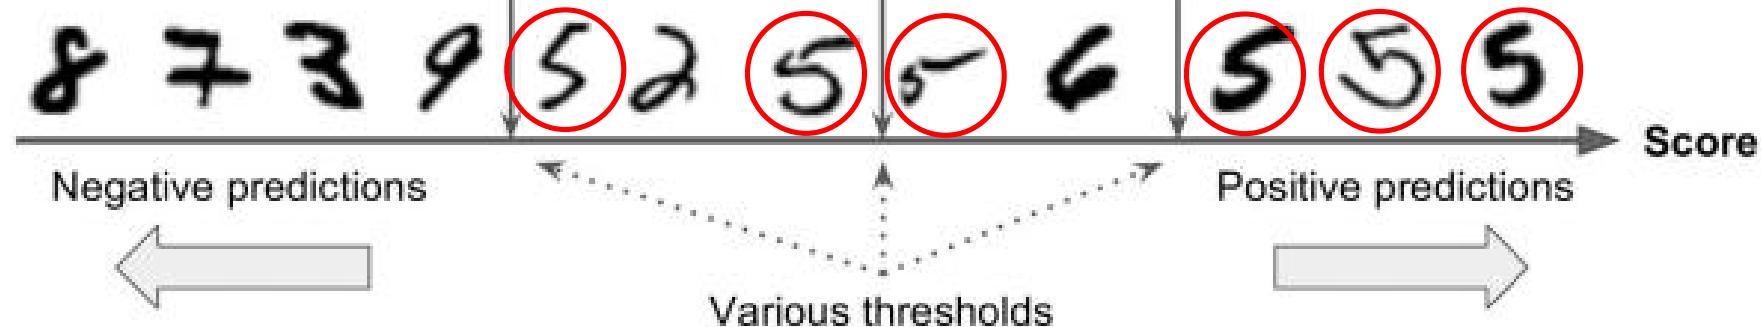
Recall: $6/6 = 100\%$

$4/6 = 67\%$

$3/6 = 50\%$

TP / (TP + FN)

전체 5 중에서 5로 분류한 비율



5 가 검출에서 누락되지 않기 원하는 경우

5가 정확히 검출되기 원하는 경우

Precision / Recall Trade-off

- Confidence 수준을 올리고 싶으면 Precision 을 높이고 Recall 을 낮추도록 Threshold 조정. 너무 많은 case 를 놓치고 싶지 않은 경우 Recall 을 높이고, Precision 을 낮춘다.
- 전체적 성능 측정에 활용 (조화평균)

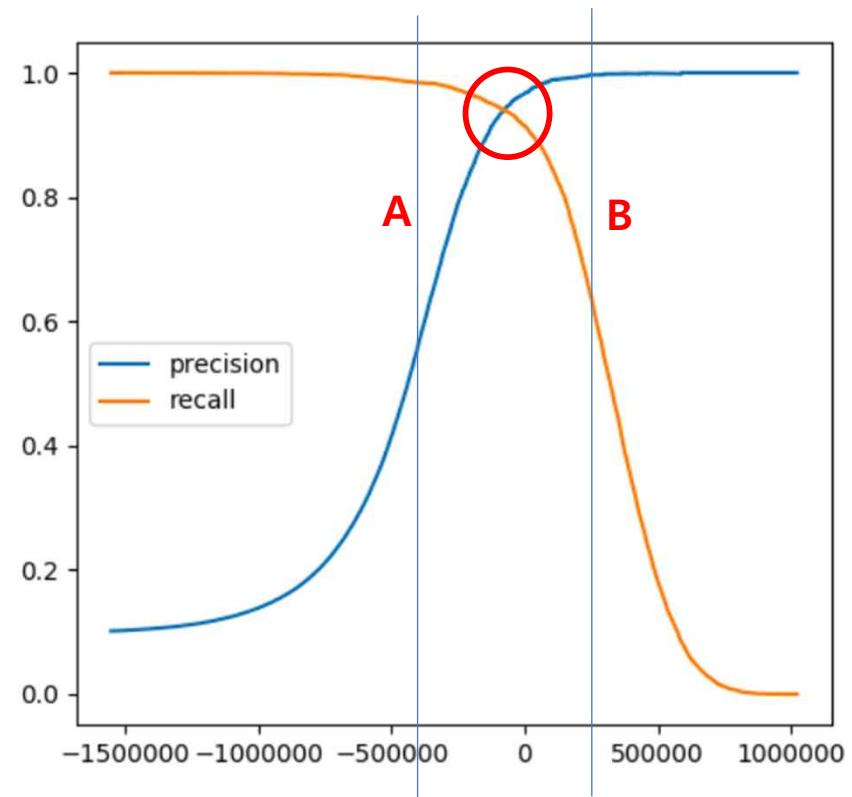
$$F1\text{-Score} = 2 * \frac{Precision * Recall}{Precision + Recall}$$

F1-Score = 0 ---> Poor (P=0 or R=0)

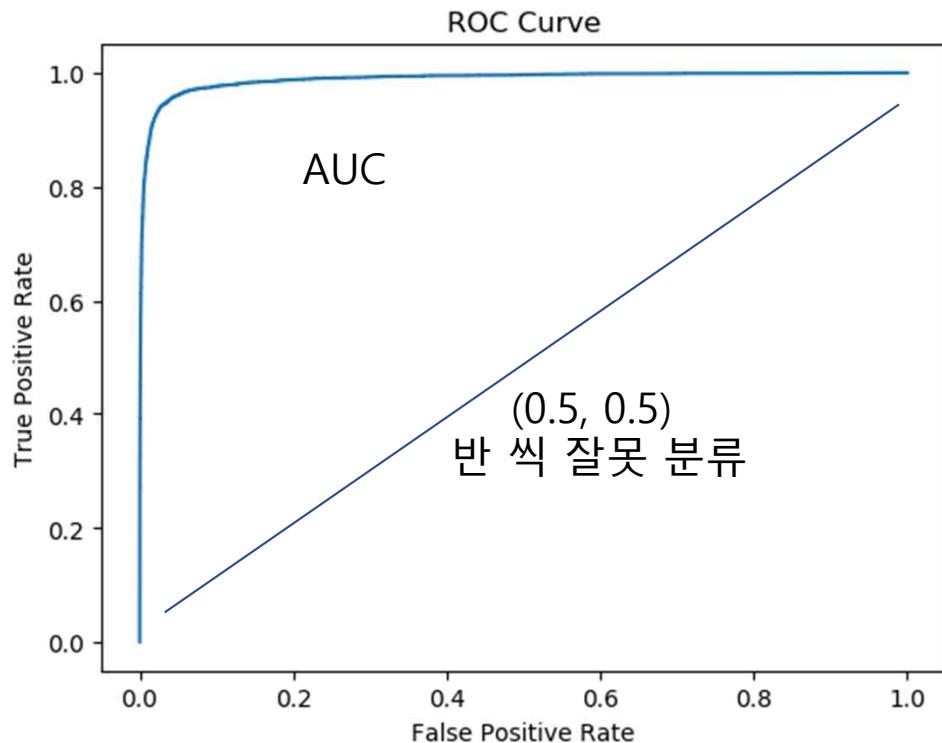
F1-Score = 1 ---> Perfect (P=1 and R=1)

A – High Recall / Low Precision

B – High Precision / Low Recall



ROC Curve (수신자 조작 특성 곡선)



- ROC_AUC (Area Under the Receiver Operating Characteristic Curve) 라고도 함
- roc_auc_score 를 이용하여 **분류기(classifier) 간의 성능 비교**를 할 수 있다.

* ROC (Receiver Operating Characteristic) curve 는 radar 상의 적기 탐지를 위해 개발되었던 분석 기법

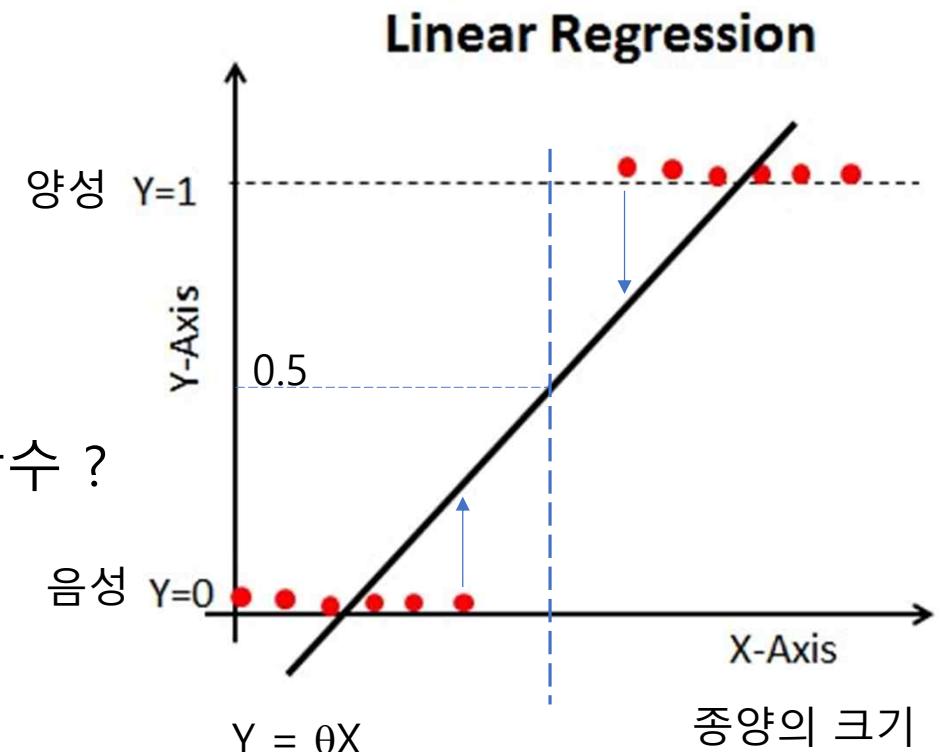
Logistic Regression

Logistic Regression (로지스틱 회귀)

- 선형회귀를 분류 문제에 적용 가능 ?

$$\hat{y} = \begin{cases} 0 & \text{if } \theta X < 0.5 \\ 1 & \text{if } \theta X \geq 0.5 \end{cases}$$

- 0 과 1 로 구성된 분류 문제에 적합한 함수 ?
- 0 과 1 에 속할 확률 값을 return
- 미분가능한 성질



Sigmoid 함수

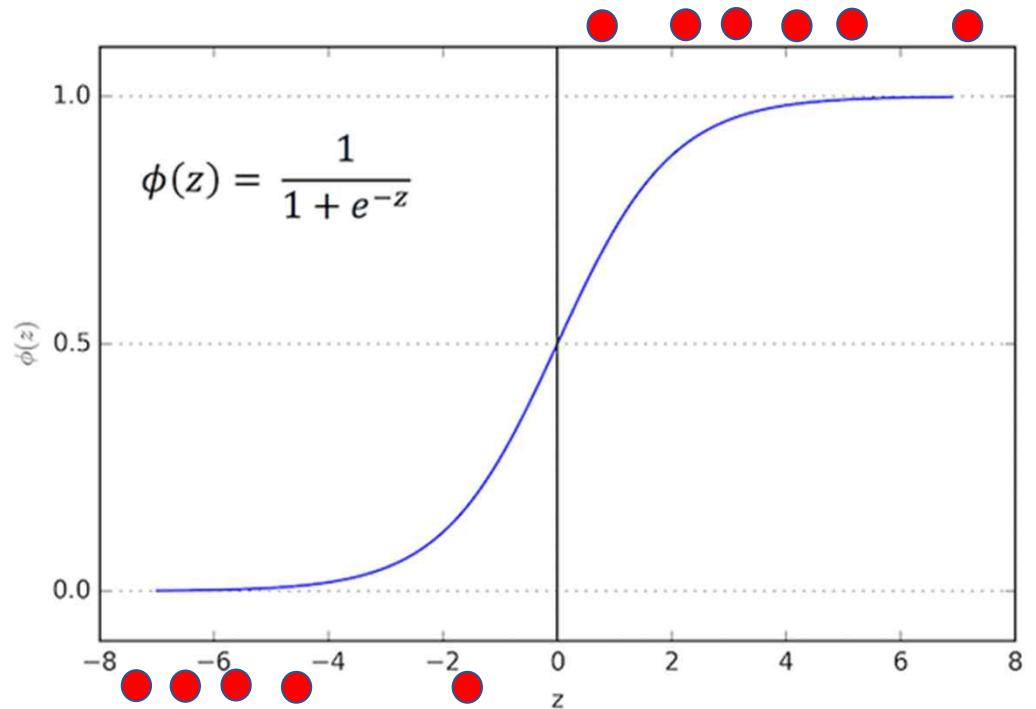
- S curve 형성
- Logistic 함수

logit

$$f(z) = \frac{1}{1+e^{-z}} \quad (z = \theta X)$$

$$\hat{y} = \begin{cases} 0 & \text{if } f(z) < 0.5 \\ 1 & \text{if } f(z) \geq 0.5 \end{cases}$$

- [0, 1] 로 bound 되어 있음
- 미분가능
- 0.5 부근에서 급격히 변화



Logistic Regression (로지스틱 회귀) classifier

1. 가장 단순한 분류기 → binary-class
2. 구현이 간단하고 모든 classification problem 의 기초
3. Logistic Regression 의 기본 concept 은 Deep Learning 에도 적용
4. 독립변수와 종속변수 간의 관계를 찾아내고 평가함
5. `sklearn.linear_model.LogisticRegression(solver='lbfgs')`
* solver – optimization algorithm

실습: 040. Logistic Regression 을 이용한 이진분류

1. 특정 사용자가 구매를 할지 여부를 예측 (구매: 1, 구매 않음: 0)
2. Dataset 구성
사용자 id, 성별, 연령, 추정급여, 구매여부
이중 연령, 추정급여 두가지 feature 를 이용하여 구매여부 예측
3. Train / Test dataset 은 8 : 2 로 분리
4. Feature Scaling 실시 (standard scaling)
5. Model evaluation by Confusion Matrix, f1-score

Ensemble Learning

Random Forest/Gradient Boosting

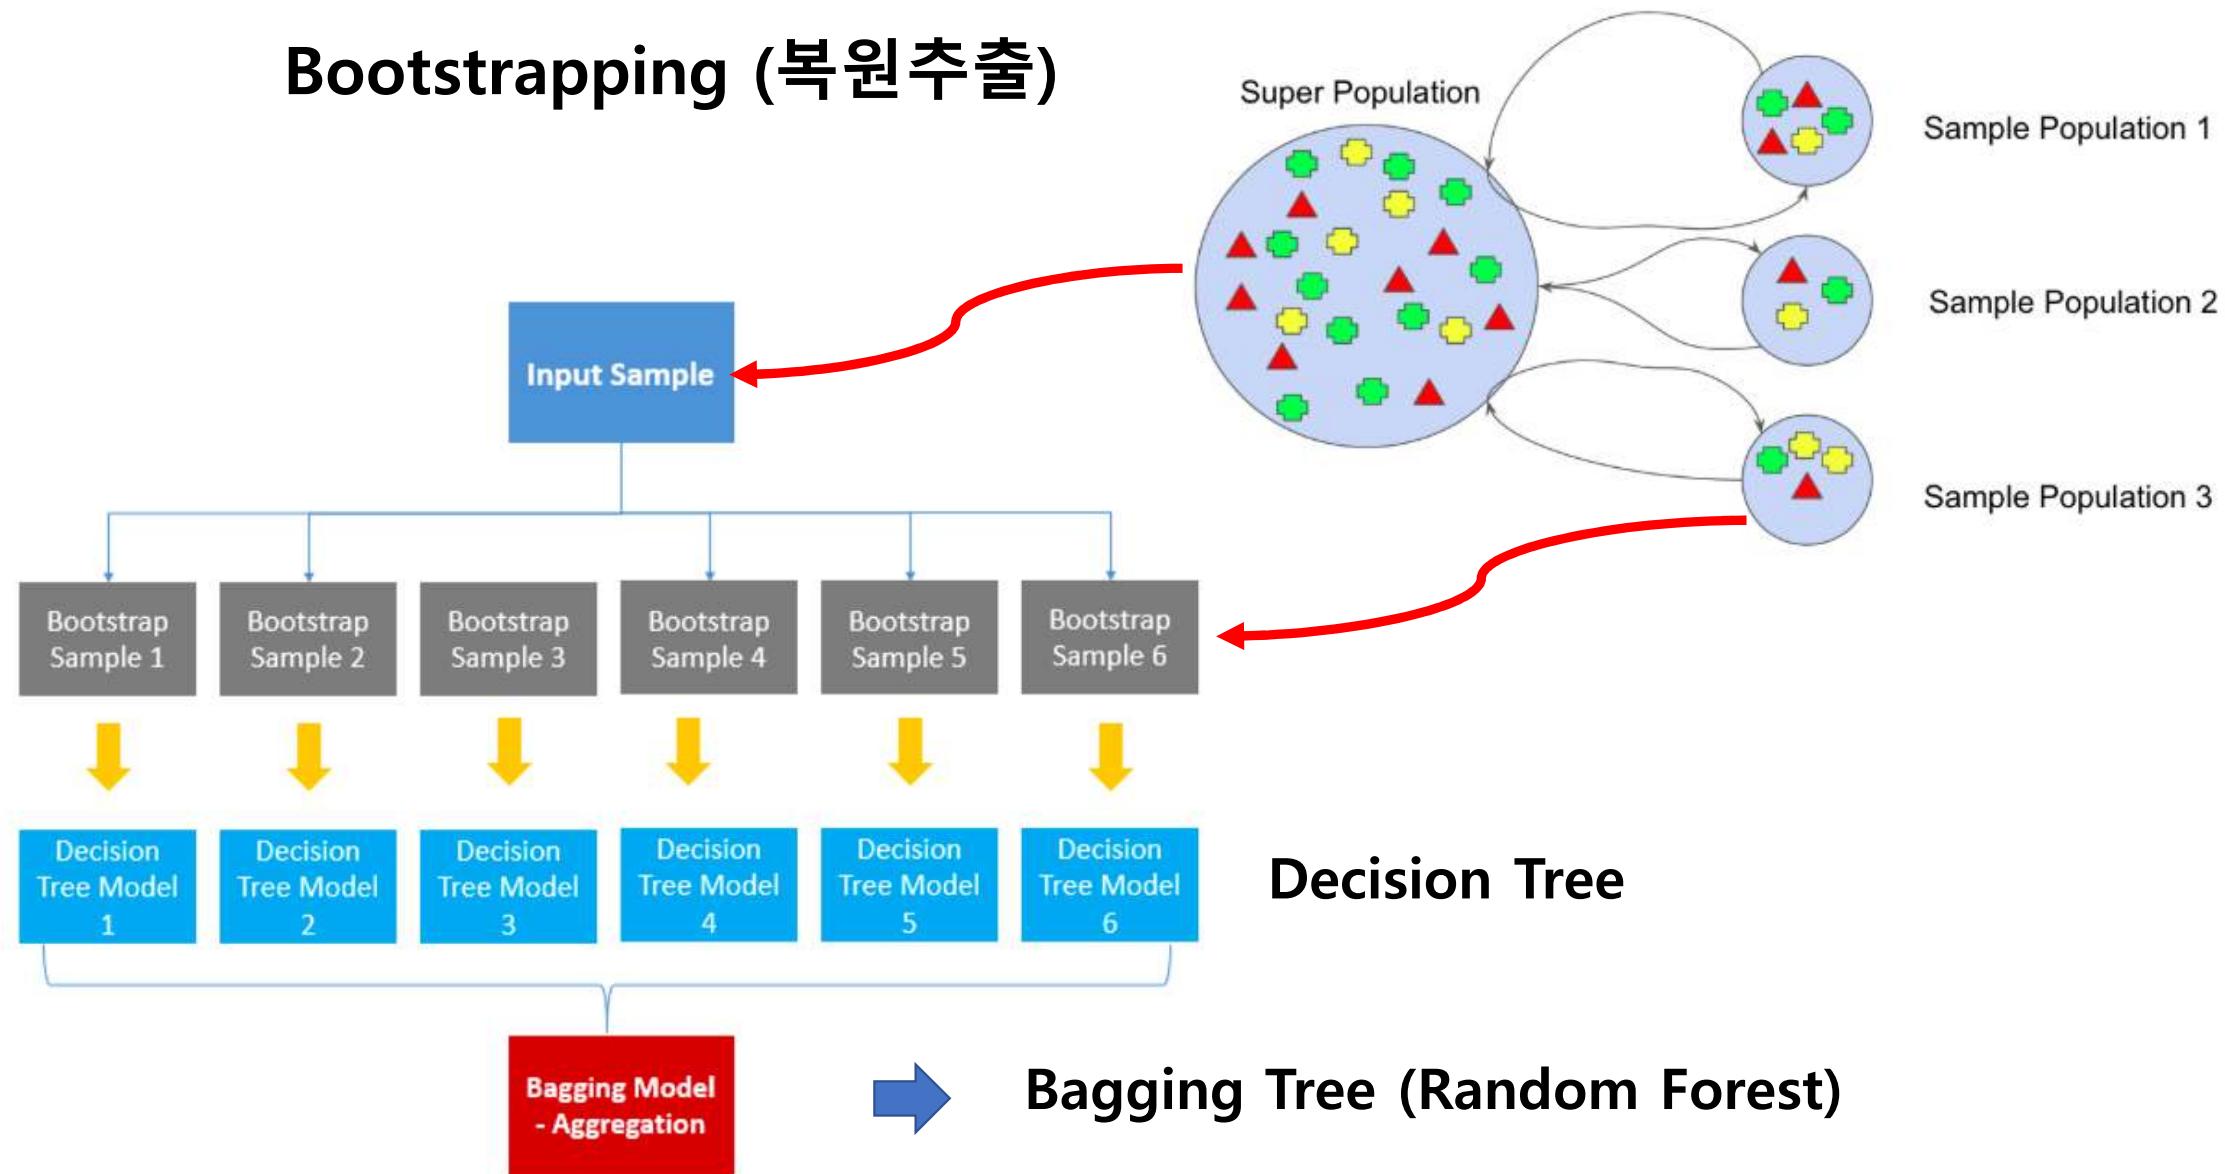
What is Ensemble Learning ?

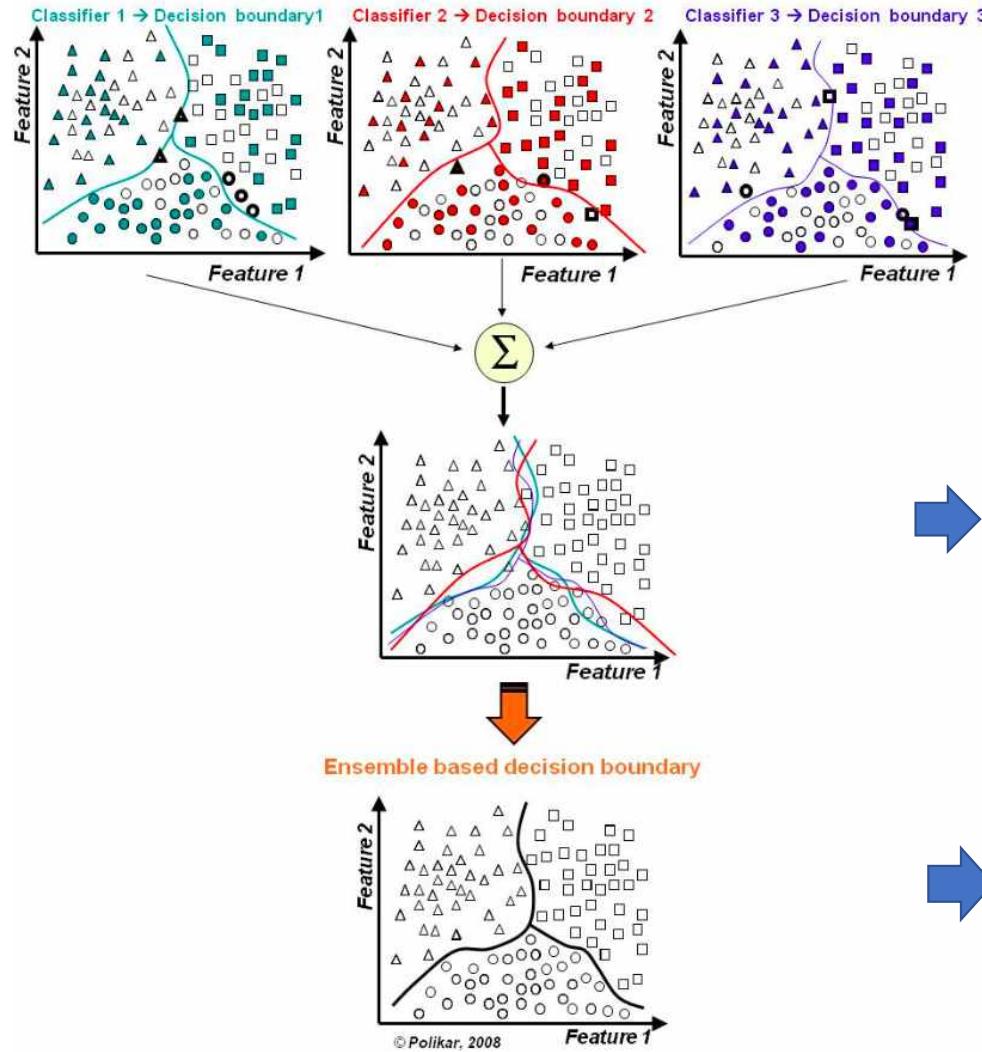
- 다수의 약한 학습기 (weak learner) 를 조합(Ensemble) 하여 더 높은 성능 추출
- Decrease Variance by **Bagging** (Bootstrap Aggregating)
- Decrease Bias by **Boosting**

What is Bagging (Bootstrap Aggregating) ?

- Training sample 의 sub-set 을 무작위로 추출하여 classifier 훈련
- Bootstrap – 중복을 허용하는 random sampling 방법 (통계학)
→ b 개의 independent training set 을 평균하면,
 $\text{variance} \rightarrow \frac{\sigma^2}{b}$ 로 감소, mean → 동일
- Aggregating – voting for classification
- **Random Forest** 가 대표적인 method

Bootstrapping (복원추출)





Decision Trees

Majority Voting

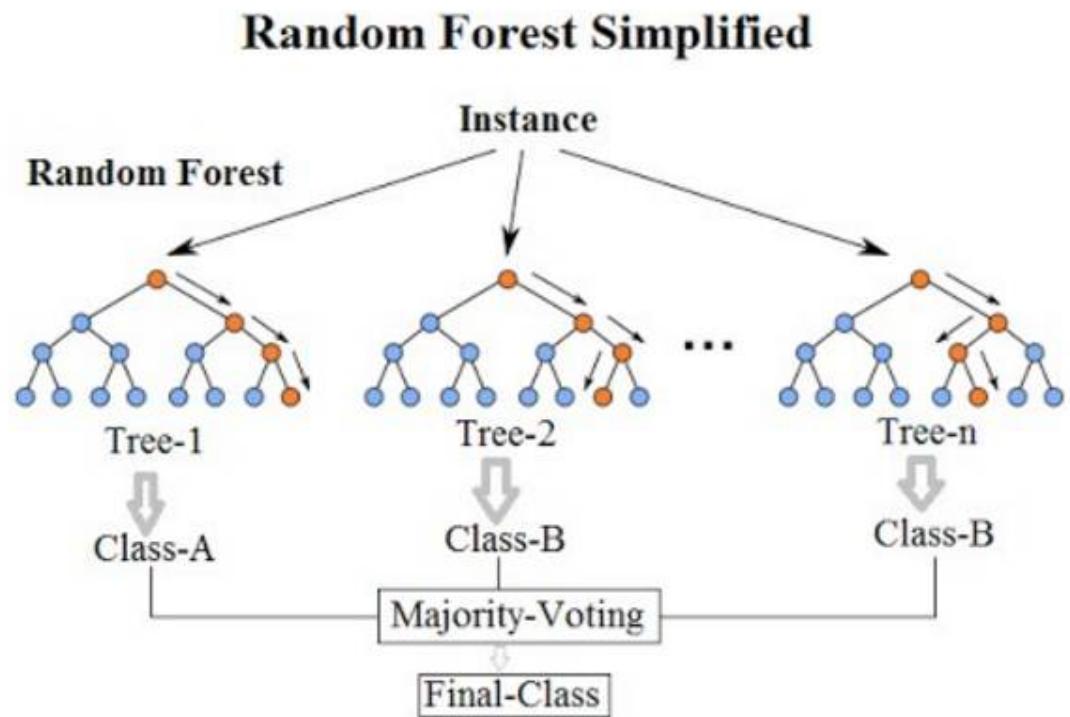
Random Forest

Bagging Tree 알고리즘

1. training data에서 random sampling하여 X_b , y_b 를 고름
(ex. 1,000 개의 data 중 100 개 sampling)
2. X_b , y_b 를 이용하여 **ID3 알고리즘**으로 **decision tree** 구성
3. B 개의 tree가 만들어질 때까지 1, 2 반복
4. B 개의 모든 tree를 이용하여 classification한 후 majority vote로 결정
5. Bias를 유지하며 Variance를 줄인다.
→ bagging은 random sampling에 의해 model을 fit 하므로 **bias (model complexity)**가 커지지 않으면서 **variance**를 줄일 수 있는 특징이 있다.

Random Forest

- Bagging Tree
→ Random Forest로 발전
- **Randomly Choose Attributes**
- bootstrapping에 의한 복원추출
+
attribute의 random 선택에 따른
independent trees 구성



Random Forest Algorithm

1. Decision Tree 에 포함될 attribute 들을 random 하게 선정

→ 모든 attribute 를 가지고 Tree 를 만들 경우 매우 강한 attribute 가
모든 tree 에 항상 포함되는 것을 막기 위한 방법

(ex. 30 개 attribute 중 10 개만 random selection)

→ 좀 더 Random 하고 독립적인 classifier (Tree) 들을 생성시킬 수
있으므로 Random Forest 로 명명

2. Tree-based model 이므로 **white box** 특징을 유지 (feature_importance_)

3. **High prediction accuracy**

4. **병렬적으로** 생성 가능하므로 속도가 빠르다

5. 각 tree 는 **매우 deep**하게 생성된다.

→ 인위적인 prune 을 하지 않으나 Ensemble 을 하면
low bias, low variance 가 된다.

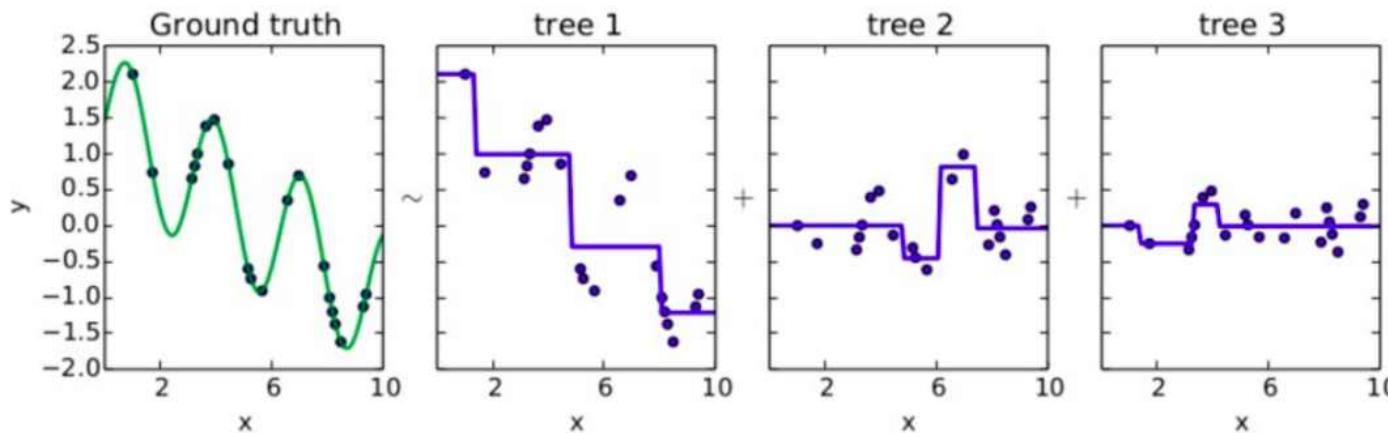
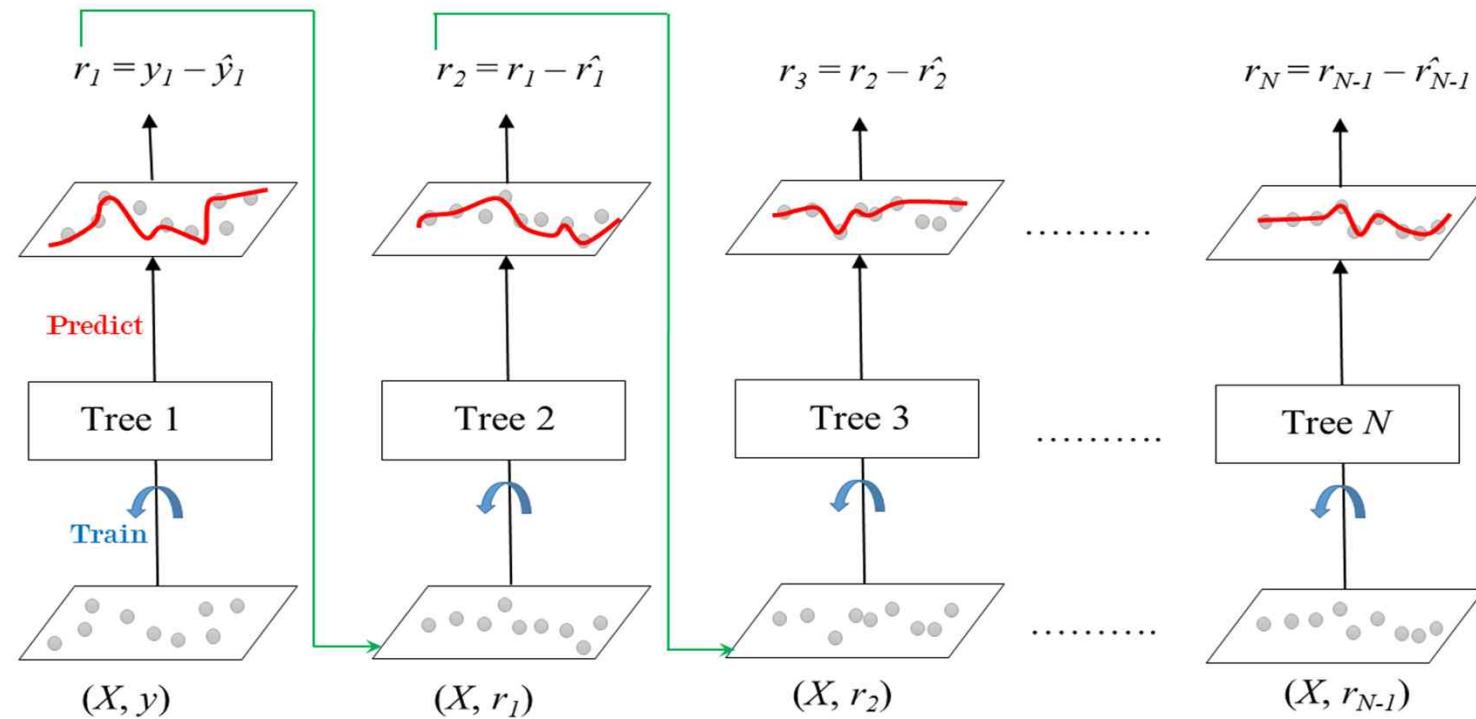
What is Boosting ?

- Misclassified data 에 더 높은 weight 를 부여하여 다음 번 model 의 sampling 에 포함될 확률을 높이는 것
- 다수의 weak learner (small decision tree) 를 훈련 시켜 이전 learner가 발생시킨 오차를 다음 learner 가 학습하는 방법
- **AdaBoost, Gradient Boost (XGBoost)** 가 대표적인 method

Gradient Boost 알고리즘

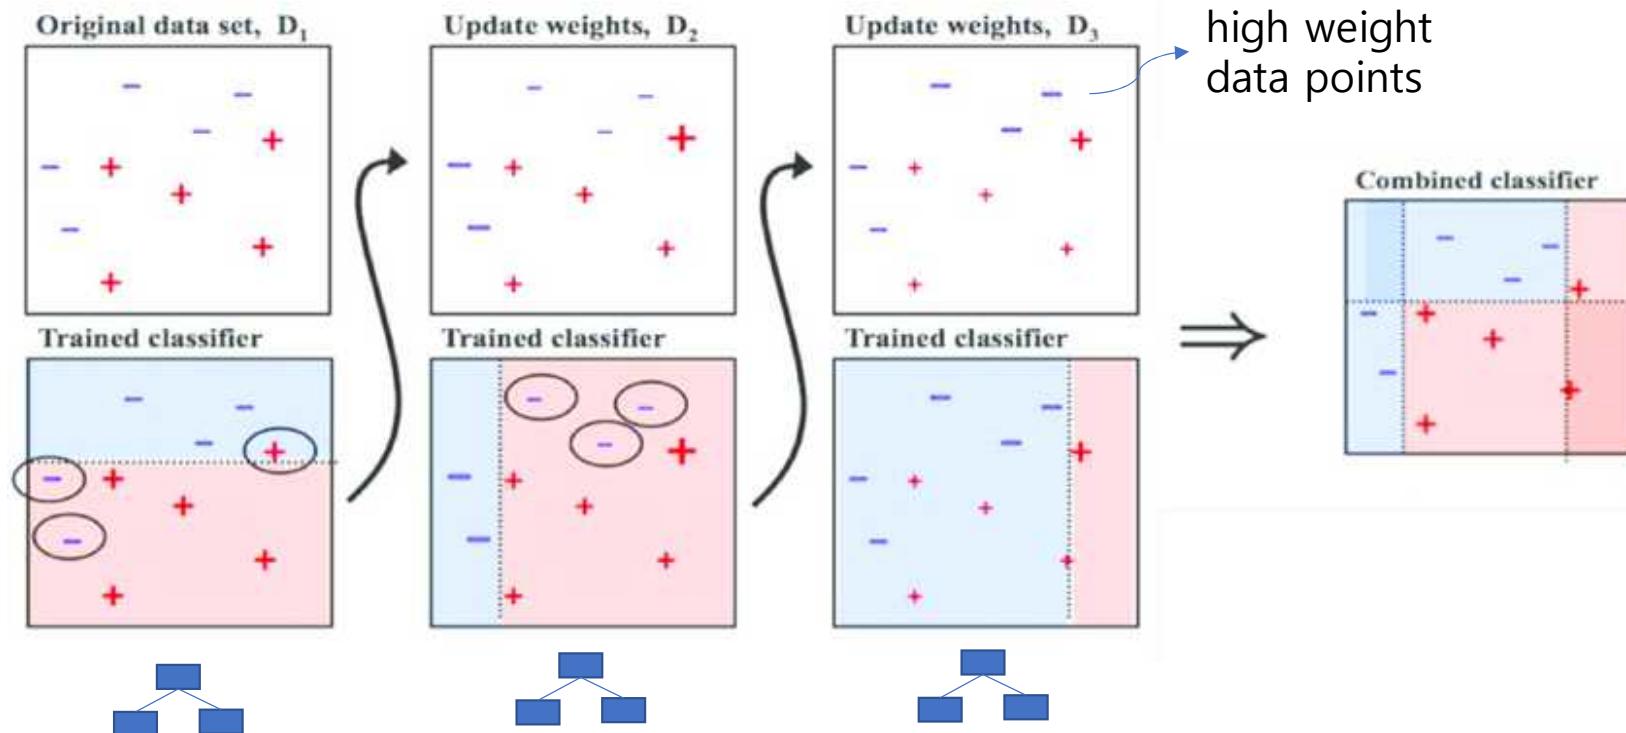
- **Weak Learner** - random choice 보다 약간 더 나은 성능의 모델
→ Decision Tree 사용
- 기존의 weak learner 가 생성한 residual error 를 감소시키는 추가 tree 를 더 이상의 감소 효과가 없을 때까지 생성
- Gradient Descent (경사하강법)에 의해 loss function (ex. MSE) 을 optimize

Gradient Boost



- 이전 tree에서 발생한 잔차 (residual error)를 next tree에서 보정

(참고) AdaBoost (Adaptive Boosting)



Stump 로 구성 – weak learners (기존 weak learner의 단점 보완)

이전 stump에서 잘 못 분류한 example 이 다음 sampling에 포함되도록 가중치를 높이는 기법

Gradient Boost for Regression

모든 target 값의 평균 Weight

1st Tree 71.2

(88+76+56+73+77+57)/6=71.2

input

	Height (m)	Favorite Color	Gender	Weight (kg)	1st Tree Residual	2nd Tree Residual
1	1.6	Blue	Male	88	16.8	15.1
2	1.6	Green	Female	76	4.8	4.3
3	1.5	Blue	Female	56	-15.2	-13.7
4	1.8	Red	Male	73	1.8	1.4
5	1.5	Green	Male	77	5.8	5.4
6	1.4	Blue	Female	57	-14.2	-12.7

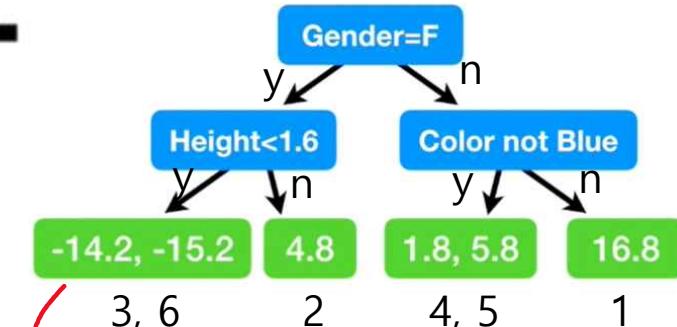
target

Residual 감소

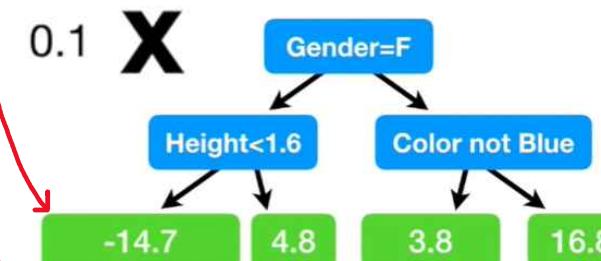
* Gradient Boost는 single leaf 부터 시작

* 실제로는 leaf가 8 ~ 32인 트리 사용

2nd Tree



마지막 leaf 노드에 두개의 residual 값이 있는 경우, 두 값의 평균으로 치환



$$71.2 + 0.1 * 16.8 = 72.9$$

$$88 - 72.9 = 15.1$$

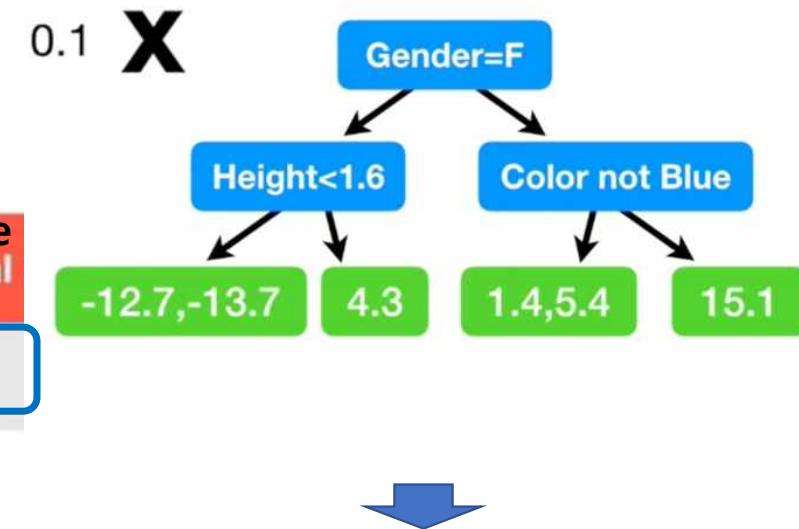
- 첫 single leaf 모델이 예측한 71.2kg보다는 실제 값(88kg)에 더 가까워짐.
- Gradient Boost 모델은 이런 식으로 실제 값에 조금씩 가까워지는 방향으로 학습.

3rd tree

$$71.2 + 0.1 * 16.8 + 0.1 * 15.1 = 74.39$$

$$88 - 74.39 = 13.6$$

	Height (m)	Favorite Color	Gender	Weight (kg)	1st Tree Residual	2nd Tree Residual	3rd Tree Residual
1	1.6	Blue	Male	88	16.8	15.1	13.6
2	1.6	Green	Female	76	4.8	4.3	3.9
3	1.5	Blue	Female	56	-15.2	-13.7	-12.4
4	1.8	Red	Male	73	1.8	1.4	1.1
5	1.5	Green	Male	77	5.8	5.4	5.1
6	1.4	Blue	Female	57	-14.2	-12.7	-11.4



Residual $\cong 0$ 이 될 때까지 반복

Feature Engineering

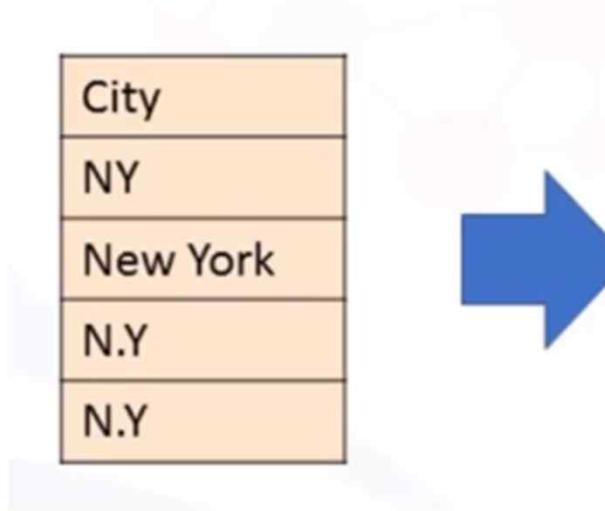
Good Feature 의 조건

- Target 과의 높은 관련성
- prediction 시점에 알 수 있음 (ex. sales data 는 익월에 집계)
- numeric
- 충분한 example 수
- 인간 전문가의 domain 지식 활용 가능

머신러닝을 위한 Feature Engineering

- ✓ Missing Values 처리
- ✓ Data Formatting
- ✓ 편향(skewed data) 처리
- ✓ Data Normalization
- ✓ Binning
- ✓ categorical 변수의 수치화

Data Formatting

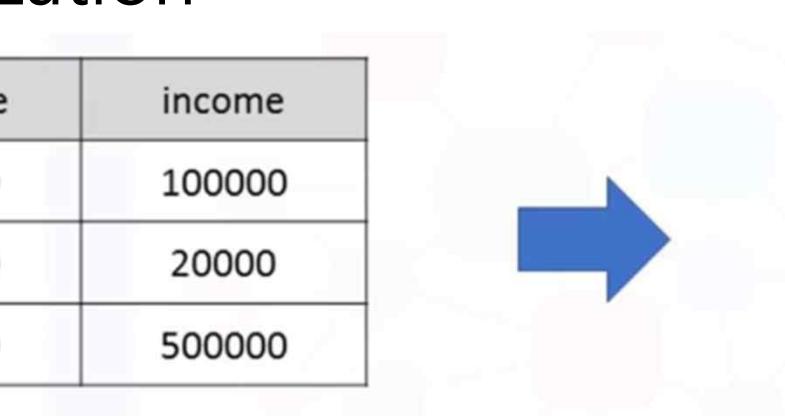


The diagram illustrates a transformation process. On the left, there is a vertical stack of five orange rectangular boxes, each containing a different representation of the word "New York". From top to bottom, the boxes contain: "City", "NY", "New York", "N.Y", and "N.Y". A large blue arrow points from this initial state to the right. On the right, there is another vertical stack of five orange rectangular boxes, all containing the text "New York".

City
NY
New York
N.Y
N.Y

City
New York
New York
New York
New York

Data Normalization



The diagram illustrates a transformation process. On the left, there is a table with two columns: "age" and "income". The "age" column contains values 20, 30, and 40. The "income" column contains values 100000, 20000, and 500000. A large blue arrow points from this initial state to the right. On the right, there is another table with the same two columns. The "age" column now contains values 0.2, 0.3, and 0.4. The "income" column now contains values 0.2, 0.04, and 1.

age	income
20	100000
30	20000
40	500000

age	income
0.2	0.2
0.3	0.04
0.4	1

category 변수의 수치화

- categorical feature : not numerical → 숫자로 변환 (ordinal, nominal)
- ordinal category (순서/크기가 있는 feature)
 - 숫자로 크기(순서) 표시
ex) L > M > S → 3, 2, 1
- nominal category (순서/크기가 없는 feature)
 - one-hot encoding
ex) color 의 숫자 표시

Binning

price
13495
16500
18920
41315
5151
6295
...



price	price-binned
13495	Low
16500	Low
18920	Medium
41315	High
5151	Low
6295	Low
...	...

Categorical 변수의 수치화

fuel
gas
diesel
gas
gas



gas	diesel
1	0
0	1
1	0
1	0

실습: 075. Titanic 호의 생존 예측

- Titanic 호 생존여부 data 이용
- Survival 여부 예측 model 작성
- Feature Engineering
- Random Forest / Gradient Boost model을 이용한 분류

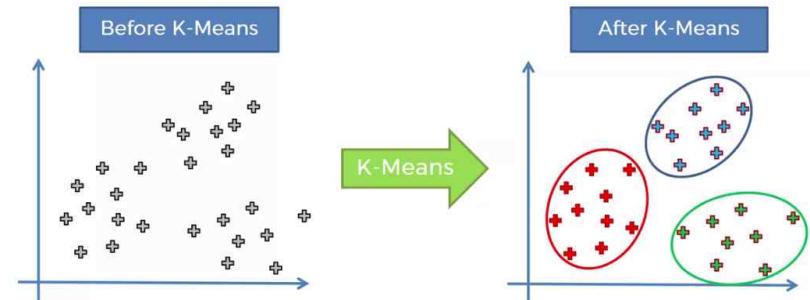
Clustering

Clustering 이란 ?

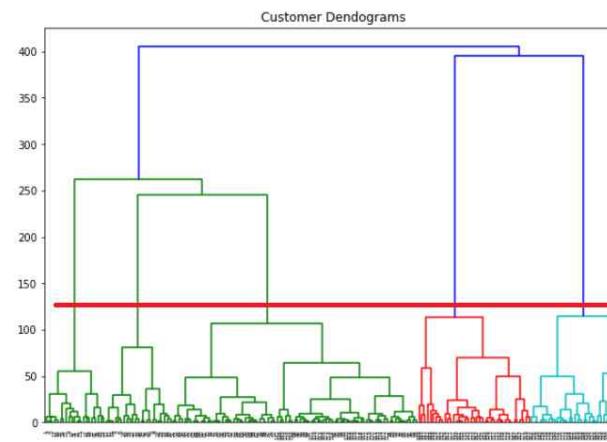
- 비슷한 object 들끼리 모으는 것
- label data 가 없는 것이 classification 과 차이
 → unsupervised machine learning
- 적용 사례
 - 고객의 구매 형태별 분류
 - 고객의 취향에 맞는 책, 동영상 등의 추천
 - 신용카드 사용의 fraud detection
 - 뉴스 자동 분류 및 추천
 - 유전자 분석 등

Clustering 알고리즘의 종류

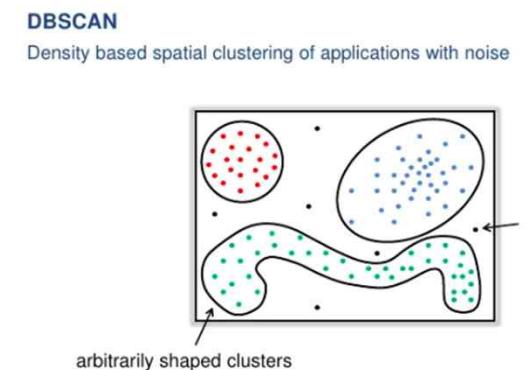
- K-Means Clustering



- Hierarchical Clustering (dendrogram)



- Density-based Clustering (DBSCAN)



K-Means Clustering 알고리즘 – Distance 계산

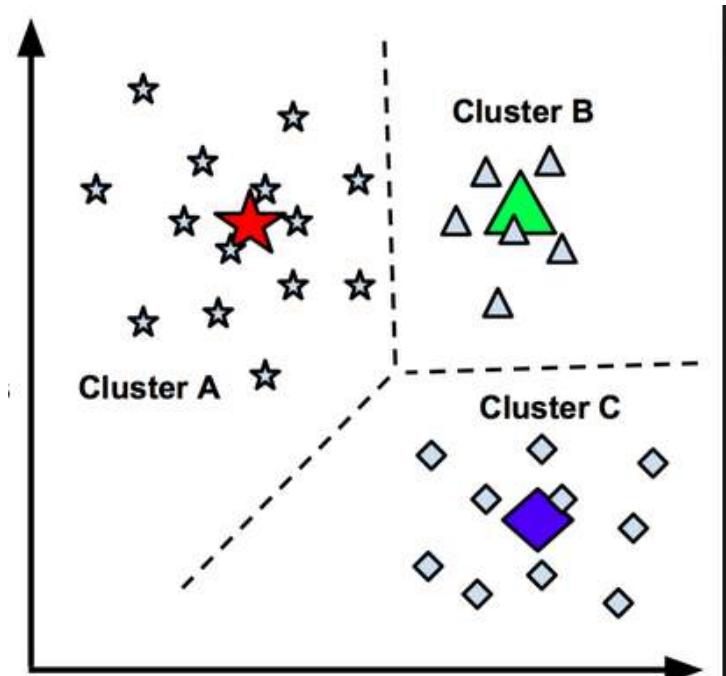
Distance = Euclidean Distance

$$= \sqrt{\sum_{i=0}^n (x_{1i} - x_{2i})^2}$$

Ex)

고객	나이	수입	교육
1	54	190	3
2	50	200	8

$\rightarrow x_1$
 $\rightarrow x_2$

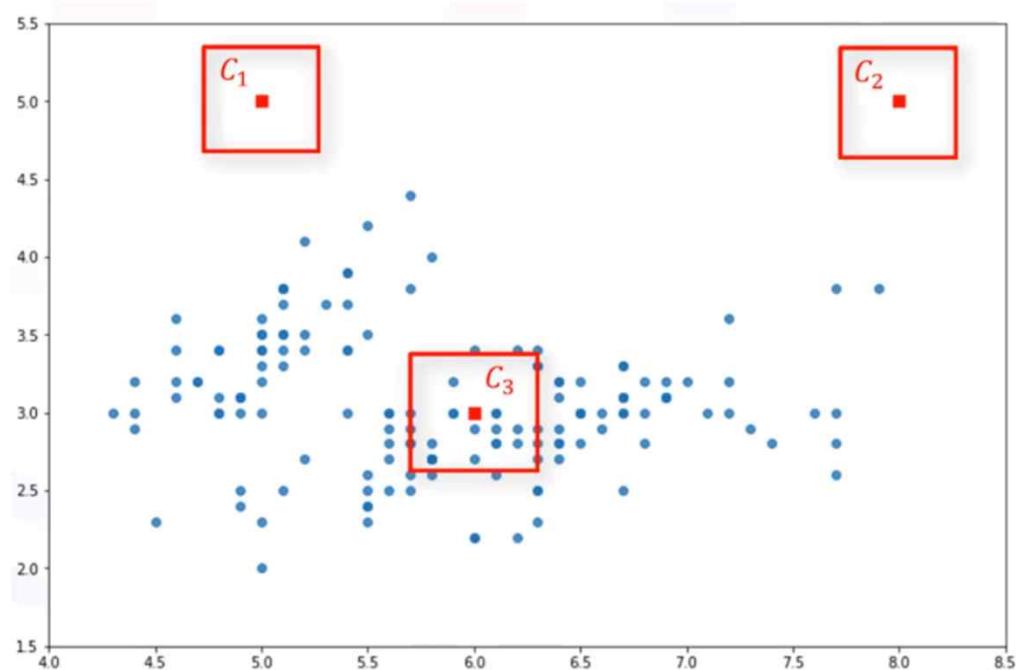


$$\text{Distance}(x_1, x_2) = \sqrt{(54 - 50)^2 + (190 - 200)^2 + (3 - 8)^2} = 11.87$$

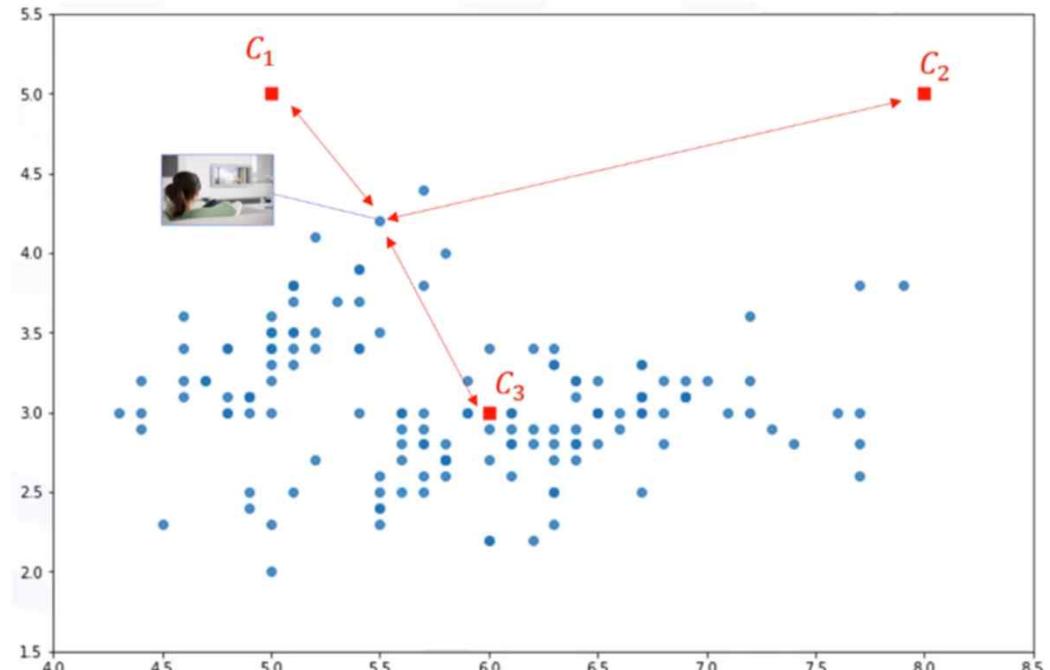
K-Means Clustering 알고리즘

1. Random하게 k개의 centroid(중심점)를 정한다.
2. 각 centroid로부터 각 data point 까지의 거리를 계산.
3. 각 data point를 가장 가까운 centroid에 할당하여 cluster를 생성.
4. K centroid의 위치를 다시 계산
5. centroid가 더 이상 움직이지 않을 때까지 2-4 단계를 반복

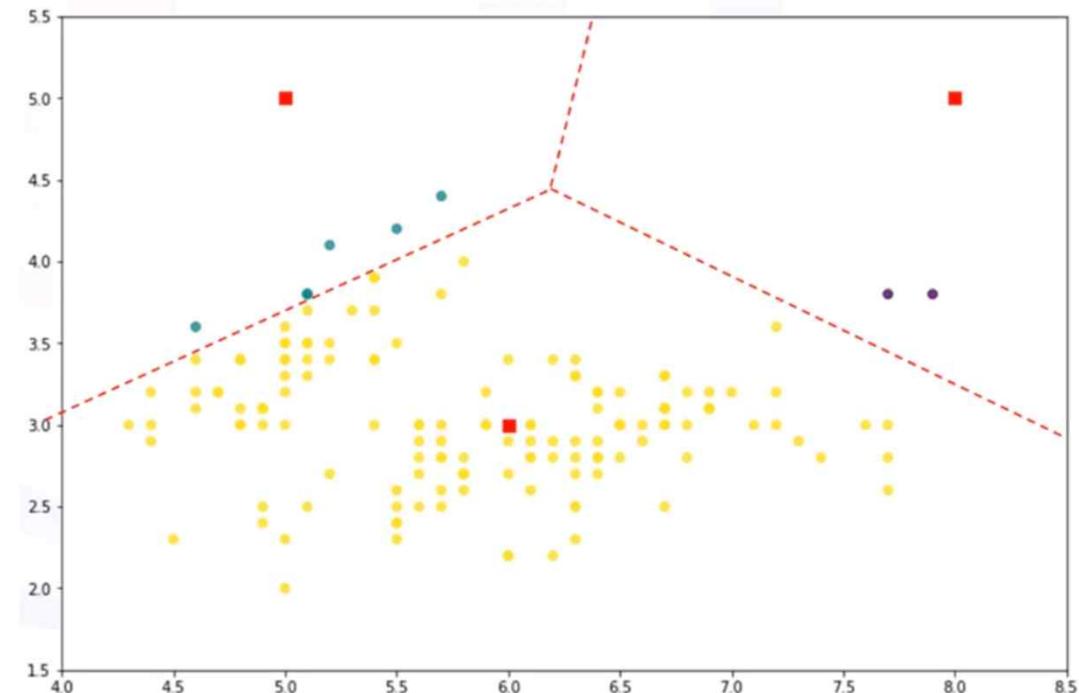
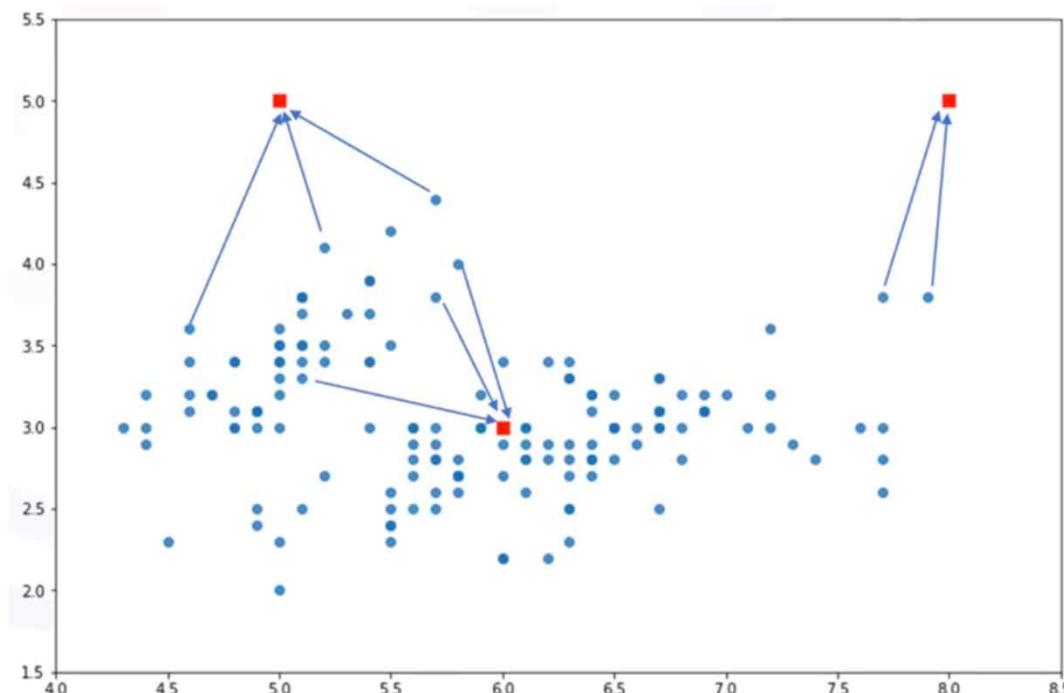
1. 임의의 centroid 선정 : $k=3$



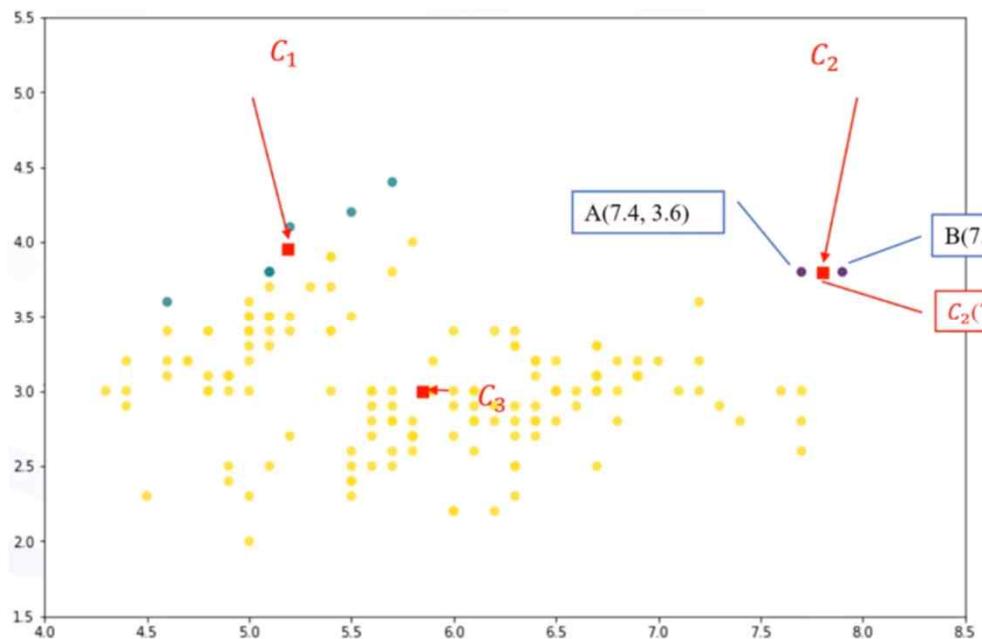
2. 거리 계산 for each data point



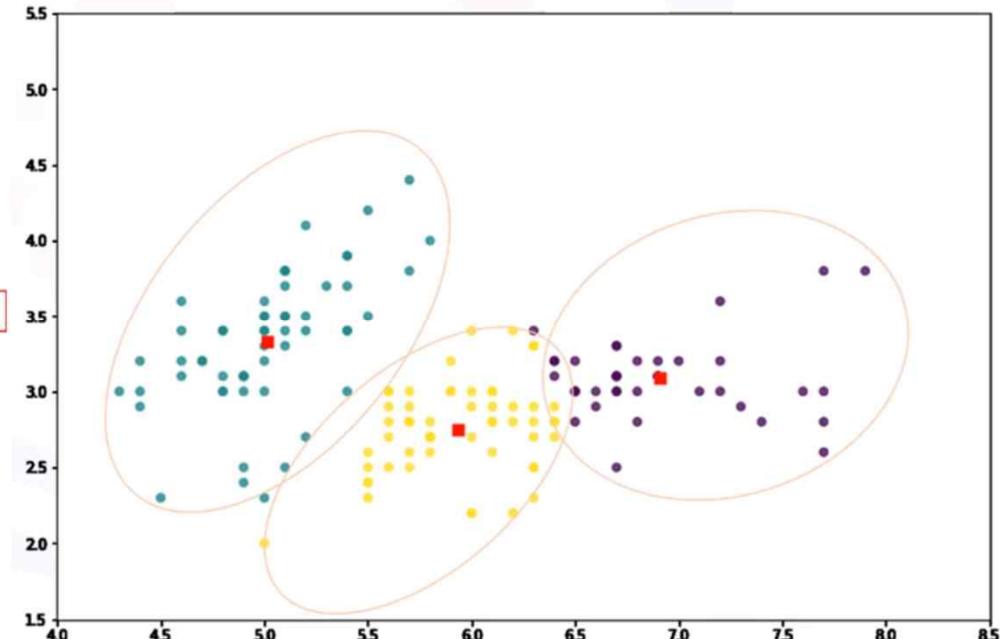
3. 가장 가까운 centroid 로 각 data point 할당



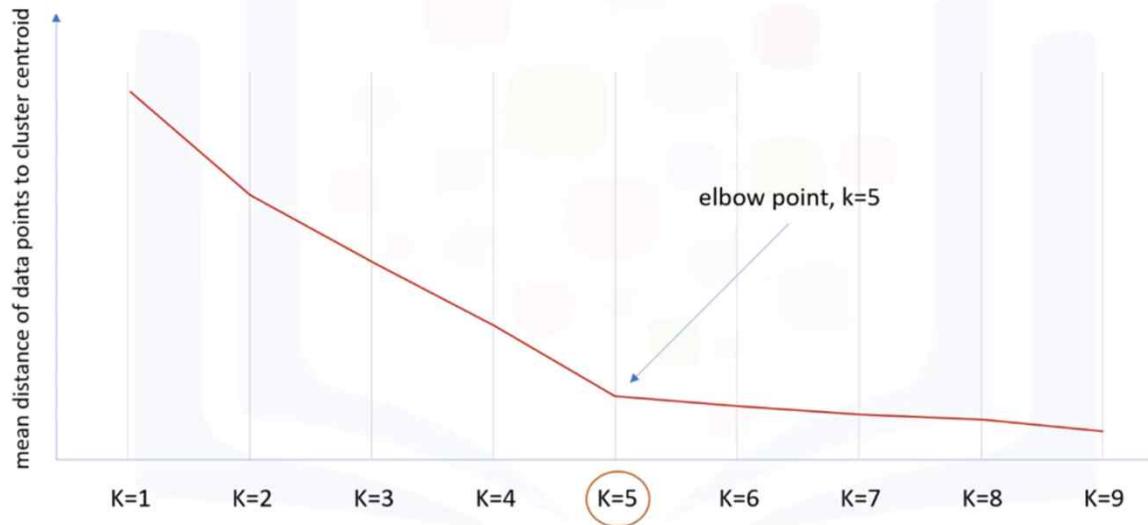
4. 각 cluster 의 new centroid 계산



5. Centroid 변화 없을 때까지 반복



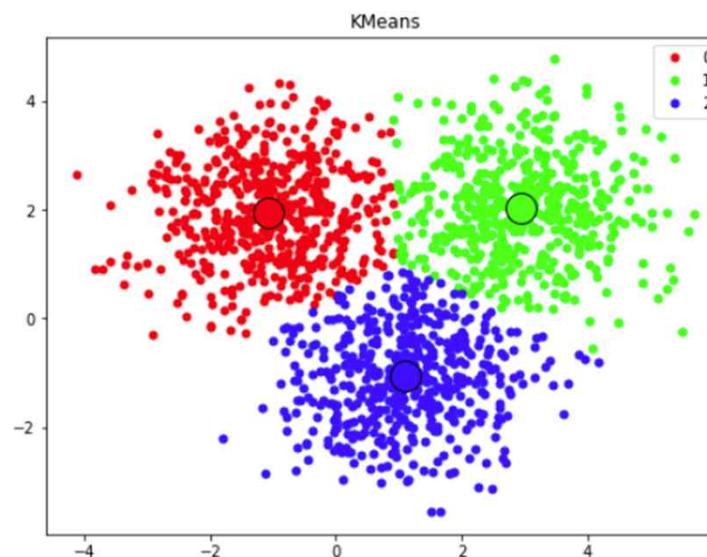
Choosing k



- K 를 잘 정하는 것이 중요
 - How ? → 경험적으로 $k = \sqrt{n}$ (n : data sample 개수)
- feature 가 많을 경우 계산량 증가

실습: 080. K-Means

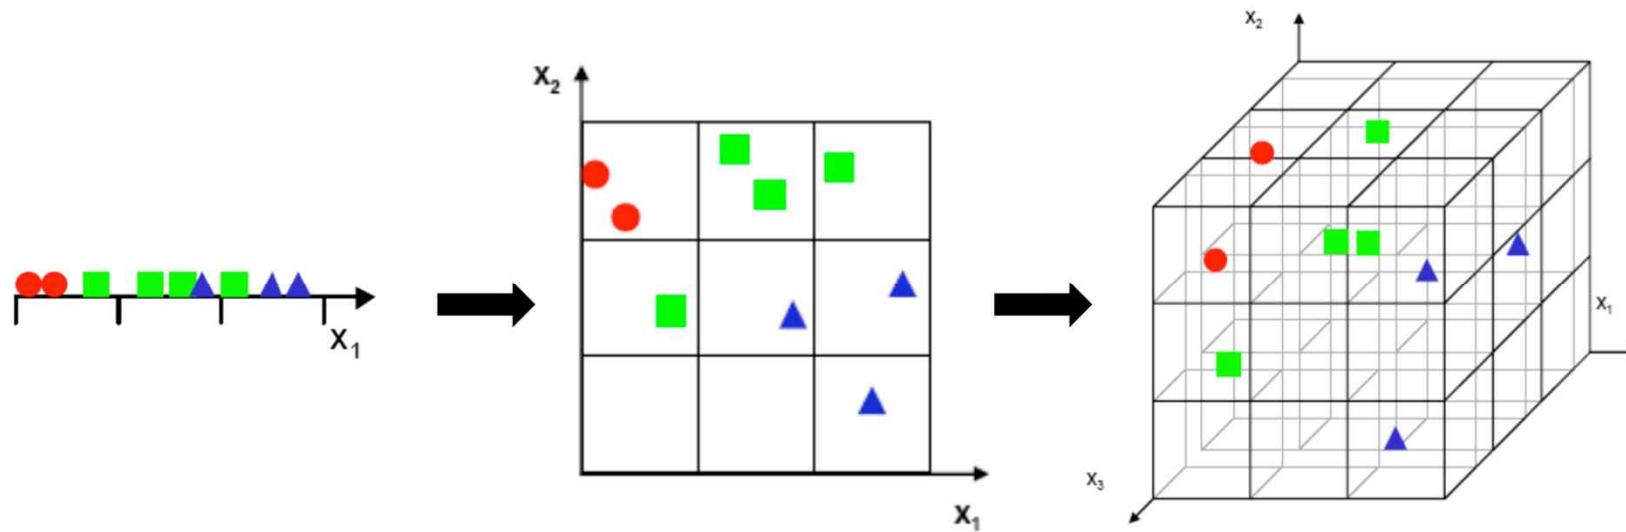
1. sklearn.cluster.Kmeans
2. Dataset : sklearn.dataset.samples_generator.make_blobs 사용
3. Matplotlib 을 이용하여 visualize



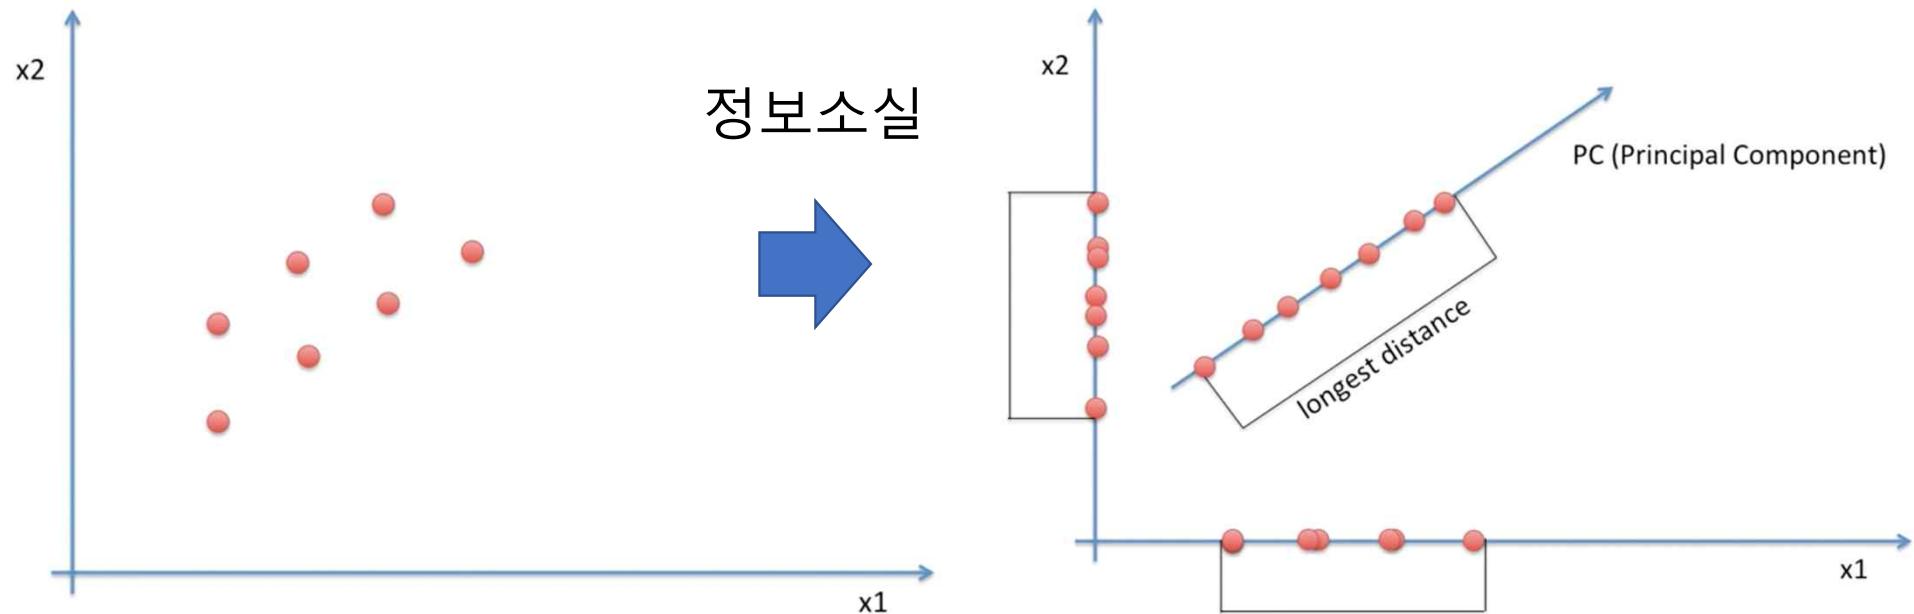
차원축소

차원의 저주 (Curse of Dimensionality)

- 차원이 증가함에 따라 vector 공간내의 space 도 증가하는데 데이터의 양이 적으면 빈공간이 많이 발생하여 예측의 정확도가 떨어진다.
- 유사한 성격의 feature (예, 키, 신장, 앉은키, 기온, 수도관 동파, 빙판길 미끄러짐 사고 등) 는 하나의 새로운 feature로 성분을 합칠 수 있음

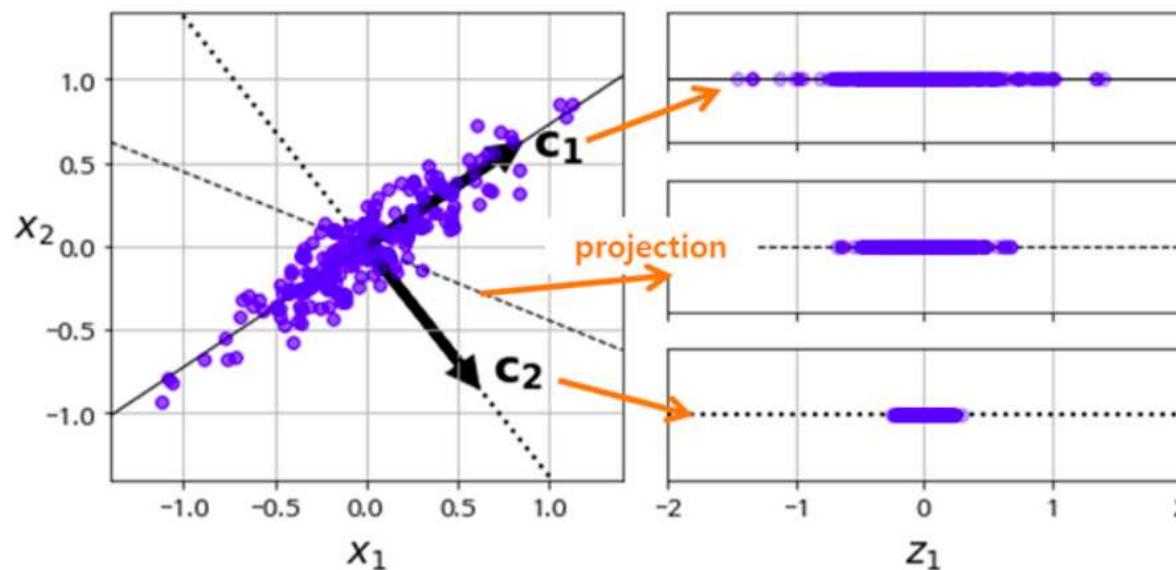


How to reduce dimension ?



PCA (Principal Component Analysis) - 주성분 분석

- 선형대수학의 SVD (특이값 분해) 를 이용하여 분산이 최대인 축을 찾음
- 데이터의 **분산(variance)**을 최대한 보존하면서 서로 직교하는 새 축을 찾아, 고차원 공간의 표본들을 선형 연관성이 없는 저차원 공간으로 변환



→ **분산을 최대한 보존**

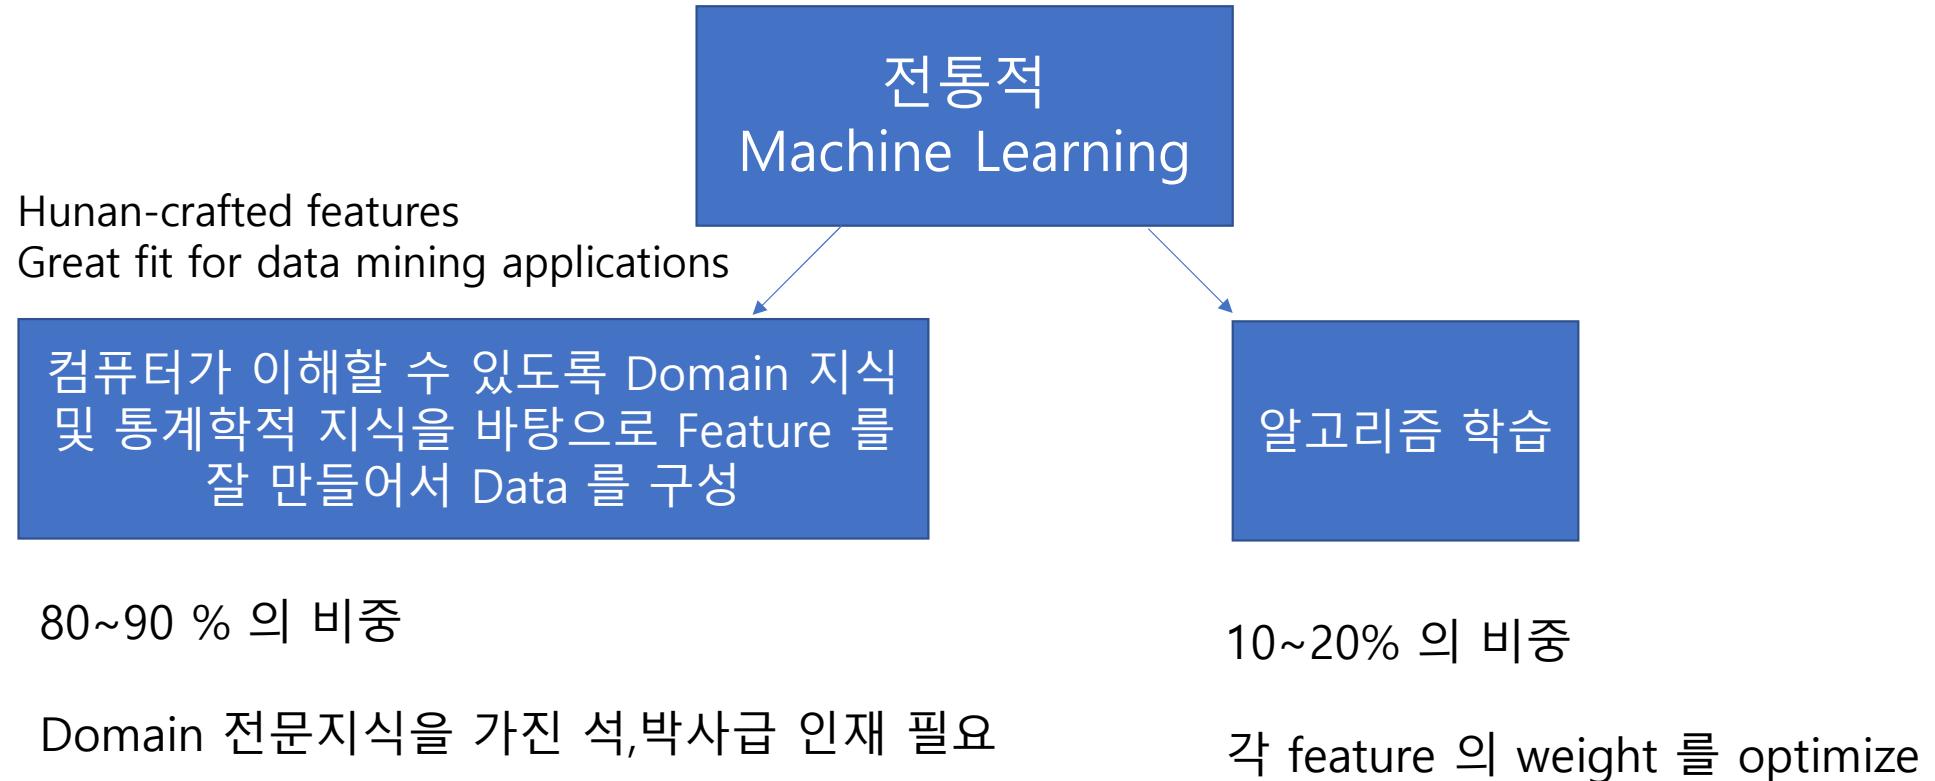
<https://i.imgur.com/Uv2dlsH.gif>

085. PCA 를 이용한 차원 축소

- PCA 적용 전 후의 Logistic Regression model 정확성 비교
- 차원 축소된 dataset 시각화

Neural Network and Deep Learning

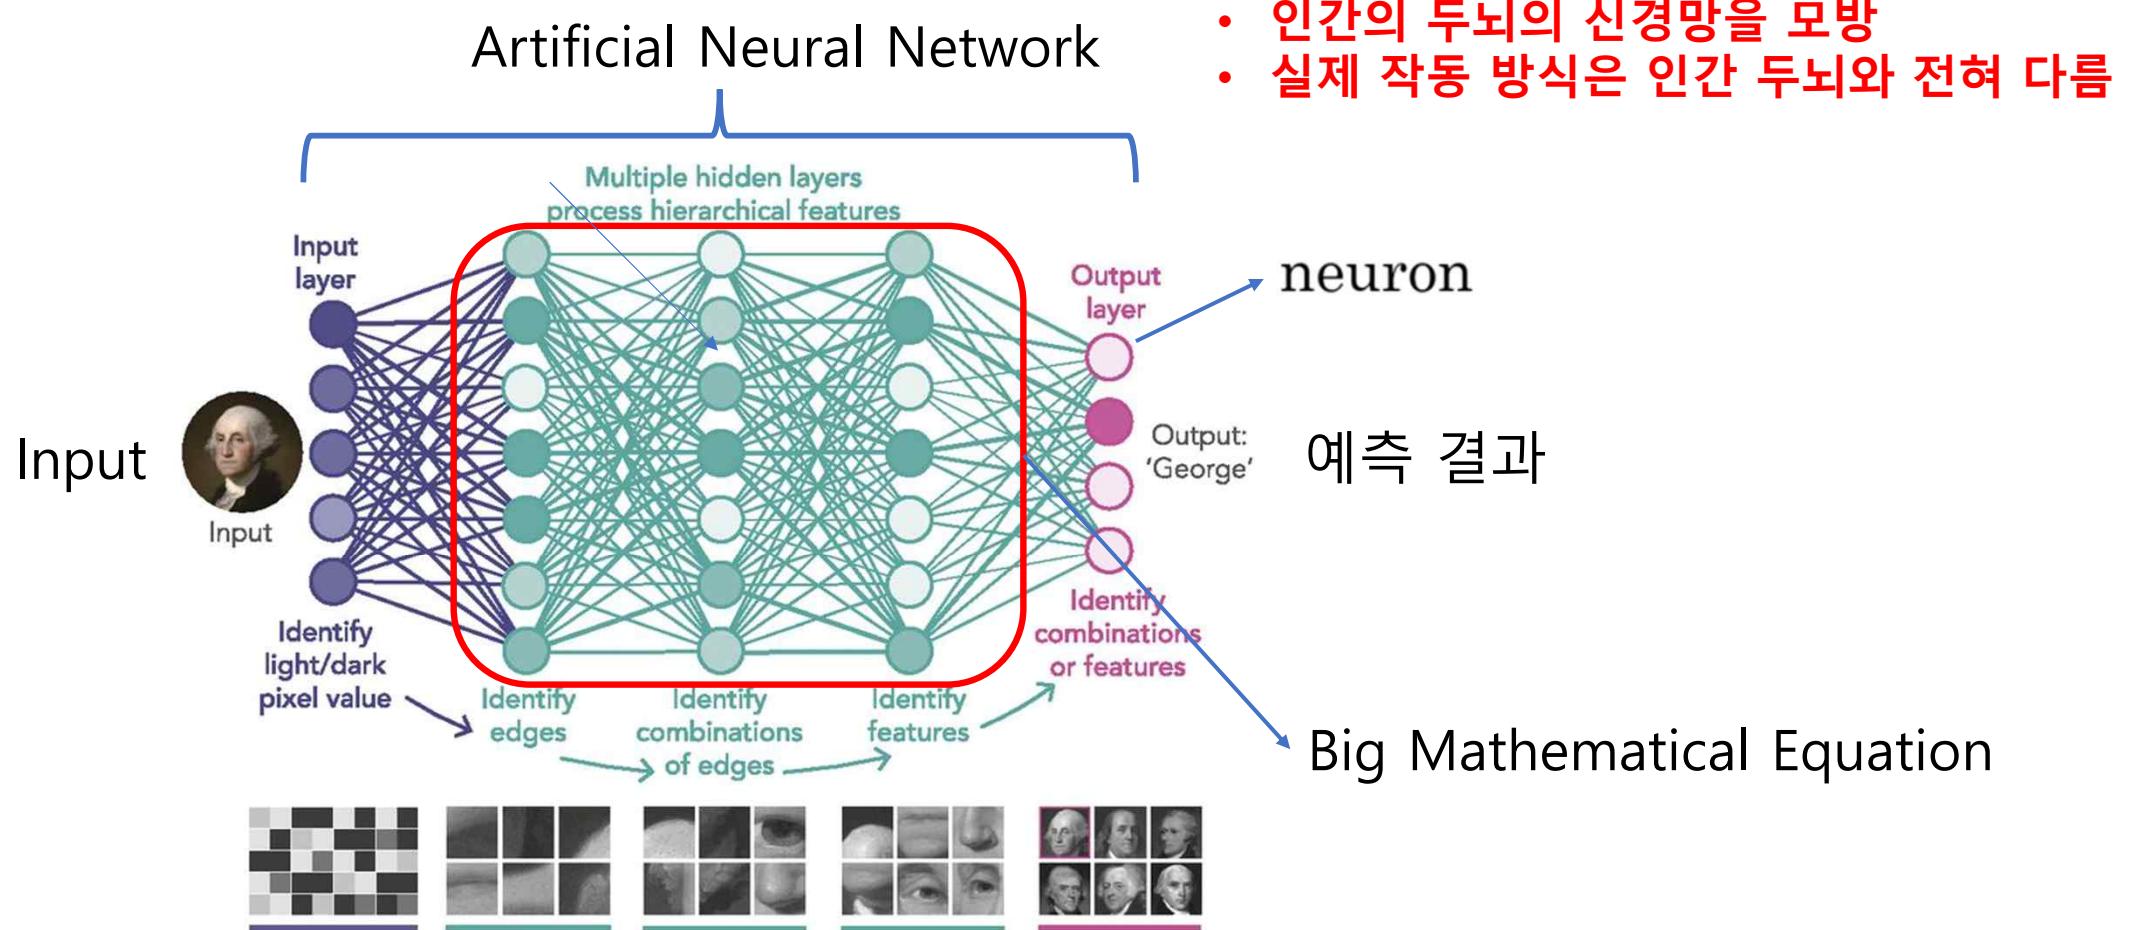
전통적 Machine Learning 의 학습



Deep Learning 의 학습

- 중요한 Feature 를 스스로 구분하여 weight 를 부여
 - 사람이 manually 정해준 feature 는 over-specified, incomplete 위험성 있고 작성에 많은 시간 소요
- 여러 층에 걸친 내부 parameter 를 스스로 학습
 - 적용하기 쉽고 빠르다.
- Raw data 를 거의 그대로 사용 – computer vision, 언어처리 등 (ex, image, sound, characters, words)
- Unsupervised, supervised learning 모두 가능
- 이미지 인식, 대화/언어 문제에 탁월한 성능

Deep Learning



Artificial Neuron (Perceptron)

구성요소:

Pre-Activation :

$$a(x) = b + \sum_i w_i x_i = b + w^T X$$

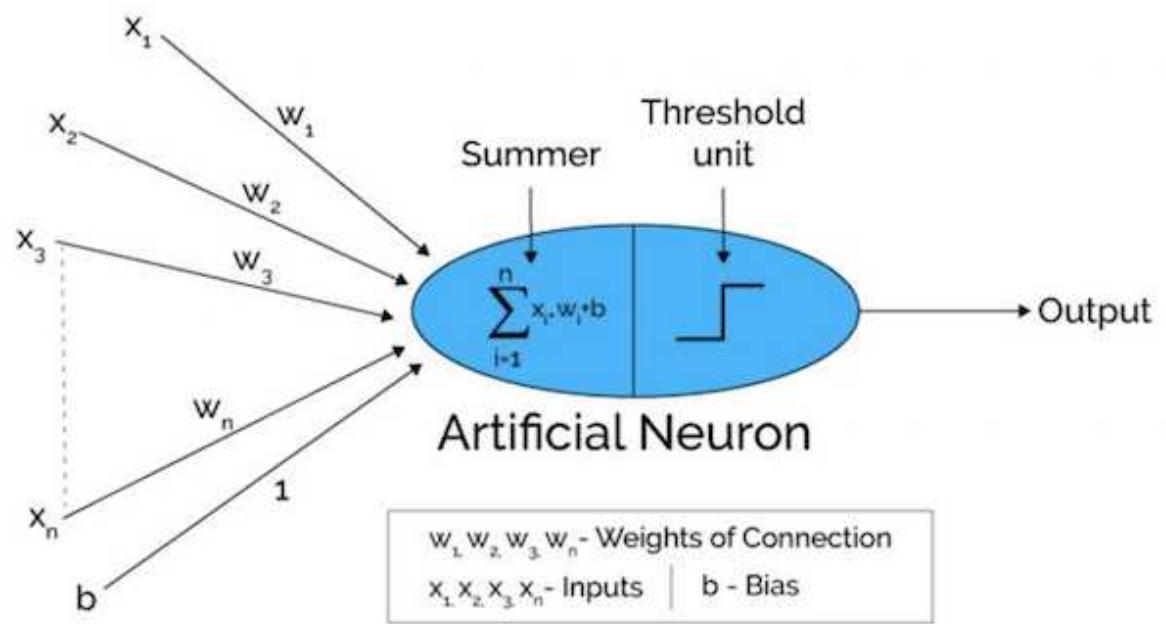
Activation :

$$h(x) = g(a(x)) = g(b + \sum_i w_i x_i)$$

w : connection weights

b : bias

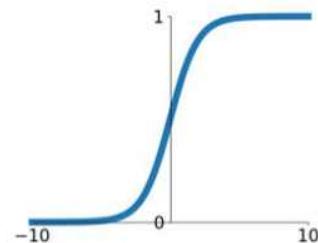
g : activation function



Activation Functions

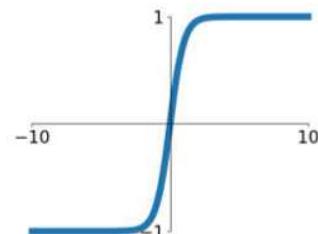
Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$



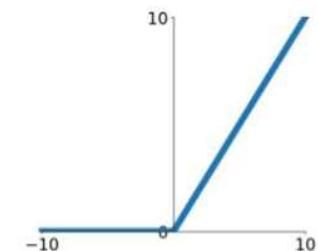
tanh

$$\tanh(x)$$



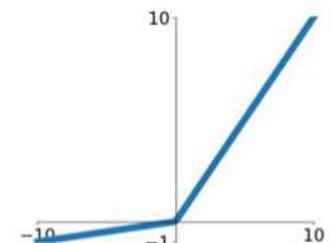
ReLU

$$\max(0, x)$$



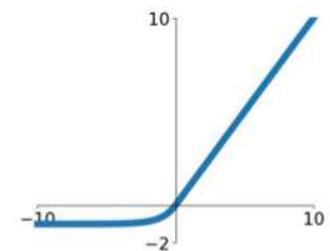
Leaky ReLU

$$\max(0.1x, x)$$



ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



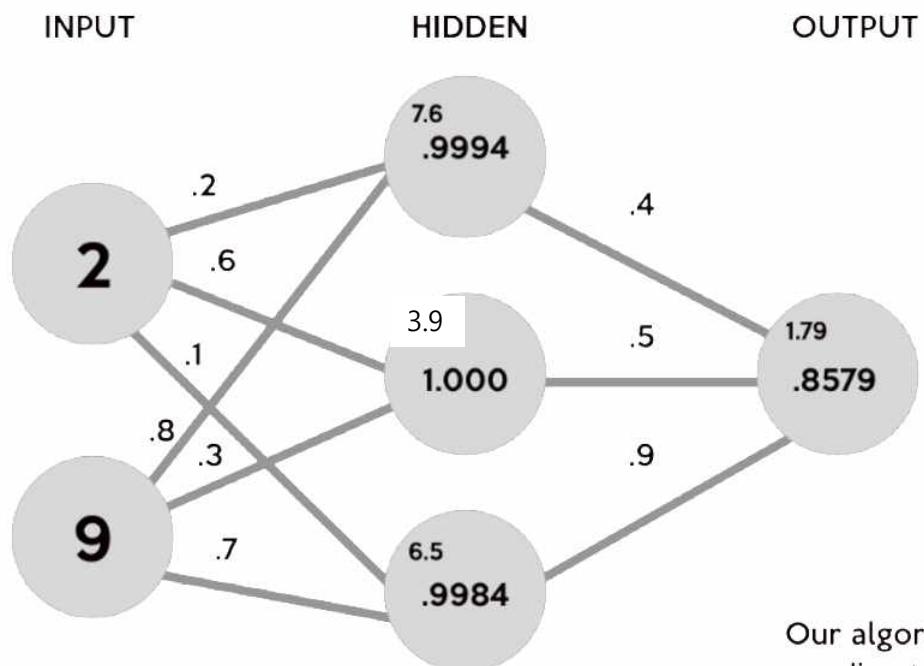
Softmax Activation Function

- 출력값의 class 분류를 위하여 출력값에 대해 정규화 → 확률 분포 출력

$$\sigma(\mathbf{z})_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} \quad \text{for } j = 1, \dots, K.$$

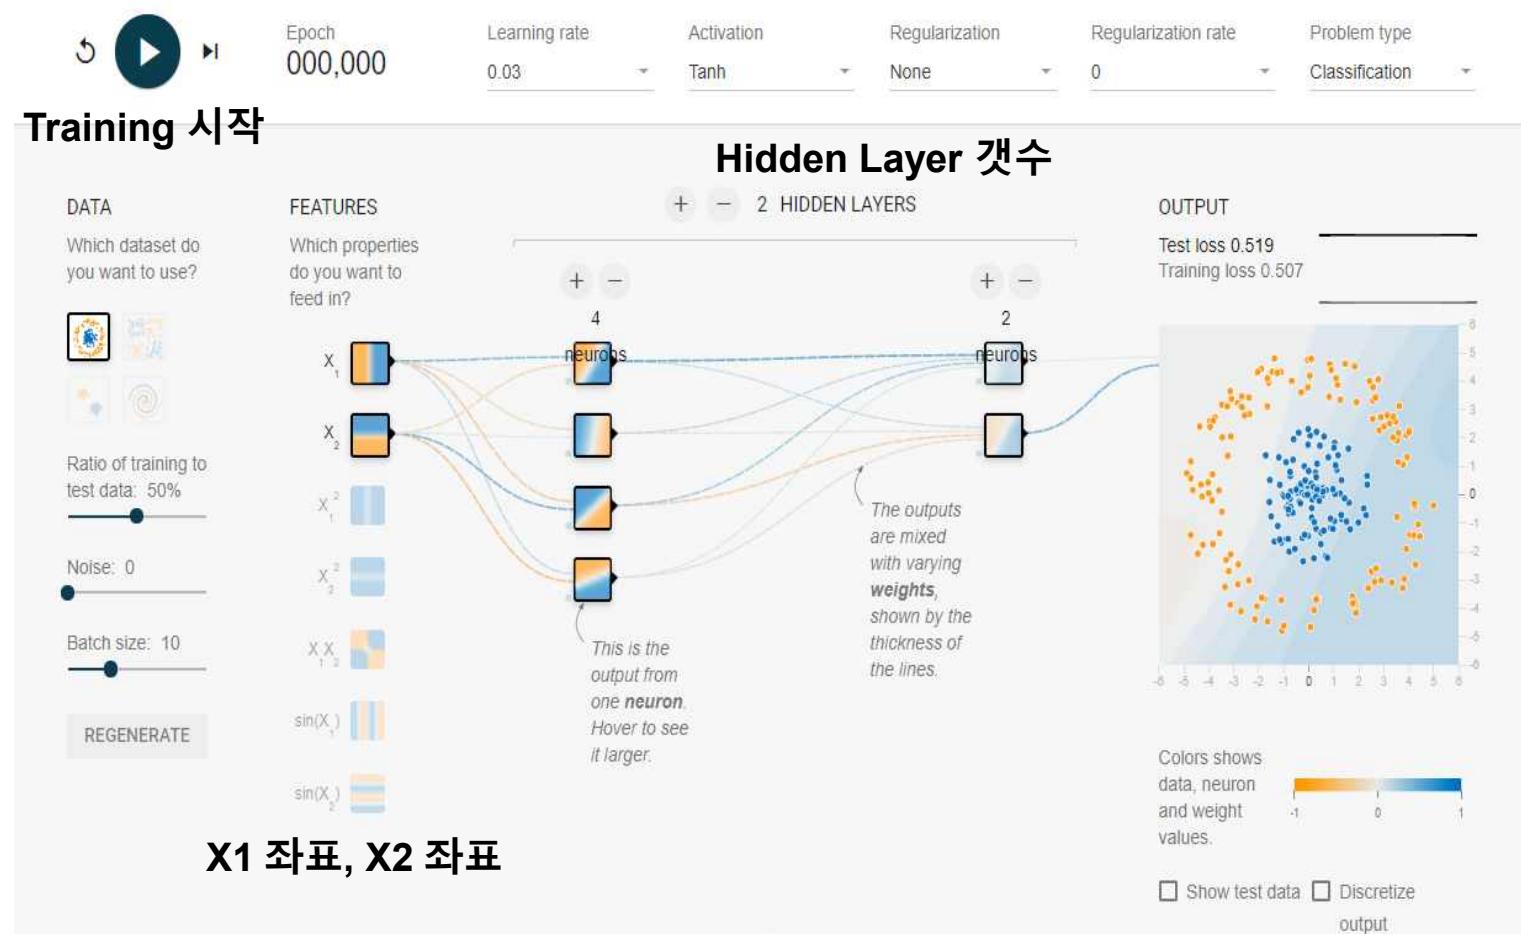


Neural Network 의 작동 원리



Our algorithm,
according to the
untrained (random)
weights, produced .85
as our test score
result.

실습 : Tensorflow Playground



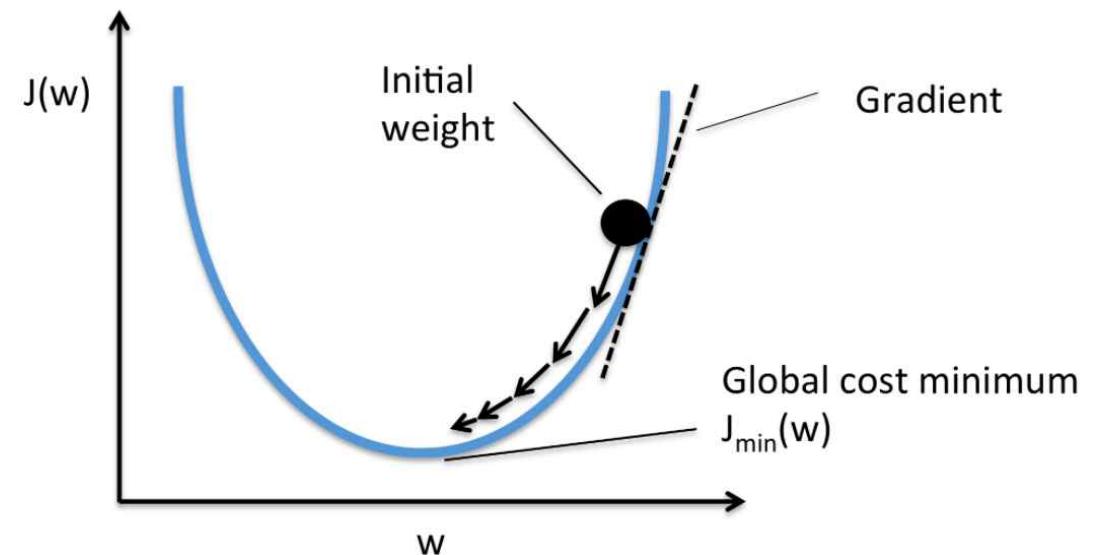
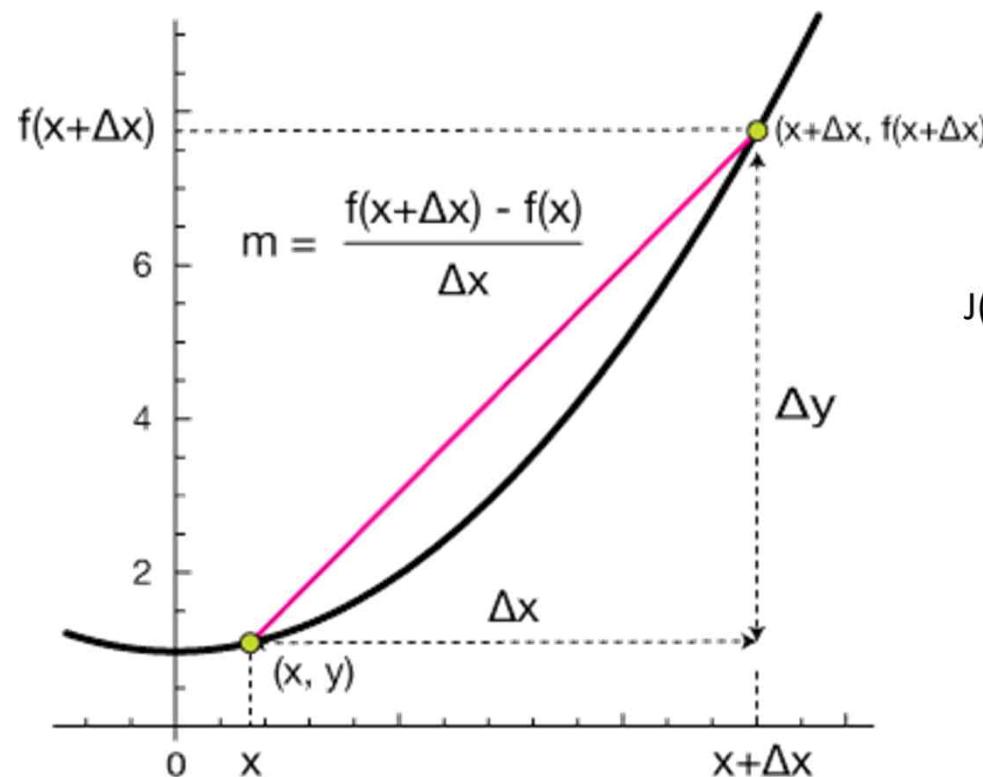
Neural Network

훈련 원리

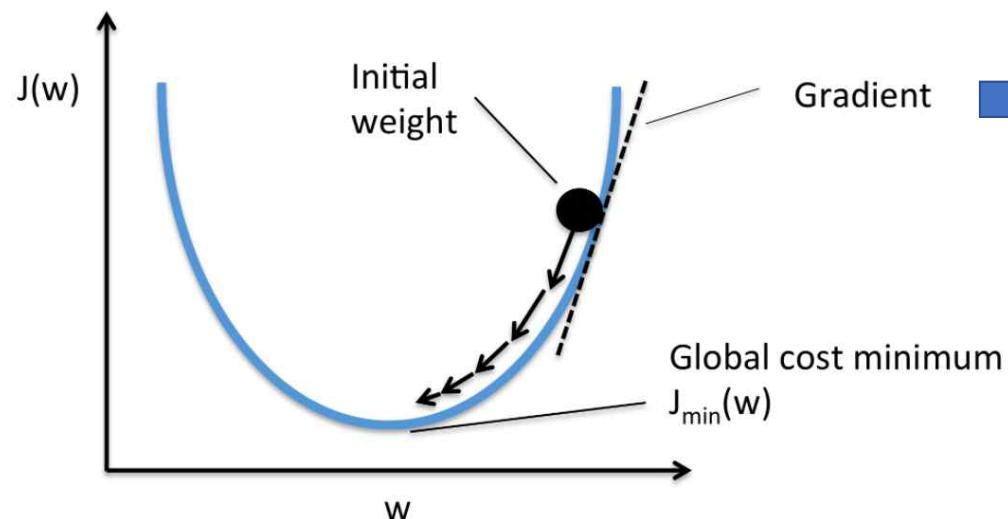
Deep Neural Network 훈련의 핵심

- Gradient Descent (경사하강법)
 - 목적 – 실제값과 예측값의 차이를 최소화 하는 parameter(θ) 발견
 - 방법 – 손실함수를 정의하여 손실함수의 값이 0 으로 수렴하도록 parameter(θ) 조절
- Backpropagation (오차역전파)
 - 손실함수를 최소화 하는 방향으로 신경망 전체의 parameter 가 update 되도록 하는 기법
- 손실함수
 - 비용함수(cost function), 목적함수(object function) 등으로도 불림
 - 경사하강법이 가능하도록 미분 가능한 함수를 정의

Derivative (도함수, 미분, 접선의 기울기)



Gradient Descent (경사하강법) Optimization



방향 – Gradient
(derivative of Cost Function)

이동 속도 – Learning Rate

$$\text{New } W = \text{old } W - (\text{Learning Rate}) * (\text{Gradient})$$

경사하강법과 parameter update (선형회귀)

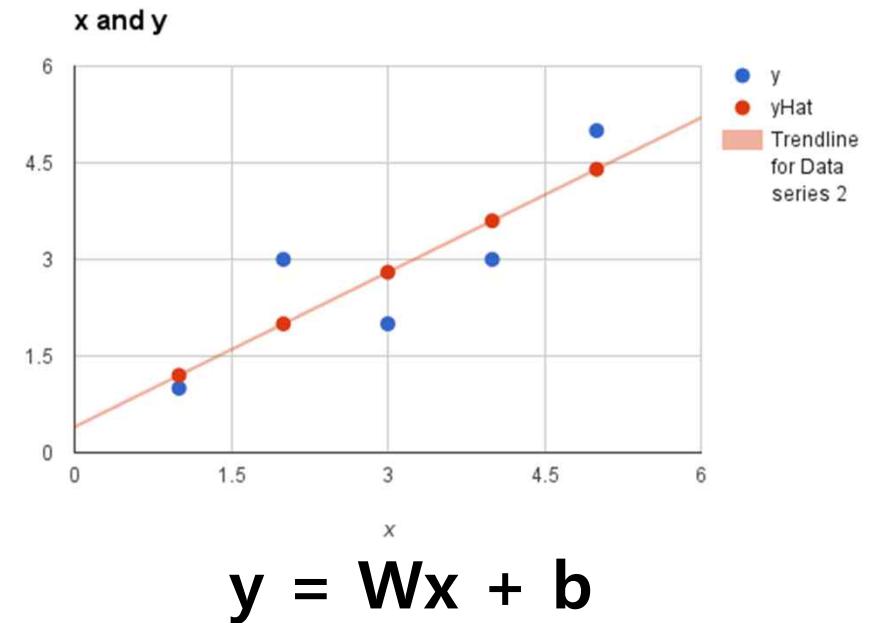
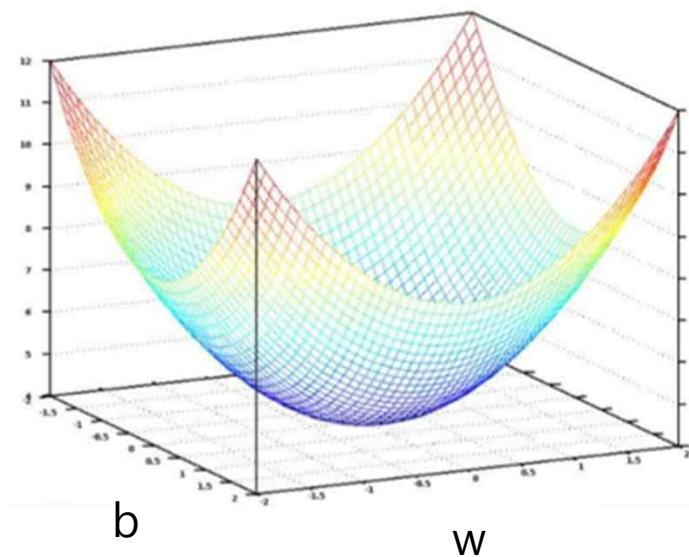
- $y = \theta_0 + \theta_1 x$
- Loss Function $L(\theta_0, \theta_1) = \frac{1}{N} \sum_{i=0}^m (y_i - (\theta_0 + \theta_1 x_i))^2$
- Gradient $\frac{\partial L(\theta_0, \theta_1)}{\partial \theta_0} = -2 \frac{1}{N} \sum_{i=0}^m (y_i - (\theta_0 + \theta_1 x_i))$
 $\frac{\partial L(\theta_0, \theta_1)}{\partial \theta_1} = -2 \frac{1}{N} \sum_{i=0}^m x_i (y_i - (\theta_0 + \theta_1 x_i))$
- Update $\theta_0 := \theta_0 - \alpha \frac{\partial L(\theta_0, \theta_1)}{\partial \theta_0}$
 $\theta_1 := \theta_1 - \alpha \frac{\partial L(\theta_0, \theta_1)}{\partial \theta_1}$

대표적 손실 함수

- Linear Regression (선형회귀) – MSE (Mean Squared Error)
- Binary Classification (이진분류) – Binary-Cross-Entropy
- Multi-Class Classification (다중분류) – Categorical-Cross-Entropy

Cost Function - Linear Regression

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{Y}_i - Y_i)^2$$



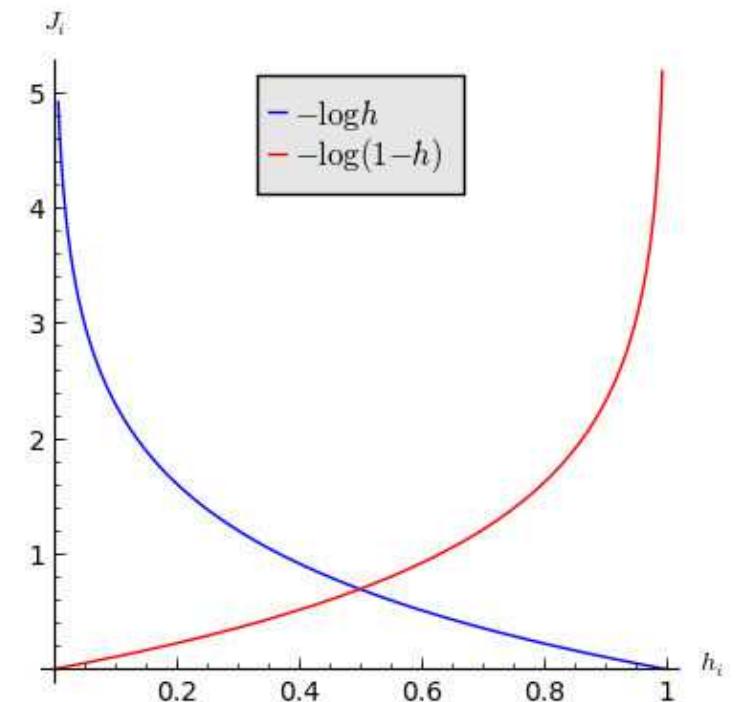
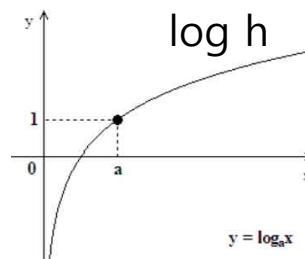
MSE(Mean Squared Error) 를
최소화 하는 W 와 b 를 optimize

Cost Function - Logistic Regression (Binary Cross-entropy)

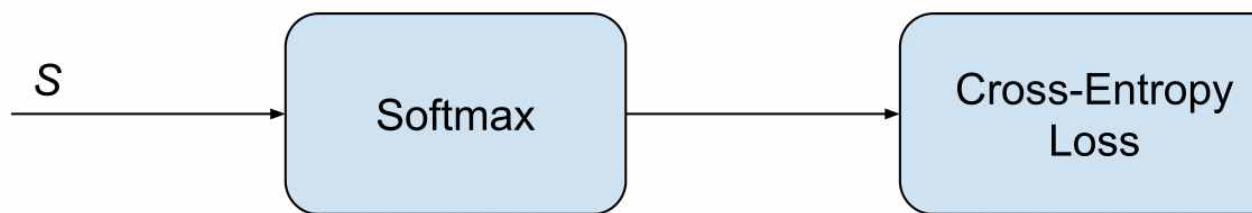
$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)})) + y^{(i)} \log h_\theta(x^{(i)}) \right]$$

If $y^{(i)} = 1$: $J(\theta) = -b g h_\theta(x^{(i)})$
where $h_\theta(x^{(i)})$ should be close to 1

If $y^{(i)} = 0$: $J(\theta) = -\log(1 - h_\theta(x^{(i)}))$
where $h_\theta(x^{(i)})$ should be close to 0



Cost Function - Categorical Crossentropy (Softmax Loss)



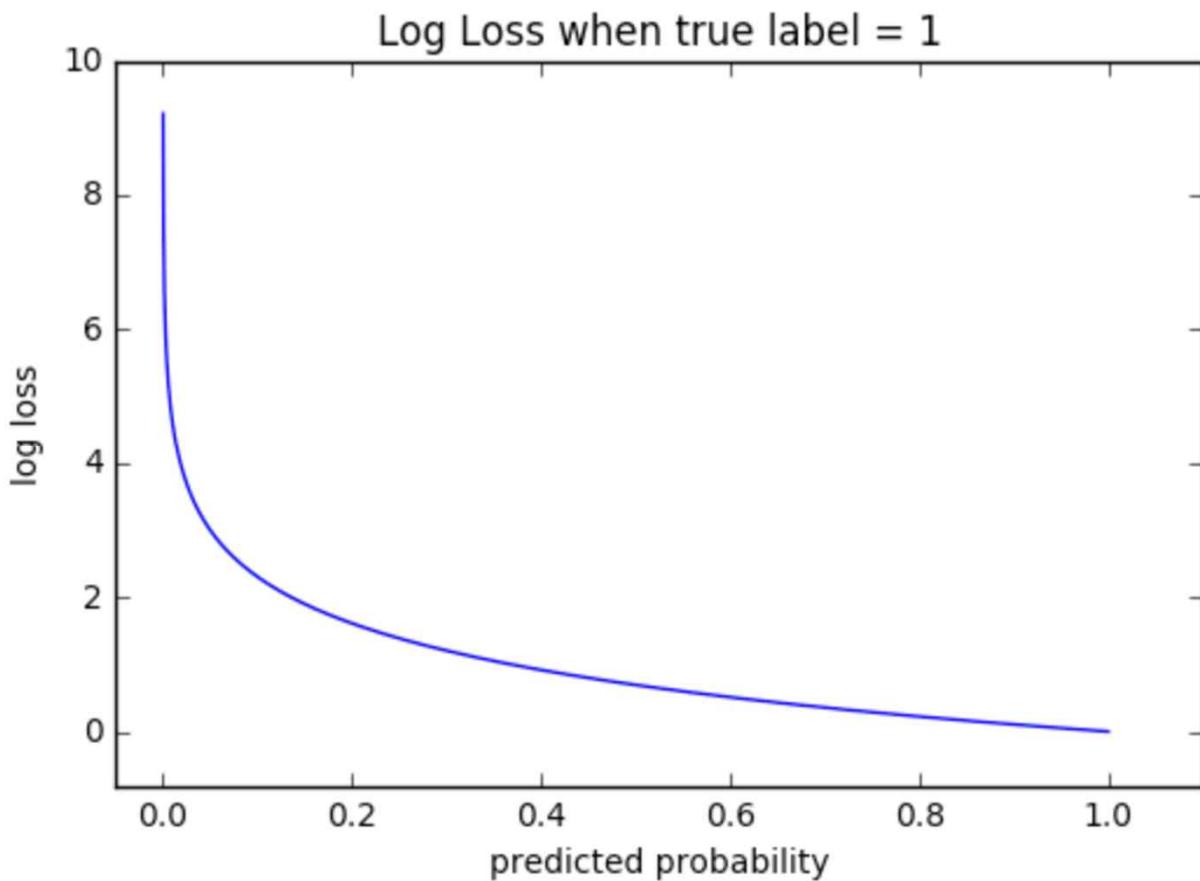
$$f(s)_i = \frac{e^{s_i}}{\sum_j^C e^{s_j}} \quad CE = - \sum_i^C t_i \log(f(s)_i)$$

t_i : 0 이 아닌 target
(one-hot encoded
되어 있으므로
multi-class 중 오직
1 개만 1)

C : multi-classes

Index	0	1	2	3	4	5	6	7	8	9
True Label	0	0	0	0	0	0	0	1	0	0
Prediction	0.1	0.01	0.01	0.01	0.20	0.01	0.01	0.60	0.03	0.02

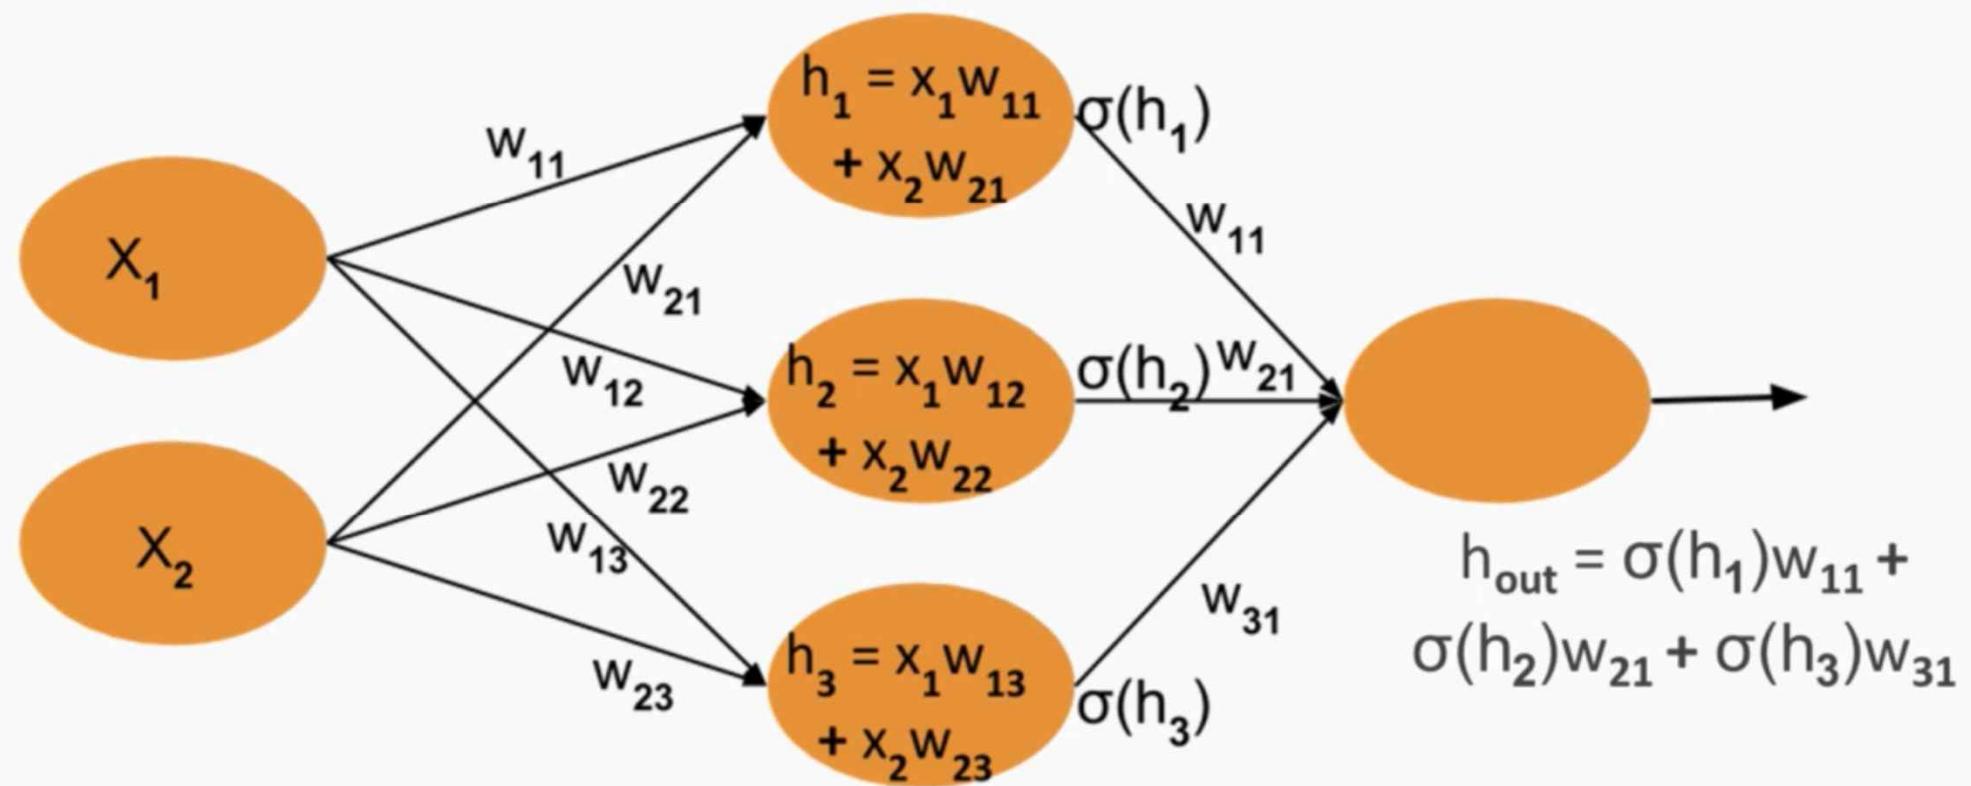
Cross-Entropy Loss



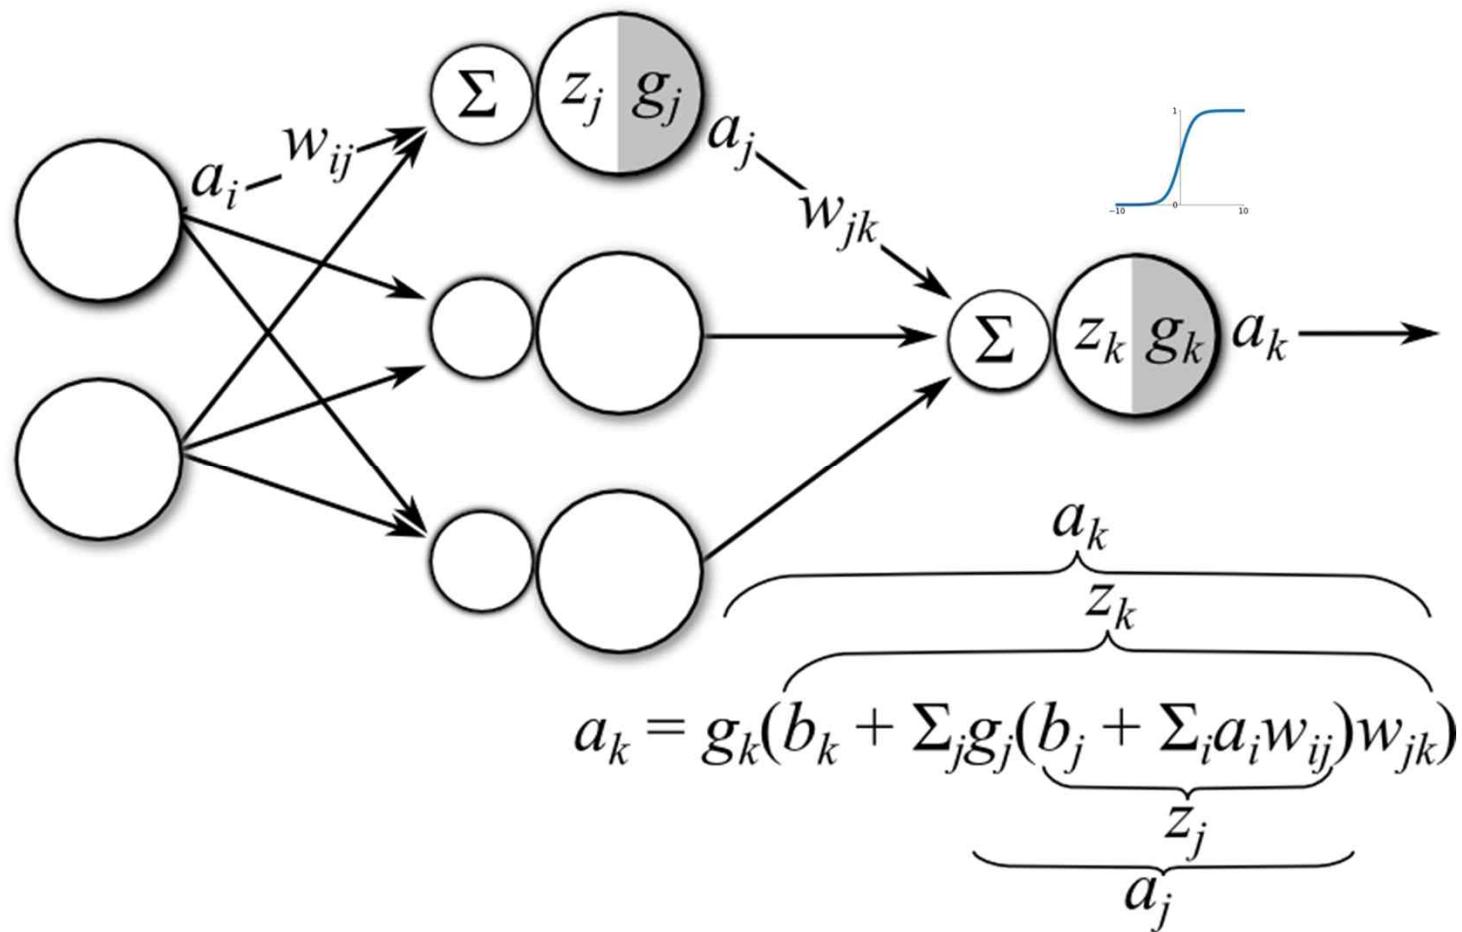
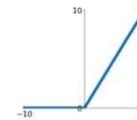
$$CE = - \sum_i^C t_i \log(f(s)_i)$$

```
def CrossEntropy(yHat, y):  
    if y == 1:  
        return -log(yHat)  
    else:  
        return -log(1 - yHat)
```

Forward Propagation



Forward Propagation



Backward Propagation 기초 공식

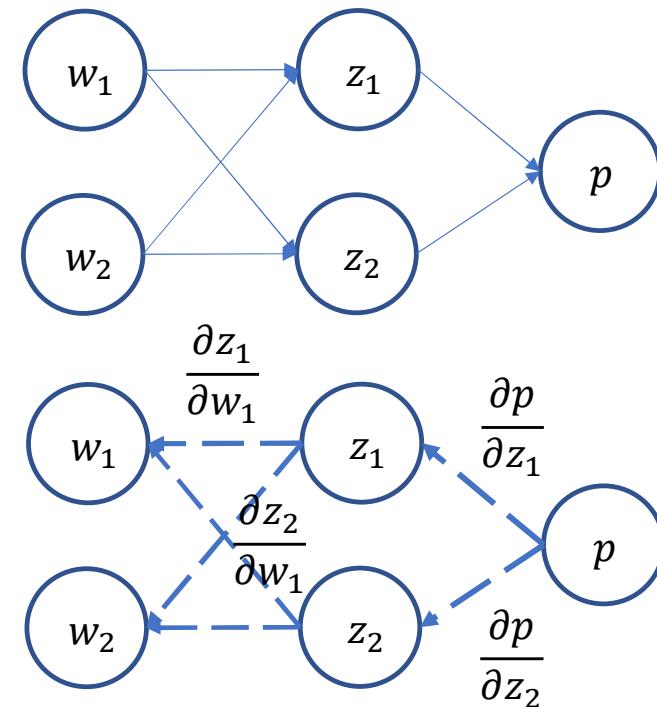
- 기본 함수의 도함수 (derivative) : $\frac{dx^2}{dx} = 2x$, $\frac{de^x}{dx} = e^x$, $\frac{d\ln(x)}{dx} = \frac{1}{x}$
- Chain Rule :

$p = f(z_1, z_2)$: 합성함수

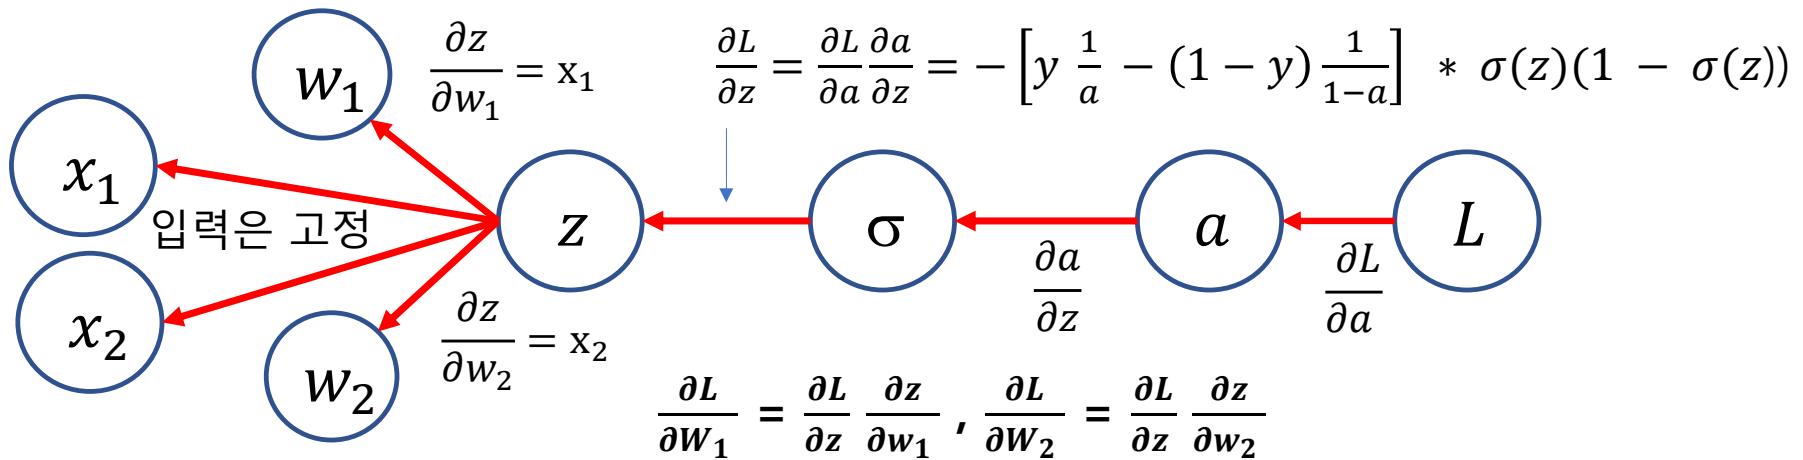
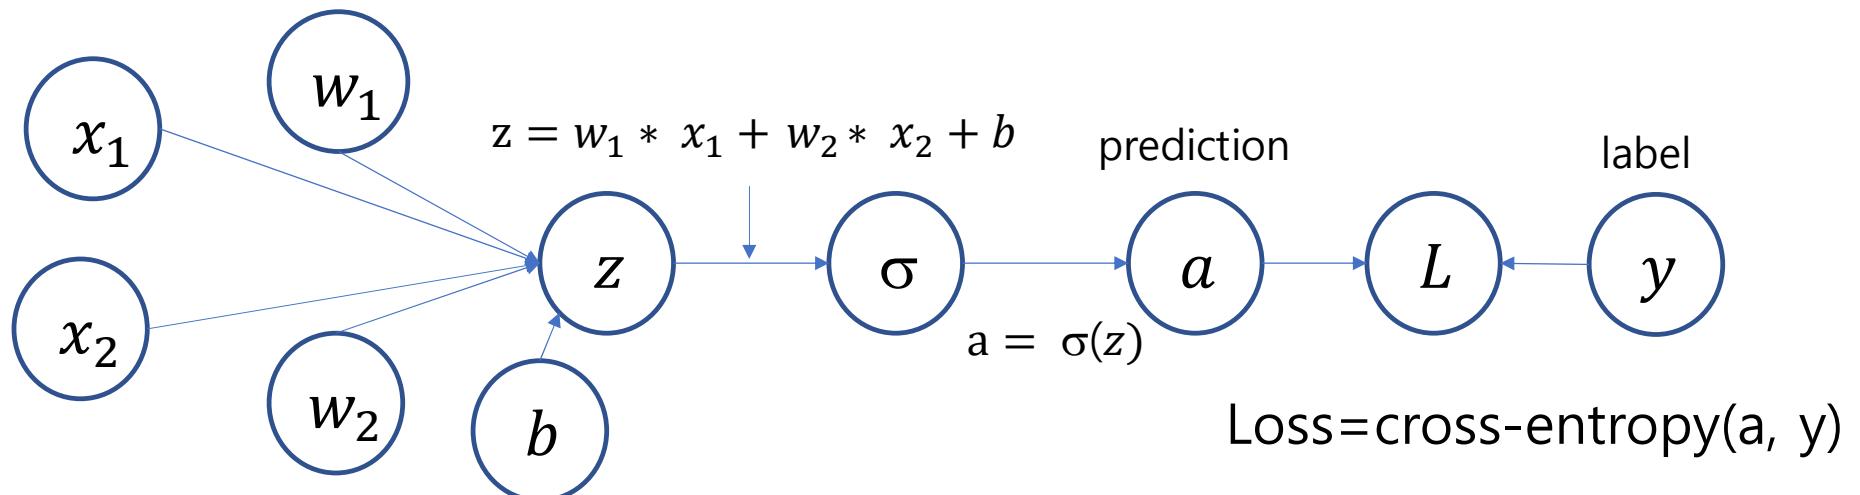
$z_1 = f(w_1, w_2)$

$z_2 = f(w_1, w_2)$

$$\frac{\partial p}{\partial w_1} = \frac{\partial p}{\partial z_1} \frac{\partial z_1}{\partial w_1} + \frac{\partial p}{\partial z_2} \frac{\partial z_2}{\partial w_1}$$
$$\frac{\partial p}{\partial w_2} = \frac{\partial p}{\partial z_1} \frac{\partial z_1}{\partial w_2} + \frac{\partial p}{\partial z_2} \frac{\partial z_2}{\partial w_2}$$

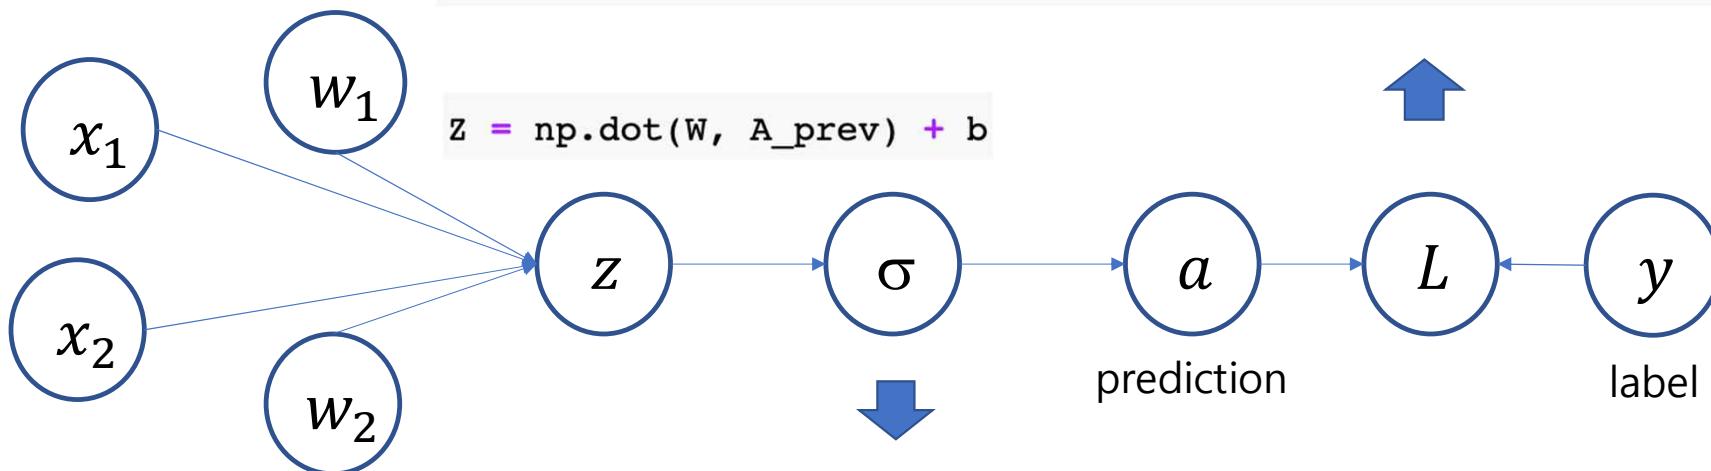


Example : 2 개의 feature 를 가진 1 layer + sigmoid activation



Forward Propagation 구현

```
def compute_cost(AL, y):
    m = y.shape[1]
    cost = - (1 / m) * np.sum(
        np.multiply(y, np.log(AL)) + np.multiply(1 - y, np.log(1 - AL)))
    return cost
```

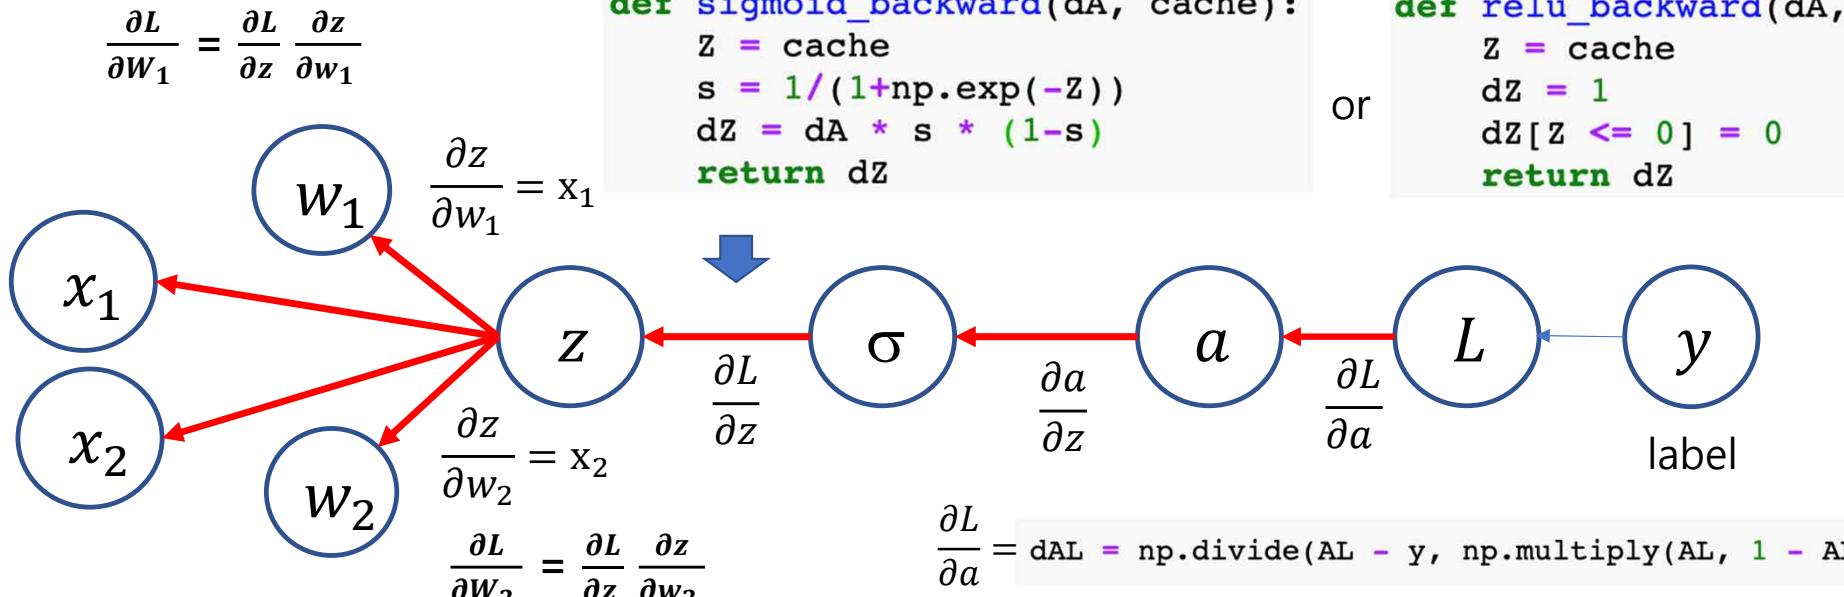


```
def sigmoid(Z):
    A = 1/(1+np.exp(-Z))
    return A, Z
```

```
def relu(Z):
    A = np.maximum(0,Z)
    return A, Z
```

or

Backward Propagation 구현



```

for l in range(1, L + 1):
    parameters["W"+str(l)] = parameters["W"+str(l)] - learning_rate * grads["dW"+str(l)]
    parameters["b"+str(l)] = parameters["b"+str(l)] - learning_rate * grads["db"+str(l)]

```

$$\begin{aligned}
\boxed{\frac{d}{dx} \sigma(x)} &= \frac{d}{dx} \left[\frac{1}{1 + e^{-x}} \right] \\
&= \frac{d}{dx} (1 + e^{-x})^{-1} \\
&= -(1 + e^{-x})^{-2} (-e^{-x}) \\
&= \frac{e^{-x}}{(1 + e^{-x})^2} \\
&= \frac{1}{1 + e^{-x}} \cdot \frac{e^{-x}}{1 + e^{-x}} \\
&= \frac{1}{1 + e^{-x}} \cdot \frac{(1 + e^{-x}) - 1}{1 + e^{-x}} \\
&= \frac{1}{1 + e^{-x}} \cdot \left(\frac{1 + e^{-x}}{1 + e^{-x}} - \frac{1}{1 + e^{-x}} \right) \\
&= \frac{1}{1 + e^{-x}} \cdot \left(1 - \frac{1}{1 + e^{-x}} \right) \\
&= \boxed{\sigma(x) \cdot (1 - \sigma(x))}
\end{aligned}$$

$$\begin{aligned}
\frac{dL}{da} &= -[y \cdot \frac{1}{a} - (1 - y) \cdot \frac{1}{1-a}] = -\frac{y}{a} + \frac{1-y}{1-a} \\
&= -\frac{y(1-a)}{a(1-a)} - \frac{a-ay}{a(1-a)} = \frac{-y+ay+a-ay}{a(1-a)} = \frac{a-y}{a(1-a)}
\end{aligned}$$

Backpropagation (Chain Rule 적용)

* 같은 색으로 표시된 부분은 한번 계산하면 여러 번 reuse

$$3: \frac{\partial p}{\partial h_1} \quad \frac{\partial p}{\partial h_2}$$

We will need these for GD

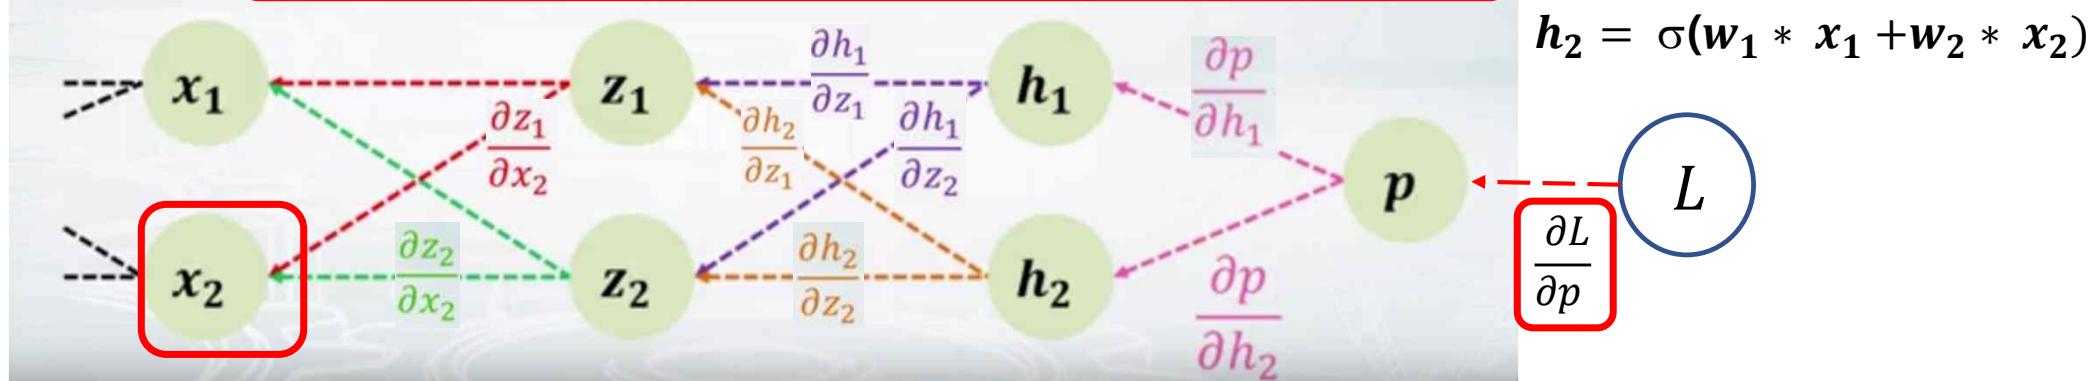
$$2: \frac{\partial p}{\partial z_1} = \frac{\partial p}{\partial h_1} \frac{\partial h_1}{\partial z_1} + \frac{\partial p}{\partial h_2} \frac{\partial h_2}{\partial z_1}$$

$$\frac{\partial p}{\partial z_2} = \frac{\partial p}{\partial h_1} \frac{\partial h_1}{\partial z_2} + \frac{\partial p}{\partial h_2} \frac{\partial h_2}{\partial z_2}$$

$$1: \frac{\partial p}{\partial x_1} = \frac{\partial p}{\partial h_1} \frac{\partial h_1}{\partial z_1} \frac{\partial z_1}{\partial x_1} + \frac{\partial p}{\partial h_2} \frac{\partial h_2}{\partial z_1} \frac{\partial z_1}{\partial x_1} + \frac{\partial p}{\partial h_1} \frac{\partial h_1}{\partial z_2} \frac{\partial z_2}{\partial x_1} + \frac{\partial p}{\partial h_2} \frac{\partial h_2}{\partial z_2} \frac{\partial z_2}{\partial x_1}$$

$$1: \boxed{\frac{\partial p}{\partial x_2} = \frac{\partial p}{\partial h_1} \frac{\partial h_1}{\partial z_1} \frac{\partial z_1}{\partial x_2} + \frac{\partial p}{\partial h_2} \frac{\partial h_2}{\partial z_1} \frac{\partial z_1}{\partial x_2} + \frac{\partial p}{\partial h_1} \frac{\partial h_1}{\partial z_2} \frac{\partial z_2}{\partial x_2} + \frac{\partial p}{\partial h_2} \frac{\partial h_2}{\partial z_2} \frac{\partial z_2}{\partial x_2}}$$

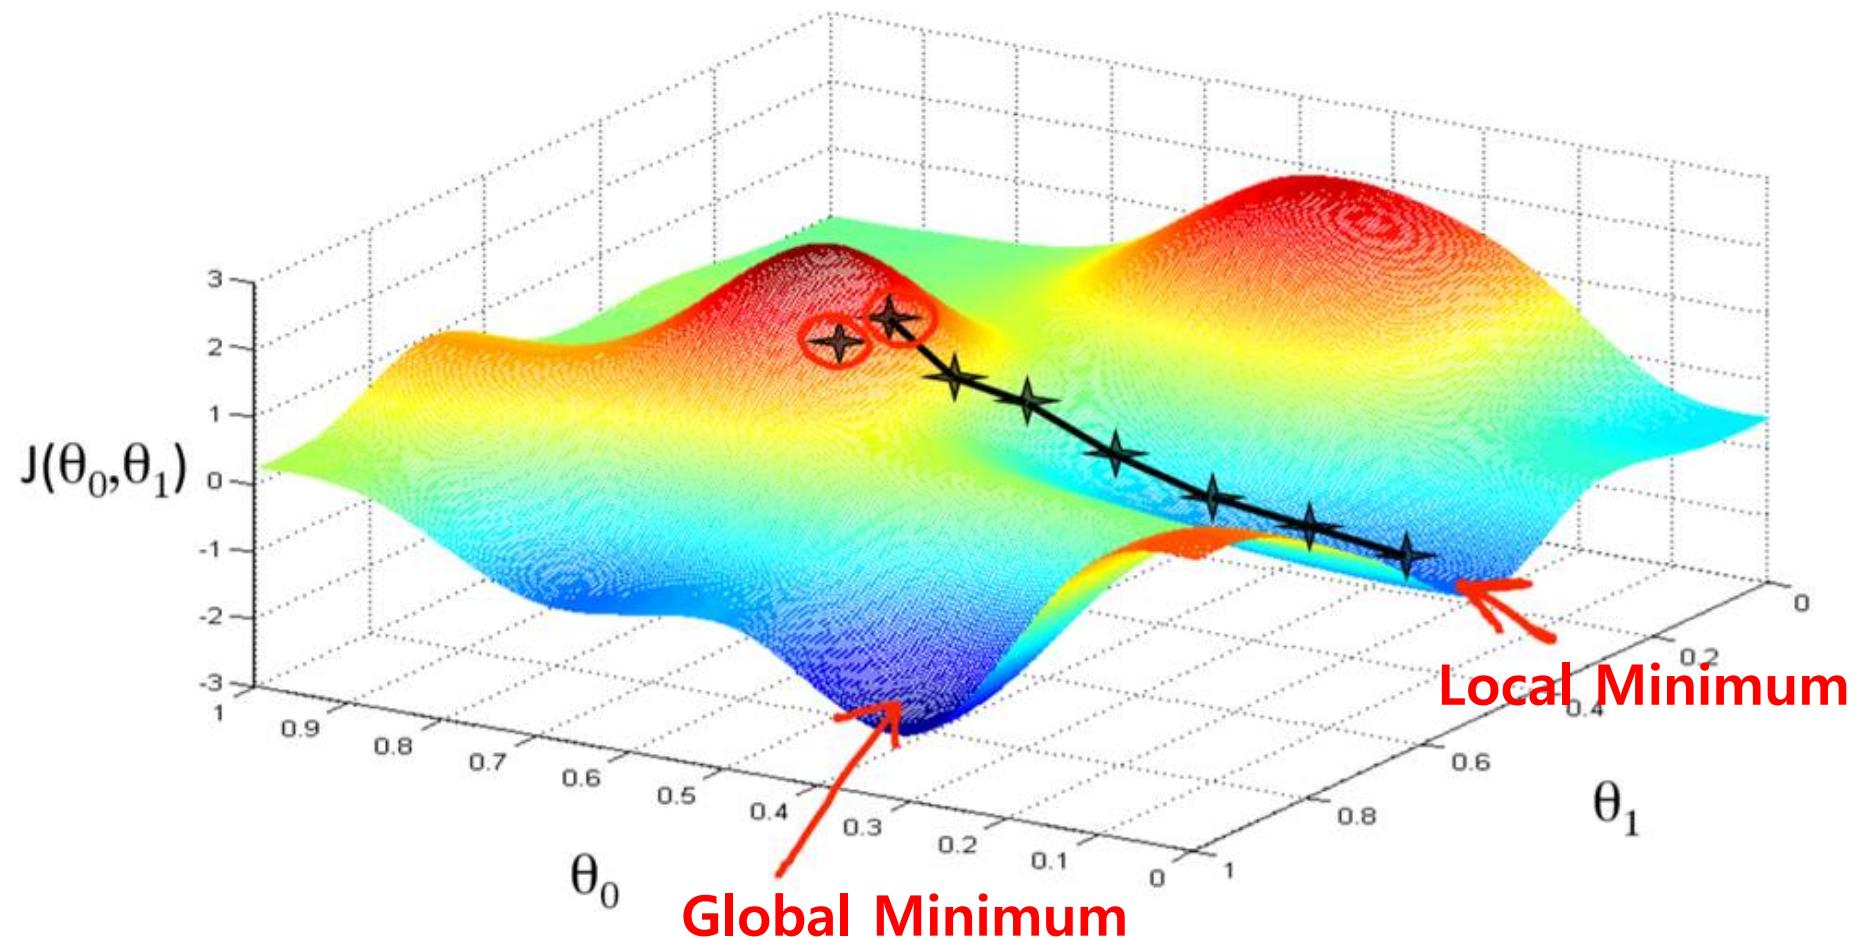
$$\frac{\partial L}{\partial p} = \frac{\partial L}{\partial p} \frac{\partial p}{\partial h_1} + \frac{\partial L}{\partial p} \frac{\partial p}{\partial h_2}$$



Backpropagation 요약

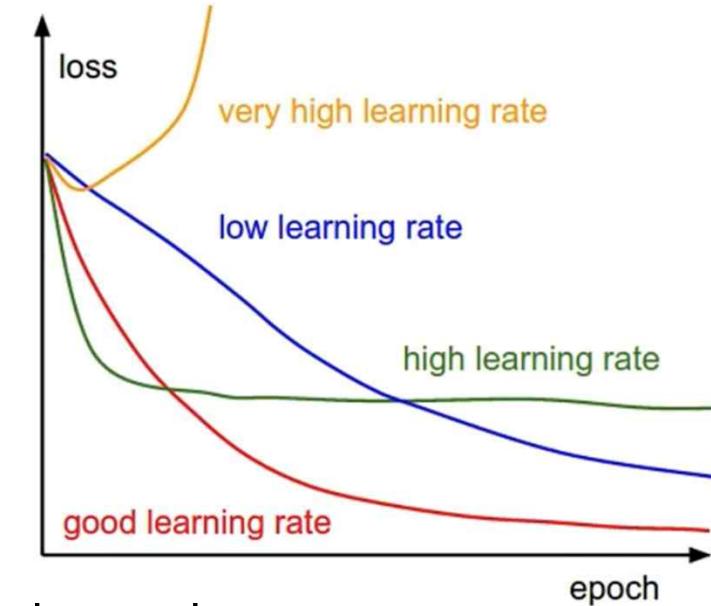
- 각각의 input data 에 대하여,
- 각 layer 별로 forward pass output 값을 계산
- Output layer 의 cost function 값을 계산
- Backpropagation 을 통해 cost function 의 derivative 를 전단계의 layer 로 전달
- Error term 의 값에 따라 각 layer 의 weight 를 update

Global Minima / Local Minima

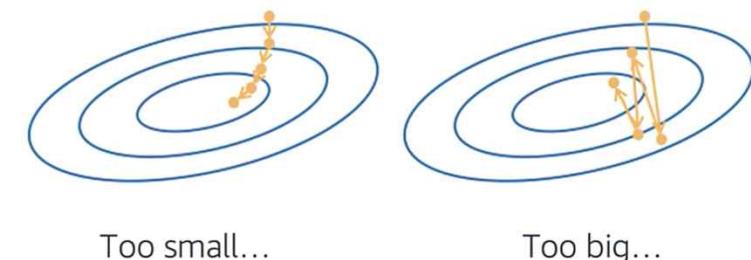


Learning Rate (α)

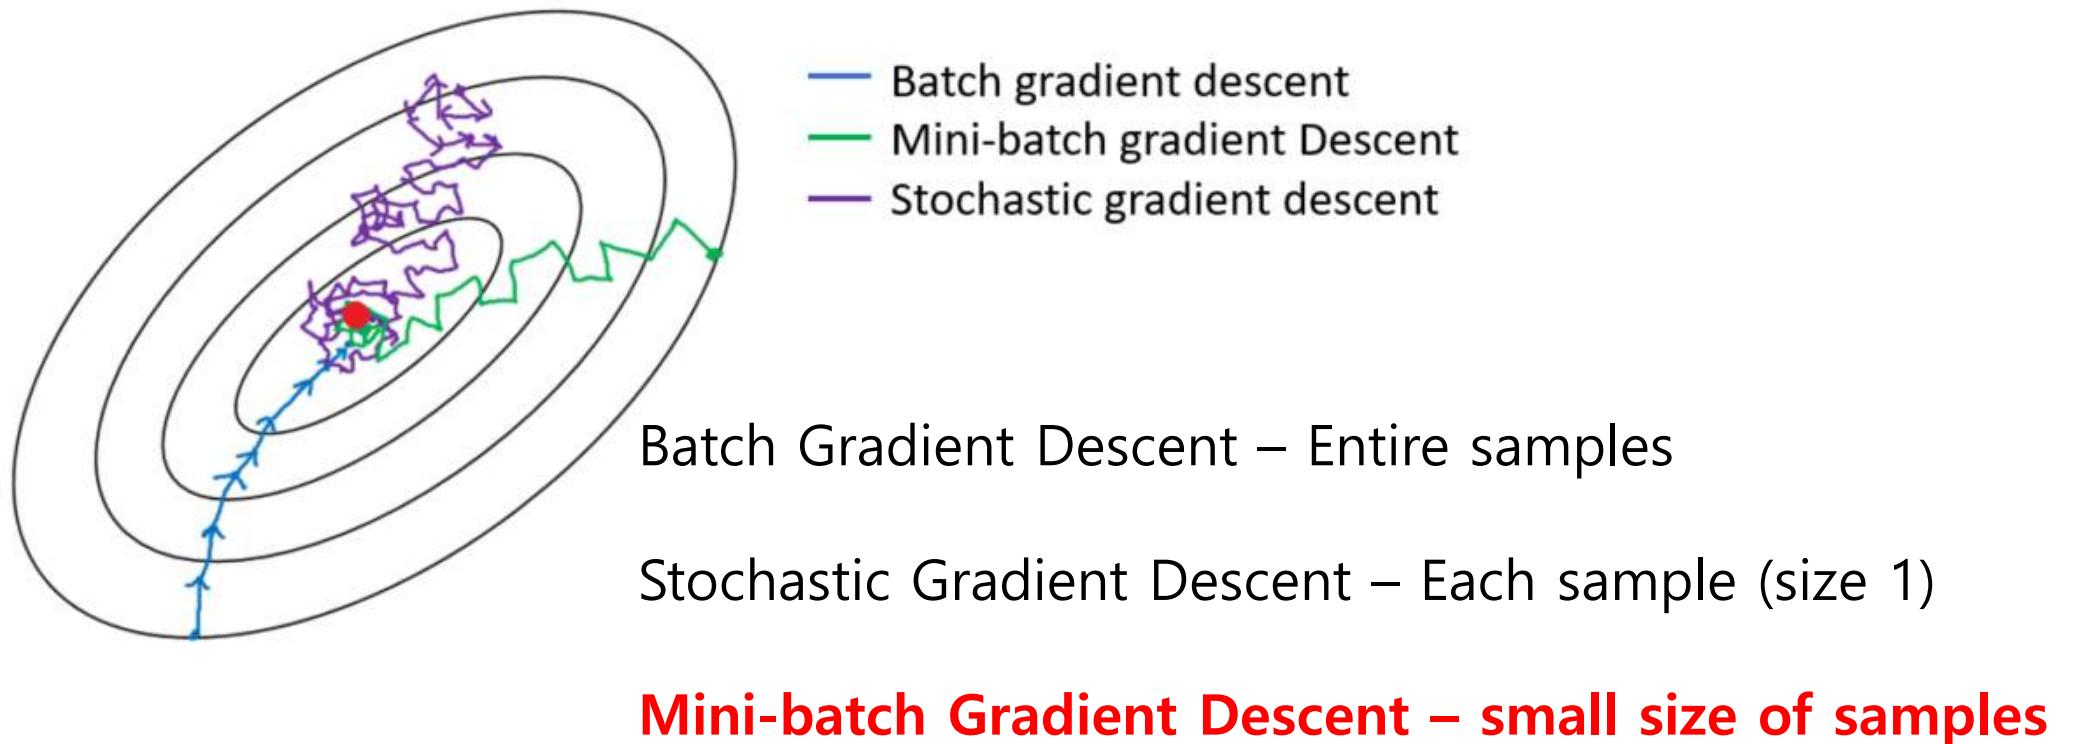
- Step size
- Range : $1e-6 \sim 1.0$ (default 0.01)
 - High learning rate – fast learning, may overshoot the target
 - Low learning rate – slow learning, may take long time



- Adaptive Learning Rates
초기값을 크게 주고 학습 진행에 따라 slow down



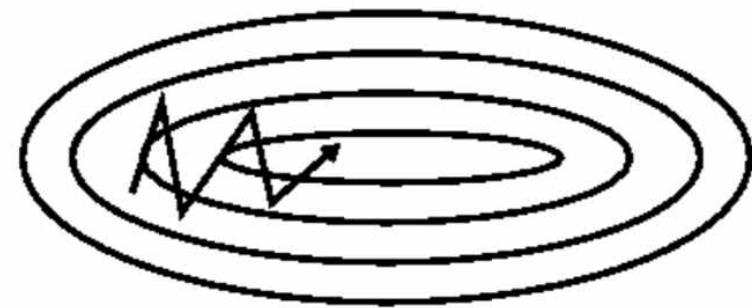
SGD (Stochastic Gradient Descent, 확률적 경사하강법)



Momentum : 방향성을 유지하며 가속



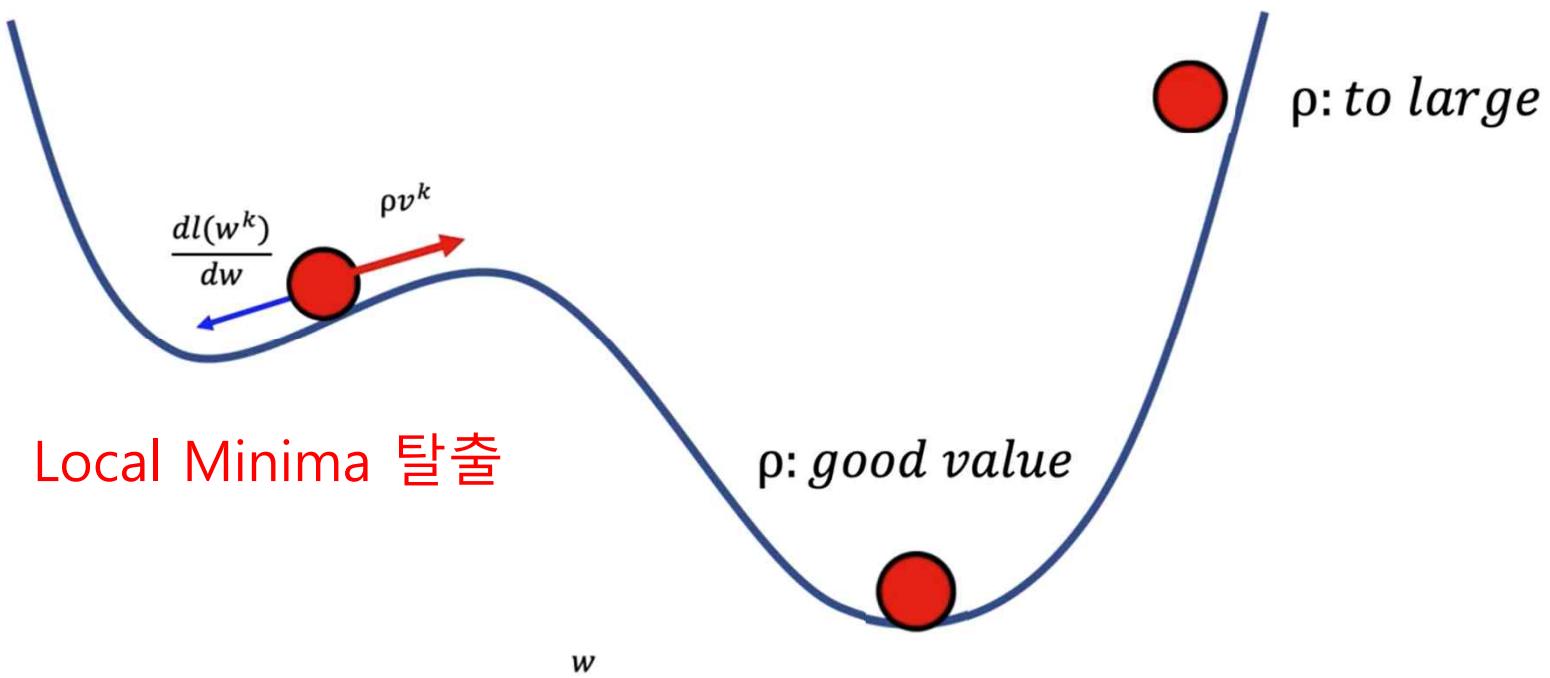
(a) SGD without momentum



(b) SGD with momentum

Global minimum 에 빨리 도달하기 위해 vertically 는 변화가 적고
horizontally 는 변화가 크도록 parameter 조절

Momentum 과 Local Minima

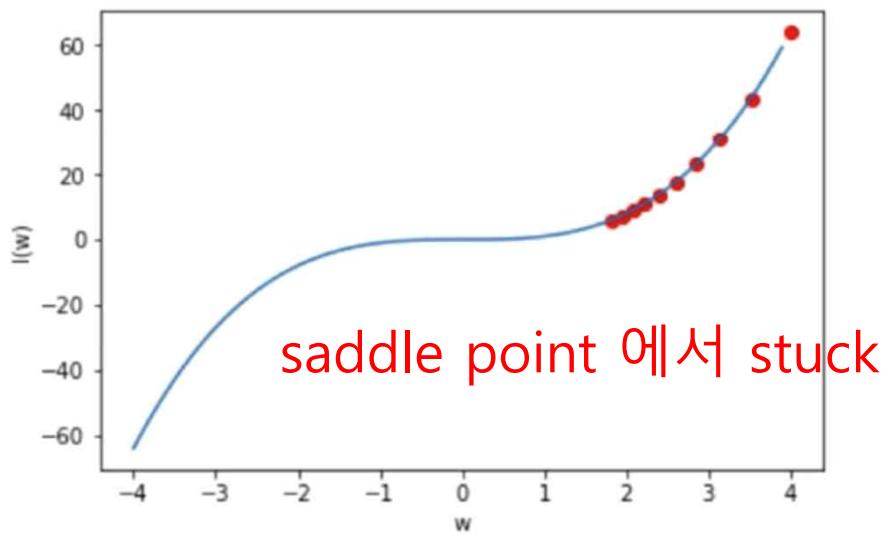


Momentum 과 weight update 비교

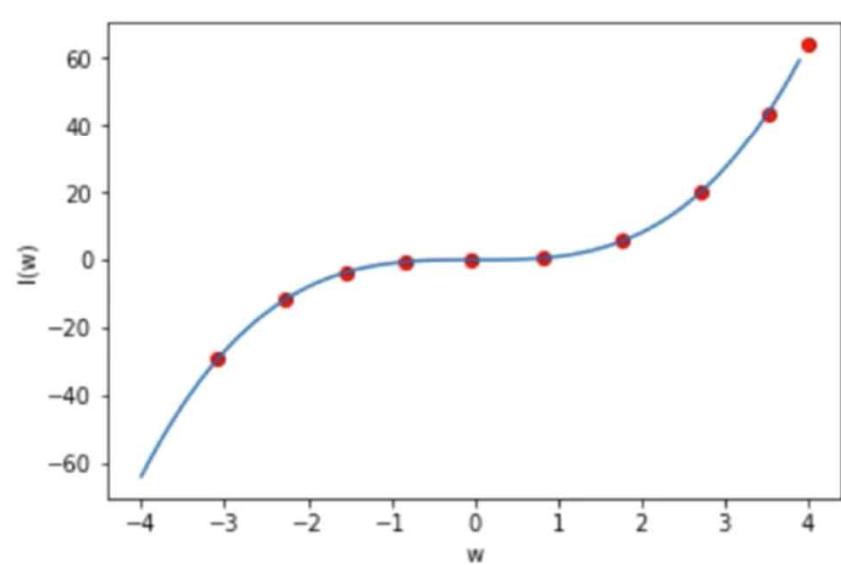
ρ : momentum

η : learning rate (lr)

lr=0.01, momentum=0



lr=0.01, momentum=0.90



Optimizers

- Stochastic Gradient Descent Optimizer
- RMSProp Optimzer
- Adagrad Optimizer
- Adam Optimizer, etc

http://ruder.io/content/images/2016/09/contours_evaluation_optimizers.gif

http://ruder.io/content/images/2016/09/saddle_point_evaluation_optimizers.gif

epoch

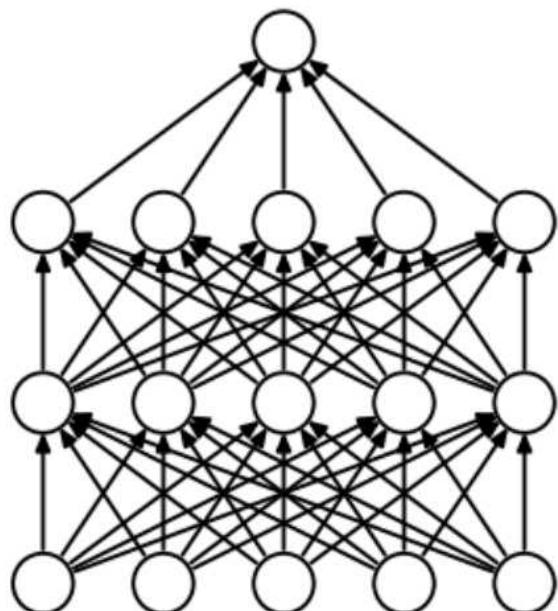
- 정의 – 전체 dataset 이 neural network 을 통해 한번 처리된 것
- Epoch 은 model 의 training 시에 hyperparameter 로 횟수 지정
- 하나의 epoch 은 한번에 처리하기 어려운 size 이므로 여러 개의 batch 로 나누어 처리
- Parameter training 을 위해서는 여러 번 epoch 을 반복해야 한다.
- One epoch 내에서의 iteration 횟수는 total sample size / batch size
- Ex) 1 epoch = 4 iterations = 2000 training example / 500 batches

Hyper-parameters

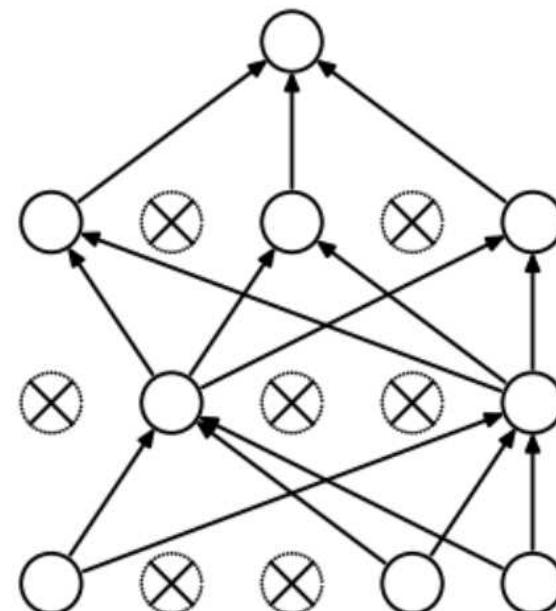
- α - Learning Rate
- β - momentum term
- # of layers
- Dropout rate
- # of epochs
- Batch size

Dropout regularization

Random 한 drop out 을 통한 과적합 방지 (특정 feature 의존 방지)



(a) Standard Neural Net



(b) After applying dropout.

Hyper-parameter 값 결정 ?

- 정해진 RULE 이 없음
- 유사한 model 참조
- 경험에 의한 guessing
- Grid search – computationally expensive

Tensorflow 2.0

What is Tensorflow ?

- <https://www.tensorflow.org/overview/?hl=ko>

The screenshot shows the TensorFlow Core website's homepage in Korean. At the top, there is a navigation bar with links for 'Install', 'Learn' (which is underlined), 'API', 'Resources', 'Community', 'Why TensorFlow', a search bar with the placeholder '검색' (Search), and a 'Language' dropdown set to 'Language'. Below the navigation bar, the page title 'TensorFlow Core' is displayed, followed by a horizontal menu with '개요', 'Tutorials', 'Guide', and 'TF 1'. A banner at the top of the main content area reads 'Last chance to register for TensorFlow World, Oct 28-31. Use code TF20 for 20% off select passes.' with a 'Register now' button. The main content features a large orange graphic on the left and text in Korean. The text includes: 'TensorFlow는 머신러닝을 위한 엔드 투 엔드 오픈소스 플랫폼입니다.', 'TensorFlow를 사용하면 초보자와 전문가 모두 머신러닝 모델을 쉽게 만들 수 있습니다. 시작하려면 아래의 섹션을 참조하세요.', and two orange buttons labeled '가이드 보기'. To the right of the text is a diagram illustrating a machine learning pipeline or architecture.

TensorFlow는 머신러닝을 위한 엔드 투 엔드 오픈소스 플랫폼입니다.

TensorFlow를 사용하면 초보자와 전문가 모두 머신러닝 모델을 쉽게 만들 수 있습니다. 시작하려면 아래의 섹션을 참조하세요.

가이드 보기 가이드 보기

가이드에서는 완벽한 엔드 투 엔드 예제와 함께 TensorFlow를 사용하는 방법을 보여줍니다.

가이드는 TensorFlow의 개념과 구성요소에 대해 설명합니다.

The diagram illustrates a machine learning pipeline. It shows a laptop on the left connected to a central processing unit (CPU) or GPU, which is further connected to a server rack. The connections are represented by orange lines with circular endpoints, indicating data flow between different components of the system.

Tensorflow Installation

- pip install --upgrade tensorflow
- import tensorflow as tf
- tf.__version__

일반용 – Sequential API

```
import tensorflow as tf
mnist = tf.keras.datasets.mnist

(x_train, y_train), (x_test, y_test) = mnist.load_data()
x_train, x_test = x_train / 255.0, x_test / 255.0

model = tf.keras.models.Sequential([
    tf.keras.layers.Flatten(input_shape=(28, 28)),
    tf.keras.layers.Dense(128, activation='relu'),
    tf.keras.layers.Dropout(0.2),
    tf.keras.layers.Dense(10, activation='softmax')
])

model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

model.fit(x_train, y_train, epochs=5)
model.evaluate(x_test, y_test)
```

전문가용 – Subclassing API

```
class MyModel(tf.keras.Model):
    def __init__(self):
        super(MyModel, self).__init__()
        self.conv1 = Conv2D(32, 3, activation='relu')
        self.flatten = Flatten()
        self.d1 = Dense(128, activation='relu')
        self.d2 = Dense(10, activation='softmax')

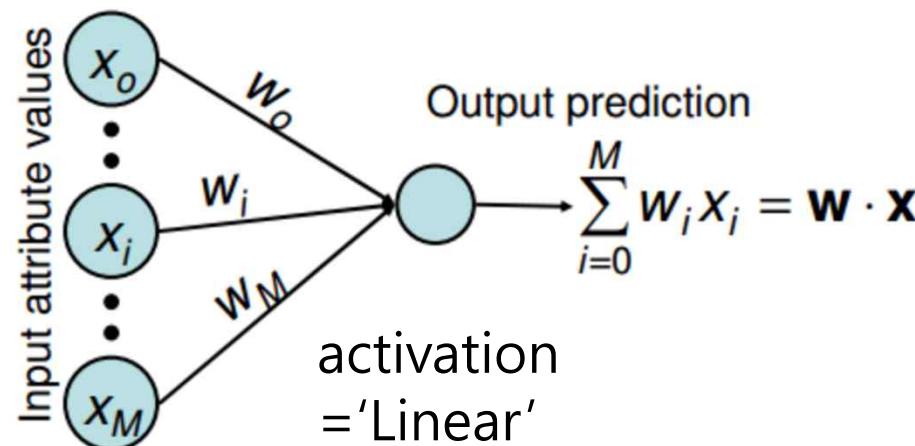
    def call(self, x):
        x = self.conv1(x)
        x = self.flatten(x)
        x = self.d1(x)
        return self.d2(x)

model = MyModel()

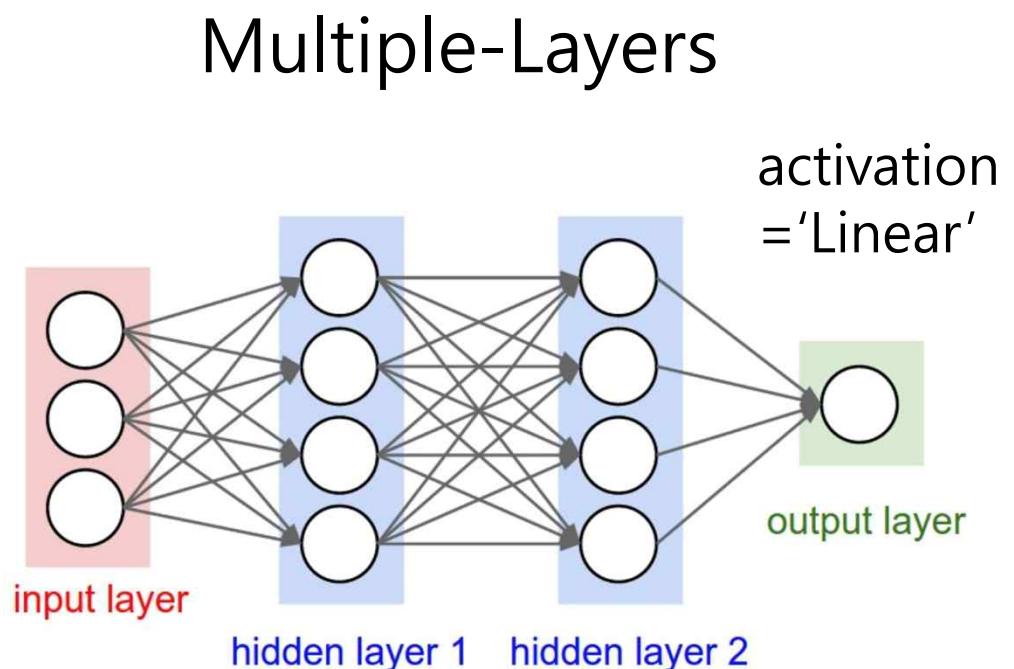
with tf.GradientTape() as tape:
    logits = model(images)
    loss_value = loss(logits, labels)
grads = tape.gradient(loss_value, model.trainable_variables)
optimizer.apply_gradients(zip(grads, model.trainable_variables))
```

Neural Network 을 이용한 Regression

NN 을 이용한 Linear Regression



One-Layer



실습 : 100. Boston 주택가격 Regression

1. Boston House Price Dataset

- `sklearn.datasets.load_boston` 이용

2. 보스턴 시의 주택 가격에 대한 데이터

- 주택의 여러가진 요건들과 주택의 가격 정보가 포함.
- 주택의 가격에 영향을 미치는 요소를 이용하여 회귀분석

3. 13 개의 독립변수와 1 개의 종속변수 (주택가격 중앙값) 으로 구성

- Feature 설명

CRIM 자치시(town) 별 1인당 범죄율,

ZN 25,000 평방피트를 초과하는 거주지역의 비율

INDUS 비소매상업지역이 점유하고 있는 토지의 비율

CHAS 찰스강에 대한 더미변수(강의 경계에 위치한 경우는 1, 아니면 0)

NOX 10ppm 당 농축 일산화질소

RM 주택 1가구당 평균 방의 개수

AGE 1940년 이전에 건축된 소유주택의 비율

DIS 5개의 보스턴 직업센터까지의 접근성 지수

RAD 방사형 도로까지의 접근성 지수

TAX 10,000 달러 당 재산세율

PTRATIO 자치시(town)별 학생/교사 비율

B $1000(Bk - 0.63)^2$, 여기서 Bk는 자치시별 흑인의 비율을 말함

LSTAT 모집단의 하위계층의 비율(%)

MEDV 본인 소유의 주택가격(중앙값) (단위: \$1,000)

Logistic Regression

(이진 분류, Binary Classification)

Sigmoid 함수

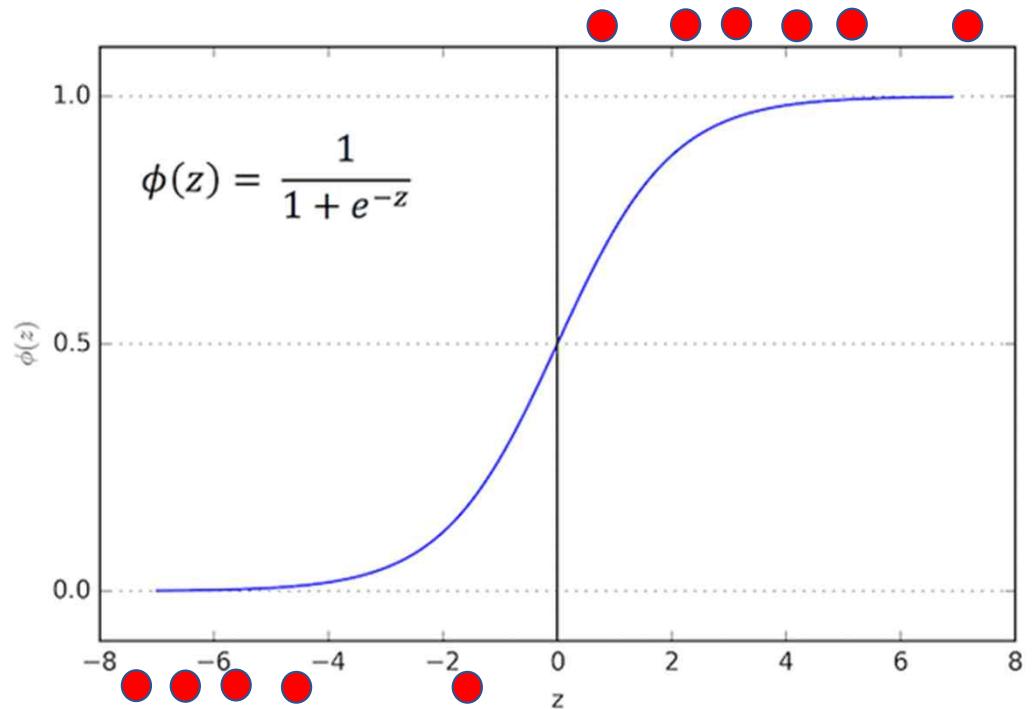
- S curve 형성
- Logistic 함수

logit

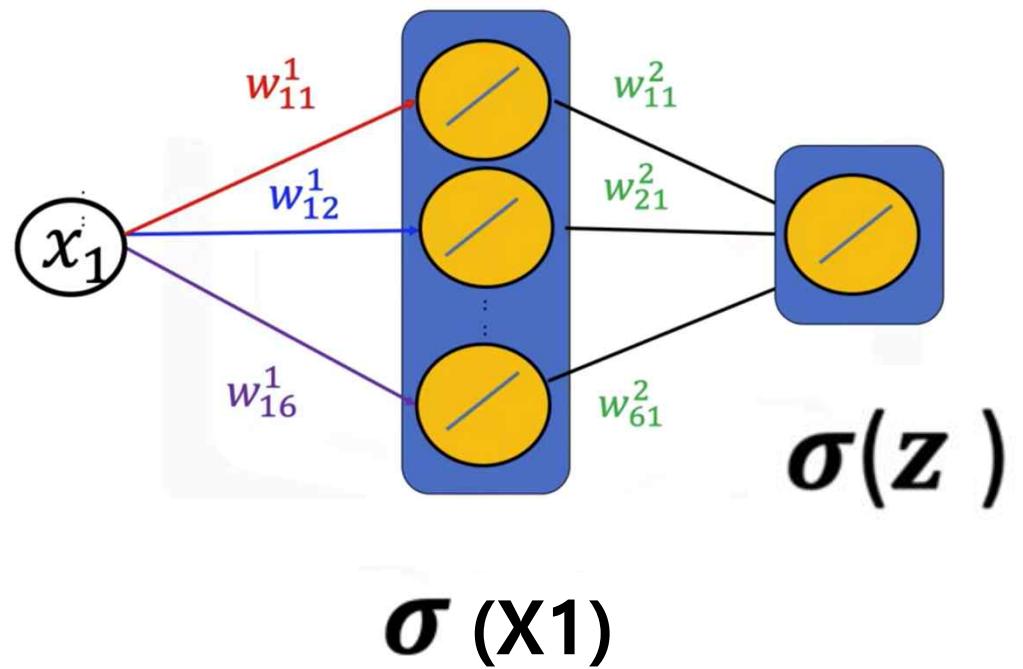
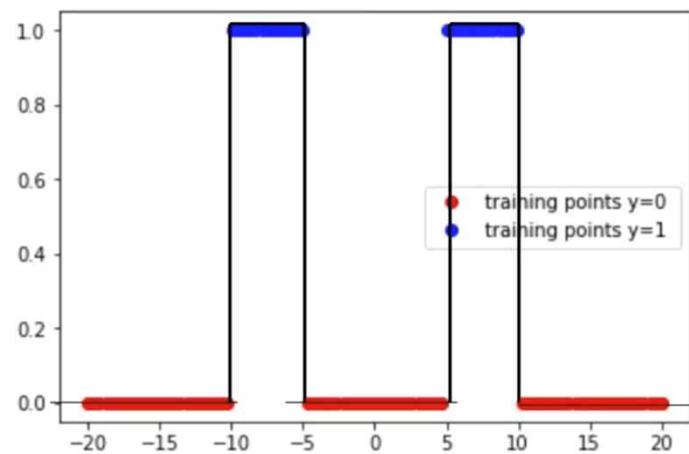
$$f(z) = \frac{1}{1+e^{-z}} \quad (z = \theta X)$$

$$\hat{y} = \begin{cases} 0 & \text{if } f(z) < 0.5 \\ 1 & \text{if } f(z) \geq 0.5 \end{cases}$$

- [0, 1] 로 bound 되어 있음
- 미분가능
- 0.5 부근에서 급격히 변화



NN 을 이용한 Logistic Regression

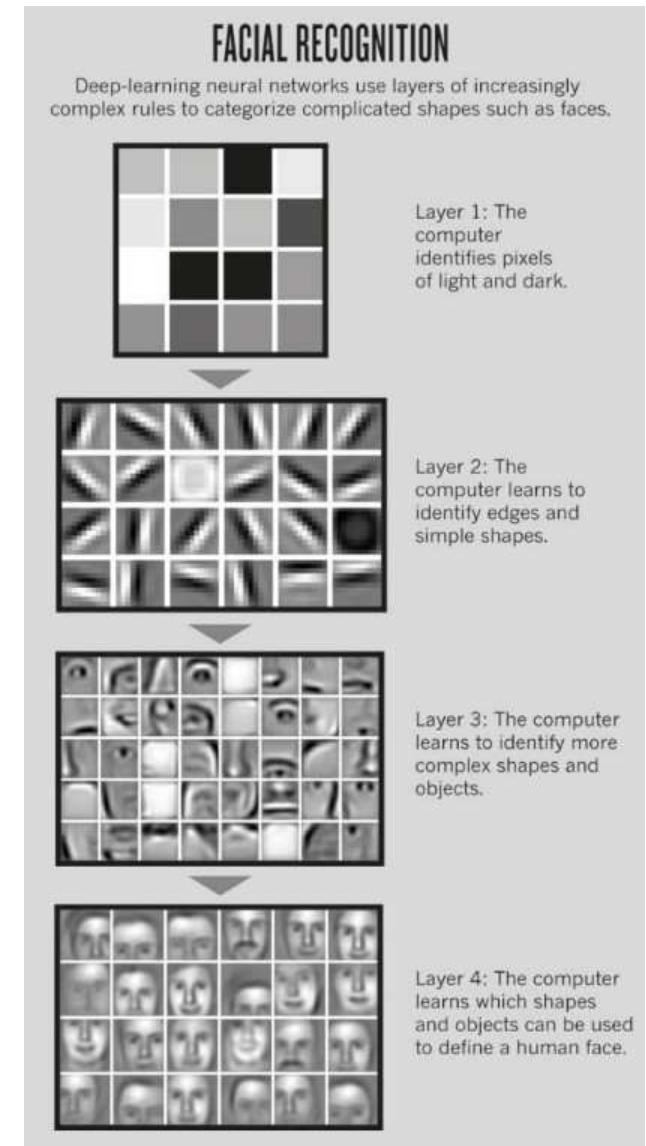
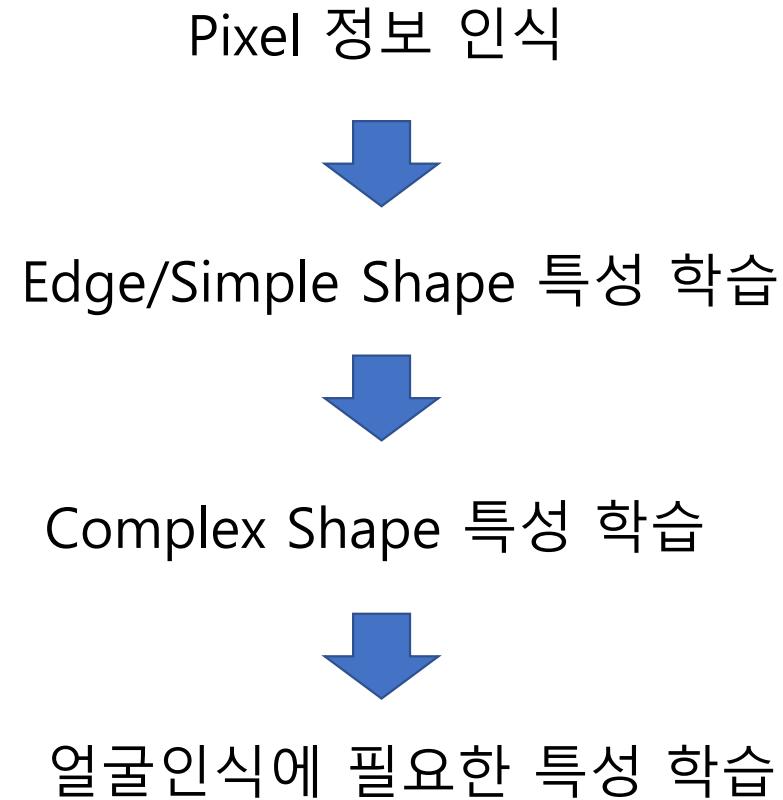


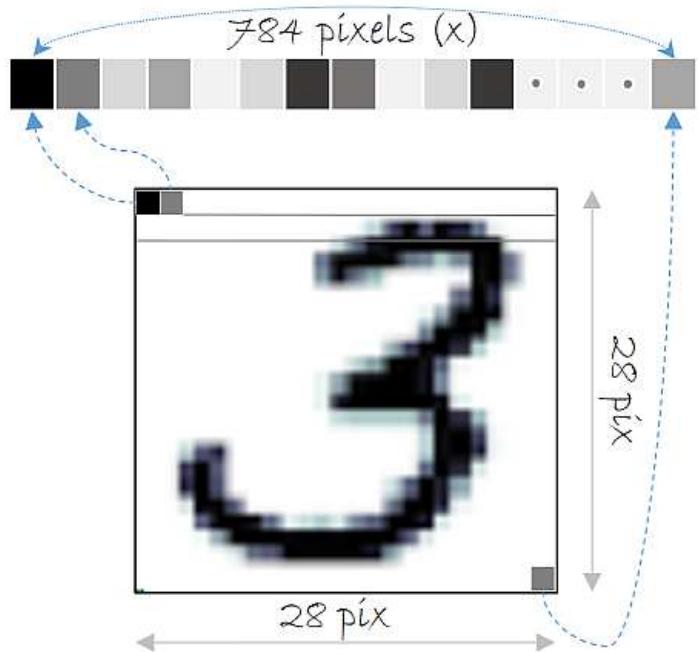
실습 : 110. Malware Detection - Logistic Regression

1. Malware Detection - binary classification
2. Neural Network Model 구성 및 Compile
3. Model Train
4. Performance Evaluation

CNN (Convolutional Neural Network)

Multiple Levels of Abstraction





2차원 이미지의 1차원 vector 처리

$60000 \times 28 \times 28 \rightarrow \text{reshape}(60000, 784)$

Image Data 의
공간적, 지역적 특성 상실

If 1 mega pixel $\rightarrow 1,000 \times 1,000 \times 3 = 3 \text{ million features !!!}$

$\rightarrow 300 \text{ 만 차원} \times \text{Layer 수} \times \text{각 Layer 의 Neuron 수}$

\rightarrow 계산량 급증

\rightarrow Image Data 를 처리하기 위한 특별한 구조의 Neural Network 필요

CNN 의 특별한 Layers

- **Convolutional Layer (합성곱층)**

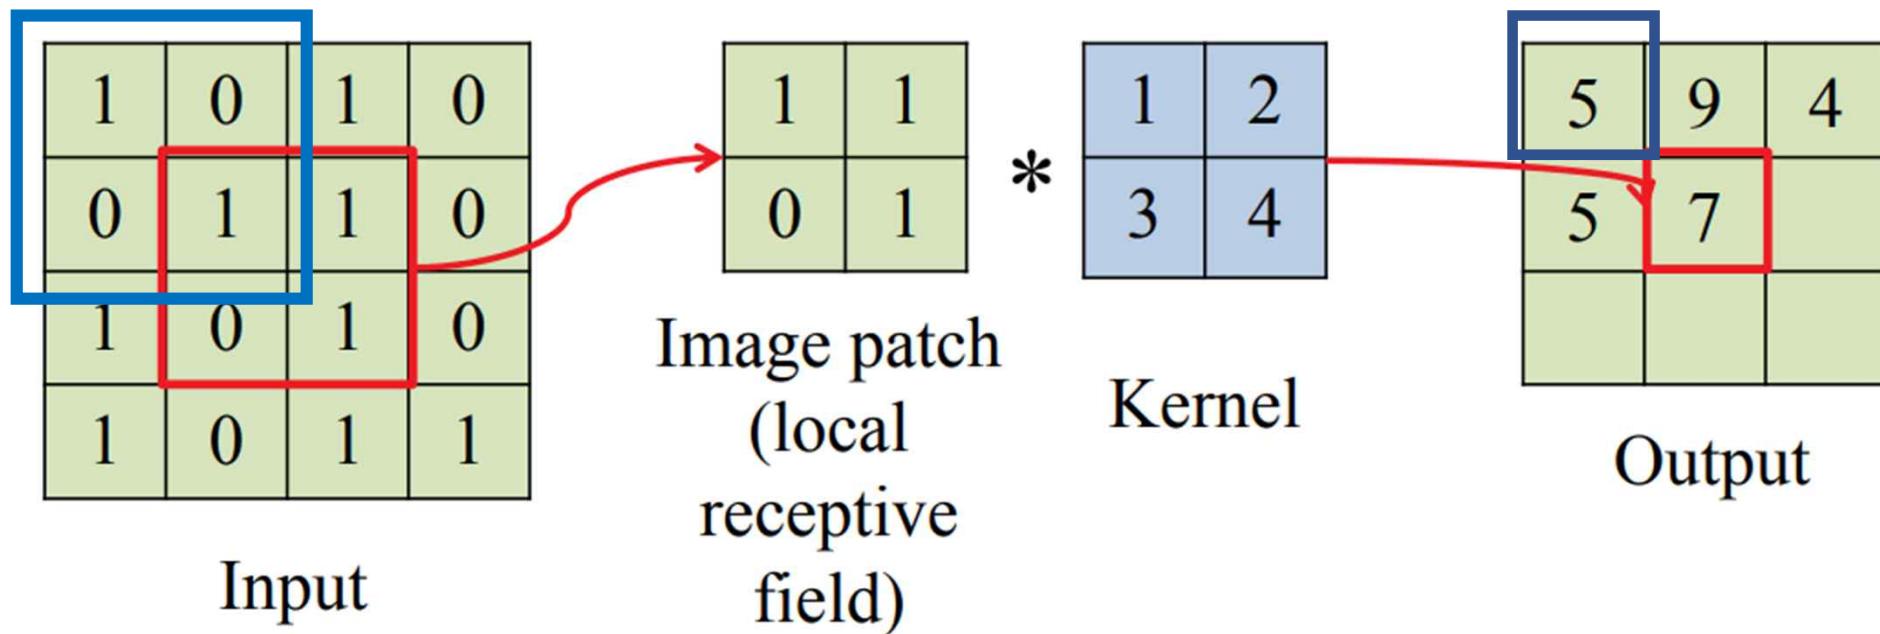
- Image 정보의 공간적 지역 특성 보존
- Filter (Kernel) 을 이용한 이미지 특성 추출

- **Pooling Layer (풀링층)**

- Image data 의 정보 손실 없는 압축

→ 계산량 및 메모리 사용량 축소, 파라미터의 수 감소 (과적합 방지)

How Convolution works ?

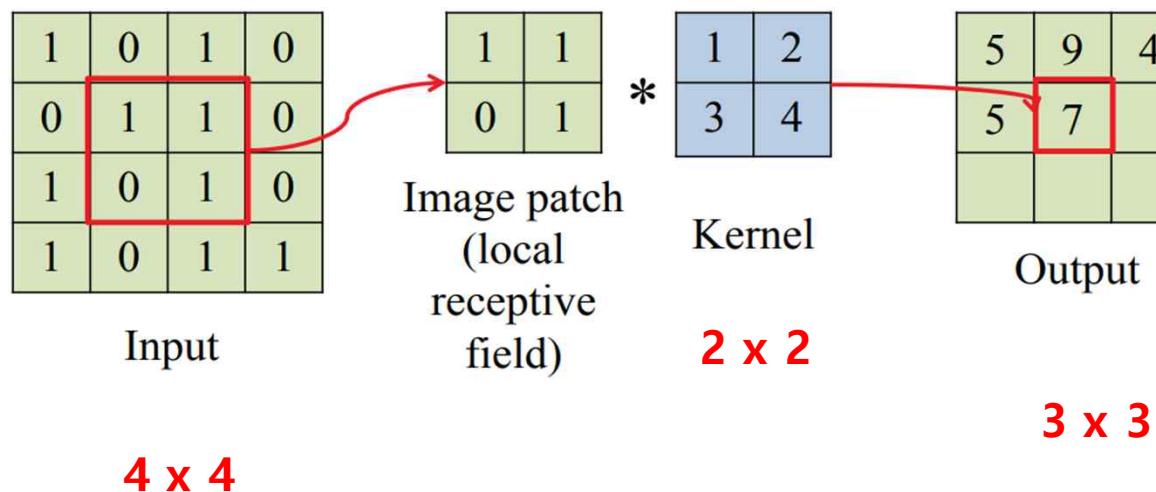


Kernel_size=(2, 2), stride=(1, 1), No padding

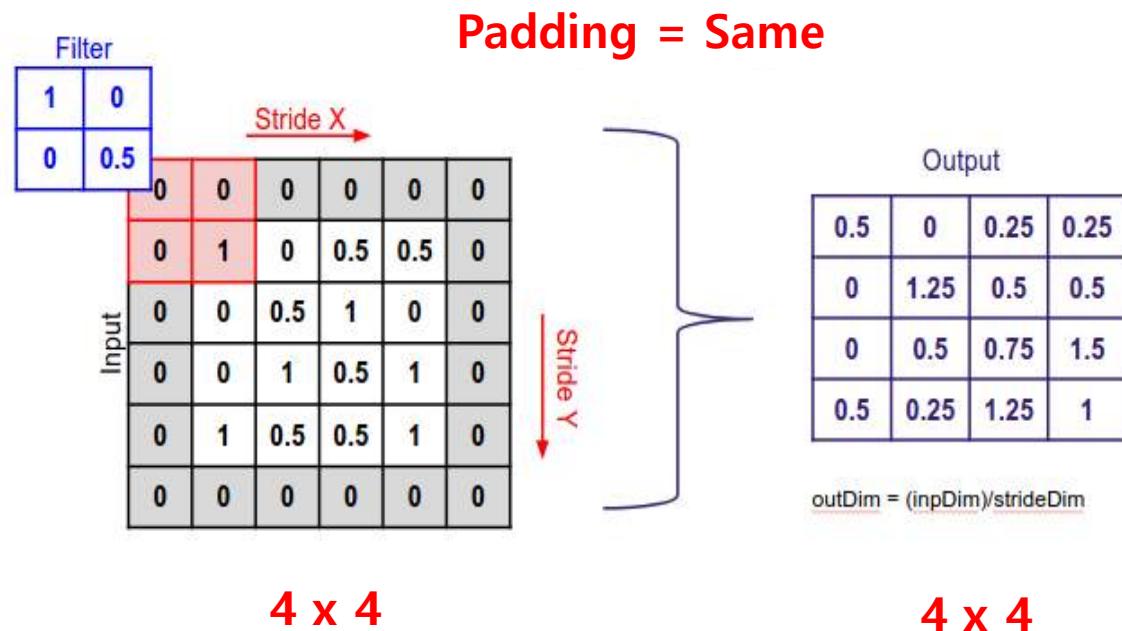
Padding

- Convolution 때마다 image의 edge 정보가 소실

Padding = **Valid (No Padding)**



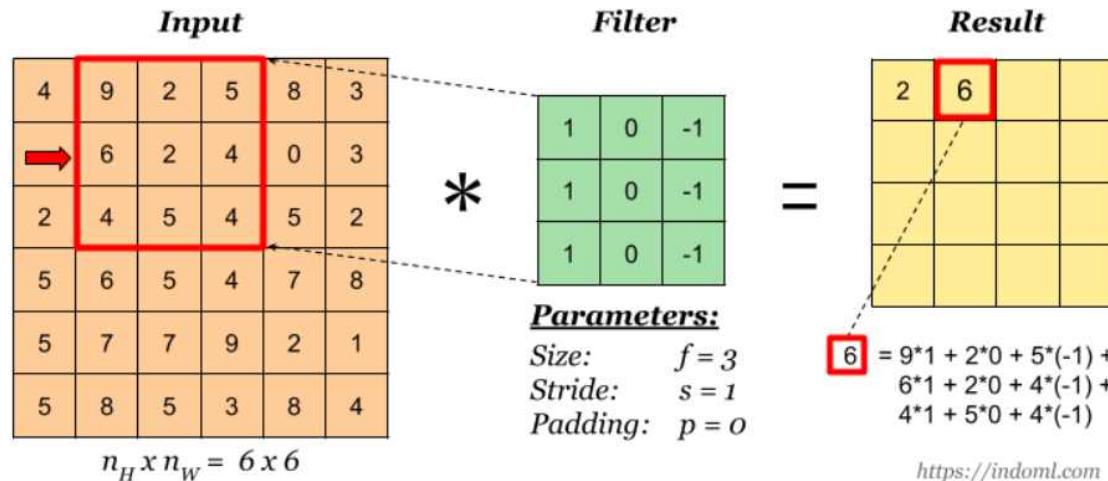
- Input size = output size (\rightarrow Input 의 주위에 0 pixel padding)
- Padding = “same” convolution



$$\text{outDim} = (\text{inpDim})/\text{strideDim}$$

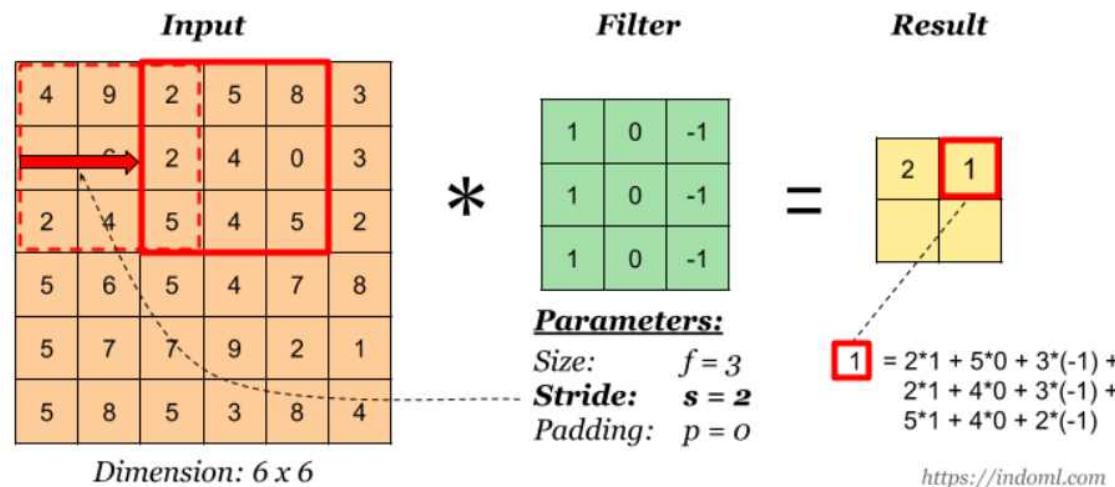
Striding

Stride = 1



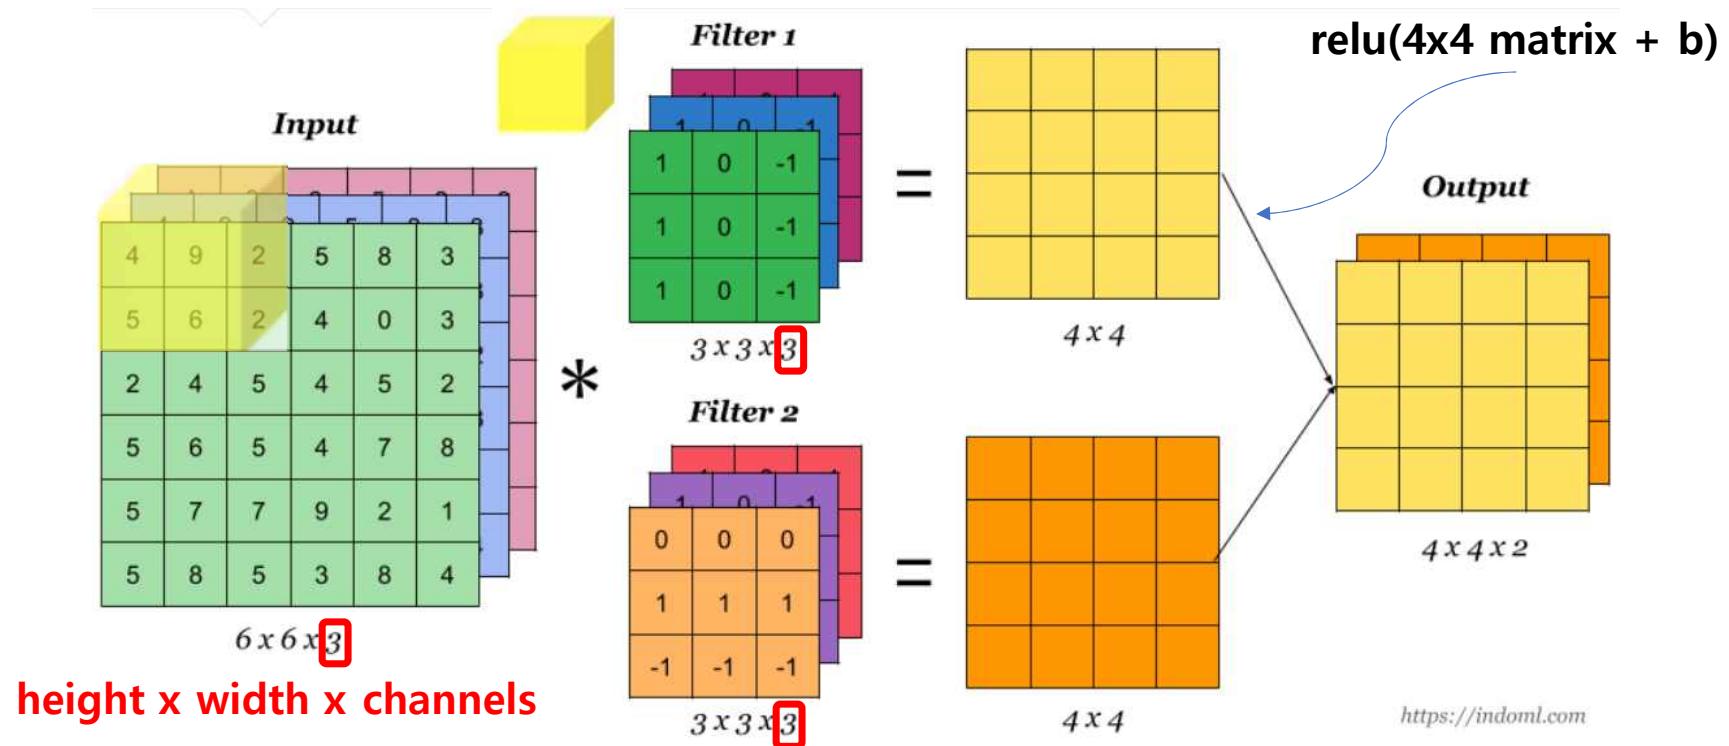
4 x 4

Stride = 2



2 x 2

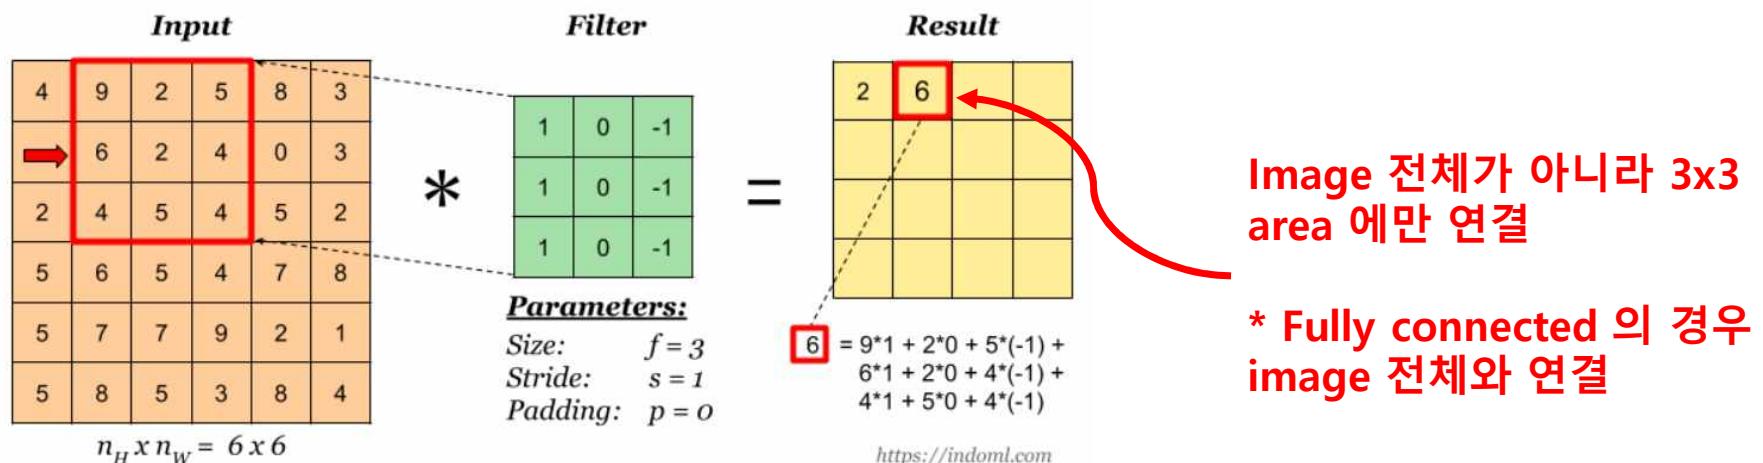
Convolutions over Volumes (RGB images)



Convolution Layer 의 2 가지 특성

1. Locality

- kernel size 만큼의 작은 구역 (patch) 의 인접한 pixel 들에 대한 correlation 관계를 비선형 필터를 적용하여 추출
- 이러한 필터를 여러 개 적용하면 다양한 local 특징을 추출 가능



2. Parameter Sharing

- input 상의 모든 patch 들은 동일한 kernel 을 적용하여 next layer 의 output 을 출력한다.
ex) vertical edge detector – image 전체에 동일한 kernel 적용
- Fully connected layer 를 image data 에 사용할 경우에 비해 parameter 의 수를 획기적으로 줄임

Kernel(Filter) 의 특성 추출 예

Original image

convolution

$*$

Kernel

$=$

Edge detection

$*$

Sharpening

$*$ $\frac{1}{9}$

$=$

Blurring

The diagram illustrates the convolution process on a squirrel image. It shows three examples of how different kernels extract specific features from the input image.

- Edge detection:** A blue arrow labeled "convolution" points to the first row of the equation. The kernel is a 3x3 matrix:

-1	-1	-1
-1	8	-1
-1	-1	-1

The result is a processed image where edges are highlighted in yellow.
- Sharpening:** The second row shows the original image followed by a multiplication sign, then a 3x3 kernel:

0	-1	0
-1	5	-1
0	-1	0

The result is a sharper version of the squirrel image.
- Blurring:** The third row shows the original image followed by a multiplication sign, then a 3x3 kernel with all elements equal to $\frac{1}{9}$:

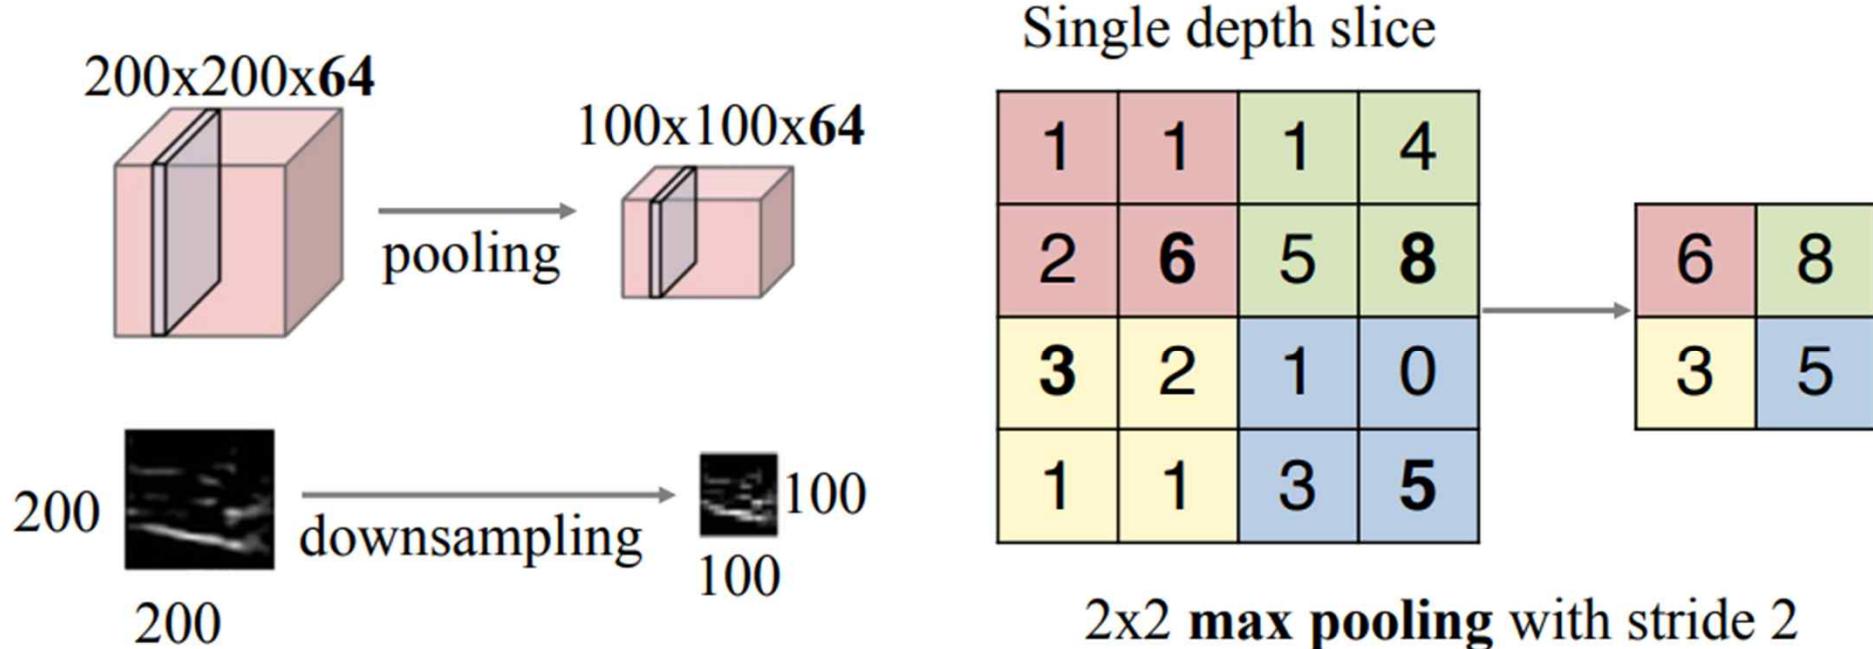
1	1	1
1	1	1
1	1	1

The result is a blurred version of the squirrel image.

- CNN 이전에는 edge detection filter 를 computer vision 전문가들이 모두 manually 만들어 줌
ex) 수직 / 수평 / 45 도 / 명암 구분 filter 등
- Neural Network 은 훨씬 더 다양한 특성의 filter 들을 back-propagation 을 이용하여 자동으로 학습하고 스스로 만들어 냄

How Pooling works ?

- Pooling 의 뉴런은 가중치가 없음
- 최대, 평균을 이용한 이미지 subsampling (부표본 작성)



Pooling Layer 의 2 가지 특성

1. Positional Invariance

- 특정 pixel 의 정확한 position 에 less sensitive
- 여러 번의 pooling 을 거치면 넓은 영역에 걸쳐 같은 효과 발생
(See Wider !)

2. Size 축소

- 계산량을 크게 줄임
- 과적합 방지

What is Flattening ?

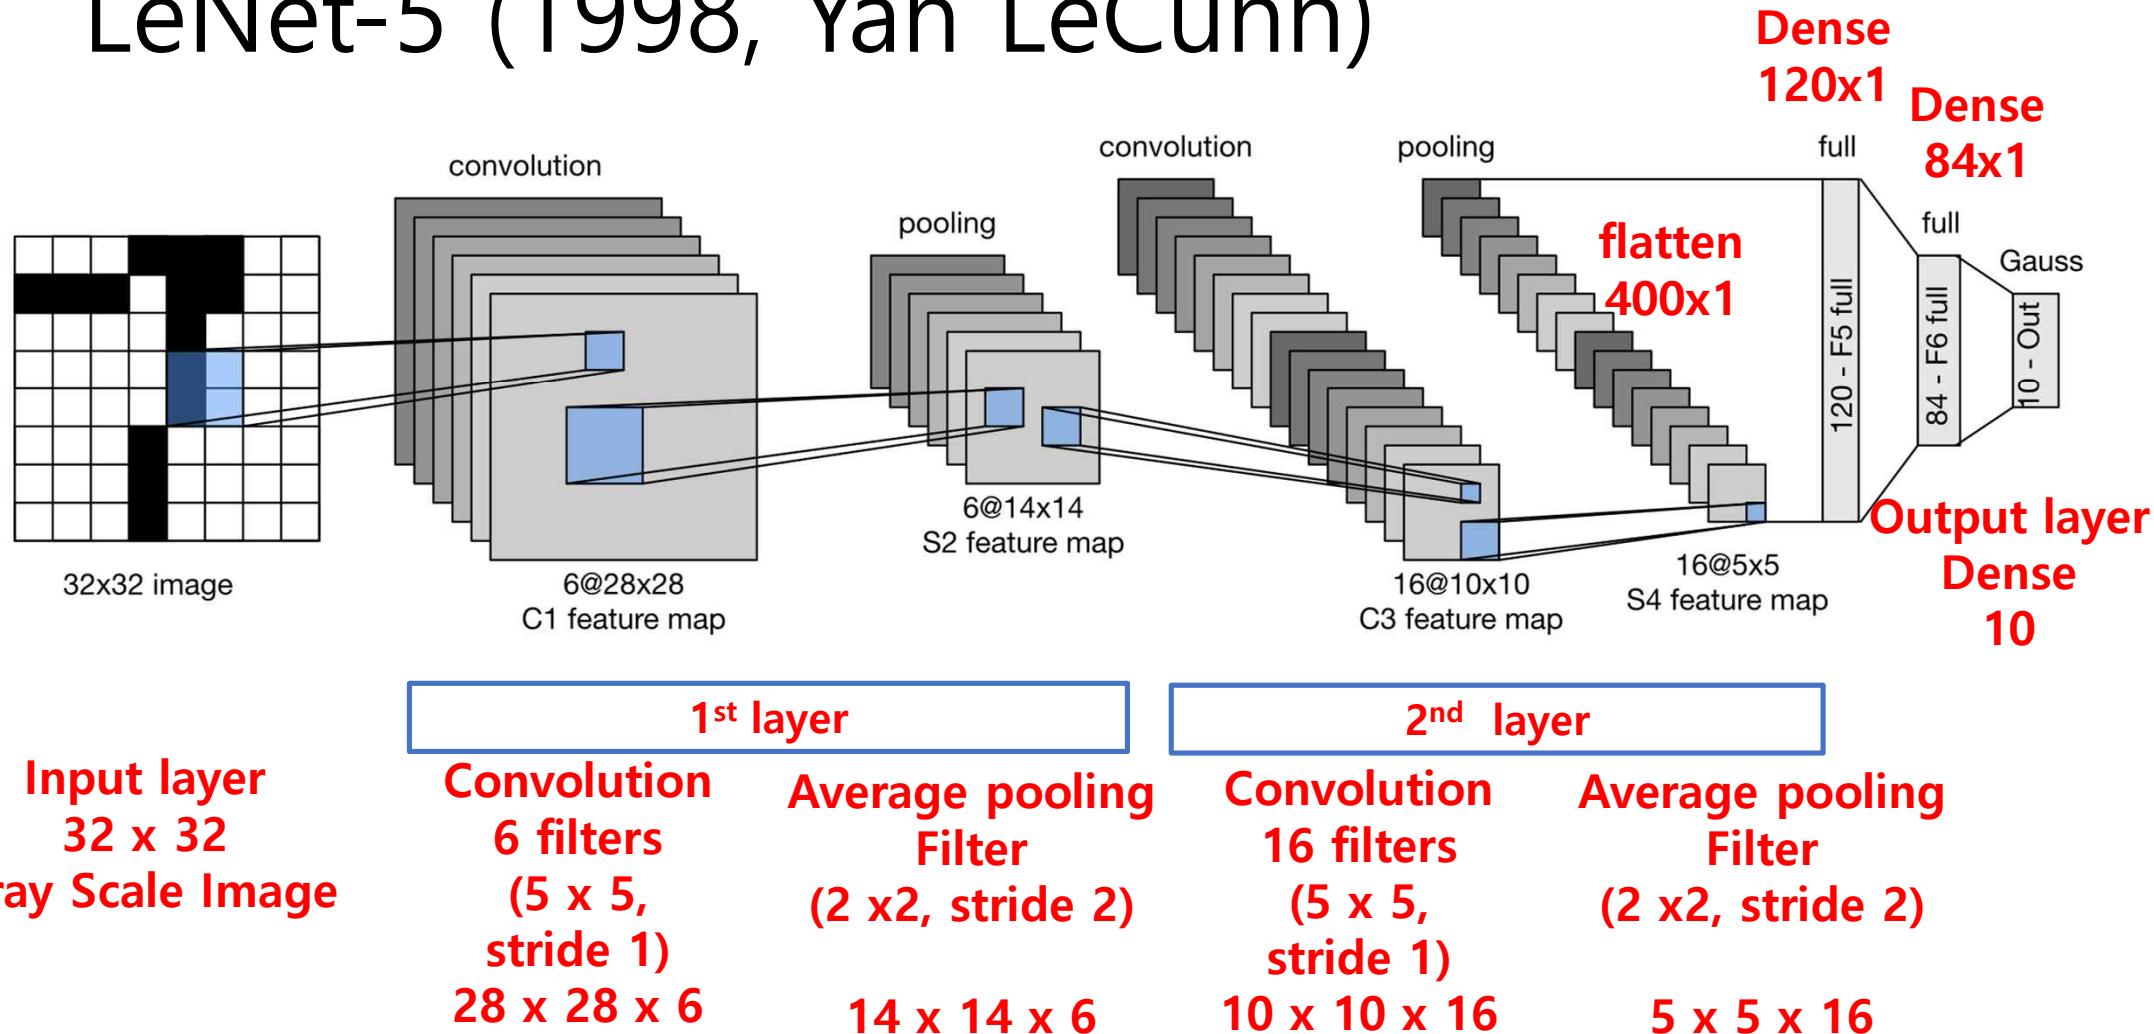
1	1	0
4	2	1
0	2	1

Pooled Feature
Map



1
1
0
4
2
1
0
2
1

LeNet-5 (1998, Yan LeCunn)



실습 : Le Net 을 이용한 손글씨 인식

1. Keras 를 이용한 Le Net 구축
2. 구축한 Le Net model 을 이용하여 Mnist 손글씨 분류

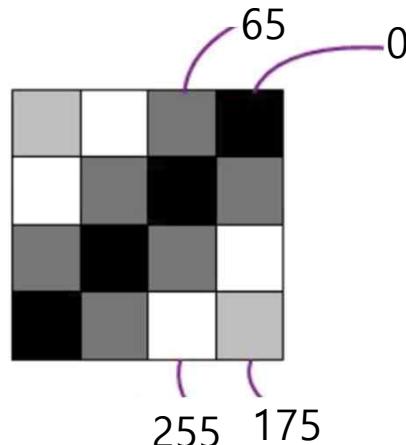
Mnist Dataset 소개

- Mixed National Institute of Standards and Technology
- 0 ~ 9 의 10 개 숫자 손글씨 image dataset
- 28 x 28 pixel 의 gray scale image
- 각 image 마다 0 to 9 의 label로 쌍을 이루고 있음
- Train set 60,000 / Test set 10,000
- Machine Learning 의 Hello World 에 해당

Pixel 의 구성

0 – black

255 - white



label = 5



label = 0



label = 4



label = 1



label = 9



label = 2



label = 1



label = 3



label = 1



label = 4



label = 3



label = 5



label = 3



label = 6



label = 1



label = 7



label = 2



label = 8



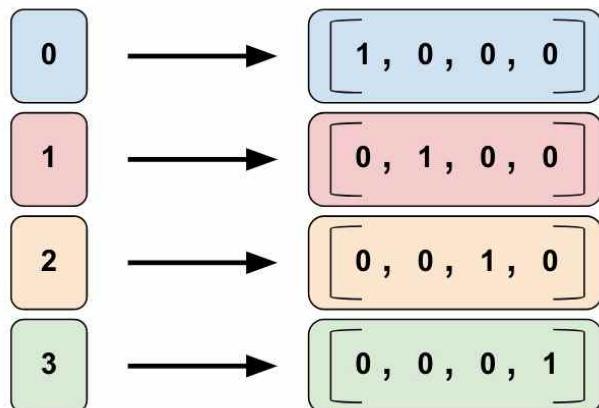
label = 6



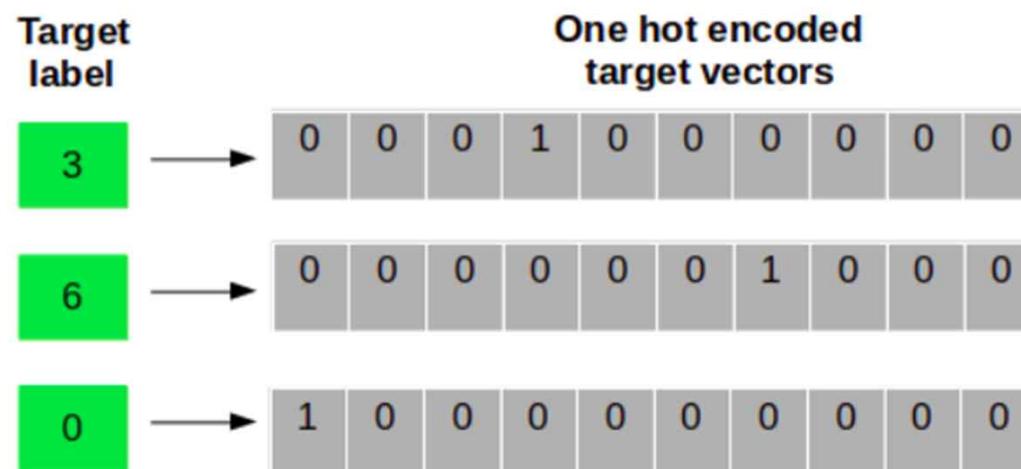
label = 9



One-Hot encoding



color	color_red	color_blue	color_green
red	1	0	0
green	0	0	1
blue	0	1	0
red	1	0	0



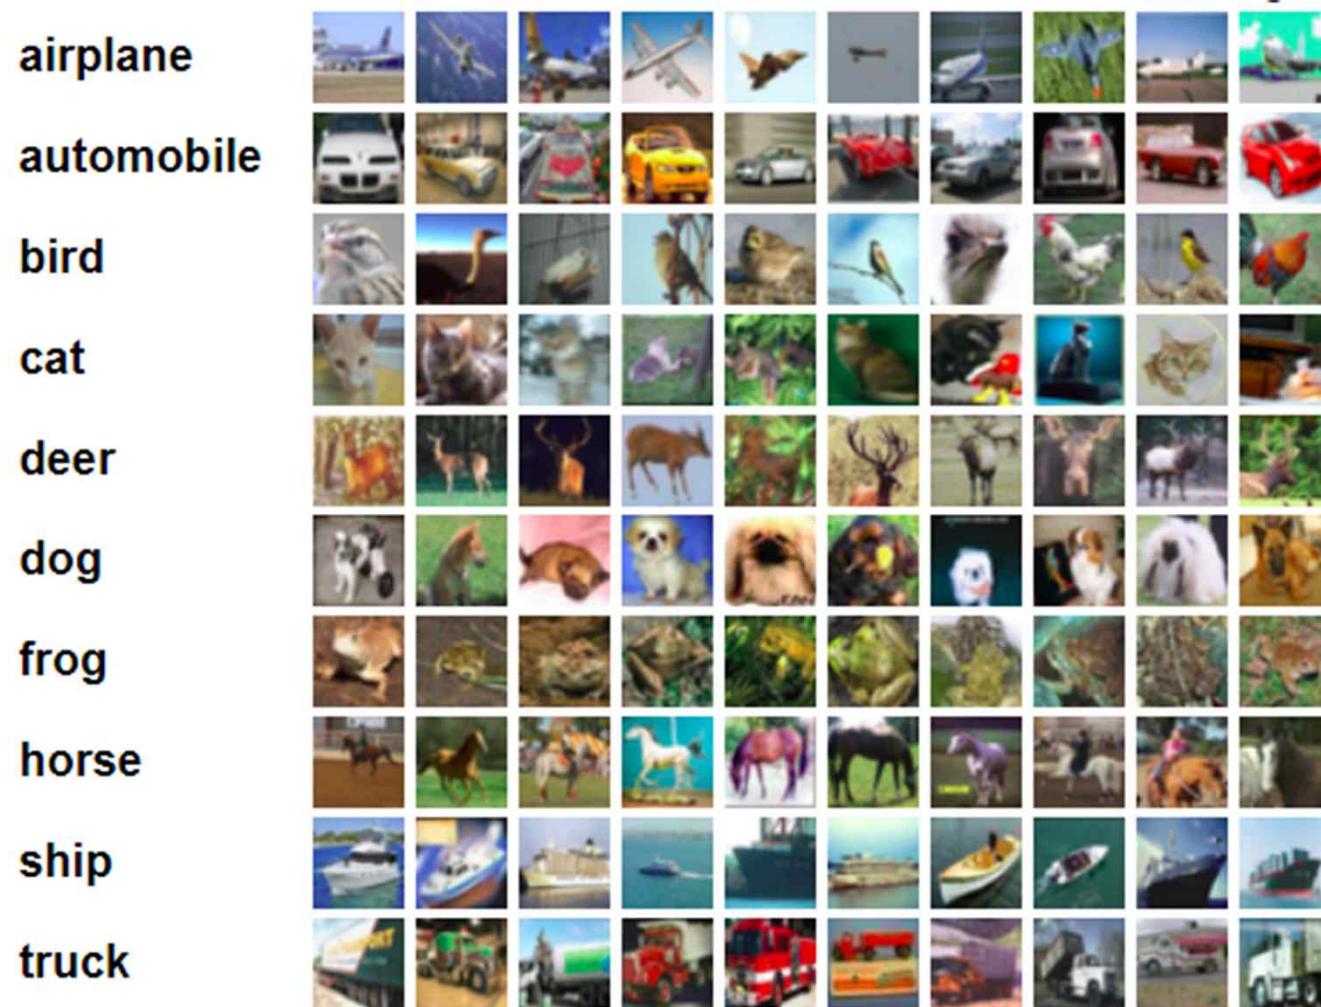
Famous CNN models

- Alex Net – 2012 년 ILSVRC(ImageNet Large Scale Visual Recognition Competition) 대회 우승
- GoogleLeNet(Inception Net) – 2014 년 ILSVRC 대회 우승
- ResNet – 2015 년 ILSVRC 대회 우승 (152 개 층)
- MobileNet – mobile device 용 pre-trained model (ImageNet 20,000 개 classes)
- VGG-16 : Keras built-in pre-trained model (2014 년, 16 layers)

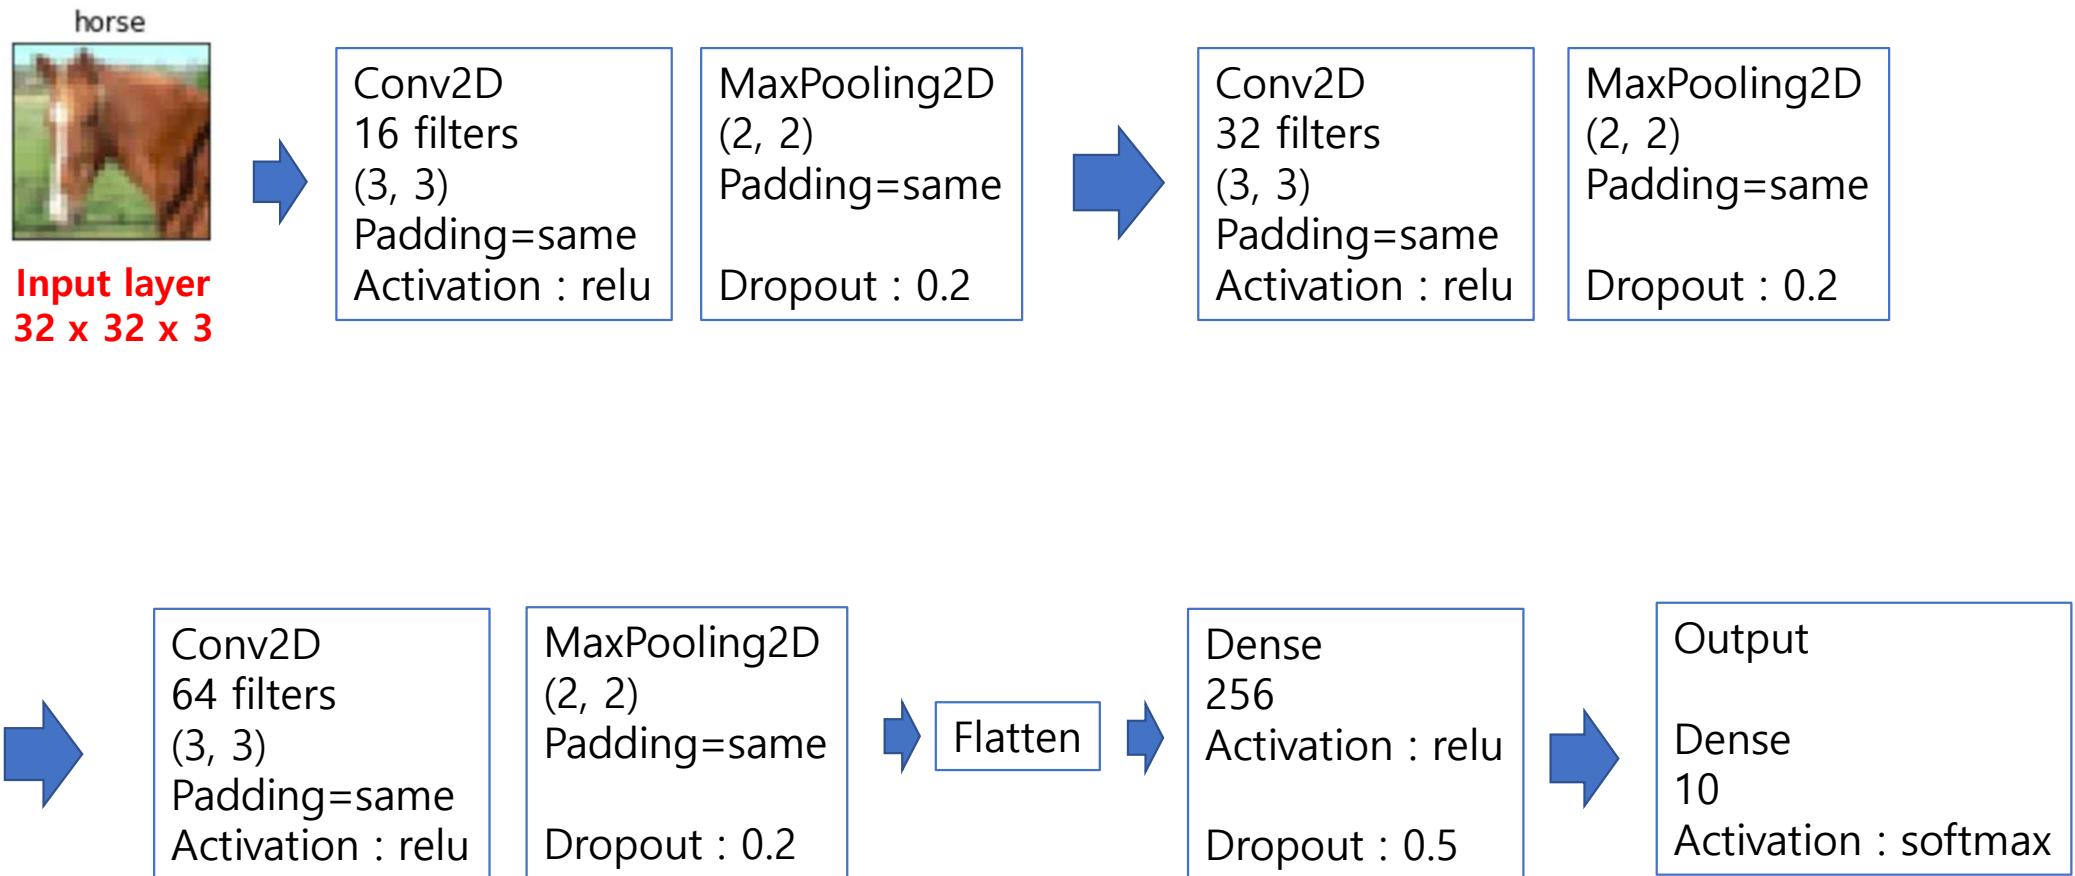
실습 : Deeper CNN 을 이용한 CIFAR-10 분류

1. CIFAR-10 dataset 은 32x32 color image 를 가진 10개의 class (airplane, automobile, bird, cat, deer, dog, frog, horse, ship, truck)
2. 각 class 별 6,000 개씩 total 60,000 개 image
3. Image 가 blur 하여 난이도 높음
(최근 성적 : <https://en.wikipedia.org/wiki/CIFAR-10>)
4. Google Colab GPU 환경 이용

CIFAR-10 image dataset

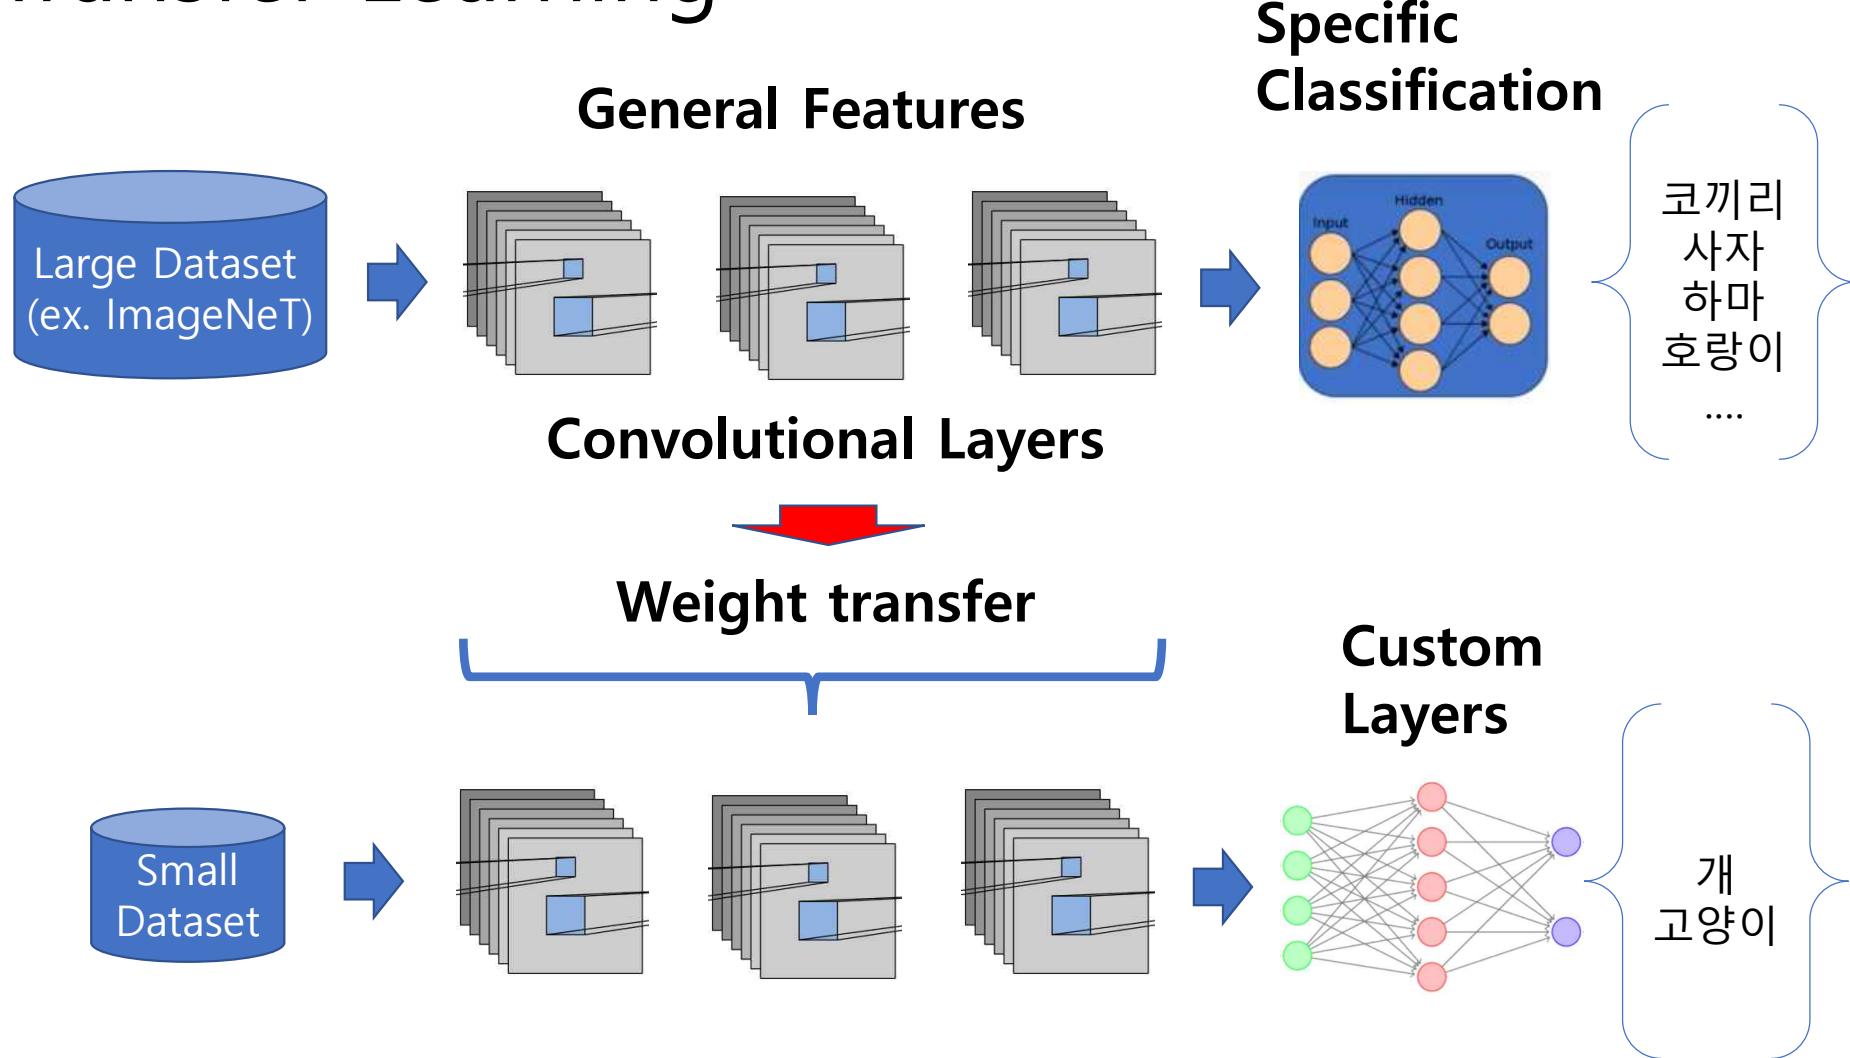


Neural Network Architecture



Transfer Learning (전이학습)

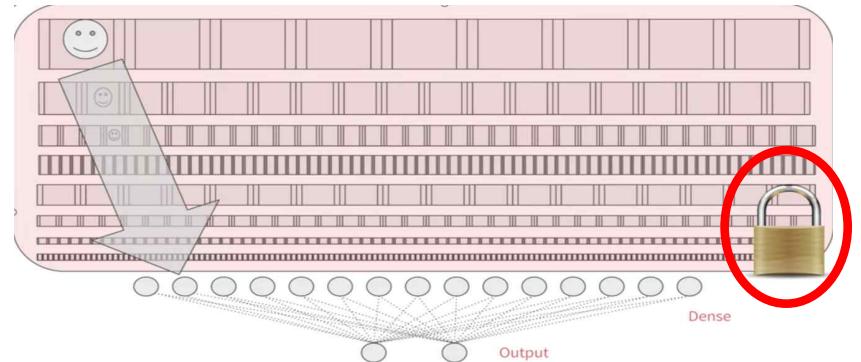
Transfer Learning



Transfer Learning Strategy

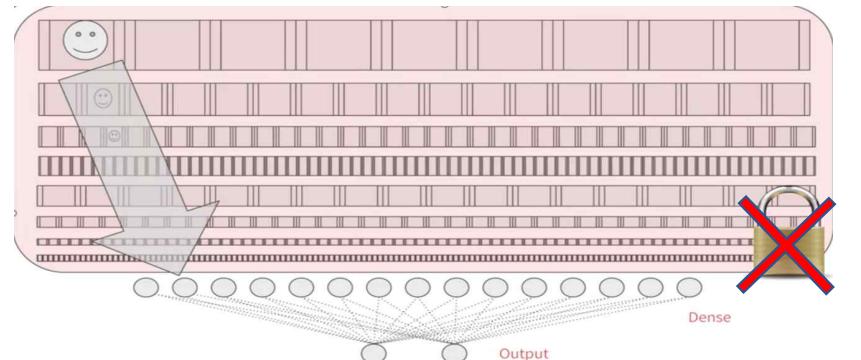
- Strategy 1

CNN layer 는 freeze 하고,
추가한 완전연결층만 새로이 train



- Strategy 2

전체 Layer 를 매우 작은 learning rate 로 re-train



Transfer Learning 고려사항

- 목적에 맞는 **dataset** 선택

ex) Cat & Dog 구분 → ImageNet 에 포함
Cancer cell 구분 → ImageNet 에 없음

- 보유 Data 의 **Volume** 고려

1. 모든 weight 새로이 training (Large Data 보유)
2. Weight 의 일부만 training
3. 마지막 layer 만 Fine-tuning (Small Data 보유)

TensorFlow Hub

The screenshot shows the TensorFlow Hub homepage. At the top is a navigation bar with the TensorFlow logo, links for 설치 (Installation), 학습 (Learning), API, 리소스 (Resources), 커뮤니티 (Community), and TensorFlow를 사용해야 하는 이유 (Why TensorFlow). To the right are buttons for 한국어 (Korean), GitHub, and 로그인 (Login). Below the navigation is a search bar with a magnifying glass icon and the word 검색 (Search). A banner in the center says "날짜를 저장하십시오! Google I/O가 5월 18일부터 20일까지 반환됩니다." (Save the date! Google I/O returns from May 18 to 20.) with a "지금 등록" (Register now) button. The main content area has a dark blue background with abstract white line art.

TensorFlow Hub, 학습된 머신러닝 모델의 저장소

TensorFlow Hub는 어디서나 미세 조정 및 배포 가능한 학습된 머신러닝 모델의 저장소입니다. 몇 줄의 코드만으로 BERT 및 Faster R-CNN과 같은 학습된 모델을 재사용할 수 있습니다.



튜토리얼 보기

TensorFlow Hub 사용 방법과 작동 방법을 알아보세요.



튜토리얼 보기

튜토리얼에서는 TensorFlow Hub를 사용하는 엔드 투 엔드 예를 보여줍니다.



모델 보기

사용 사례에 맞는 학습된 TF, TFLite 및 TF.js 모델을 찾아보세요.

A code editor window showing Python code for using TensorFlow Hub. It includes a toolbar with icons for copy, paste, and run. The code imports tensorflow_hub and uses KerasLayer to load a pre-trained model, then prints its shape.

```
!pip install --upgrade tensorflow_hub

import tensorflow_hub as hub

model = hub.KerasLayer("https://tfhub.dev/googlennlm-en-dim128/2")
embeddings = model(["The rain in Spain.", "falls",
                   "mainly", "In the plain!"])

print(embeddings.shape) # (4, 128)
```

실습 : 150. TensorFlow Hub 을 이용한 전이 학습

1. pre-trained model (MobileNet_V2) 을 feature extractor로 이용하여 꽃 image 에 특화된 image 분류 model build
2. Model 구성

```
model = tf.keras.Sequential([
    MobileNet_feature_extractor_layer,
    tf.keras.layers.Dense(flowers_data.num_classes, activation='softmax')
])
```

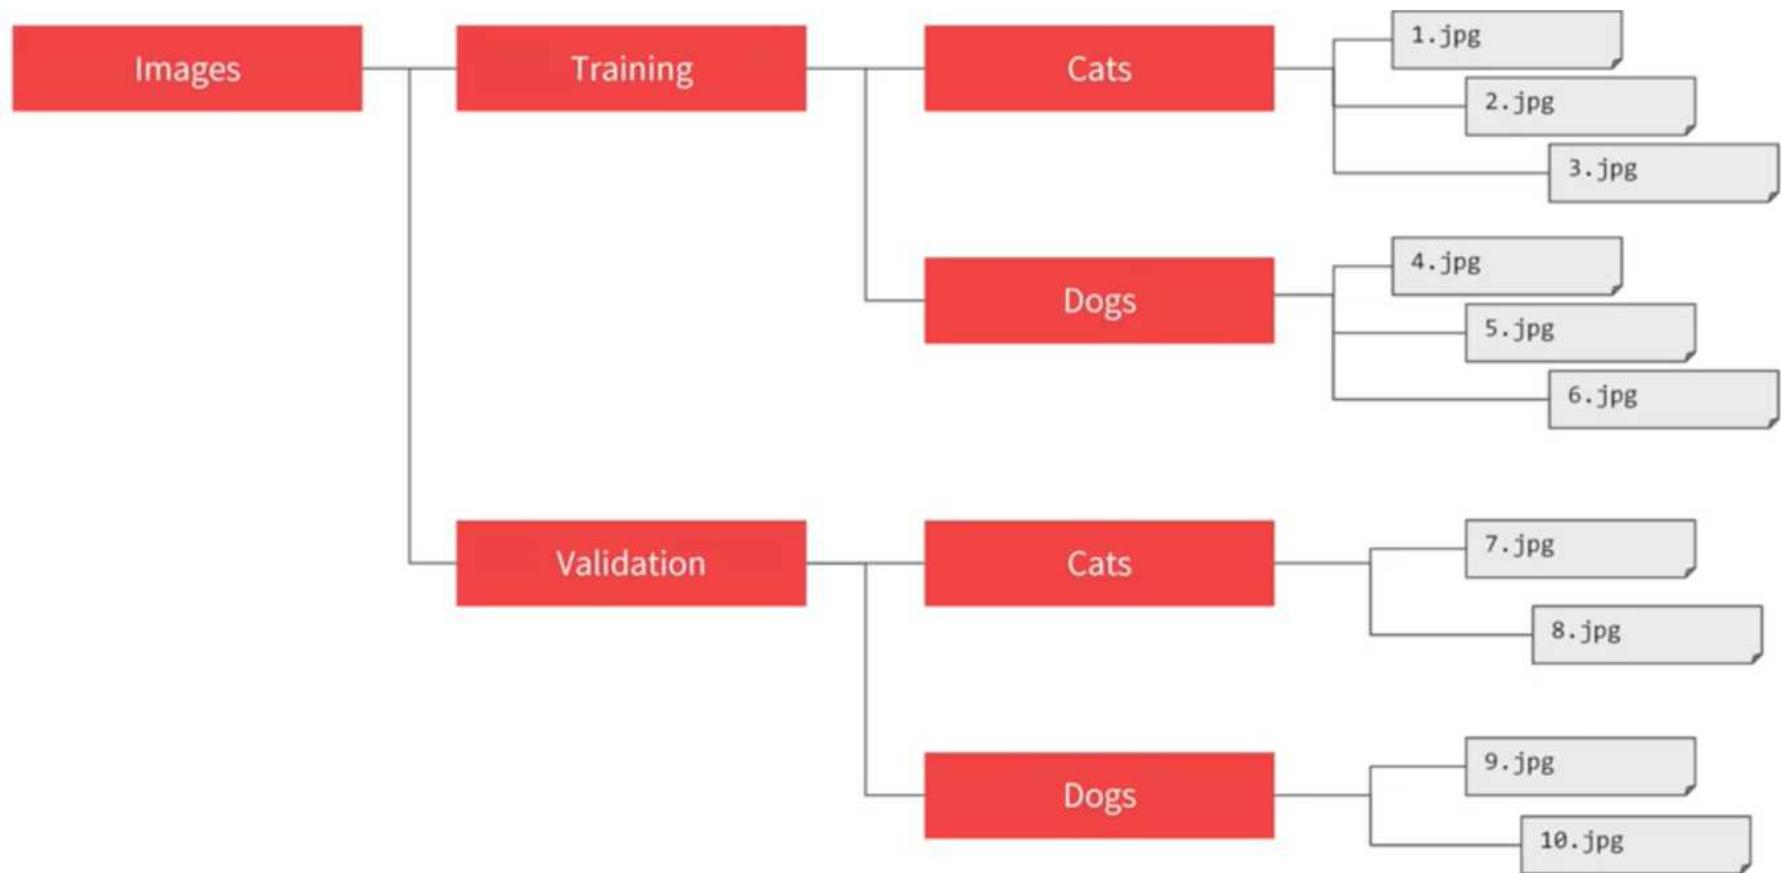
MobileNet 소개

- ImageNet 의 수백만장 image 를 이용하여 trained
- 1000 개의 class 로 image 구분



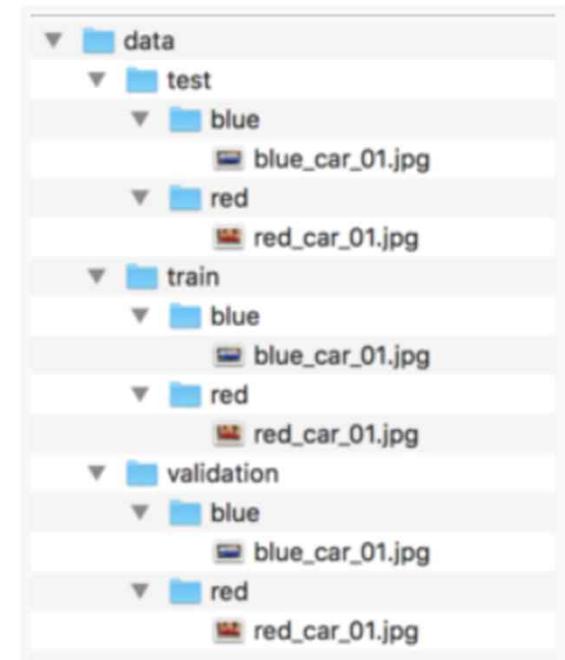
class name	probability	imagenet class id
Egyptian cat	0.478	285
tabby, tabby cat	0.300	281
tiger cat	0.167	282
remote control, remote	0.016	761
Siamese cat, Siamese	0.008	284

ImageDataGenerator folder structure



ImageDataGenerator methods

- .flow_from_directory
 - 대용량 data 를 directory 에서 직접 load
(with data augmentation)
 - directory 구조에 의해 자동으로 label 인식



flow_from_directory 사용법

- from tensorflow.keras.preprocessing.image import ImageDataGenerator

- Instance 생성 :

```
train_data_gen = ImageDataGenerator(rescale=1/255.)
```

- flow_from_directory method 호출 :

```
train_generator = train_data_gen.flow_from_directory(  
    train_dir,  
    target_size(150, 150), → image size 통일  
    batch_size=20,  
    class_mode='binary' or 'categorical')
```

Deep Neural Network

비지도 학습 방법

Autoencoder

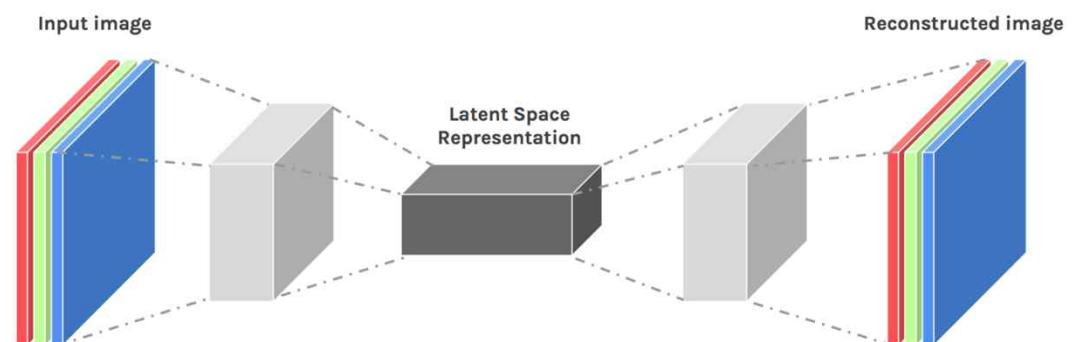
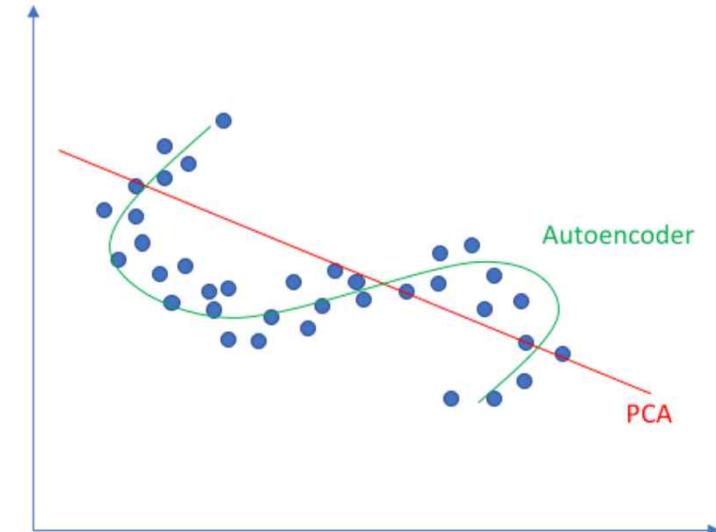
Autoencoder

- 차원의 감소 : most relevant feature 추출

- PCA : linear transformation
- Autoencoder : non-linear transformation

- 적용 분야

- 정보의 압축
- Noise 제거
- 유사한 image 검색
- Image 변형에 의한 새로운 image 생성
- Pre-Training



latent representation (잠재 표현) - intuition

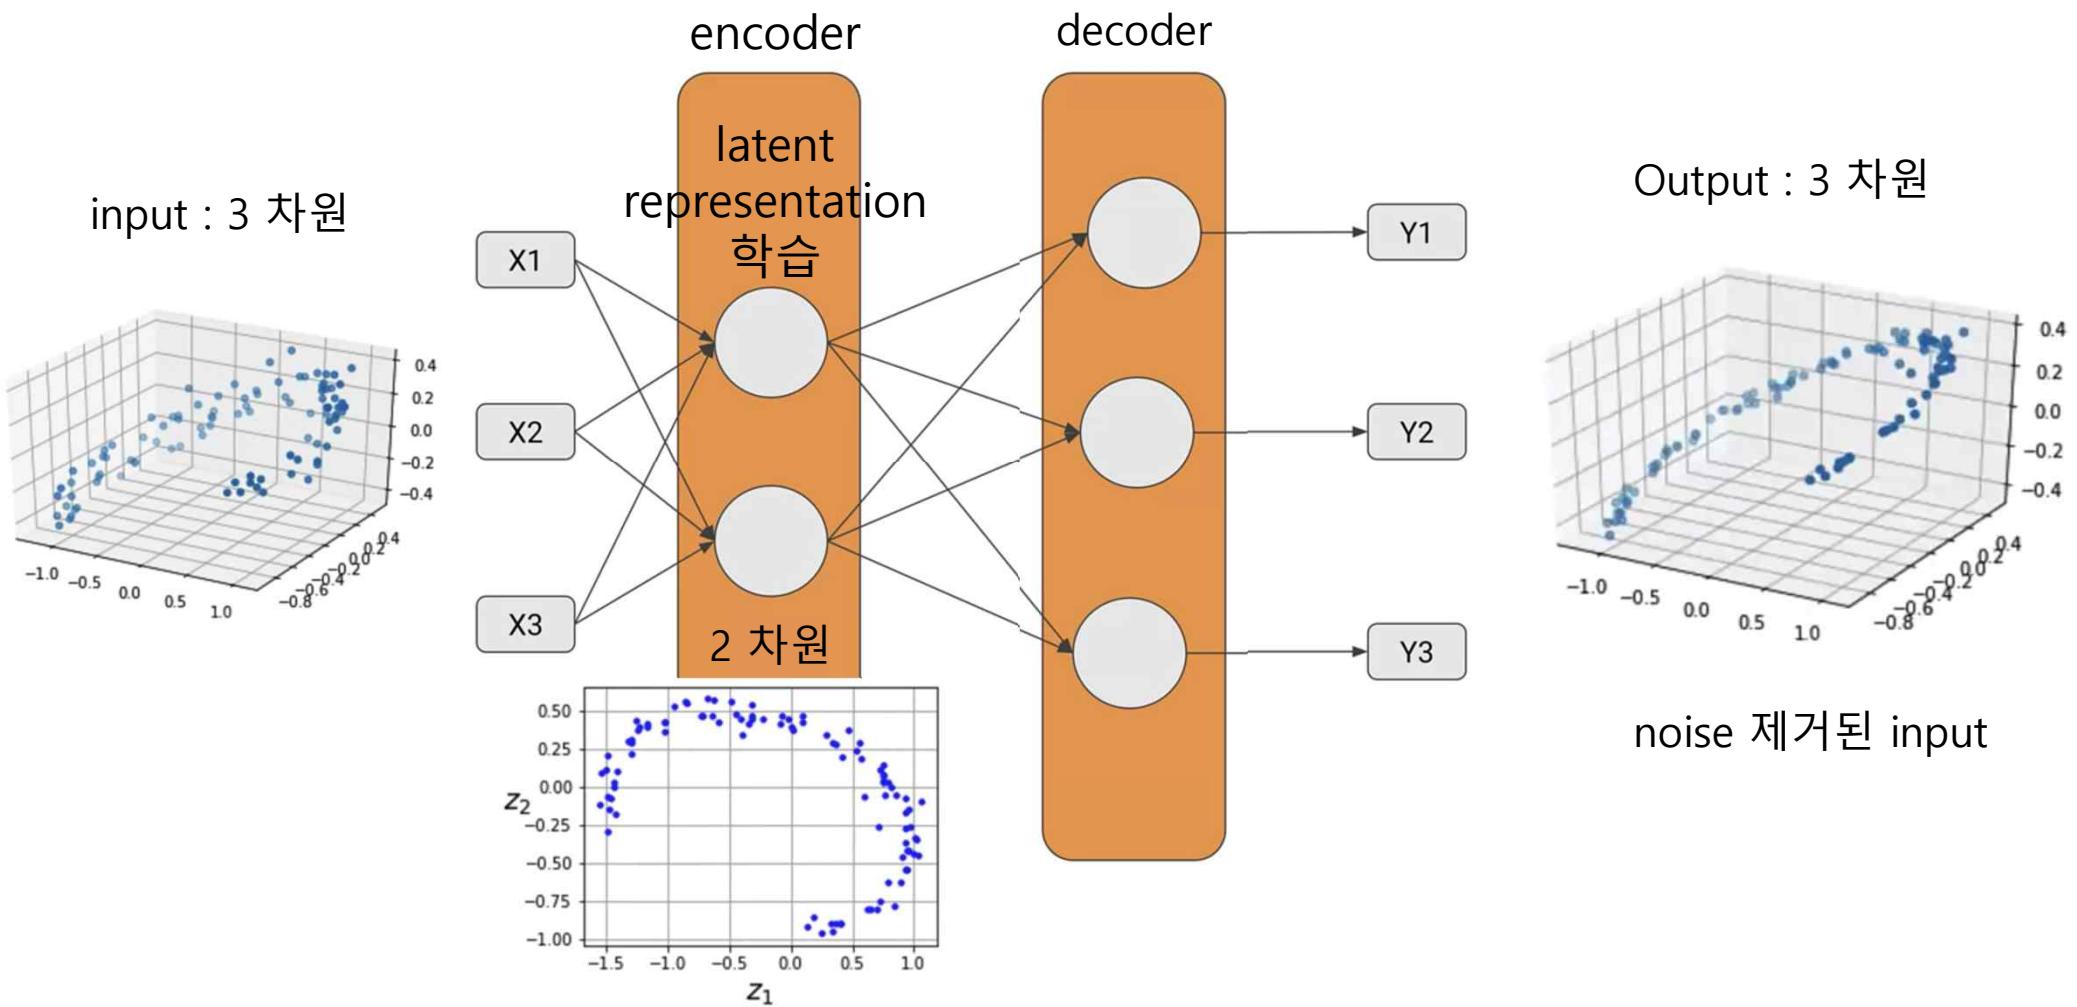
83 12 21 42 99 18 51

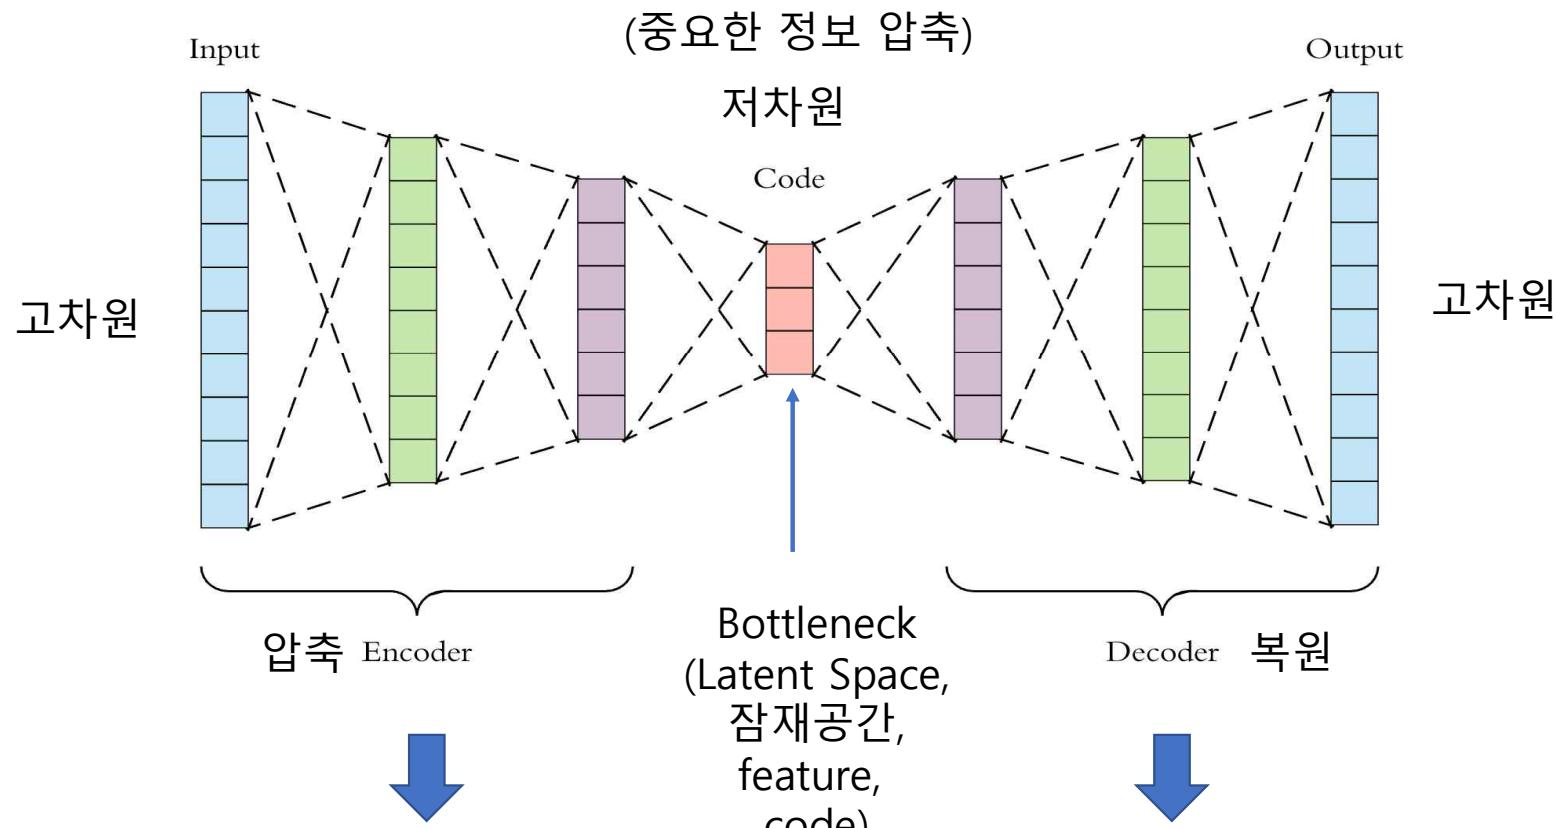
4 9 16 25 36 49 64 81 100 121 144 169

기억하기 쉬운 수열은 ?

- 첫번째 sequence 는 no pattern
- 두번째 sequence 는 제곱 pattern → latent pattern 존재

Autoencoder 의 기본 구조



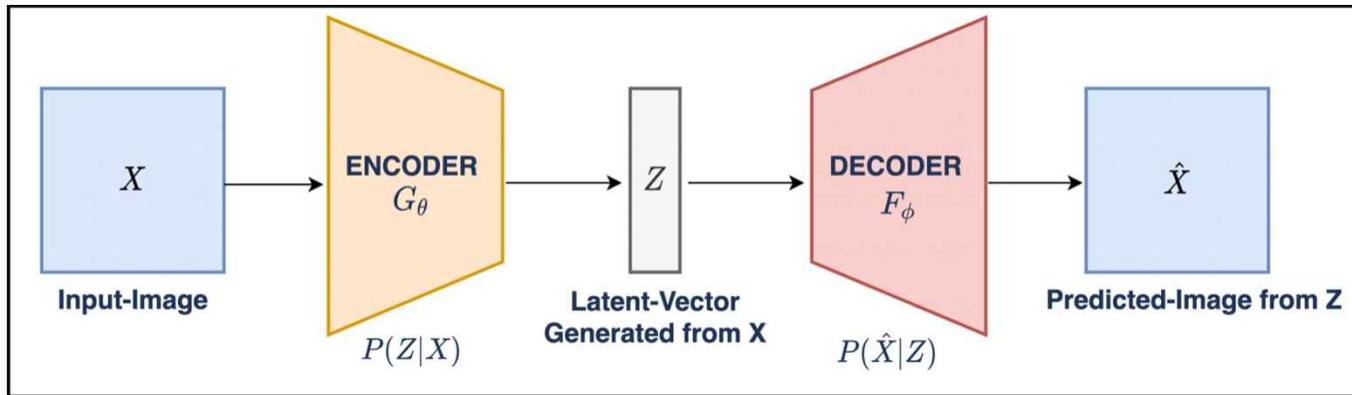


이미지와 같은 고차원 데이터를 Encoding을 통해 저차원 Hidden 공간으로 표현

→ Latent Space (= Latent Variable)

Latent Variable의 정보를 기반으로
원래의 이미지를 복원(Reconstruction)
하는 과정 수행

Autoencoder – 작동 방식



$$L(x, y) = \|x - \hat{x}\|^2$$

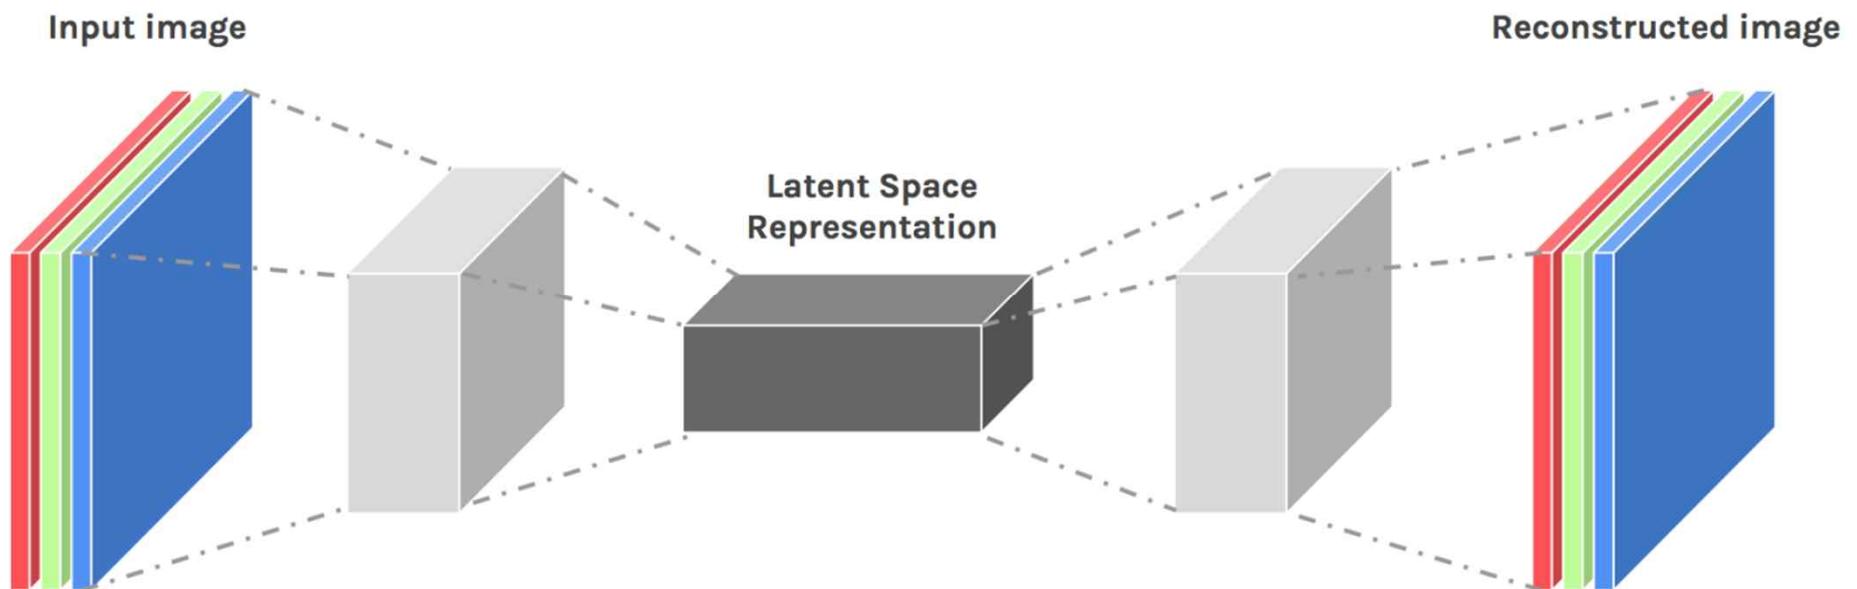
$$\begin{aligned} z &= G(X) \\ \hat{x} &= F(z) = F(G(X)) \end{aligned}$$



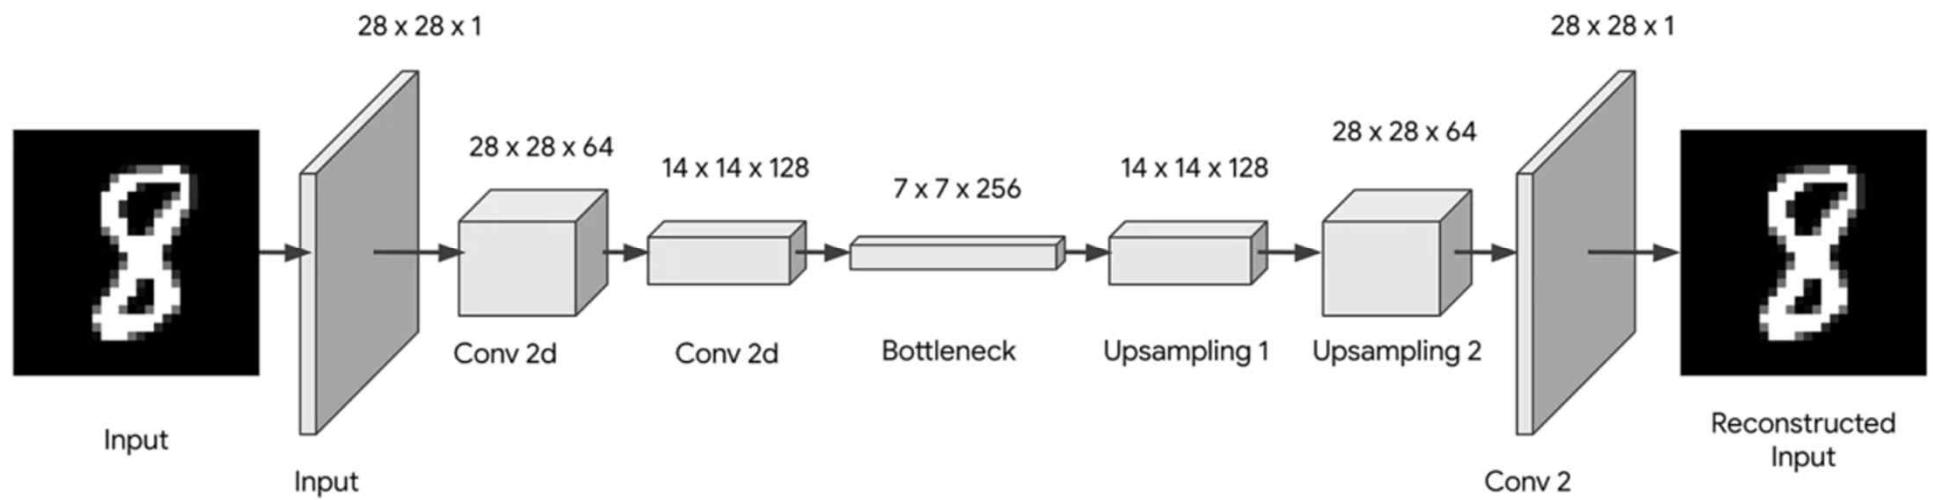
비지도학습 문제를 지도학습 문제로 바꾸어 해결
(자신을 Label로 사용)

$L(x, y)$ - mse(입력이 정규분포) or cross-entropy(입력이 베르누이 분포)

Convolutional Auto-Encoders

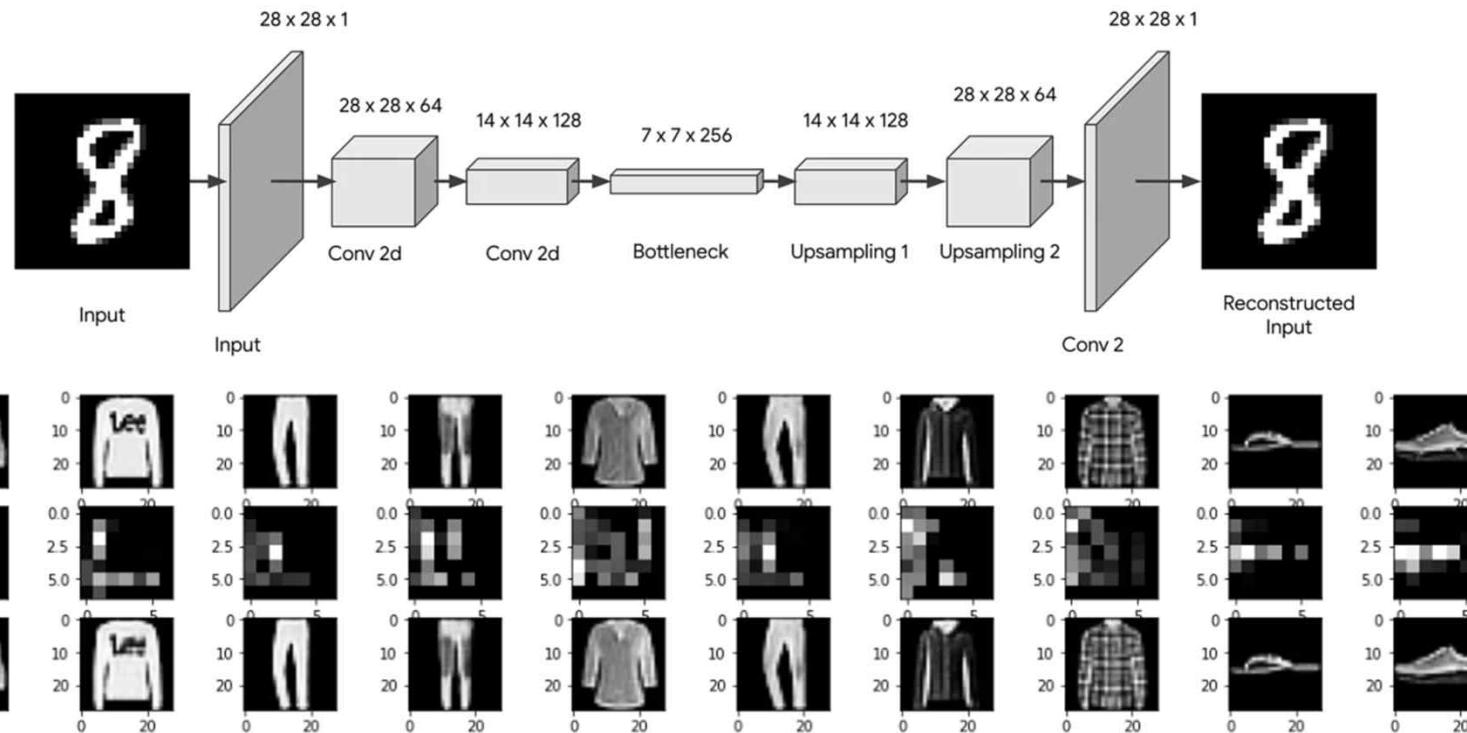


Convolutional Auto-Encoders



실습 : 300. Convolutional Autoencoder

- (Fashion) mnist dataset 을 encoding 후 decoding 하여 복원



Deep Learning

Sequence Model

What is sequence data ?

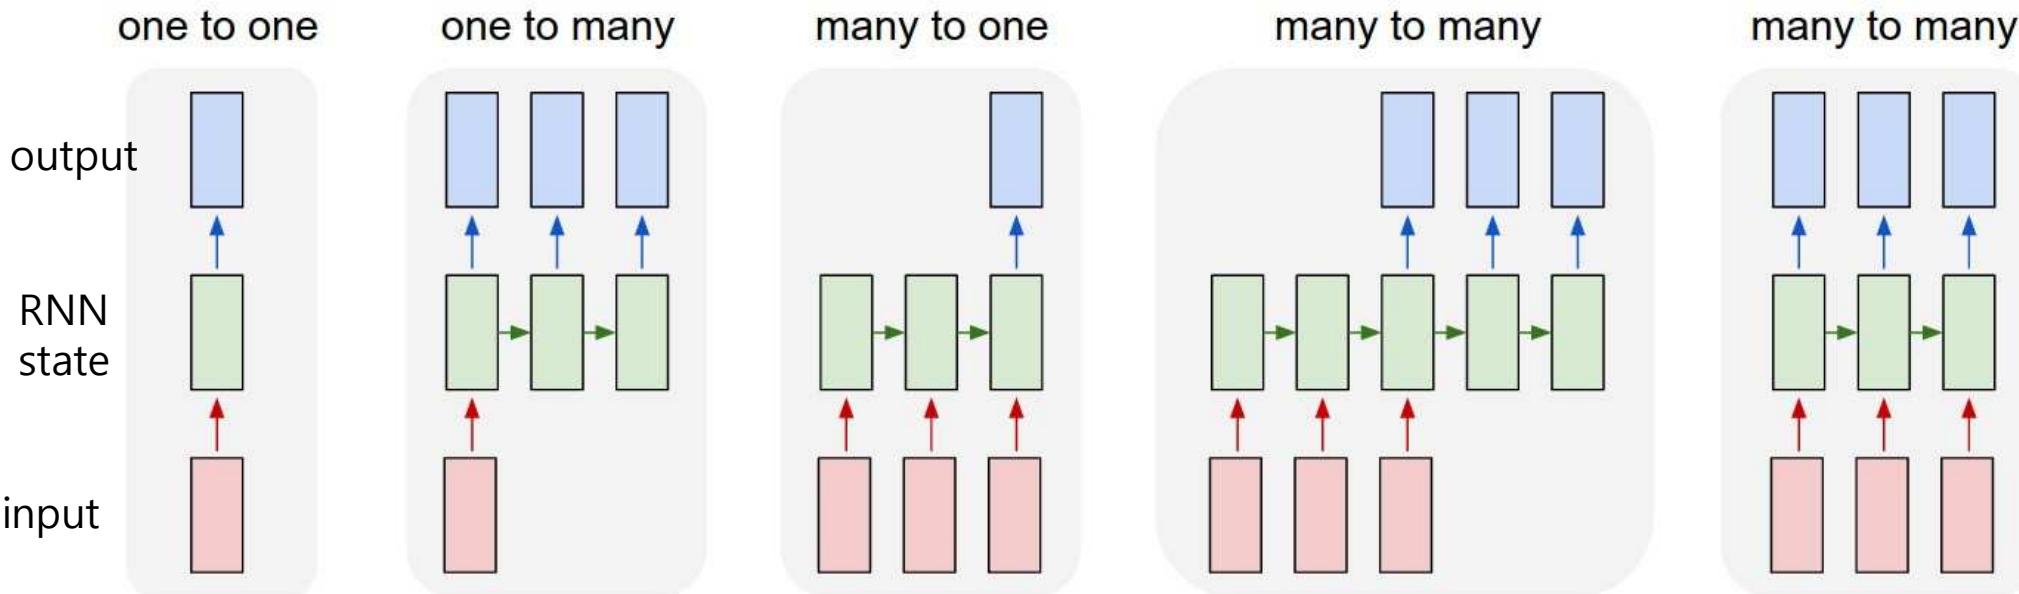
- Speech recognition : 파동의 연속 → 단어의 연속으로 변환
- Music generation : 연속된 음표 출력
- Sentiment classification : Text → 평점, 부정/긍정 판단
- DNA 분석 : 염기서열 → 질병유무, 단백질 종류 등
- 자동 번역 : 한국어 → 영어
- Video activity recognition : 연속된 장면 → 행동 판단
- Financial Data : 시계열자료 → 주가, 환율 예측 등

RNN (Recurrent Neural Network)

RNN (Recurrent Neural Network)

- 시퀀스 데이터에 특화
- '기억' 능력을 갖고 있음
 - * 네트워크의 기억 - 지금까지의 입력 데이터를 요약한 정보
(새로운 입력이 들어올 때마다 네트워크는 자신의 기억을 조금씩 수정)
- 입력을 모두 처리하고 난 후 네트워크에게 남겨진 기억은 시퀀스 전체를 요약하는 정보
(사람의 시퀀스 정보 처리 방식과 비슷, 기억을 바탕으로 새로운 단어 이해)
- 이 과정은 새로운 단어마다 계속해서 반복 → Recurrent (순환적)

Different Types of RNN



예) 이미지 분류

- 이미지로 부터 문장 생성
(Image Captioning)
- 작곡, 작시
- 감성 분석
(sentiment Analysis → positive/negative)
- Spam detection
- 기계 번역 (영어 → 한국어 문장)
- Chatbot
- Question Answering
- video 각 frame에 label 생성
- 품사 tagging
- 개체명 인식
- Character 단위 문장 생성 등

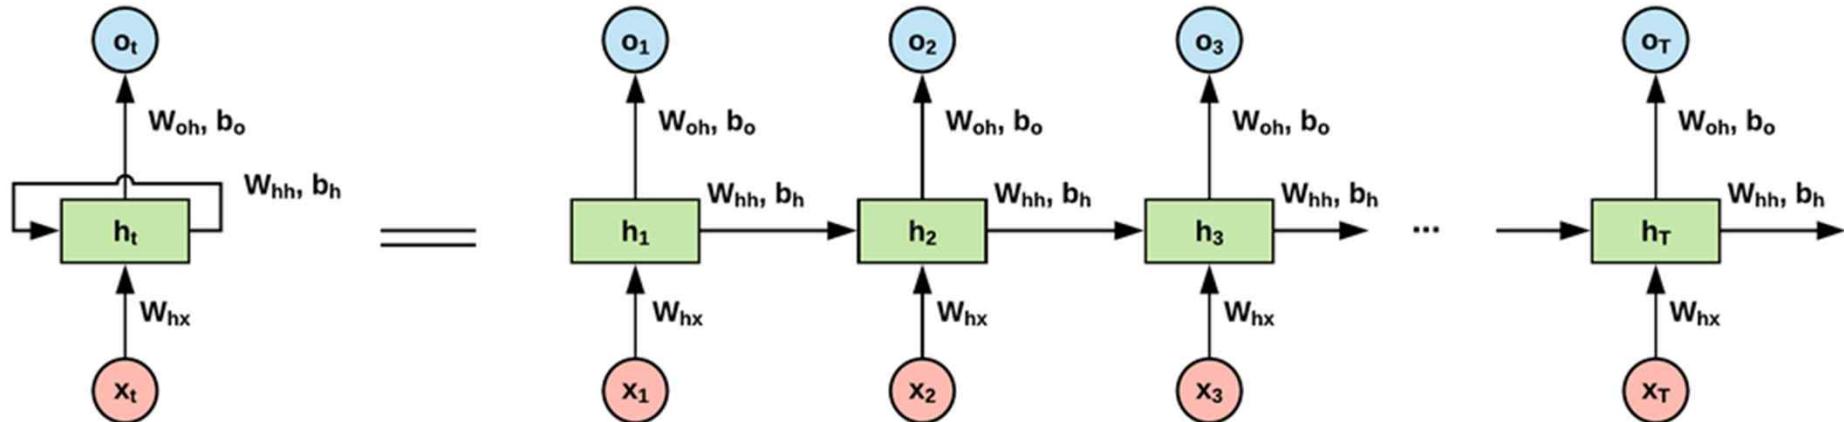
RNN (Unfold 표시)

Internal State :

$$h_t = \tanh (W_h h_{t-1} + W_x x_t)$$

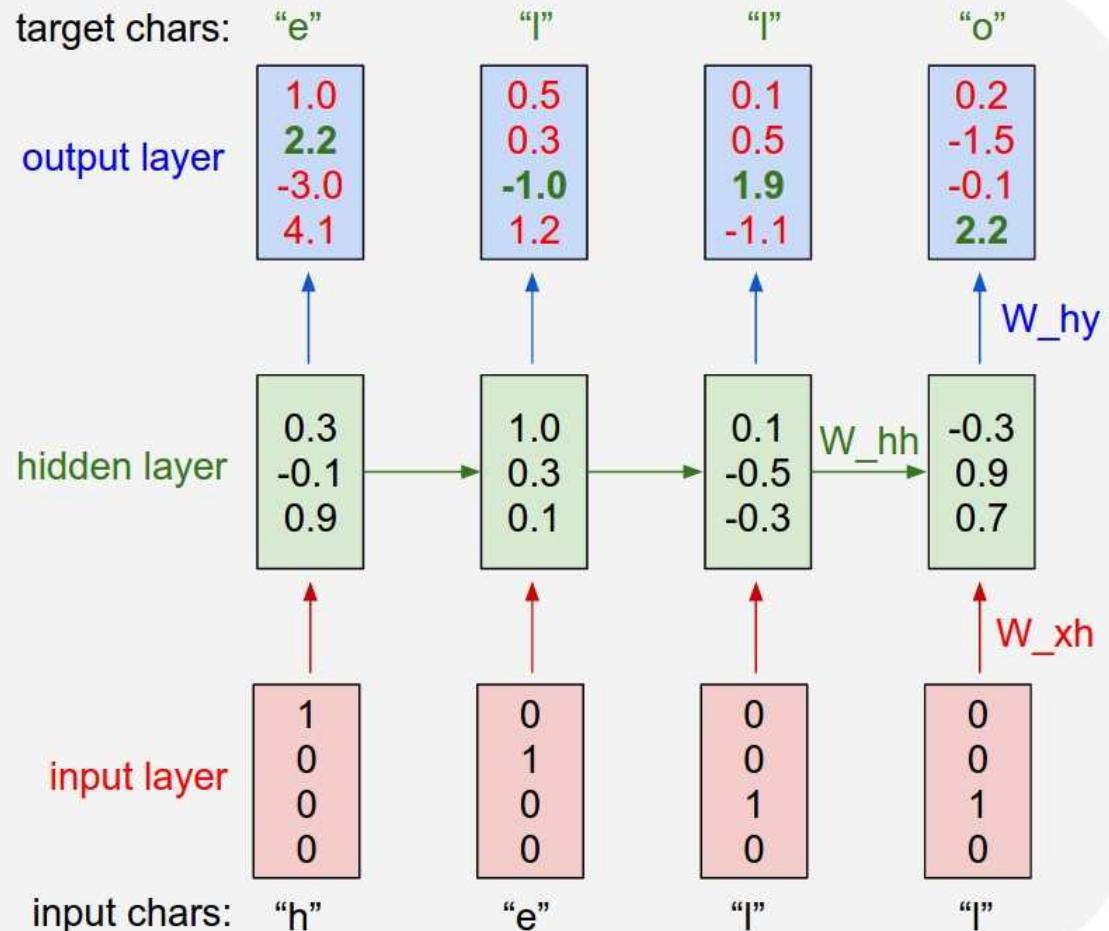
Output :

$$o_t = \text{softmax} (W_o h_t)$$



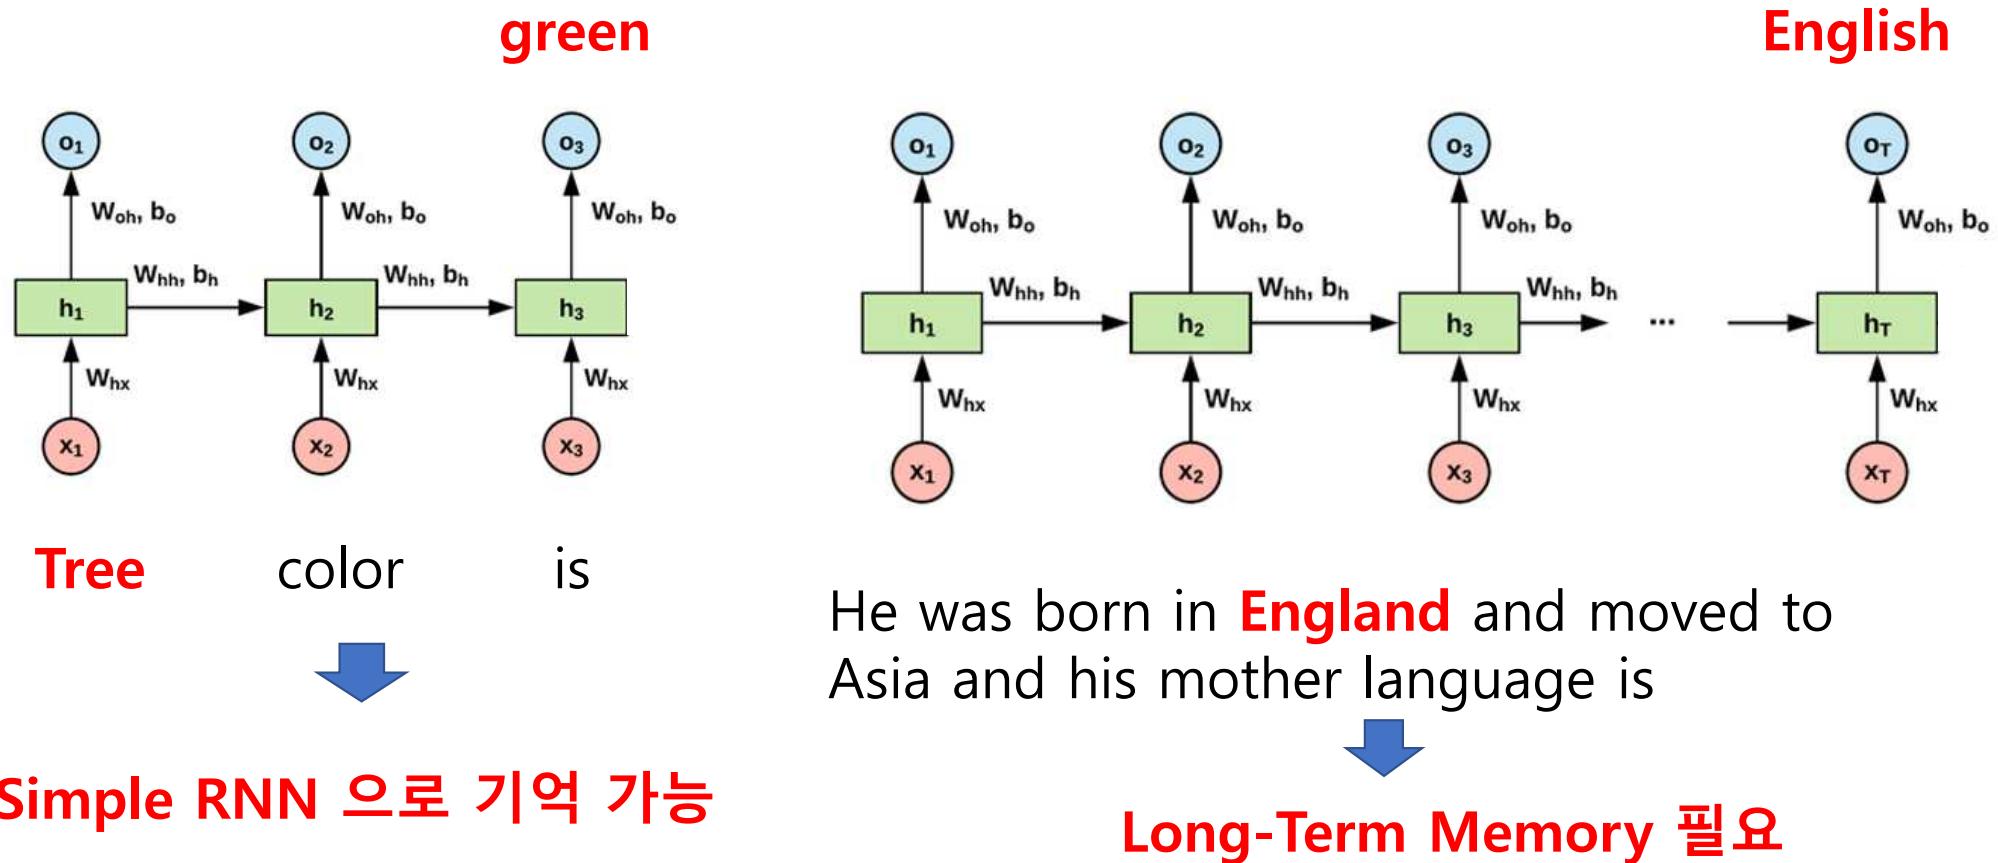
- RNN 을 순서대로 펼쳐 놓으면 weight 를 공유하는 매우 deep 한 neural network 이 된다.
- BPTT (Backpropagation Through Time) 으로 parameter 학습

How RNN is trained ?

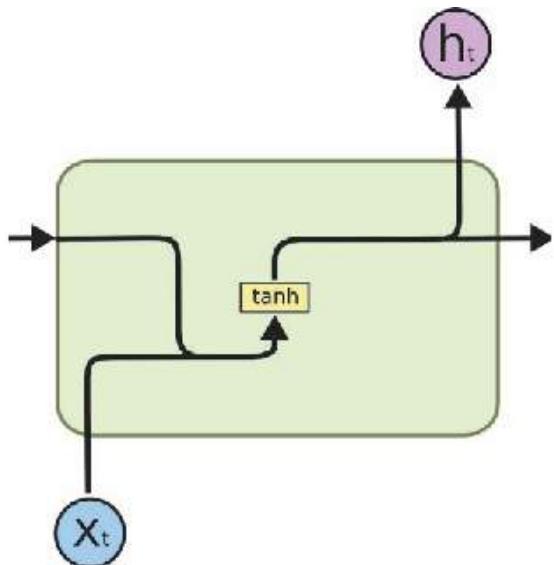


- "h", "e", "l", "o" 4 개 문자만 있다고 가정
- 각 문자를 One-hot encoding
- "h" 를 시작 문자로 주면 "hello" 가 출력 되도록 훈련
- 각 time step 의 target character 는 "hello" 내의 next character
- Gradient descent 와 backpropagation 을 통해 output layer 의 target score 가 증가되도록 함 (green color)
- "l" 다음의 character 는 현재의 "l" 만으로 판단할 수 없음 (history 필요)

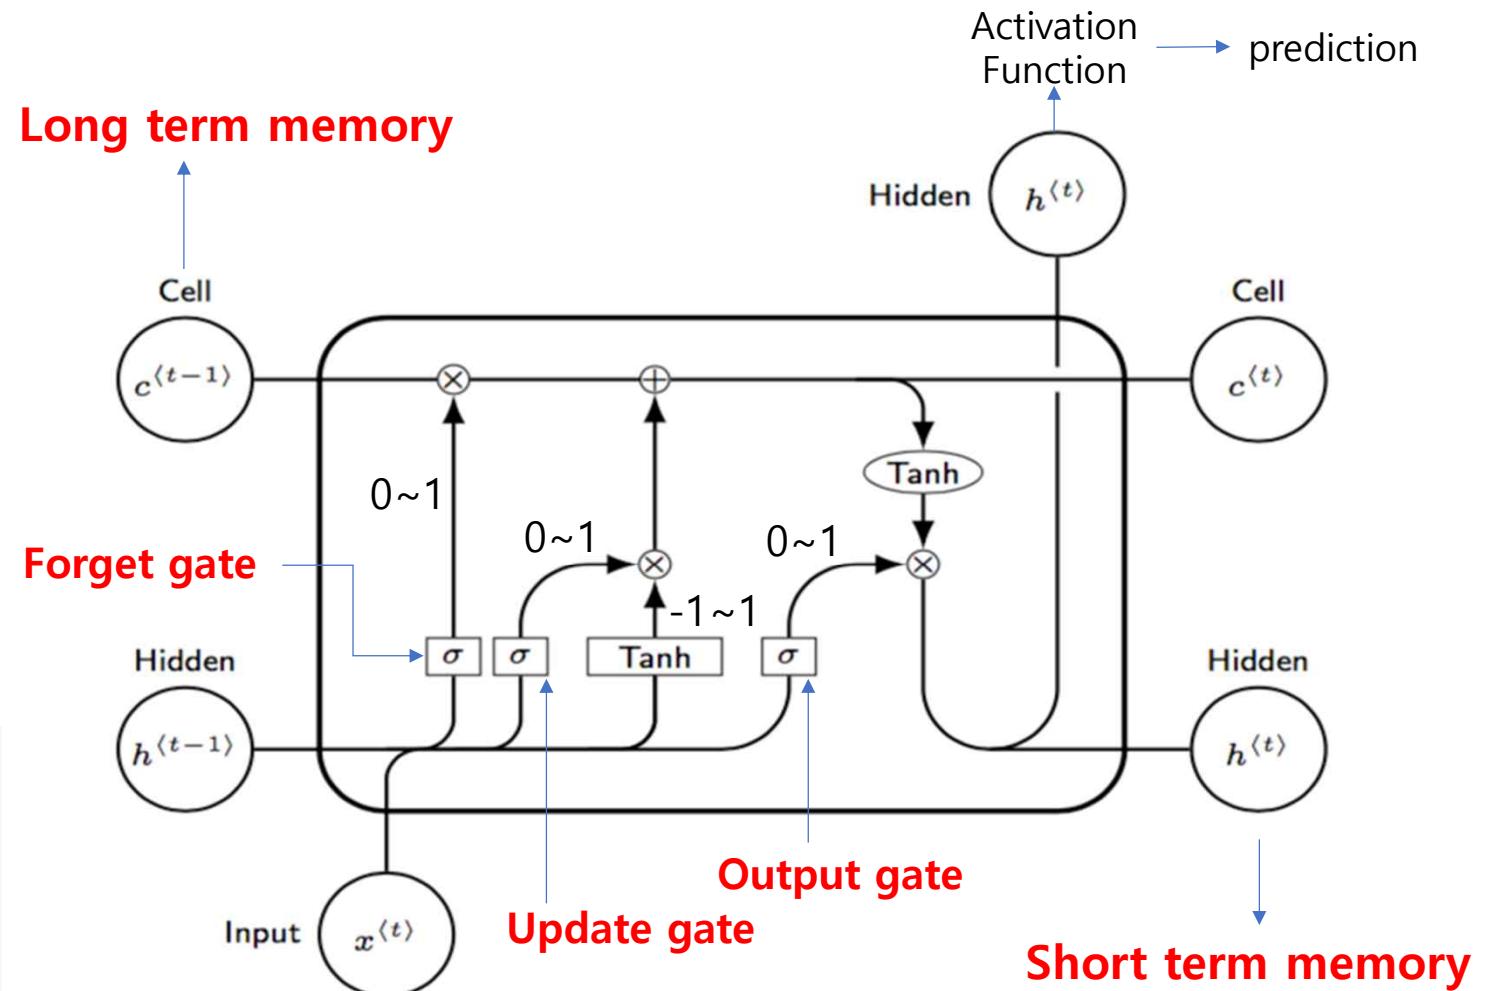
LSTM (Long Short-Term Memory)



SimpleRNN



LSTM (Long Short-Term Memory)



LSTM 내부 구조

- **Input** – 이전 step 의 hidden + new data

$$\tilde{C}^{<t>} = \tanh(W_c[a^{<t-1>}, x^{<t>}] + b_c) \rightarrow \text{새로운 cell status 후보}$$

- **Update gate** – input 을 어느정도 받아들일지 결정 (0-무시, 1-전체)

$$\Gamma_u = \sigma(W_u[a^{<t-1>}, x^{<t>}] + b_u)$$

- **Forget gate** – 이전 cell state 를 어느정도 기억할지 결정 (0-forget, 1-전체 기억)

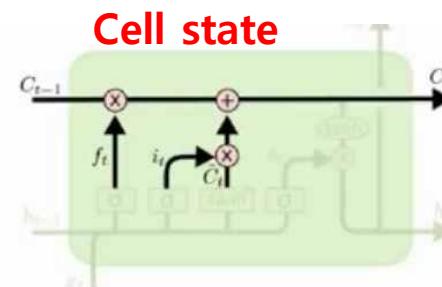
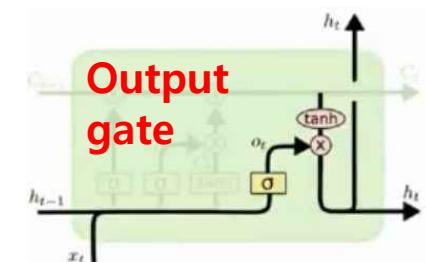
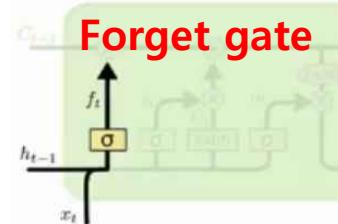
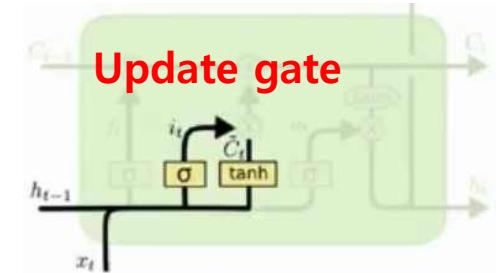
$$\Gamma_f = \sigma(W_f[a^{<t-1>}, x^{<t>}] + b_f)$$

- **Output gate** – input 을 어느정도 다음 step 으로 보낼지 결정

$$\Gamma_o = \sigma(W_o[a^{<t-1>}, x^{<t>}] + b_o)$$

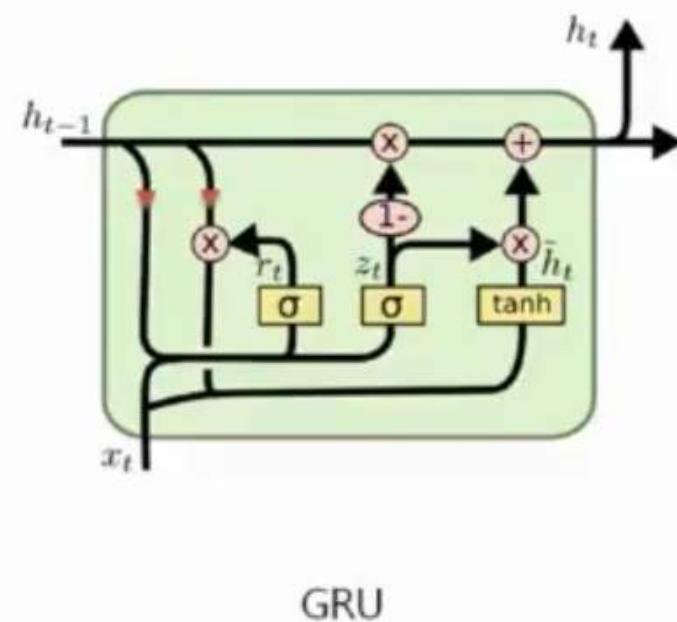
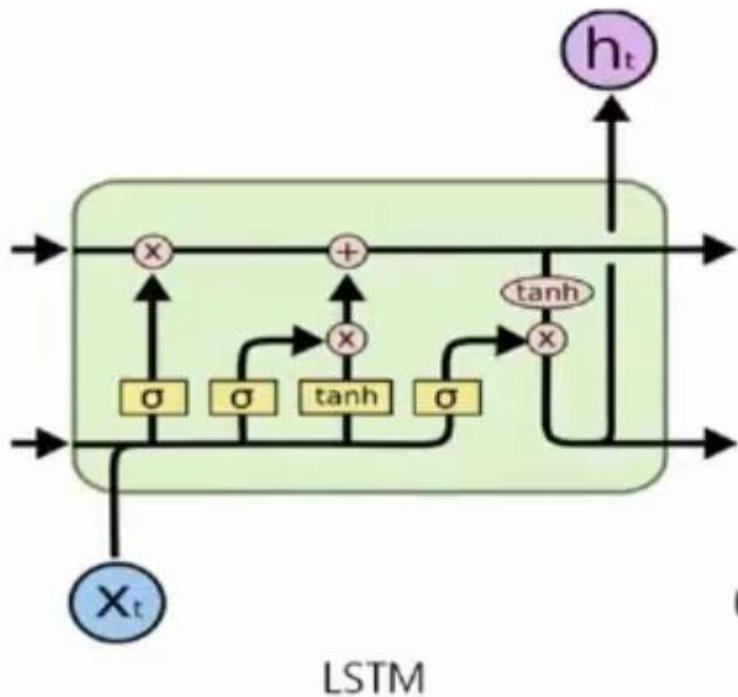
- $C^{<t>} = \Gamma_u * \tilde{C}^{<t>} + \Gamma_f * C^{<t-1>}$

- $a^{<t>} = \Gamma_o * \tanh C^{<t>}$



GRU (Gated Recurrent Unit)

- LSTM 의 장점을 유지하면서 일부 Gate 를 생략하여 계산의 복잡성을 낮춤



실습: 165. Simple LSTM

- input 은 0 ~ 99 까지의 연속된 숫자
- target 은 (1 ~ 101) * 2
- 연속된 5 개의 숫자를 보고 다음 숫자를 알아맞추도록 LSTM 을 이용한 model 작성
 - ex) [[5], [6], [7], [8], [9]] → [20]
[[35], [36], [37], [38], [39]]. → [80]

실습: 200. LSTM 을 이용한 주가 예측

- Apple 주식의 가격 추세 예측
- Yahoo finance data 이용

